Annexes

Prix d'excellence pour les professeurs enseignants

Guillaume Roy-Fortin

À la demande de la direction exécutive des affaires académiques, nous présentons toutes les annexes du dossier de candidature fusionnées dans le présent document. La table des matières de la page suivante remplace donc l'hiérarchie de fichiers prévue dans le dépôt initial.

30 octobre 2026

Table des matières

1 Cours MT881 **2**

1.1 Notes de cours . . . 2
1.2 Exercices avec solutions . . . 72
1.3 Plan de cours . . . 125
1.4 Évaluations . . . 131

2 Cours MAT472 **141**

2.1 Exercices pour la portion algèbre linéaire . . . 141
2.2 Solutions complètes des exercices . . . 172

3 Atelier IA **246**

3.1 Lettre de remerciement du Collège de Maisonneuve . . . 246
3.2 Diapositives : principes mathématiques des réseaux de neurones . . . 248

4 Exposition **296**

4.1 Conférence ouverture de l'AMQ . . . 296

5 Développement de programmes **429**

5.1 Microprogramme en mathématiques de l'IA . . . 429
5.2 Fiche descriptive du cours SCM680 . . . 436

6 Congrès de l'AMQ **438**

6.1 Programme officiel . . . 438

1

Cours MT881

1.1 Notes de cours

Le génie pour l'industrie

École de technologie supérieure
Département des enseignements généraux
Local B-2500 514-396-8938
Site internet : `http://www.etsmtl.ca/`

MTI881

ASPECTS MATHÉMATIQUES DE L'APPRENTISSAGE PROFOND

NOTES DE COURS

RÉDIGÉES PAR
GUILLAUME ROY-FORTIN

MARS 2025

Ce document est mis à disposition selon les termes de la licence Creative Commons Attribution - Pas d'Utilisation Commerciale - Pas de Modification 4.0 International.

Table des matières

1 Rappels d'algèbre linéaire et de calcul différentiel **1**
1.1 Espaces vectoriels euclidiens . . . 1
1.1.1 Vecteurs et opérations sur les vecteurs . . . 1
1.1.2 Combinaison linéaire, indépendance et base . . . 5
1.2 Calcul matriciel et transformations linéaires . . . 6
1.3 Vecteurs propres et théorème spectral . . . 11
1.4 Calcul différentiel et optimisation . . . 13
1.4.1 Descente de gradient . . . 14

2 Réseaux de neurones profonds **19**
2.1 Principes généraux . . . 19
2.2 Apprendre via la descente de gradient . . . 23
2.3 Rétropropagation . . . 25

3 Problèmes d'apprentissage **29**
3.1 Problèmes d'apprentissage avec la fonction de coût quadratique et la sigmoïde . . . 29
3.2 Entropie croisée . . . 31
3.3 Initialisation et problèmes d'apprentissage : théorèmes de Hanin . . . 33

4 Universalité et puissance expressive **35**
4.1 La question de l'universalité . . . 35
4.2 Le théorème de Cybenko . . . 36
4.3 Heuristique de l'universalité . . . 37

5 Rôle de la profondeur dans la puissance expressive **41**
5.1 Une section en dents de scie . . . 41
5.2 Additivité vs. composition . . . 44
5.3 Théorème de séparation de Telgarsky . . . 45

6 Introduction à l'apprentissage profond géométrique **47**
6.1 Réseaux de convolution et classification d'images . . . 47
6.2 Préliminaires mathématiques . . . 49
6.3 Introduction à la théorie spectrale des graphes . . . 51

7 Réduction spectrale de la dimension **55**
7.1 L'hypothèse de la variété . . . 55
7.2 Variétés . . . 56
7.3 Analyse en composantes principales . . . 57
7.4 Réduction spectrale de la dimension . . . 58

7.4.1 L'algorithme de Belkin-Niyogi 59
7.4.2 Optimalité de la projection spectrale 60

Bibliographie **63**

Index **63**

Avant-propos

Le deep learning n'a plus besoin de présentation : ses nombreuses prouesses sont largement documentées et célébrées. Mais sait-on vraiment ce qui rend ces réseaux profonds aussi habiles ? Pour plusieurs, l'apprentissage profond demeure une mystérieuse boîte noire qui produit des résultats étonnants en opérant toutefois selon des modalités opaques.

Or, une partie de la théorie derrière les exploits de ces réseaux de neurones se trouve au confluent de l'algèbre linéaire, des statistiques, du calcul différentiel et de la théorie de la probabilité, pour ne nommer que ceux-là. Autrement dit, les mathématiques peuvent éclairer un peu certains aspects de cette boîte noire. C'est ce que propose d'explorer le cours MTI881.

Ce cours intitulé *Aspects mathématiques de l'apprentissage profond* a été donné de nouveau à l'été 2022 et 2023. Il est destiné aux étudiants destiné aux étudiants gradués de génie logiciel et technologies de l'information. Le présent document contient les notes de cours pertinentes à la matière vue en classe. Il s'agit d'une première itération encore très incomplète à plein d'égards. Nous prions donc le lecteur d'être tolérant envers l'auteur !

Les inévitables erreurs et coquilles peuvent être signalées à l'auteur par courriel à l'adresse suivante : guillaume.roy-fortin@etsmtl.ca.

Guillaume Roy-Fortin,
Professeur enseignant à l'ÉTS.

Chapitre 1

Rappels d'algèbre linéaire et de calcul différentiel

Dans ce chapitre, nous allons brièvement survoler certains éléments essentiels qui seront nécessaires pour la compréhension des chapitres ultérieurs. Ce survol sera bref et il est donc recommandé au lecteur qui n'est pas familier avec ces notions de consulter l'une des nombreuses références disponibles sur l'algèbre linéaire ou le calcul différentiel avant de se plonger dans le reste du texte.

1.1 Espaces vectoriels euclidiens

1.1.1 Vecteurs et opérations sur les vecteurs

Définition 1.1 : Vecteur

Un **vecteur u** $\in \mathbb{R}^n$ est un $n-$tuple de nombres réels $u_1, u_2, ..., u_n$ que l'on peut représenter comme un vecteur colonne

$$\mathbf{u} = \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{pmatrix}$$

ou encore comme un vecteur rangée

$$\mathbf{u}^T = \begin{pmatrix} u_1 & u_2 & ... & u_n \end{pmatrix}.$$

Dans l'espace euclidien à n dimensions, on associe de manière unique le vecteur

$$\mathbf{u} = \begin{pmatrix} u_1 \\ u_2 \\ ... \\ u_n \end{pmatrix}$$

à *n'importe quel* trajet équivalent à celui qui part de l'origine **0** et se terminant au point de coordonnées $(u_1, u_2, ..., u_n)$.

Exemple 1.1

Lorsque n est de basse dimension (2 ou 3) il est utile de représenter graphiquement les vecteurs. Par exemple, pour $\mathbf{u} = \begin{pmatrix} 1 \\ 2 \end{pmatrix} \in \mathbb{R}^2$, on a

Similairement, on peut représenter $\mathbf{u} = \begin{pmatrix} 1 \\ 2 \\ 1 \end{pmatrix} \in \mathbb{R}^3$ par

On présente maintenant les opérations de base que l'on peut exécuter sur les vecteurs.

Définition 1.2 : Opérations vectorielles

Soit $\mathbf{u} = \begin{pmatrix} u_1 \\ \dots \\ u_n \end{pmatrix}$ et $\mathbf{v} = \begin{pmatrix} v_1 \\ \dots \\ v_n \end{pmatrix}$ deux vecteurs de $\mathbb{R}^n$.

- L'**addition vectorielle** permet d'additioner deux vecteurs pour en créer un troisième :

$$\mathbf{u} + \mathbf{v} = \begin{pmatrix} u_1 + v_1 \\ \dots \\ u_n + v_n \end{pmatrix}.$$

- Soit $k \in \mathbb{R}$. On peut contracter, dilater (et inverser si $k < 0$) un vecteur $\mathbf{u}$ via la **multiplication scalaire**, qui est définie par

$$k\mathbf{u} = \begin{pmatrix} ku_1 \\ \dots \\ ku_n \end{pmatrix}.$$

Dans le cas de la multiplication par un scalaire, les cas $|k| > 1$ et $|k| < 1$ correspondent respectivement à une dilatation et à une contraction du vecteur original. Si $k < 0$, l'orientation du vecteur est inversée, c'est-à-dire qu'on inverse les points de départ et d'arrivée du trajet qu'il représente.

Exemple 1.2

Voici une interprétation géométrique des opérations que l'on vient de définir sur les vecteurs.

- Addition vectorielle :
- Multiplication scalaire :

Définition 1.3 : Produit scalaire

Soit $\mathbf{u}, \mathbf{b}$ deux vecteurs de $\mathbb{R}^n$. Le **produit scalaire** entre $\mathbf{u}$ et $\mathbf{v}$ est

$$(u, v) = \sum_{i=1}^{n} u_i v_i = u_1 v_1 + u_2 v_2 + ... + u_n v_n.$$

Il importe de remarquer que le résultat du produit scalaire est un nombre que l'on peut interpréter comme une mesure de similarité entre deux vecteurs. On verra dans quelques instants de quelle manière exactement cette mesure de similarité peut être interprétée. Notons finalement que le produit scalaire est parfois appelé produit intérieur ou simplement par son nom anglais *« dot product »*.

Définition 1.4 : Norme

La **norme** d'un vecteur $\mathbf{u} \in \mathbb{R}^n$, notée $||\mathbf{u}||$, est calculée par

$$||\mathbf{u}|| = \sqrt{(u, u)} = \sqrt{u_1^2 + u_2^2 + ... + u_n^2}.$$

C'est un nombre non-négatif qui correspond à la longueur (ou magnitude) du vecteur $\mathbf{u}$.

Remarquons par ailleurs que dans le cas $n = 2$, la formule pour calculer la norme d'un vecteur n'est rien de plus que le théorème de Pythagore.

Exemple 1.3

Soit $\mathbf{u} = \begin{pmatrix} 1 \\ 2 \end{pmatrix} \in \mathbb{R}^2$. Alors,

$$(u, u) = 1^2 + 2^2 = 5$$

et

$$||\mathbf{u}|| = \sqrt{(u, u)} = \sqrt{5}.$$

Le prochain résultat fournit une interprétation géométrique du produit scalaire.

Théorème 1.1

Soit deux vecteurs $\mathbf{u}, \mathbf{v}$ et θ l'angle aigu entre eux. Alors,

$$(\mathbf{u}, \mathbf{v}) = ||\mathbf{u}|| \cdot ||\mathbf{v}|| \cdot \cos\theta.$$

Exemple 1.4

Soit $\mathbf{u} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$ et $\mathbf{v} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$. Alors, $(u, v) = 2 \cdot 1 + 1 \cdot 0 = 2$, $||\mathbf{u}|| = \sqrt{5}$ et $||\mathbf{v}|| = 1$, de sorte que l'angle θ entre les deux vecteurs est donné par

$$\theta = \arccos\left(\frac{2}{\sqrt{5}}\right),$$

ce que l'on peut observer géométriquement

En fait, (u, v) nous fournit la longueur signée de la projection de $\mathbf{u}$ sur $\mathbf{v}$.

Un corollaire du théorème précédent est le critère suivant pour déterminer si deux vecteur sont perpendiculaires.

Théorème 1.2

Deux vecteurs $\mathbf{u}, \mathbf{v}$ sont orthogonaux (ou perpendiculaires) si et seulement

$$(\mathbf{u}, \mathbf{v}) = 0,$$

ce que l'on notera parfois par $\mathbf{u} \perp \mathbf{v}$.

Exemple 1.5

Soit les vecteurs $\mathbf{u} = \begin{pmatrix} -1 \\ 2 \end{pmatrix}$ et $\mathbf{v} = \begin{pmatrix} 4 \\ 2 \end{pmatrix}$. Alors $(\mathbf{u}, \mathbf{v}) = -1 \cdot 4 + 2 \cdot 2 = 0$. Or,

$$0 = (\mathbf{u}, \mathbf{v}) = ||\mathbf{u}|| \cdot ||\mathbf{v}|| \cos\theta,$$

d'où on tire directement que $\cos\theta = 0$ et donc que $\theta = \frac{\pi}{2}$ et $\mathbf{u} \perp \mathbf{v}$.

Théorème 1.3 : Inégalité de Cauchy-Schwarz

Soit $\mathbf{u}, \mathbf{v}$ des vecteurs de $\mathbb{R}^n$. Alors,

$$|(\mathbf{u}, \mathbf{v})| \leq ||\mathbf{u}|| \cdot ||\mathbf{v}||,$$

avec égalité si et seulement si $\mathbf{u}$ et $\mathbf{v}$ sont colinéaires, c'est-à-dire s'il existe un scalaire k tel que $\mathbf{u} = k\mathbf{v}$.

1.1.2 Combinaison linéaire, indépendance et base

Définition 1.5 : Combinaison linéaire

Soit $\{\mathbf{u}_1, \mathbf{u}_2, ..., \mathbf{u}_k\}$ une collection de k vecteurs de $\mathbb{R}^n$. Une **combinaison linéaire** de ces vecteurs est une expression de la forme

$$\sum_{i=1}^{k} \alpha_i \mathbf{u}_i = \alpha_1 \mathbf{u}_1 + \alpha_2 \mathbf{u}_2 + ... + \alpha_k \mathbf{u}_k,$$

où les nombres α_i sont des réels appelés **coefficients** de la combinaison linéaire.

Exemple 1.6

Soit $\mathbf{u}_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ et $\mathbf{u}_2 = \begin{pmatrix} -1 \\ 0 \end{pmatrix}$. Alors,

$$\mathbf{v} = 3\mathbf{u}_1 + 2\mathbf{u}_2 = 3\begin{pmatrix} 1 \\ 1 \end{pmatrix} + 2\begin{pmatrix} -1 \\ 0 \end{pmatrix} = \begin{pmatrix} 1 \\ 3 \end{pmatrix}$$

est une combinaison linéaire de $\{\mathbf{u}_1, \mathbf{u}_2\}$. Le portrait géométrique est le suivant :

L'exemple suivant présente une combinaison linéaire avec 3 vecteurs particuliers qui forment ce que l'on appelle la *base canonique* de $\mathbb{R}^3$.

Exemple 1.7

Soit les vecteurs $\mathbf{i} = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \mathbf{j} = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}$ et $\mathbf{k} = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$ dans l'espace euclidien de dimension 3. Alors, pour tout $\mathbf{u} = \begin{pmatrix} u_1 \\ u_2 \\ u_3 \end{pmatrix}$ de $\mathbb{R}^3$, on peut écrire

$$\mathbf{u} = u_1\mathbf{i} + u_2\mathbf{j} + u_3\mathbf{k}.$$

On dit donc que l'ensemble $\{\mathbf{i}, \mathbf{j}, \mathbf{k}\}$ forme une **base** de $\mathbb{R}^3$.

Définition 1.6 : Base

Un ensemble de n vecteurs $\mathfrak{B} = \{\mathbf{u}_1, \mathbf{u}_2, ..., \mathbf{u}_n\}$ forme une **base** de $\mathbb{R}^n$ si, pour tout $v \in \mathbb{R}^n$, il existe des nombres $\alpha_i \in \mathbb{R},\ i = 1, 2, ..., n$ tels que

$$\begin{aligned} v &= \sum_{i=1}^{n} \alpha_i \mathbf{u}_i \\ &= \alpha_1 \mathbf{u}_1 + \alpha_2 \mathbf{u}_2 + ... + \alpha_n \mathbf{u}_n. \end{aligned}$$

Autrement dit, cela veut dire que l'ensemble

$$\text{sp}\{\mathbf{u}_1, ..., \mathbf{u}_n\}$$

de toutes les combinaisons linéaires des vecteurs de $\mathfrak{B} = \{\mathbf{u}_1, ..., \mathbf{u}_n\}$ engendre tout $\mathbb{R}^n$.

Exemple 1.8

On affirme (sans preuve) que $\mathfrak{B} = \left\{\begin{pmatrix}1\\2\end{pmatrix}, \begin{pmatrix}-1\\1\end{pmatrix}\right\}$ est une base de $\mathbb{R}^2$. Soit par exemple $\mathbf{v} = \begin{pmatrix}-1\\7\end{pmatrix}$. Alors,

$$\mathbf{v} = 2\begin{pmatrix}1\\2\end{pmatrix} + 3\begin{pmatrix}-1\\1\end{pmatrix}.$$

Les coefficients de la combinaison linéaire permettant d'engendrer $\mathbf{v}$ dans la base $\mathfrak{B}$ sont $\alpha_1 = 2$ et $\alpha_2 = 3$.

Lorsqu'on travaille dans une base fixée $\mathfrak{B} = \{\mathbf{u}_1, \mathbf{u}_2, ..., \mathbf{u}_n\}$ et que

$$\mathbf{v} = \sum_{i=1}^{n} \alpha_i \mathbf{u}_i,$$

on dit que les nombres α_i sont les **coordonnées** de $\mathbf{v}$ dans la base $\mathfrak{B}$ et on écrit alors

$$[v]_{\mathfrak{B}} = \begin{pmatrix}\alpha_1\\...\\\alpha_n\end{pmatrix}.$$

Exemple 1.9

En reprenant la base $\mathfrak{B} = \left\{\begin{pmatrix}1\\2\end{pmatrix}, \begin{pmatrix}-1\\1\end{pmatrix}\right\}$ de l'exemple 1.8 et toujours avec $\mathbf{v} = \begin{pmatrix}-1\\7\end{pmatrix}$, on a $\mathbf{v} = 2\mathbf{u}_1 + 3\mathbf{u}_2$ et donc

$$[v]_{\mathfrak{B}} = \begin{pmatrix}2\\3\end{pmatrix}.$$

1.2 Calcul matriciel et transformations linéaires

Définition 1.7 : Transformation linéaire

Une **transformation linéaire** est une application

$$T : \mathbb{R}^n \to \mathbb{R}^n$$

telle que, pour tout $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$ et $\alpha, \beta \in \mathbb{R}$, on a :

$$T(\alpha\mathbf{u} + \beta\mathbf{v} = \alpha T(\mathbf{u}) + \beta T(\mathbf{v}).$$

Toute transformation linéaire peut être uniquement représentée par une matrice et inversement toute matrice représente une transformation linéaire.

Définition 1.8 : Matrice

Une **matrice** A est un tableau de nombres (réels ou complexes). Dans le cas réel on écrira

$$A \in \mathbb{R}^{m\times n},$$

où m est le nombre de lignes et n le nombre de colonnes. On note par a_{ij} l'élément situé dans i-ème ligne et la j-ème colonne.

La forme générale d'une matrice $A \in \mathbb{R}^{m\times n}$ est donc

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix}$$

Exemple 1.10

Soit $A \in \times$ la matrice donnée par

$$A = \begin{pmatrix} 1 & -1 & 0 \\ 2 & 3 & 1 \end{pmatrix}$$

Cette matrice représente une application $A : \mathbb{R}^3 \to \mathbb{R}^2$:

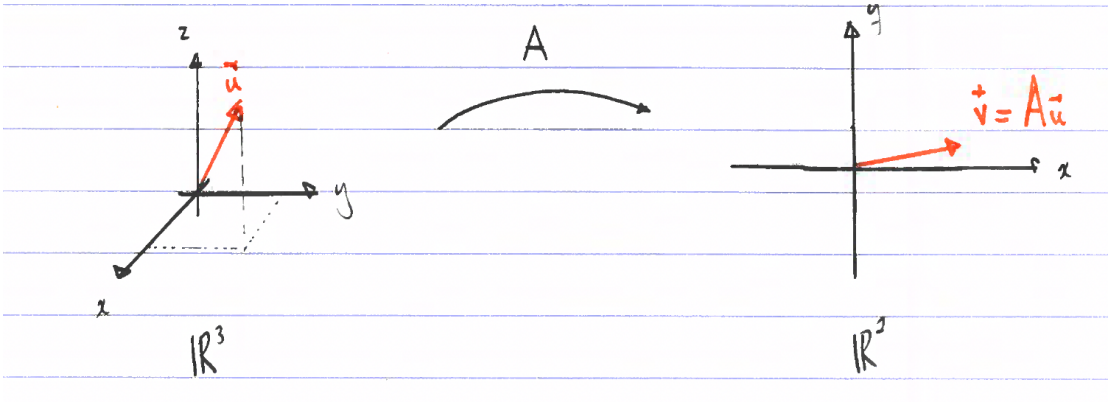

Définition 1.9 : Transposée

La **transposée** A^T d'une matrice $A \in \mathbb{R}^{m\times n}$ est la matrice $A^T \in \times$ telle que $(A^T)_{ij} = a_{ji}$.

Exemple 1.11

Soit $A = \begin{pmatrix} 1 & -1 & 0 \\ 2 & 3 & 1 \end{pmatrix}$ une matrice 2×3. Alors, la transposée de A est la matrice 3×2 donnée par

$$A^T = \begin{pmatrix} 1 & 2 \\ -1 & 3 \\ 0 & 1 \end{pmatrix}.$$

On remarque par exemple que $(A)_{12} = a_{12} = (A^T)_{21} = -1$.

Remarquons au passage qu'un vecteur $\mathbf{v} \in \mathbb{R}^n$ peut-être vu comme une matrice

$$\vec{v} = \begin{pmatrix} v_1 \\ \vdots \\ v_n \end{pmatrix}; \quad \vec{v}^T = \begin{pmatrix} v_1 & \dots & v_n \end{pmatrix}$$

où $\mathbf{v} \in \mathbb{R}^{n \times 1}$ est un vecteur colonne dont la transposée $\mathbf{v}^T \in \mathbb{R}^{1 \times n}$ est un vecteur ligne.

Définition 1.10 : Multiplication matricielle

La **multiplication matricielle** de matrices A, B est définie si A possède le même nombre de *colonnes* que B a de *lignes*. Ainsi, si A est $m \times n$ et B est $n \times p$, alors $C = AB$ est de dimension $m \times p$:

$$\begin{pmatrix} & \\ & \end{pmatrix} \cdot \begin{pmatrix} & \\ & \end{pmatrix} = \begin{pmatrix} & \\ & \end{pmatrix}$$

Le produit est défini par $C_{ij} = \sum_k A_{ik} B_{kj}$.

Exemple 1.12

Soit $A = \begin{pmatrix} 2 & 3 & 0 \\ -1 & 4 & 1 \end{pmatrix}$ et $\mathbf{u} = \begin{pmatrix} 1 \\ 0 \\ 2 \end{pmatrix}$. Alors,

$$A\mathbf{u} = \begin{pmatrix} 2 & 3 & 0 \\ -1 & 4 & 1 \end{pmatrix} \cdot \begin{pmatrix} 1 \\ 0 \\ 2 \end{pmatrix} = \begin{pmatrix} 2 \cdot 1 + 3 \cdot 0 + 0 \cdot 2 \\ -1 \cdot 1 + 4 \cdot 0 + 1 \cdot 2 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}.$$

Encore une fois, il faut voir A comme une transformation linéaire de $\mathbb{R}^3$ vers $\mathbb{R}^2$:

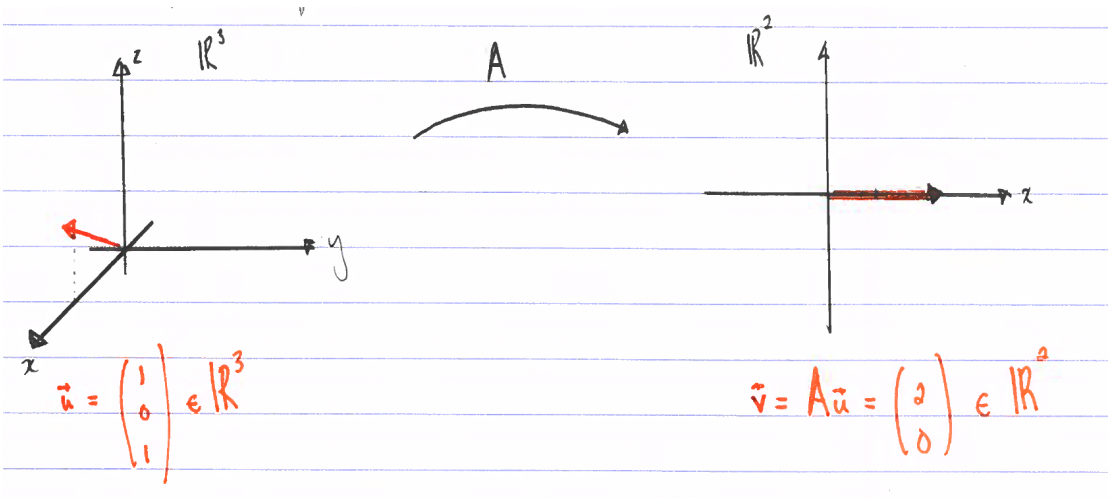

Théorème 1.4 : Propriétés de la multiplication matricielle

Soit A, B et C des matrices dont les dimensions sont telles que tout les produits mentionnés plus bas sont définis. Alors,

1. $A(B+C) = AB + AC$ (Distributivité)
2. $A(BC) = (AB)C$ (Associativité)
3. $(AB)^T = B^T A^T$

Attention : la multiplication matricielle n'est *pas* commutative ! C'est-à-dire que, en général, $AB \neq BA$.

On remarque que cela nous permet de réécrire le produit scalaire $(\mathbf{u}, \mathbf{v})$ de deux vecteurs via

$$\mathbf{u}^T\mathbf{v} = \begin{pmatrix} u_1 & \dots & u_n \end{pmatrix} \begin{pmatrix} v_1 \\ \vdots \\ v_n \end{pmatrix} = u_1 v_1 + \dots + u_n v_n.$$

Cette notation sera couramment employée dans le reste du texte.

Définition 1.11 : La matrice identité

La **matrice identité** I_n est la matrice $n \times n$ qui possède des 1 sur la diagonale et 0 partout ailleurs. Elle satisfait

$$I_n\mathbf{u} = \mathbf{u}, \quad \forall \mathbf{u} \in \mathbb{R}^n.$$

Par exemple, la matrice identité dans $\mathbb{R}^3$ est donnée par

$$I_3 = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}.$$

Définition 1.12 : Matrice inverse

La matrice *inverse* d'une matrice carrée A de dimension n est la matrice A^{-1} qui satisfait

$$AA^{-1} = A^{-1}A = I_n.$$

Il est très important de remarquer que ce ne sont pas toutes les matrices carrées qui sont inversibles. L'étude de l'inversibilité d'une matrice est un sujet délicat qui est typiquement au coeur d'un premier cours consacré exclusivement à l'algèbre linéaire.

Exemple 1.13

Soit $A = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$. Alors, A^{-1} existe et on a $A^{-1} = \begin{pmatrix} 1 & -1 \\ 0 & 1 \end{pmatrix}$ En effet, on calcule aisément que

$$AA^{-1} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = I_2.$$

Géométriquement, on a

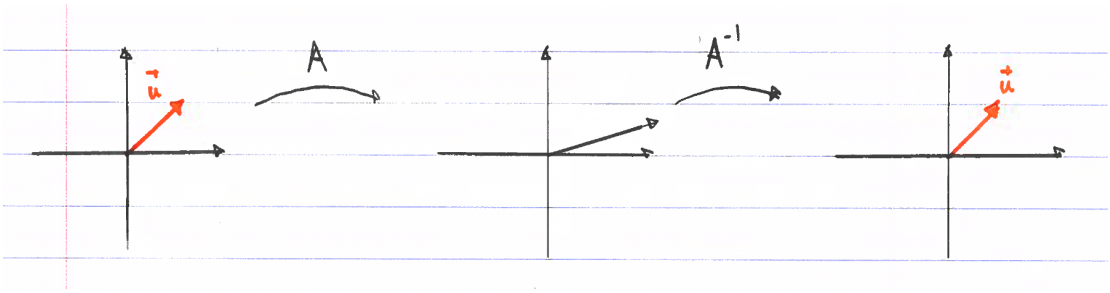

Ici, $\mathbf{u} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ $A\mathbf{u} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$ $A^{-1}\begin{pmatrix} 2 \\ 1 \end{pmatrix} = \mathbf{u}$.

Définition 1.13 : Transformation affine

Une **transformation affine** $A : \mathbb{R}^n \to \mathbb{R}^m$ est une transformation de la forme

$$A\mathbf{u} = W\mathbf{u} + \mathbf{b},$$

où W est une matrice $m \times n$ et $b \in \mathbb{R}^m$.

Exemple 1.14

Montrer géométriquement l'effet de la transformation affine $A : \mathbb{R}^3 \to \mathbb{R}^2$ définie par $A\mathbf{u} = W\mathbf{u} + \mathbf{b}$ avec

$$W = \begin{pmatrix} 1 & 1 & -2 \\ 0 & -1 & 0 \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} -1 \\ 0 \end{pmatrix}$$

sur le vecteur $\mathbf{u} = \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix}$.

Solution :

On calcule directement $W\mathbf{u} = \begin{pmatrix} 1 & 1 & -2 \\ 0 & -1 & 0 \end{pmatrix}\begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} -1 \\ 1 \end{pmatrix}$, de telle sorte que

$$A\mathbf{u} = W\mathbf{u} + \mathbf{b} = \begin{pmatrix} -1 \\ -1 \end{pmatrix} + \begin{pmatrix} -1 \\ 0 \end{pmatrix} = \begin{pmatrix} -2 \\ 1 \end{pmatrix}.$$

Géométriquement, on a

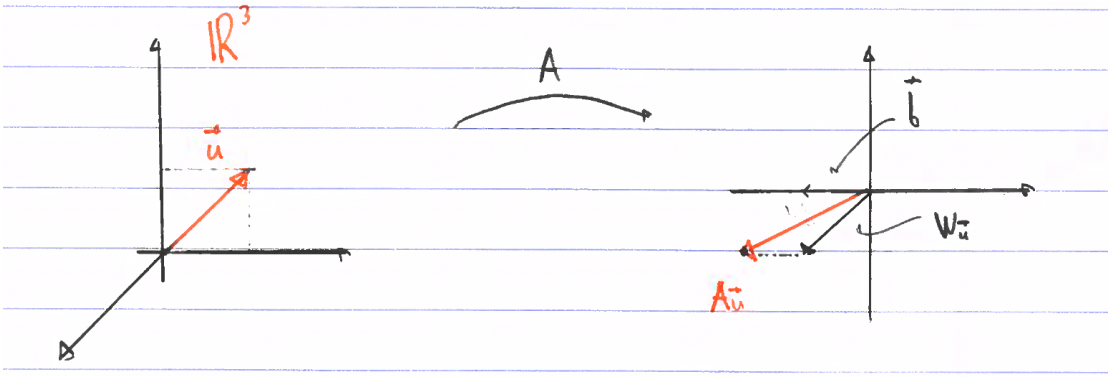

1.3 Vecteurs propres et théorème spectral

Définition 1.14 : Vecteur et valeur propre

Soit A une matrice carrée de dimension n. Alors, un **vecteur propre** de A est un vecteur $\mathbf{u}$ qui satisfait l'équation

$$A\mathbf{u} = \lambda\mathbf{u}.$$

Dans ce cas, on dit que le nombre λ est la **valeur propre** associée au vecteur propre $\mathbf{u}$.

Exemple 1.15

Soit $\begin{pmatrix} 0 & 1 \\ -2 & 3 \end{pmatrix}$ et $\mathbf{u} = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$. Alors,

$$A\mathbf{u} = \begin{pmatrix} 0 & 1 \\ -2 & 3 \end{pmatrix}\begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} -1 \\ 1 \end{pmatrix} = (-1)\mathbf{u}.$$

Donc, $\mathbf{u}$ est un vecteur propre de A associé à la valeur propre $\lambda = -1$.

Comment interpréter géométriquement les vecteurs et valeurs propres d'une matrice A? Supposons que $\mathbf{u}_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ et $\mathbf{u}_2 = \begin{pmatrix} -2 \\ 4 \end{pmatrix}$ sont des vecteurs propres de valeurs propres $\lambda_1 = 2$ et $\lambda_2 = \frac{1}{2}$ respectivement. On a alors

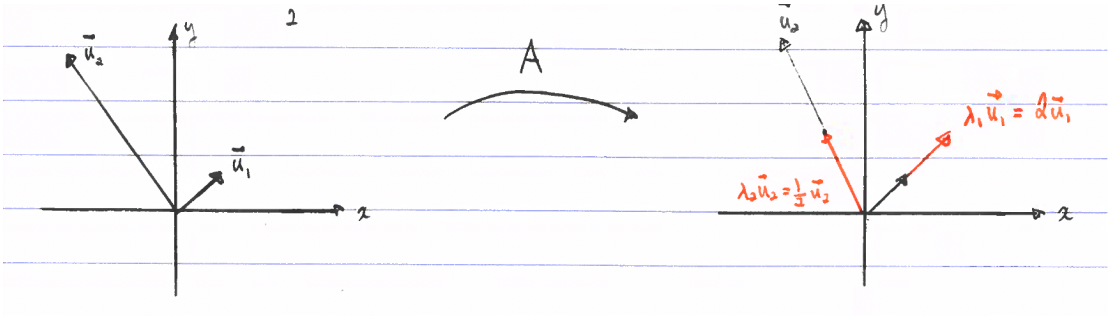

Ainsi, une matrice A agit sur ses vecteurs propres en les dilatant ou en les contractant (et en inversant leur sens si $\lambda < 0$), mais sans modifier leur direction.

Définition 1.15 : Matrices orthogonale et symétrique

- Une matrice **orthogonale** est une matrice telle que
$$A^T = A^{-1}.$$
- Une matrice **symétrique** est une matrice telle que
$$A = A^T.$$

On remarque que ces deux définitions impliquent que, forcément, seule une matrice carrée peut être orthogonale ou symétrique.

Théorème 1.5 : Théorème spectral

Soit S une matrice symétrique de dimension n.

- Alors, S admet une base orthonormale $\mathfrak{B} = \{\mathbf{u}_1, ..., \mathbf{u}_n\}$ de vecteurs propres de S.
- De plus, si on pose $Q = \begin{pmatrix} \mathbf{u}_1 & \mathbf{u}_2 & ... & \mathbf{u}_n \end{pmatrix}$, alors Q est une matrice orthogonale et on a
$$D = Q^{-1} A Q,$$
avec $D = \text{diag}\{\lambda_i\}$, c'est-à-dire
$$D = \begin{pmatrix} \lambda_1 & 0 & 0 & \\ 0 & \lambda_2 & 0 & \\ & & \ddots & \\ & & & \lambda_n \end{pmatrix}.$$

On rappelle qu'une base orthonormale (ONB) est une base $\{\mathbf{u}_1, ..., \mathbf{u}_n\}$ de $\mathbb{R}^n$ telle que $\mathbf{u}_i \perp \mathbf{u}_j$ dès que $i \neq j$ et $||\mathbf{u}_i|| = 1,\ i = 1, ..., n$.

Exemple 1.16

Soit $A = \begin{pmatrix} 1 & -2 \\ -2 & 1 \end{pmatrix}$. Vérifier que A est symétrique et qu'elle admet une base orthonormale de vecteurs propres.

Solution :

On a $A^T = \begin{pmatrix} 1 & -2 \\ -2 & 1 \end{pmatrix} = A$ et donc A est symétrique.

Avec un logiciel de calcul symbolique, on trouve 2 vecteurs propres

$$\mathbf{u}_1 = \begin{pmatrix} -1 \\ 1 \end{pmatrix} \text{ et } \mathbf{u}_2 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

de valeurs propres respectives $\lambda_1 = 3$ et $\lambda_2 = -1$. On calcule $(\mathbf{u}_1, \mathbf{u}_2) = (-1)\cdot 1 + 1 \cdot 1 = 0$ et donc $\mathbf{u}_1$ et $\mathbf{u}_2$ sont bien orthogonaux. Soit maintenant

$$\mathbf{v}_1 = \frac{\mathbf{u}_1}{||\mathbf{u}_1||} \text{ et } \mathbf{v}_2 = \frac{\mathbf{u}_2}{||\mathbf{u}_2||}$$

la normalisation de ces vecteurs propres. Alors, $\{\mathbf{v}_1, \mathbf{v}_2\}$ est une base orthonormale de vecteurs propres de A.

1.4 Calcul différentiel et optimisation

On révise désormais très brièvement certains thèmes propres au calcul différentiel qui nous permettront plus tard d'optimiser des fonctions de plusieurs variables. On commence d'abord avec le cas le plus simple en supposant que f et g sont deux fonctions dérivables d'une variable. Alors, la *règle de la chaîne* permet de dériver la composition

$$(f \circ g)'(x) = f'(g(x))g'(x).$$

En utilisant la notation de Leibniz, on a plutôt

$$\frac{d}{dx}\big(f \circ g\big) = \frac{df}{dg}\frac{dg}{dx}.$$

Exemple 1.17

Soit $y(x) = 3x + 4$ et $f(y) = y^3$. Alors,

$$\begin{aligned}(f \circ y)'(x) &= \big[f(y(x))\big]' = f'(y)y'(x) \\ &= 3y^2(3x+4)' \\ &= 3(3x+4)^2 \cdot 3 = 9(3x+4)^2.\end{aligned}$$

Évidemment, si on avait directement eu $h(x) = (3x+4)^3$, on aurait calculé

$$h'(x) = 3(3x+4)^2 \cdot 3 = 9(3x+4)^2.$$

Le résultat suivant permet d'étendre cette règle à la composition de fonctions de 2 variables.

Théorème 1.6 : Règle de la chaîne, 2 variables indépendantes

Supposons que $x(u,v)$ et $y(u,v)$ sont 2 fonctions différentiables de u,v et que $z(x,y)$ est une fonction différentiable de x et y. Alors,

$$z(u,v) = z(x(u,v), y(u,v))$$

est une fonction différentiable de u,v et

$$\frac{\partial z}{\partial u} = \frac{\partial z}{\partial x}\frac{\partial x}{\partial u} + \frac{\partial z}{\partial y}\frac{\partial y}{\partial u} \text{ et } \frac{\partial z}{\partial v} = \frac{\partial z}{\partial x}\frac{\partial x}{\partial v} + \frac{\partial z}{\partial y}\frac{\partial y}{\partial v}.$$

Ces règles se visualisent par l'arbre suivant

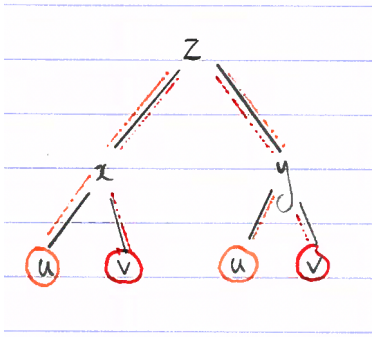

Exemple 1.18

Soit $x(u,v) = u^2 + v^2$ et $y(u,v) = 3u - 2v$ et $z(x,y) = e^{2x+y}$. Alors, on calcule

$$\frac{\partial x}{\partial u} = 2u,\ \frac{\partial x}{\partial v} = 2v,\ \frac{\partial y}{\partial u} = 3,\ \frac{\partial y}{\partial v} = -2.$$

De plus,

$$\frac{\partial z}{\partial x} = 2e^{2x+y} \text{ et } \frac{\partial z}{\partial y} = e^{2x+y}.$$

Donc,

$$\begin{aligned}\frac{\partial z}{\partial u} = \frac{\partial z}{\partial x}\frac{\partial x}{\partial u} + \frac{\partial z}{\partial y}\frac{\partial y}{\partial u} &= 2e^{2x+y}\cdot(2u) + e^{2x+y}\cdot 3 \\ &= e^{2x+y}(4u+3) \\ &= e^{2u^2+2v^2+3u-2v}(4u+3).\end{aligned}$$

Un calcul similaire permet d'obtenir $\dfrac{\partial z}{\partial v}$.

1.4.1 Descente de gradient

Supposons que vous êtes en forêt dans un paysage montagneux et que vous ne voyez pas autour de vous en raison de la densité des arbres. Quel est le meilleur moyen de retrouver le base de la montagne ?

Vous pouvez examiner localement la topographie autour de vous et décider de faire un petit pas dans la direction immédiate qui vous fera le plus diminuer votre altitude. En répétant suffisamment longtemps ce petit manège, vous devriez arriver à retrouver la vallée. La descente de gradient est une technique mathématique qui fait exactement la même chose lorsqu'on vise à trouver le minimum d'une fonction.

On rappelle d'abord le fait suivant: si $f :]a,b[\to \mathbb{R}$ est une fonction dérivable et que f admet un extremum (minimum ou maximum) local en $c \in]a,b[$, alors $f'(c) = 0$.

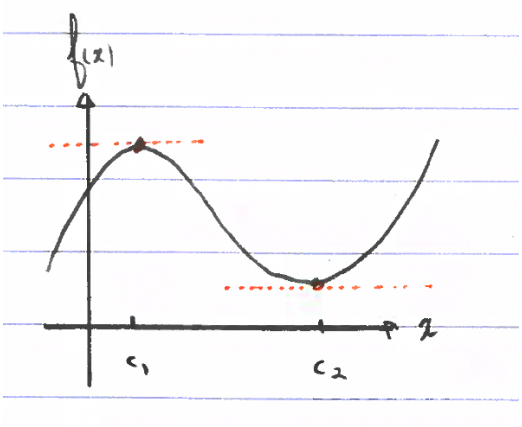

Ici, on a $f'(c_1) = f'(c_2) = 0$.

Pour approcher numériquement un tel extremum local, on emploie donc la technique itérative de descente du gradient.

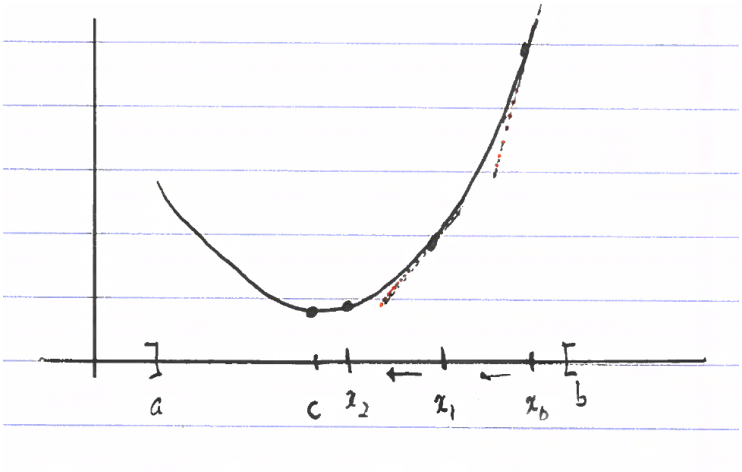

On fixe d'abord un *pas* $\eta > 0$ et on initialise un processus itératif en un point quelconque $x_0 \in]a,b[$.

1. $x_1 = x_0 + \eta f'(x_0)$, et on remarque que l'on se déplace vers la gauche si $f'(x_0) < 0$ et vers la droite si $f'(x_0) > 0$.

2. $x_2 = x_1 + \eta f'(x_1)$ et ainsi de suite.

Il est important ici de remarquer que cet algorithme, bien que souvent fonctionnel, est très naïf : un tas de complications sont possibles. Que se passe-t-il, par exemple, si on tombe sur un maximum local tel que $f'(c) = 0$? Est-ce que la procédure est certaine de converger vers le minimum recherché ? Quand est-on suffisamment « proche » pour cesser les itérations ? Ces questions sont importantes et complexes !

Ces idées se généralisent naturellement aux fonctions de plusieurs variables.

Définition 1.16 : Vecteur gradient

Soit $f : \mathscr{D} \subset \mathbb{R}^n \to \mathbb{R}$ une fonction différentiable. Alors, le **gradient** de f est un champ vectoriel $\mathscr{D} \subset \mathbb{R}^n \to \mathbb{R}^n$ défini par

$$\nabla f(x_1, ..., x_n) = \begin{pmatrix} \frac{\partial f}{\partial x_1} & \frac{\partial f}{\partial x_2} & ... & \frac{\partial f}{\partial x_n} \end{pmatrix}$$

Autrement dit, le vecteur gradient d'une fonction est un vecteur dont les composantes en un point donné sont les dérivées partielles de cette fonction évaluées à ce point.

Théorème 1.7

Soit $f : \mathscr{D} \subset \mathbb{R}^n \to \mathbb{R}$ une fonction différentiable. Si f admet un extremum local en $x_0 \in \mathscr{D}$, alors $\nabla f(x_0) = \mathbf{0}$.

Cela veut dire que si, lors d'une promenade dans un paysage montagneux, on se retrouve au sommet d'une montagne ou dans le creux d'une vallée, alors le *plan tangent* à la surface au point où on se situe est horizontal.

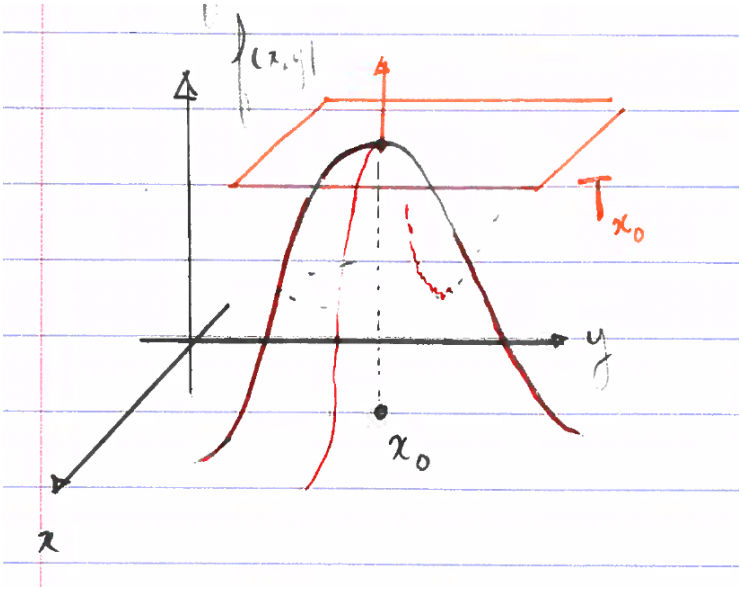

Toute l'idée de descente du gradient repose sur le fait suivant : le vecteur gradient $\nabla f(x_0)$ pointe dans la direction d'accroissement *maximal* de f en $x_0 \in \mathscr{D}$. Similairement, $-\nabla f(x_0)$ pointe dans la direction de la plus grande décroissance de f en x_0.

Exemple 1.19

Soit $f(x,y) = x^2 + y^2$. Alors,

$$\nabla f(x,y) = \begin{pmatrix} \frac{\partial f}{\partial x} & \frac{\partial f}{\partial y} \end{pmatrix} = \begin{pmatrix} 2x & 2y \end{pmatrix}.$$

Ainsi, en $x_0 = (1,1)$, on a $\nabla f(1,1) = (2,2)$.

Chapitre 2

Réseaux de neurones profonds

Dans ce chapitre, nous allons introduire les réseaux de neurones profonds, en définir les différentes composantes pour finalement indiquer comment ceux-ci peuvent *apprendre*. Ceci se fera à l'aide d'une tâche classique qui est désormais considérée comme le « *Hello World* » de l'apprentissage machine, soit la reconnaissance automatisée de chiffres manuscrits.

2.1 Principes généraux

Considérons donc une tâche classique qui se fait de manière automatique pour les humains : la reconnaissance de chiffres manuscrits.

Chiffres manuscrits tirés de la base de données MNIST.

Comment apprendre à reconnaître un « 4 » manuscrit, par exemple, et à le classe comme tel ? C'est assurément quelque chose de très difficile à effectuer directement. On ne pourrait pas espérer avoir beaucoup de succès en décrivant les propriétés figuratives qui composent la représentation d'un chiffre : « *le chiffre 4 est composé d'un long trait, de trois petits, parfois reliés au sommet, parfois pas…* ». Bonne chance !

Pour aborder autrement ce problème, on considère un *réseau de neurones*, qui n'est rien de plus qu'un graphe dans lequel circule de l'information.

Définition 2.1 : Réseau de neurones

En général, un **réseau de neurones profond** (RNP) est un graphe, dont les sommets sont appelés des **neurones** et les arêtes des **connexions**. Les neurones sont disposés en plusieurs **couches** et on imagine l'information circulant à partir de la couche d'entrée vers la couche de sortie.

Il est utile d'imaginer chaque neurone comme une ampoule qui peut être plus ou moins allumée, l'intensité de la lumière étant formellement appelée **activation**.

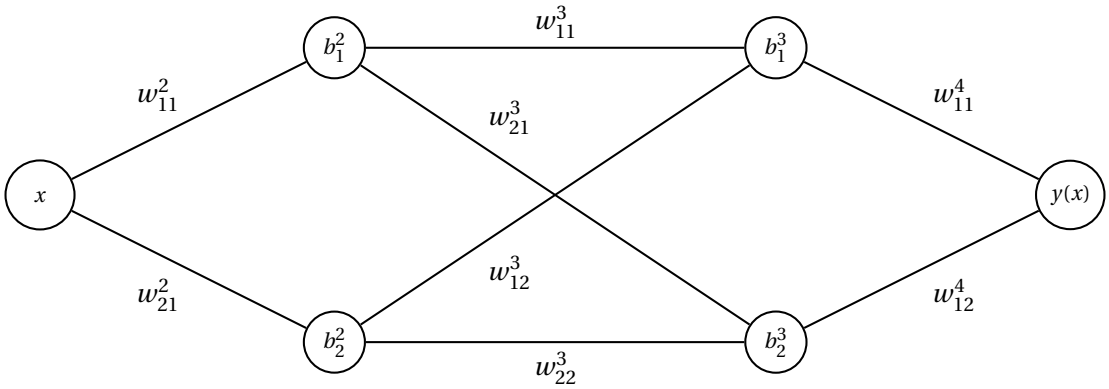

- Les *couches* du réseau sont notées $\ell = 1, ..., L$.
- On note $\{d_1, d_2, ..., d_L\}$ la *largeur* ou *dimension* de chaque couche.
- Au j-ème neurone de la couche ℓ, on associe un *biais* b_j^ℓ.
- À chaque connexion on associe un *poids* w. En particulier, w_{jk}^ℓ est le poids qui relie le k-ème neurone de la couche $\ell - 1$ avec le j-ème neurone de la couche ℓ.
- On note a_j^ℓ l'*activation* ou la *puissance* du signal du j-ème neurone de la couche ℓ.

De manière générale, les indices en super script dénoteront la couche et ceux en sous script la position du neurone dans une couche donnée.

Exemple 2.1
Le réseau de l'exemple ci-haut contient 4 couches : $\ell = 1,2,3,4$ de dimensions respectives $d_i = 1,2,2,1$.

Définition 2.2 : Préactivation

On considère le vecteur $\mathbf{w}_j^\ell$ de tous les poids entrant dans le j-ème neurone de la couche ℓ ainsi que le vecteur $\mathbf{a}^{\ell-1}$ contenant toutes les activations des neurones de la couche $\ell-1$.

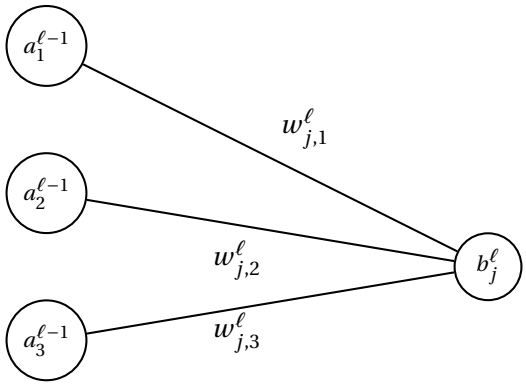

Alors, la **préactivation** du j-ème neurone de la couche ℓ est définie par

$$z_j^\ell = \mathbf{w}_j^\ell \cdot \mathbf{a}^{\ell-1} + b_j^\ell.$$

Il est utile de s'éloigner un peu des formules et de la notation qui peut être lourde pour bien comprendre ce en quoi consiste la préactivation : il s'agit simplement d'une moyenne pondérée des activations de la couche précédente. Chaque neurone de la couche précédente contribue à la préactivation d'un neurone donné de la couche subséquente en lui transmettant sa propre activation, par le biais d'une connexion qui peut être plus ou moins forte.

Définition 2.3 : Activation

L'**activation** du j-ème neurone de la couche ℓ est calculée par

$$a_j^\ell = \sigma(z_j^\ell),$$

où $\sigma : \mathbb{R} \to \mathbb{R}$ est une *fonction d'activation* fixée et z_j^ℓ est la préactivation du neurone considéré.

Ainsi, l'activation d'un neurone est simplement l'image de sa préactivation par une fonction d'activation fixée.

Exemple 2.2

Il existe théoriquement une infinité de fonctions d'activation possibles. Voici deux des plus populaires, que l'on utilisera à plusieurs reprises dans le reste du texte.

- La fonction **ReLU** (*Rectified Linear Unit*), définie par $\sigma(z) = \max\{0, z\}$.

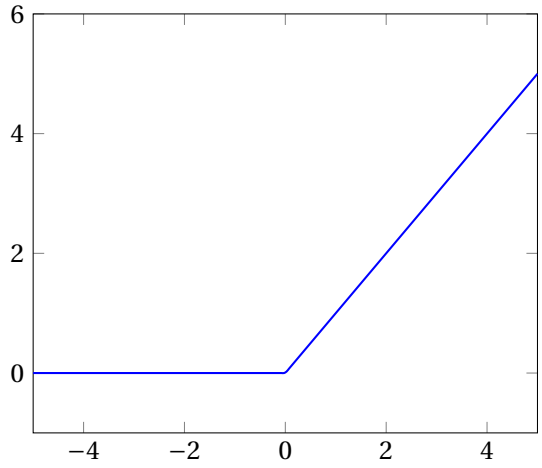

- La fonction **sigmoïde**, donnée par $\sigma(z) = \dfrac{1}{1+e^{-z}}$.

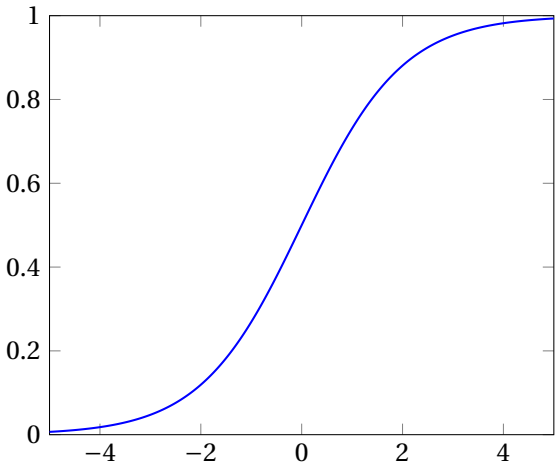

L'objectif des fonctions d'activation est d'introduire une non-linéarité dans le réseau, pour donc élargir la classe des fonctions qu'il est (théoriquement) possible d'approximer. Le modèle complet d'un réseau de neurones est donc une fonction

$$\mathscr{F} : \mathbb{R}^n \to \mathbb{R}^m,$$

avec $n = d_1$ et $m = d_L$.

Il est possible de synthétiser le mécanisme de propagation avant de l'information dans un réseau de neurones en adoptant un point de vue vectoriel. On dénote

- $W^\ell = (w^\ell_{jk})$, la matrice de tous les poids allant de la couche $(\ell - 1)$ à la couche ℓ.

- b^ℓ, le vecteur contenant tous les biais des neurones de la couche ℓ.
- z^ℓ, le vecteur contenant les préactivations des neurones de la couche ℓ.
- Enfin, a^ℓ, le vecteur des activations des neurones de la couche ℓ.

Avant l'activation, la propagation avant de l'information de la couche $(\ell-1)$ à la couche ℓ est une transformation affine

$$T_\ell : \mathbb{R}^{d_{\ell-1}} \to \mathbb{R}^{d_\ell},$$

donnée par

$$z_\ell = T_\ell(a^{(\ell-1)} = W^\ell a^{\ell-1} + b^\ell.$$

Ainsi, la fonction $\mathscr{F} : \mathbb{R}^{d_1} \to \mathbb{R}^{d_L}$ que réalise le réseau peut être ainsi décomposée

$$\mathscr{F} = \mathrm{Act}_L \circ T_L \circ \mathrm{Act}_{L-1} \circ T_{L-1} \circ \ldots \circ \mathrm{Act}_1 \circ T_1,$$

où Act$=\sigma$ sont les activations vectorielles et T_i sont les transformations affines vues un peu plus haut.

On revient maintenant à notre objectif principal, soit la tâche de construire un réseau capable de classer des chiffres manuscrits. Avec la terminologie que l'on vient de développer, on veut que le réseau représente une fonction $\mathscr{F}$ qui soit capable d'approximer correctement une fonction dite *parfaite* ou *idéale*, typiquement notée f^*, la fonction qui associe parfaitement chaque image d'un chiffre manuscrit à la catégorie (entre 0 et 9) appropriée. Mais comment faire apprendre à un réseau ? C'est en modifiant ses réglages, ses boutons ses *paramètres* que l'on pourra lui permettre de s'ajuster et de graduellement se rapprocher de la fonction idéale f^*.

Définition 2.4 : Paramètres

Les *paramètres* d'un réseau de neurones sont l'ensemble des poids w et biais b qui le composent. On peut voir chaque paramètre comme un petit bouton qu'il faut constamment ajuster et régler pour obtenir la configuration que l'on recherche pour accomplir la tâche visée.

Enfin, on distingue deux types d'apprentissage principaux pour les réseaux de neurones.

Définition 2.5 : Types d'apprentissage

- L'apprentissage **supervisé** lorsqu'on on utilise des données d'entraînement étiquetées.
- L'apprentissage **non-supervisé** dans le cas contraire, c'est-à-dire lorsque les données d'entraînement utilisées ne sont pas étiquetées.

Dans le cas qui nous occupe, la base de données de chiffres manuscrits MNIST étant étiquetée, nous sommes dans un contexte d'apprentissage supervisé.

2.2 Apprendre via la descente de gradient

Notre but est donc de construire un réseau de neurones approprié à notre tâche et de le faire apprendre, c'est-à-dire de trouver les valeurs des paramètres w, b qui lui permettront d'avoir les meilleures

performances pour la tâche de classification de chiffres manuscrits. Pour être capable de mesurer les performances du réseau, nous utiliserons la fonction dite de **coût** ou **d'erreur** suivante

$$C(w,b) = \frac{1}{2n}\sum_x ||\mathbf{y}(x) - \mathbf{a}^L||^2,$$

où x est une donnée d'entraînement sous forme vectorielle, **y(x)** est la sortie désirée associée à l'entrée x et n correspond au nombre total de données d'entraînement. Intuitivement, la fonction de coût compare la différence entre la sortie attendue et la sortie obtenue pour chaque donnée d'entrée x et en fait une moyenne.

Enfin, il est important de remarquer que la fonction de coût dépend des paramètres. En effet, la performance du réseau sera plus ou moins bonne selon le choix des poids et des biais que l'on aura effectué. Est-ce la seule fonction de coût possible? Évidemment, la réponse est non. Nous aurions par exemple pu utiliser

$$\tilde{C}(w,b) := \#\text{d'images correctement classées},$$

ce qui est conceptuellement correct, dans la mesure où cette fonction donne également une mesure de la performance du réseau. Or, cette fonction n'est pas *lisse* et donc non différentiable. L'avantage de C telle que définie plus haut est qu'il s'agit d'une fonction de classe C^∞ avec laquelle on peut utiliser la puissance des techniques issues du calcul différentiel.

On veut trouver le point (w,b) qui va *minimiser* la fonction de coût C et on peut donc utiliser la technique de descente du gradient.

$$\begin{cases} w_k \mapsto w_k' = w_k - \eta\frac{\partial C}{\partial w_k}, \\ \\ b_j \mapsto b_j' = b_j - \eta\frac{\partial C}{\partial b_j}. \end{cases} \tag{2.1}$$

Puisque $C = \frac{1}{2n}\sum_x C_x$, avec $C_x = \frac{1}{2}||\mathbf{y}(x) - \mathbf{a}^L||^2$, calculer le gradient ∇C exige de balayer *toutes* les données d'entraînement. Pour pallier ce problème, on introduit le concept suivant.

Définition 2.6 : Descente stochastique de gradient

La **descente stochastique de gradient** (que l'on abrégera souvent par *SGD*) est une technique pour minimiser une fonction de coût $C(w,b)$ et qui se décline en trois étapes:

1. On choisit *aléatoirement* une **mini-batch** de m données d'entraînement

$$x_1, x_2, ..., x_m.$$

2. On met à jour les arguments de la fonction de coût, soit les paramètres w, b via

$$\begin{cases} w_k \mapsto w_k' = w_k - \eta\frac{1}{m}\sum_{j=1}^m \frac{\partial C_{x_j}}{\partial w_k}, \\ \\ b_\ell \mapsto b_\ell' = b_\ell - \eta\frac{1}{m}\sum_{j=1}^m \frac{\partial C_{x_j}}{\partial b_\ell}. \end{cases} \tag{2.2}$$

2.3 Rétropropagation

Le descente de gradient exige de calculer *toutes* les dérivées partielles $\frac{\partial C}{\partial w}, \frac{\partial C}{\partial b}$ pour chacun des paramètres w, b qui constituent le réseau de neurones. Une approche naïve consiste à estimer chacune de celle-ci par

$$\frac{\partial C}{\partial w} \approx \frac{C(w+\epsilon) - C(w)}{\epsilon}$$

pour un choix suffisamment petit de ϵ. Or, cette manière de procéder exige de calculer la quantité $C(w+\epsilon)$ pour chaque paramètre! Si on a N de ceux-ci, il faudra alors faire N traversées du réseau pour compléter une seule itération de la descente de gradient! On comprend aisément que lorsque N devient grand, cette approche devient impossible à implémenter en pratique.C'est la technique de *rétropropagation* qui nous permettra de calculer ces dérivées partielles de manière plus efficace. Le traitement que nous proposons ici est basé sur celui dans [Nielsen].

L'idée générale est d'introduire une petite perturbation Δ_j^ℓ dans la préactivation: $z_j^\ell \mapsto z_j^\ell + \Delta_j^\ell$. Un développement de Taylor du premier degré donne maintenant

$$C(z_j^\ell + \Delta_j^\ell) - C(z_j^\ell) \approx \frac{\partial C}{\partial z_j^\ell}\Delta_j^\ell.$$

Puisque $C \geq 0$ et qu'on veut minimiser C, on veut donc que $\frac{\partial C}{\partial z_j^\ell}\Delta_j^\ell << 0$. Deux cas de figure sont ainsi possibles. D'abord, si $\frac{\partial C}{\partial z_j^\ell}$ est gros, on choisit Δ_j^ℓ de signe opposé. Dans le cas contraire où $\frac{\partial C}{\partial z_j^\ell}$ est petit, on ne peut rien faire et ce neurone est donc déjà, dans un certain sens, configuré de manière optimale. C'est cette interprétation de la taille de la dérivée $\frac{\partial C}{\partial z_j^\ell}$ qui nous incite à présenter la définition suivante.

Définition 2.7 : Erreur d'un neurone

L'**erreur** δ_j^ℓ d'un neurone est

$$\delta_j^\ell = \frac{\partial C}{\partial z_j^\ell}.$$

De manière vectorielle, on notera parfois les erreurs de la couche ℓ par

$$\delta^\ell = \begin{pmatrix} \delta_1^\ell \\ \vdots \\ \delta_{d_\ell}^\ell \end{pmatrix}.$$

On considère d'abord les dernières couches $(L-1)$ et L d'un réseau.

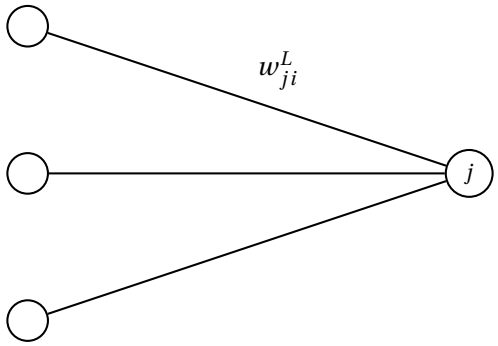

On rappelle ici que $a_j^L = \sigma(z_j^L)$. De plus, la préactivation z_j^L est calculée par

$$z_j^L = \left(\sum_k w_{kj}^L \cdot a_k^{L-1} \right) + b_j^L.$$

Ainsi, en vertu de la règle de la chaîne, on a

$$\frac{\partial C}{\partial z_j^L} = \frac{\partial C}{\partial a_j^L} \sigma'(z_j^L),$$

que l'on peut réécrire pour obtenir la première équation de la rétropropagation.

Théorème 2.1 : Première équation de la rétropropagation (RP1)

$$\delta_j^L = \frac{\partial C}{\partial a_j^L} \cdot \sigma'(z_j^L).$$

De plus, une autre application de la règle de la chaîne nous donne immédiatement

$$\delta_j^\ell = \frac{\partial C}{\partial z_j^\ell} = \sum_k \frac{\partial C}{\partial z_k^{\ell+1}} \frac{\partial z_k^{\ell+1}}{\partial z_j^\ell} = \sum_k \frac{\partial z_k^{\ell+1}}{\partial z_j^\ell} \delta_k^{\ell+1}.$$

On sait que

$$z_k^{\ell+1} = \sum_i w_{ki}^{\ell+1} a_i^\ell + b_k^{\ell+1},$$

d'où

$$\frac{\partial z_k^{\ell+1}}{\partial z_j^\ell} = w_{kj}^{\ell+1} \sigma'(z_j^\ell).$$

Ceci nous permet d'obtenir une seconde équation de la rétropropagation.

Théorème 2.2 : Seconde équation de la rétropropagation (RP2)

$$\delta_j^\ell = \sum_k w_{kj}^{\ell+1} \cdot \delta_k^{\ell+1} \cdot \sigma'(z_j^\ell).$$

L'usage combiné des deux premières équations de la rétropropagation nous permet de propager vers l'arrière les erreurs δ_j^ℓ d'une couche à l'autre en débutant par la dernière. Or, notre objectif initial est de connaître le gradient de la fonction de coût. Il nous reste donc à trouver une manière d'exprimer les dérivées partielles $\frac{\partial C}{\partial w}, \frac{\partial C}{\partial b}$ en fonction des erreurs δ_j^ℓ, ce que feront nos deux dernières équations de la rétropropagation.

Une autre utilisation directe de la règle de la chaîne nous permet de calculer

$$\frac{\partial C}{\partial b_j^\ell} = \sum_k \frac{\partial C}{\partial z_k^\ell} \cdot \frac{\partial z_k^\ell}{\partial b_j^\ell} = \frac{\partial C}{\partial z_j^\ell} = \delta_j^\ell.$$

Théorème 2.3 : Troisième équation de la rétropropagation (RP3)

$$\frac{\partial C}{\partial b_j^\ell} = \delta_j^\ell.$$

Finalement, une dernière utilisation de la règle de la chaîne donne

$$\frac{\partial C}{\partial w_{jk}^\ell} = \sum_i \frac{\partial C}{\partial z_i^\ell} \cdot \frac{\partial z_i^\ell}{\partial w_{jk}^\ell} = \frac{\partial C}{\partial z_j^\ell} \cdot \frac{\partial z_j^\ell}{\partial w_{jk}^\ell} = \delta_j^\ell \cdot a_k^{\ell-1},$$

où l'on a utilisé le fait que $\frac{\partial z_i^\ell}{\partial w_{jk}^\ell}$ vaut 0 dès que $i \neq j$.

Théorème 2.4 : Quatrième équation de la rétropropagation (RP4)

$$\frac{\partial C}{\partial w_{jk}}^{\ell} = \delta_j^\ell \cdot a_k^{\ell+1}.$$

Chapitre 3

Problèmes d'apprentissage

Les idées de base permettant l'apprentissage d'un réseau de neurones présentées au chapitre précédent se heurtent souvent en pratique à des obstacles qui neutralisent le bon fonctionnement du réseau. Dans ce chapitre, nous allons explorer certains de ces obstacles et considérer différentes approches pour les contourner.

3.1 Problèmes d'apprentissage avec la fonction de coût quadratique et la sigmoïde

On rappelle que la fonction de coût *quadratique* introduite au chapitre précédent est définie par

$$C = C(w,b) = \frac{1}{2n}\sum_x ||y(x) - a^L||^2.$$

De plus, on utilisera la fonction d'activation sigmoïde $\sigma : \mathbb{R} \to \mathbb{R}$ donnée par $\sigma(x) = \frac{1}{1+e^{-x}}$. On remarque aisément que σ tend respectivement vers $1,0$ lorsque x tend vers $\pm\infty$.

Revenons maintenant à notre approche de descente de gradient en une dimension. On considère la fonction $f(x)$ suivante avec le taux d'apprentissage $\eta = 1$.

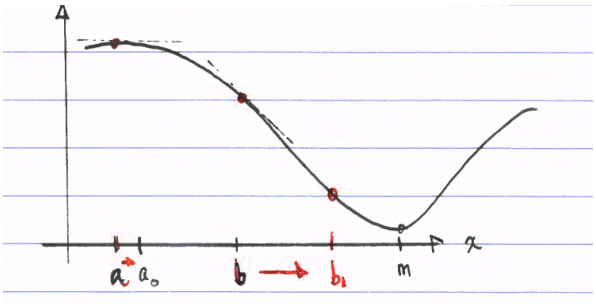

On observe les faits suivants :

- Lorsque la dérivée $f'(a)$ s'approche de zéro, la convergence vers m est très lente.
- Au contraire, quand $|f'(a)|$ est « grand », la converge vers m est plus rapide.

Considérons un réseau de neurones très simple $\mathscr{F} : \mathbb{R} \to \mathbb{R}$, donné par

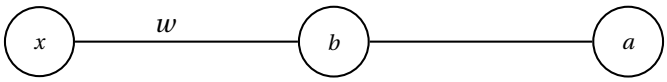

Ici, $z = wx + b$ et $a = \sigma(z)$, avec σ la fonction sigmoïde. Notre objectif est de faire apprendre à ce réseau l'application

$$1 \mapsto 0.$$

Autrement dit, on voudrait qu'il apprenne à fournir la sortie $a = 0$ lorsqu'on lui fournit $x = 1$ comme entrée. Pour voir un peu comment le réseau va apprendre, fixons d'abord $w = 0.6$ et $b = 0.9$. Alors,

$$\mathscr{F}(x) = \sigma(0.6x + 0.9).$$

et on calcule aisément que $\mathscr{F}(1) \approx 0.82$. Pour le moment, donc, ce réseau fait assez mal son travail. C'est la fonction de coût quadratique qui permet de quantifier cette inefficacité

$$C_1 = \frac{1}{2}(a^L - y)^2 = \frac{1}{2}(0.82 - 0)^2 \approx 0.334.$$

Est-ce que la descente de gradient s'effectuera efficacement? Pour y voir, calculons d'abord la dérivée partielle suivante

$$\frac{\partial C}{\partial w} = \frac{\partial}{\partial w}\left(\frac{1}{2}(y(x) - \sigma(wx + b)\right)^2 = (y(x) - \sigma(z)) \cdot \sigma'(z) \cdot z'.$$

On a donc

$$\frac{\partial C}{\partial w} = (a - y) \cdot x \cdot \sigma'(z).$$

En remplaçant avec $x = 1$ et $y = 0$ et via un calcul similaire, on obtient finalement

$$\frac{\partial C}{\partial w} = a\sigma'(z), \quad \frac{\partial C}{\partial b} = a\sigma'(z).$$

Or, rappelons-nous du graphe de la fonction sigmoïde

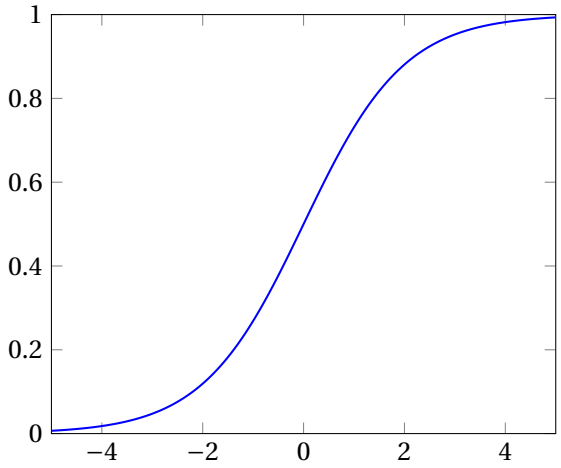

Ainsi, quand $a = \sigma(z)$ est grand, i.e. C est grand, alors $\sigma'(z)$ est petit et donc *une grande erreur implique ici un apprentissage lent*! Pourtant, on voudrait bien le contraire, car c'est lorsque l'erreur est grande que l'apprentissage devrait être efficace, rapide.

Exemple 3.1
Calculons ici explicitement la dérivée de la fonction sigmoïde.

$$\sigma'(z) = (-1)(1+e^{-z})^{-2} \cdot (1+e^{-z})' = \frac{e^{-z}}{(1+e^{-z})^2} = \frac{e^{-z}}{1+e^{-z}}\sigma(z).$$

3.2 Entropie croisée

L'objectif de cette section est de résoudre le problème rencontré précédemment en introduisant une nouvelle fonction de coût qui sera telle que l'apprentissage est efficace lorsque l'erreur est grande. On considère maintenant le réseau suivant.

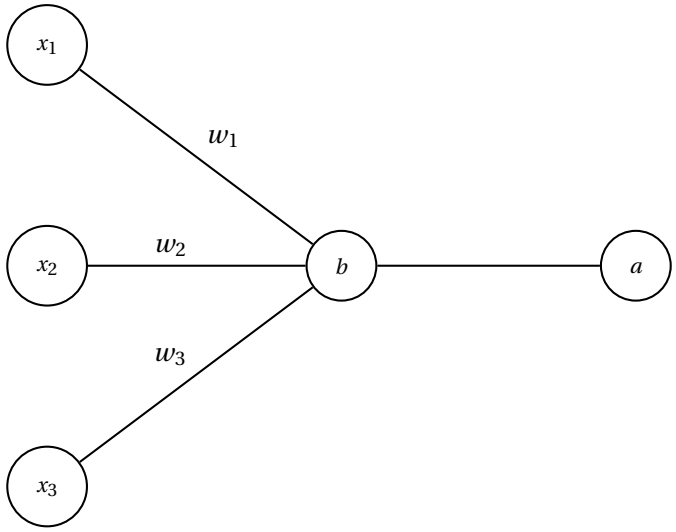

La préactivation est donc calculée par

$$z = \left(\sum_{i=1}^{3} w_i x_i\right) + b$$

et $a = \sigma(z)$, où σ est toujours la sigmoïde.

Définition 3.1 : Entropie croisée

La fonction de coût d'**entropie-croisée** est définie par

$$C = -\frac{1}{n}\sum_x y\ln(a) + (1-y)\ln(1-a),$$

où

- x : données d'entrées,
- n : nombre de données d'entrées,
- a : la sortie produite par le réseau pour la une donnée d'entrée (i.e. $a = a(x)$),
- y : la sortie désirée pour x.

Exemple 3.2

Montrons que la fonction de coût d'entropie-croisée est non-négative. On commence par remarquer que puisque $0 < a < 1$, on a aussi $0 < 1-a < 1$ et donc que les quantités $\ln(a)$ et $\ln(1-a)$ sont négatives. De plus, y et $1-y$ sont positifs et donc les termes $y\ln(a)$ et $(1-y)\ln(1-a)$ sont négatifs et $C > 0$.

Voyons voir si cette fonction d'entropie-croisée une bonne fonction d'erreur. On suppose d'abord que $a \approx 0$ et que $y = 0$. En se concentrant sur une seule donnée x, on a $n = 1$ et on remarque que

$$\begin{aligned} C &= -\frac{1}{n}\sum_x y\ln(a) + (1-y)\ln(a) \\ &= -y\ln(a) - (1-y)\ln(1-a) \approx 0. \end{aligned}$$

Un raisonnement similaire tient également lorsque $a \approx 1$ et $y = 1$. Ainsi, lorsque le réseau produit une réponse proche de celle qui est désirée, l'erreur est minime. Supposons maintenant que le réseau fait très mal son travail, par exemple $a \to 0^+$ et $y = 1$. On a alors

$$C = -y\ln(a) - (1-y)\ln(1-a) \to \infty.$$

Donc, si $a \approx y$, le coût (ou l'erreur) est bas et il est élevé lorsque a diffère substantiellement de y, ce qui rend raisonnable l'usage de l'entropie-croisée comme fonction d'erreur. Ceci dit, est-ce que cette fonction est meilleure que la fonction d'erreur quadratique qui causait le problème d'apprentissage de la section précédente? Pour y voir plus clair, on pose $y = y(x)$, $a = \sigma(z)$ et on calcule les dérivées partielles suivantes

$$\begin{aligned} \frac{\partial C}{\partial w_j} &= \frac{\partial}{\partial w_j}\left(-\frac{1}{n}\sum_x y\ln(a) + (1-y)\ln(1-a)\right) \\ &= -\frac{1}{n}\sum_x y\frac{1}{\sigma(z)}\sigma'(z)x_j + (1-y)\frac{1}{1-\sigma(z)}(-\sigma'(z))x_j \\ &= -\frac{1}{n}\sum_x \frac{y(1-\sigma(z))\sigma'(z)x_j}{\sigma(z)(1-\sigma(z))} - \frac{(1-y)\sigma(z)\sigma'(z)x_j}{\sigma(z)(1-\sigma(z))} \\ &= -\frac{1}{n}\sum_x \left(\frac{y - y\sigma(z) - \sigma(z) + y\sigma(z)}{\sigma(z)(1-\sigma(z))}\right)\sigma'(z)x_j \\ &= \frac{1}{n}\sum_x \frac{\sigma'(z)x_j}{\sigma(z)(1-\sigma(z))}(\sigma(z) - y). \end{aligned}$$

De plus, on sait que, si $\sigma(z) = \dfrac{1}{1+e^{-z}}$, alors $\sigma'(z) = \dfrac{e^{-z}}{1+e^{-z}}$. Or,

$$(1-\sigma(z)) = 1 - \frac{1}{1+e^{-z}} = \frac{1+e^{-z}-1}{1+e^{-z}} = \frac{e^{-z}}{1+e^{-z}}.$$

On obtient ainsi la relation

$$\sigma'(z) = (1-\sigma(z))\sigma(z).$$

et on a donc finalement

$$\frac{\partial C}{\partial w_j} = \frac{1}{n}\sum_x x_j(\sigma(z) - y).$$

Le taux d'apprentissage du poids w_j est donc contrôlé par la quantité $(\sigma(z) - y)$. Ainsi, plus large est l'erreur, plus vite on apprend, ce qui est une propriété désirable!En particulier, on évite également le problème d'apprentissage causé par $\sigma'(z)$ décrit dans la section précédente.

3.3 Initialisation et problèmes d'apprentissage : théorèmes de Hanin

On considère un réseau ReLU, c'est-à-dire un réseau où la fonction d'activation est $\sigma(z) = \max(0, z)$ avec des couches de largeur d_j; $j = 1, 2, ..., L$ et dont les poids et les biais sont initialisés *aléatoirement*

$$\begin{cases} w_{jk}^{\ell} \sim W_{\ell}, \\ b_j^{\ell} \sim B_{\ell}, \end{cases} \tag{3.1}$$

où W_ℓ et B_ℓ sont des densités de probabilité. On remarque au passage que si les paramètres w, b sont aléatoires, alors le réseau lui-même devient une fonction aléatoire.

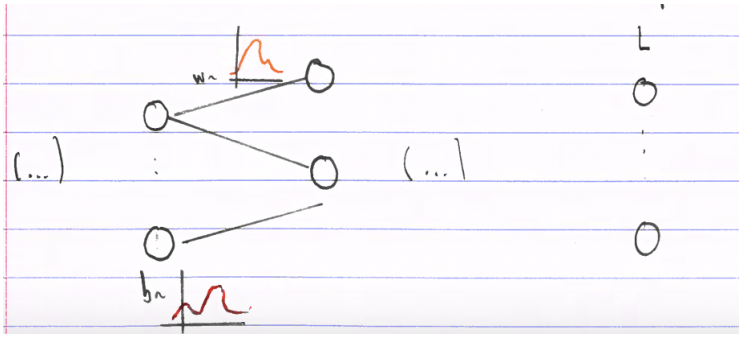

Les paramètres d'un réseau sont échantillonés à partir de distributions aléatoires.

On notera aussi $a^{\ell} = \begin{pmatrix} a_1^{\ell} \\ \vdots \\ a_{d_\ell}^{\ell} \end{pmatrix}$ le vecteur des activations de la couche ℓ.

Définition 3.2 : Activation moyenne

L'**activation moyenne** (normalisée) M_ℓ de la couche ℓ est donnée par

$$M_\ell = \frac{1}{d_\ell} ||a^{\ell}||^2.$$

Exemple 3.3

On considère la seconde couche d'un réseau de neurones suivante.

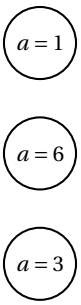

Elle correspond au vecteur d'activation $a^2 = \begin{pmatrix} 1 \\ 6 \\ 3 \end{pmatrix}$, avec $d_2 = 3$ et $||a^2||^2 = (1^2 + 6^2 + 3^2) = 46$. Donc,

l'activation moyenne de la couche 2 de ce réseau est

$$M_2 = \frac{1}{d_2}||a^2||^2 = \frac{1}{3}\cdot 46 \approx 15,3.$$

La question qui nous occupera pour le reste de ce chapitre est la suivante: que se passe-t-il avec l'apprentissage du réseau si M_L devient de plus en plus petit (ou grand) au fur et à mesure que L augmente?

Définition 3.3 : Échec d'apprentissage du 1er type (EA1)

On définit l'**échec d'apprentissage du 1er type** par

L'activation moyenne M_L de la dernière couche augmente ou diminue exponentiellement avec la profondeur L du réseau.

On suppose ici que l'entrée $x \in \mathbb{R}^{d_1}$ est fixée. La motivation derrière cette dernière définition est la suivante: si on peut trouver une manière efficace d'éviter (EA1), on devrait alors pouvoir entraîner un réseau profond aussi facilement qu'un réseau peu profond.

Théorème 3.1 : (EA1) Hanin, Rolnick (2018)

L'espérance $\mathbb{E}(M_L)$ de l'activation moyenne de la dernière couche est égale à la norme $||x||$ de l'entrée si

i. W_ℓ et B_ℓ sont des distributions symétriques.

ii. Les variables aléatoires w^ℓ_{jk} et b^ℓ_j sont indépendantes.

iii. Les variances des distributions W_ℓ et B_ℓ satisfont

$$\text{Var}(W_\ell) = \text{Var}(B_\ell) = \frac{2}{\text{fan-in}} = \frac{2}{d_{\ell-1}}.$$

On appellera donc le *fan-in* d'un poids ou d'un biais associé à une couche ℓ la taille $d_{\ell-1}$ de la couche précédente.Notons au passage que si ces variances sont plus élevées, alors $\mathbb{E}(M_L)$ croîtra exponentiellement avec L tandis que c'est la diminution qui sera exponentielle dans le cas où les variances sont inférieures au seuil crucial de $\frac{2}{d_{\ell-1}}$. On rappelle également que deux variables aléatoires X et Y sont *indépendantes* si

$$P(X = x \text{ et } Y = y) = P(X = x)\cdot P(Y = y)$$

pour tout choix de réalisations x et y. Finalement, on calcule la variance d'une variable aléatoire X par

$$\text{Var}(X) = \mathbb{E}\left[(X - \mathbb{E}(X))^2\right] = \mathbb{E}(X^2) - (\mathbb{E}(X))^2.$$

Chapitre 4

Universalité et puissance expressive

On sait qu'un réseau de neurones est une fonction $\mathscr{F} : \mathbb{R}_1^d \to \mathbb{R}^{d_L}$. Est-il raisonnable d'espérer que celui-ci puisse approximer une fonction modèle f ? Autrement dit, quelle est la puissance expressive théorique d'un réseau de neurones ? Ce sont les questions auxquelles nous allons nous consacrer dans ce chapitre.

4.1 La question de l'universalité

On considère un réseau de neurones comme celui-ci :

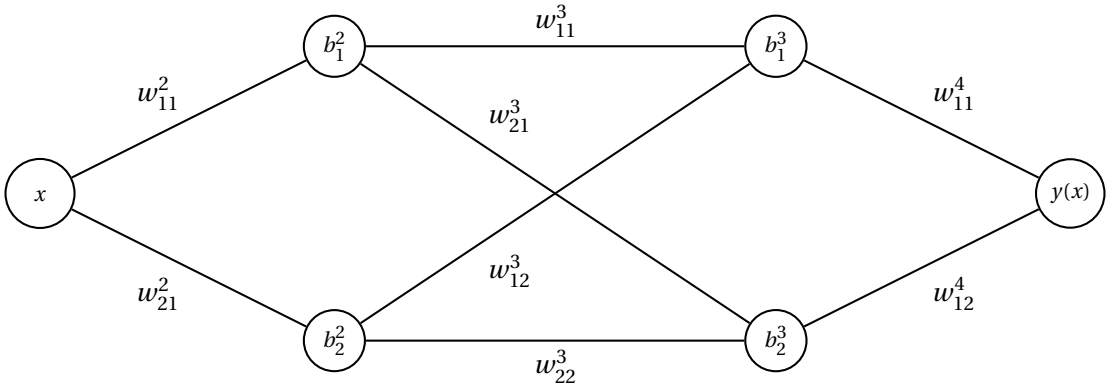

De manière générale, un réseau de neurones est une fonction $f : \mathbb{R}^m \to \mathbb{R}^n$, avec $m = d_1$ et $n = d_L$, où les nombres $\{d_1, d_2, ..., d_L\}$ donnent la *largeur* de chaque couche. Une interrogation naturelle est celle de l'*universalité* de ces réseaux de neurones :

« Étant donnée une fonction idéale ou naturelle f^*,
existe-t-il un réseau de neurones f tel que $f \approx f^*$? »

4.2 Le théorème de Cybenko

Définition 4.1 : Espace de fonctions continues

Soit $X \subset \mathbb{R}^n$. Alors, $C^0(X)$ est l'espace contenant les fonctions

$$f : X \to \mathbb{R}$$

qui sont partout continues.

On considère maintenant l'ensemble

$$S = \{G(x) = \sum_{j=1}^{D} \alpha_j \sigma(w^j \cdot x + b_j) : w^j \in \mathbb{R}^n;\ \alpha_j, \beta_j \in \mathbb{R}\},$$

où $x \in \mathbb{R}^n$. Les éléments $G(x) \in S$ correspondent aux réseaux

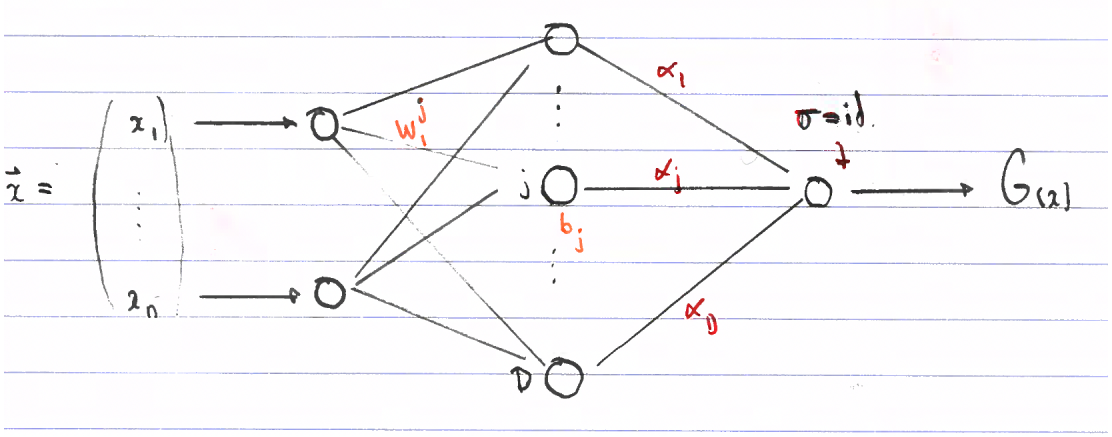

Ici, les w^j sont les vecteurs contenant tous les poids qui entrent dans le $j-$ème neurone de la couche profonde. Donc, les $G(x)$ sont des réseaux de

$$\mathbb{R}^n \to \mathbb{R}$$

avec une seule couche cachée de largeur (ou dimension) D et sans activation à la sortie.

Définition 4.2 : Hypercube unité

L'**hypercube unité** I^n de dimension n est l'ensemble

$$I^n = [0,1]^n \subset \mathbb{R}^n.$$

On généralise désormais la classe de fonctions d'activation qui ressemblent à la sigmoïde employée dans les chapitres précédents.

Définition 4.3 : Activations sigmoïdales

Une fonction d'activation

$$\sigma : \mathbb{R} \to \mathbb{R}$$

est **sigmoïdale** si

$$\sigma(x) \to \begin{cases} 0 & \text{si } x \to -\infty, \\ 1 & \text{si } x \to \infty. \end{cases}$$

Exemple 4.1

On se rappelle la définition de l'activation sigmoïde

$$\sigma(z) = \frac{1}{1+e^{-z}}.$$

Alors, $\lim_{z\to-\infty} \sigma(z) = 0$ et $\lim_{z\to\infty} \sigma(z) = 1$. Donc, σ est sigmoïdale.

Le théorème suivant fournit une réponse claire à la question de l'universalité posée au début de ce chapitre.

Théorème 4.1 : Cybenko (1989)

Soit σ une fonction d'activation sigmoïdale continue. Alors, l'ensemble S est *dense* dans $C^0(I^n)$. Autrement dit, pour tout $f^* \in C^0(I^n)$ et pour tout $\epsilon > 0$, il existe

$$G(x) = \sum_{j=1}^{D} \alpha_j \sigma(w^j \cdot x + b_j)$$

tel que

$$\sup_{x\in I^n} |G(x) - f^*(x)| < \epsilon.$$

La quantité

$$||G - f||_{L^\infty} = \sup_{x\in I^n} |G(x) - f^*(x)|$$

mesure l'erreur ponctuelle d'approximation de f^* par G en $x \in I^n$. On peut ainsi voir $\epsilon > 0$ comme le seuil de tolérance à l'erreur de notre approximation. C'est donc dire que l'on peut approximer n'importe quelle fonction continue f^* avec un seuil de précision ϵ arbitrairement petit, par un réseau qui contient une seule couche cachée. C'est ce que l'on veut dire par *universalité* des réseaux de neurones.

4.3 Heuristique de l'universalité

On présente dans cette section les principales idées derrière une preuve d'un théorème d'universalité comme celui de Cybenko. Le principe général est d'approximer une fonction compliquée par des objets plus simples. On considère

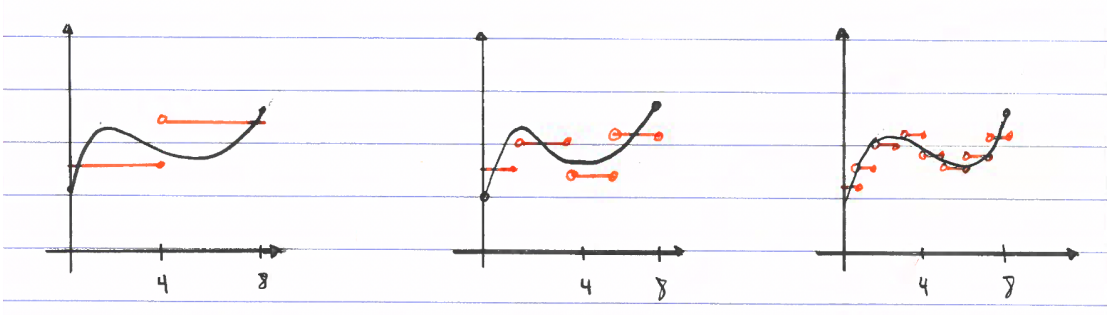

Ces fonctions « escaliers » sont constantes par morceaux et on les appelle des fonctions *simples*.

Définition 4.4 : Fonctions indicatrices, simples

- Soit $(a,b) \in \mathbb{R}$ un intervalle. La **fonction indicatrice** de l'intervalle (a,b) est définie par

$$\chi_{(a,b)} = \begin{cases} 1 & \text{si } x \in (a,b), \\ 0 & \text{sinon.} \end{cases} \tag{4.1}$$

- Une fonction **simple** est une fonction qui peut s'écrire sous la forme

$$s(x) = \sum_{i=1}^{n} \alpha_i \chi_{(a,b)}.$$

Il s'avère qu'en prenant suffisamment de morceaux, c'est-à-dire en laissant n devenir assez grand dans la définition précédente, on peut estimer avec une précision arbitrairement grande les fonctions continues par les fonctions simples.

Théorème 4.2 : Densité des fonctions simples

Les fonctions simples sont denses dans $L^p(I^n) \subseteq C^0(I^n)$.

Il s'agit maintenant de voir si les réseaux $G(x)$ du théorème de Cybenko peuvent produire de telles fonctions simples. Pour le reste de cette section, on fixe $\sigma(x) = \frac{1}{1+e^{-x}}$. On considère les graphes de $\sigma(x)$ et $\sigma(100x)$.

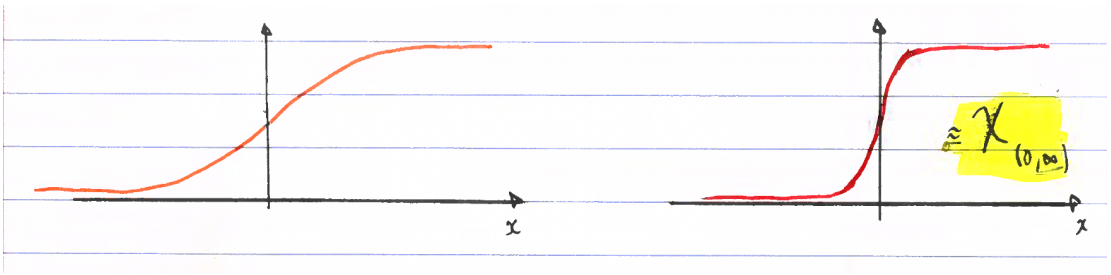

On remarque que le graphe de $\sigma(100x)$ ressemble à celui de la fonction indicatrice de l'intervalle $(0,\infty)$. Ainsi, on peut par exemple considérer $\sigma(100x - 10000)$

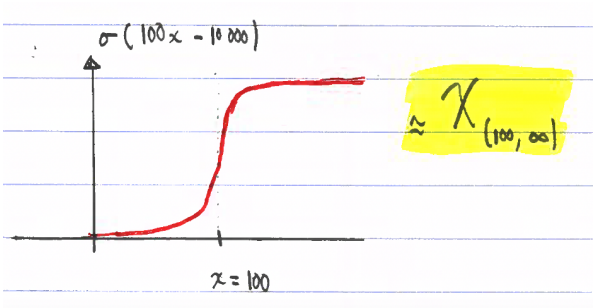

De manière générale, pour λ suffisamment grand, on a

$$\sigma(\lambda x + \beta) \approx \chi_{(a,\infty)},$$

avec $a = -\frac{\beta}{\lambda}$. De plus, on remarque que

$$\chi_{(a,b)} = \chi_{(a,\infty)} - \chi_{(b,\infty)}.$$

Donc, les combinaisons linéaires des $\sigma(\lambda x + \beta)$ engendrent les fonctions simples. Or, ces combinaisons linéaires sont précisément les $G(x)$ des réseaux du théorème de Cybenko! En effet, ces combinaisons linéaires sont de la forme

$$G(x) = \sum_{i=1}^{N} \alpha_i \sigma(\lambda x + \beta).$$

Quelques remarques et questions en terminant pour compléter notre discussion sur la puissance expressive.

- Nous n'avons fait aucun usage de la profondeur ici : les réseaux du théorème de Cybenko ont $L = 3$ et $d_2 = N = N(\epsilon)$ grand! En fait, typiquement on aura

  $$N(\epsilon) \to \infty$$

  quand $\epsilon \to 0$.

- Nos « blocs lego » de construction sont des fonctions simples. Pourrait-on utiliser la profondeur des réseaux de neurones pour construire des « blocs lego » plus flexibles ?

- Est-ce que la profondeur sert vraiment ? Comment, avec un nombre fini de neurones, concevoir le « meilleur » réseau ?

La figure suivante présente deux paradigmes généraux d'architecture pour les réseaux de neurones, soit respectivement les modes *wide and shallow* et *deep and narrow*.

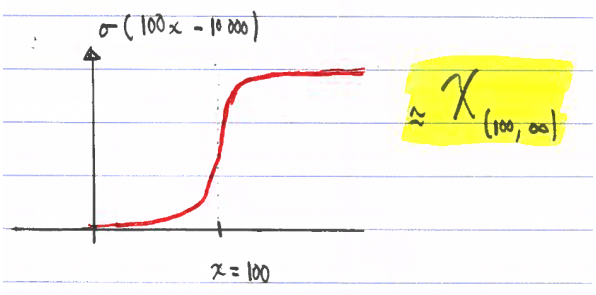

Chapitre 5

Rôle de la profondeur dans la puissance expressive

On a vu dans le chapitre précédent que les réseaux de neurones étaient des approximateurs universels. Or, pour établir cet important constat, aucun usage de la profondeur n'a été. Est-il donc avantageux de disposer des neurones en couches successives plutôt que de les superposer dans une seule couche large? L'objectif de ce chapitre est de clarifier la portée de l'usage de la profondeur dans les réseaux de neurones.

5.1 Une section en dents de scie

On rappelle le sous-espace vectoriel composé des réseaux de neurones du théorème de Cybenko

$$S = \{G(x) = \sum_{j=1}^{D} \alpha_j \sigma(w^j \cdot x + b_j) : w^j \in \mathbb{R}^n; \alpha_j, \beta_j \in \mathbb{R}\}$$

et où $x \in \mathbb{R}^n$. Nous savons par le théorème de Cybenko que S est dense dans l'espace des fonctions continues. Or, ces réseaux sont très peu profonds: ils ont une seule couche cachée. Est-ce que la profondeur sert vraiment? Pour explorer cette question, on définit l'ensemble $\mathscr{R}(L, D; \sigma)$ comme celui contenant tous les réseaux de neurones de profondeur L, de largeur maximal D et activés par σ. Soit aussi la fonction $m : [0,1] \to \mathbb{R}$ définie par

$$m(x) = \begin{cases} 2x & \text{si } 0 \leq x \leq \frac{1}{2}, \\ 2-2x & \text{si } \frac{1}{2} \leq x \leq 1. \end{cases}$$

Existe-t-il un réseau de neurones capable de calculer exactement la fonction $m(x)$?

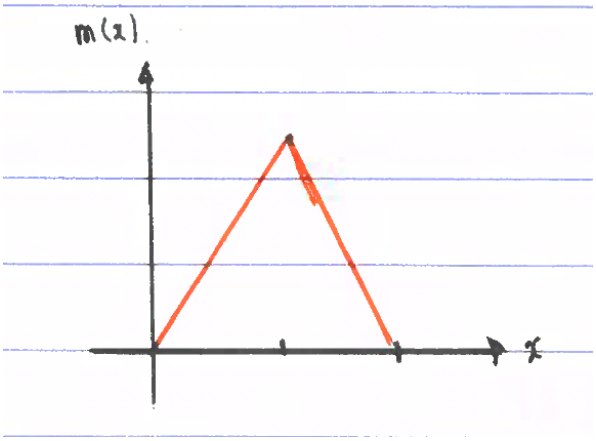

On fixe $\sigma = \text{ReLU}$. Alors, on a

$$2\sigma(x) = \begin{cases} 2x & \text{si } 0x \geq 0, \\ 0 & \text{si } x \leq 0. \end{cases}$$

De plus,

$$\sigma\left(x - \frac{1}{2}\right) = \begin{cases} x - \frac{1}{2} & \text{si } x \geq \frac{1}{2}, \\ 0 & \text{sinon.} \end{cases}$$

Aussi,

$$-4\sigma\left(x - \frac{1}{2}\right) = \begin{cases} 2 - 4x - \frac{1}{2} & \text{si } x \geq \frac{1}{2}, \\ 0 & \text{sinon.} \end{cases}$$

Ainsi,

$$2\sigma(x) - 4\sigma\left(x - \frac{1}{2}\right) = \begin{cases} 0 & \text{si} x \leq 0, \\ 2x & \text{si } 0 \leq x \leq \frac{1}{2}, \\ 2 - 2x & \text{si } x \geq \frac{1}{2}. \end{cases}$$

Donc,

$$m(x) = \sigma\left(2\sigma(x) - 4\sigma\left(x - \frac{1}{2}\right)\right),$$

ce qui correspond au réseau suivant.

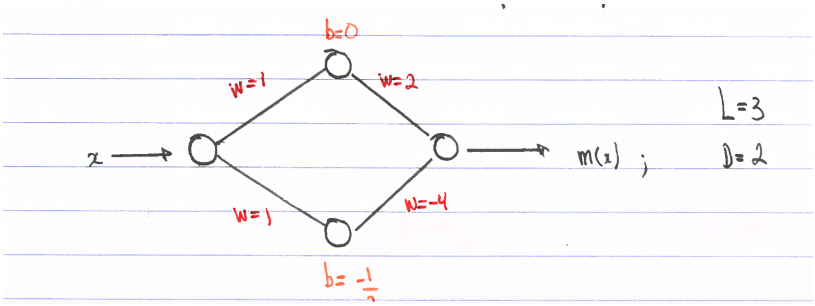

Que se passe-t-il si on rend le réseau plus profond ?

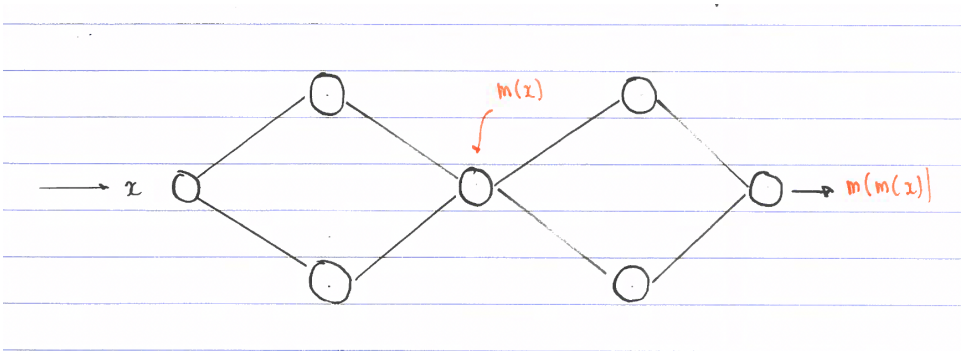

Graphiquement, on remarque donc que la composition produit plus de dents de scie.

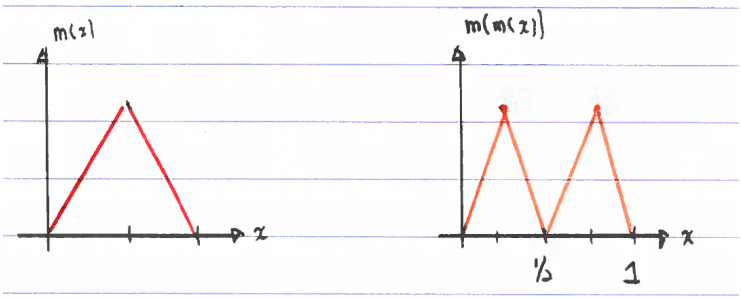

De manière similaire, on peut aussi considérer la composition $m^{(3)}(x) = m(m(m(x)))$.

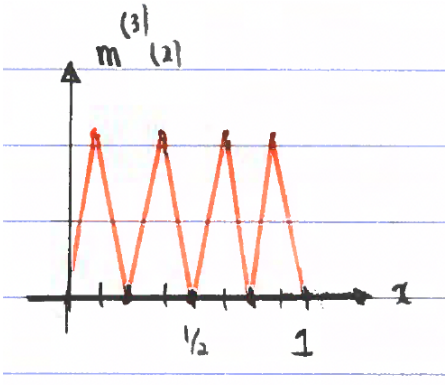

La relation entre l'ordre de la composition et le nombre de pics produits sur le graphe est décrite dans le tableau suivant.

n	Nombre de neurones dans le réseau de $m^{(n)}$	Nombre de pics produits
1	$4 = 3+1$	1
2	$7 = 2\cdot 2+1$	2
3	$10 = 3\cdot 2+1$	4
$\vdots$		
n	$3n+1$	2^{n-1}

En général, le réseau associé à la composition d'ordre n, c'est-à-dire à $m^{(n)(x)}$ produit donc 2^{n-1} oscillations avec

$$\begin{cases} L = 2n+1 \text{ couches}, \ D = 2, \\ 3n+1 \text{neurones}, \\ O(n) \text{ paramètres}. \end{cases}$$

Et si on disposait nos $3n+1$ neurones à la manière des réseaux du théorème de Cybenko, soit en largeur sur une seule couche profonde ? Autrement dit, considérons plutôt

$$g_n \in \mathscr{R}(L=3, D=3n; \sigma),$$

où

$$g_n(x) = \sum_{j=1}^{3n} \alpha_j \sigma(w^j \cdot x + b_j).$$

Les réseaux g_n utilisent le même nombre de neurones que ceux qui représentent $m^{(n)}(x)$ et il est naturel de se demander laquelle des deux configurations est la plus avantageuse pour la puissance expressive. On veut donc comparer le rôle de la composition à celui de l'additivité.

5.2 Additivité vs. composition

Définition 5.1 : Fonction α-linéaire par morceaux.

Une fonction f est α **linéaire par morceaux** (α-lpm) si elle est linéaire par morceaux avec *au plus* α morceaux.

Exemple 5.1

La fonction ReLU est clairement $2-lpm$ tandis que $m^{(n)}(x)$ est $(2^n+2)-lpm$.

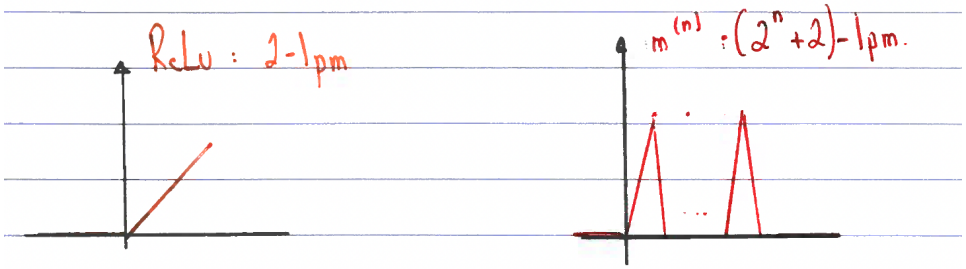

Le résultat suivant précise les effets respectifs de l'addition et de la composition sur la linéarité par morceaux.

Théorème 5.1

Soit f une fonction α-lpm et g une fonction β-lpm. Alors,

i. $(f+g)$ est $(a+b)$-lpm.

ii. $(f \circ g)$ est (ab)-lpm.

Comme corollaire, on obtient donc immédiatement les faits suivants :

- $m^{(n)}(x)$ est 2^n-lpm.
- $g \in \mathscr{R}(L=3; D=3n; \sigma = \text{ReLU})$ est $6n$-lpm.

On voit donc ici toute la portée de la composition dans la puissance expressive. En effet, si par exemple $n=100$, alors le réseau profond $m^{(100)}(x)$ peut créer jusqu'à 2^{100} morceaux tandis que celui peu profond à la Cybenko ne peut qu'en créer 600.

5.3 Théorème de séparation de Telgarsky

Le but de cette section est de préciser davantage la différence de la portée des réseaux profonds par rapport à ceux qui ne le sont pas. Pour ce faire, nous utiliserons une tâche de classification qui permettra de mesurer les performances de différents réseaux.

Définition 5.2 : Problème de n-classification

Le **problème de classification de n points**, aussi appelé **problème de n-classification** est le suivant. On considère 2^n points $(x_i, y_i) \in \mathbb{R}^2$, avec $x_i \in [0, 1-2^{-n}]$ et $y_i = 0, 1, 0, 1...$

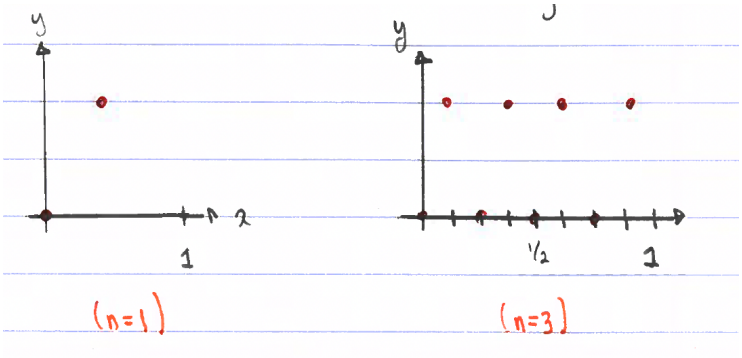

Pour $f : [0,1] \to \mathbb{R}$, on considère la discrétisation $\tilde{f}$ de l'image de f, définie par

$$\tilde{f}(x) = \begin{cases} 1 & \text{si } f(x) \geq \frac{1}{2}, \\ 0 & \text{si } f(x) < \frac{1}{2}. \end{cases}$$

L'**erreur** $E(f)$ d'une fonction f au test de n-classification est alors donnée par

$$E(f) = \frac{1}{2^n} \sum_i \chi\left\{\tilde{f}(x_i) \neq y_i\right\},$$

où $\chi\left\{\tilde{f}(x_i) \neq y_i\right\}$ vaut 1 quand f a échoué à classer correctement le point x_i et 0 dans le cas contraire.

On peut voir $E(f)$ comme la proportion de points mal classés par f au problème de n-classification. On remarque d'emblée que $E(m^{(n)}(x)) = 0$.

Théorème 5.2 : Telgarsky (2016)

Soit $g \in \mathscr{R}(L, D; \sigma)$ avec $D < 2^{\frac{n-1}{L-1}}$. Alors,

$$E(g) > \frac{1}{6}.$$

Ce résultat tranche de manière définitive le débat entre les réseaux à la Cybenko et ceux disposés en profondeur. En effet, si on force le réseau g à avoir $L = 3$ couches (Cybenko), alors il faut $D \geq 2^{\frac{n-1}{2}}$ pour pouvoir espérer approcher les performances de $m^{(n)}$ au test de n-classification. On dit donc que la profondeur *sépare* le pouvoir expressif des réseaux de neurones.

Chapitre 6

Introduction à l'apprentissage profond géométrique

On a vu comment les réseaux de neurones pouvaient apprendre à classer des images représentant des chiffres manuscrits. L'objectif de ce chapitre est de présenter une manière de faire apprendre des réseaux de neurones lorsque les données ne sont pas représentées sous forme de grille.

6.1 Réseaux de convolution et classification d'images

L'approche la plus simple pour la tâche de classification d'images et de prendre le *bitmap* représentant une image et de l'aplatir en vecteur colonne pour le fournir en entrée à un réseau dont la première couche contient autant de neurones que l'image a de pixels. Est-ce la meilleure approche ?

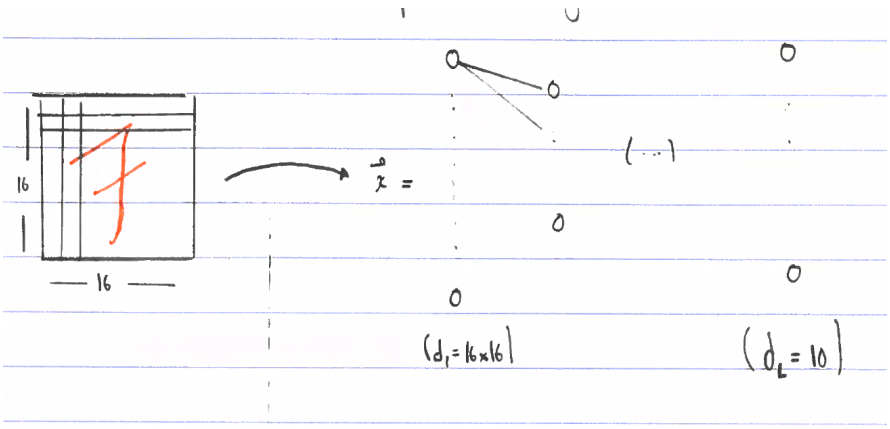

On voudrait construire un réseau qui tient compte de deux aspects de notre tâche :

- Invariance sous translation : « *une voiture est une voiture, peu importe où elle est placée dans l'image.* »

- Localité : « *les pixels proches ont tendance à se ressembler.* »

Comment, par exemple, reconnaître une roue ? On utilise un *filtre* ou *noyau* qui va balayer l'image et donner à chaque position un score de ressemblance.

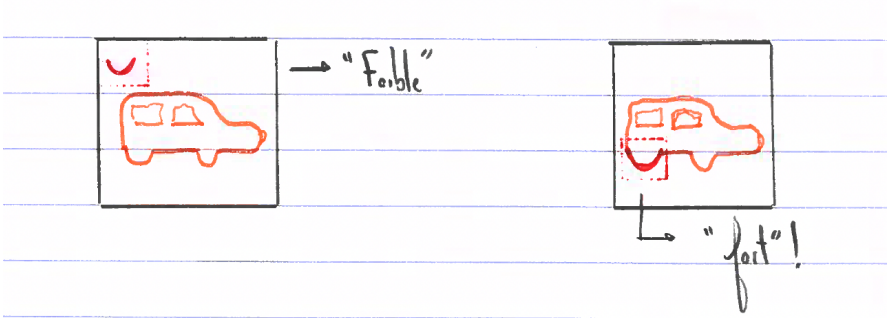

C'est cette idée qui est à la base des réseaux dits de *convolution*. On rappelle d'abord que, puisque

$$\vec{u} \cdot \vec{v} = ||\vec{u}|| \cdot ||\vec{v}|| \cos\theta,$$

le produit scalaire peut être interprété comme une mesure de similarité entre deux vecteurs $\vec{u}$, $\vec{v}$. On dira qu'une *couche convolutionnelle* C_Γ agit de la manière suivante.

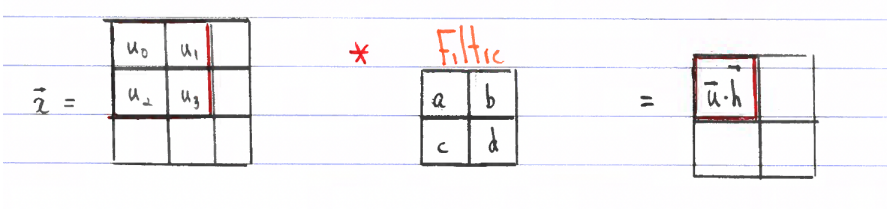

Ici, $\vec{u} = (u_0, u_1, u_2, u_3)^T$ est une sous-grille de l'image x et $\vec{h} = (a, b, c, d)^T$ est un filtre. Précisons maintenant certains termes utilisés avec cette méthode.

- *Stride:* incrément de balayage du filtre.
- *Padding:* rajout artificiel de lignes/colonnes au bord pour préserver la dimension.

Pourquoi le nom *convolution*? On rappelle que la convolution discrète de deux signaux u et h est définie par

$$(u * h)(n) = \sum_{k=-\infty}^{\infty} u(k)h(n-k) = \sum_{k=0}^{3} u(k)h(n-k),$$

car $u(k) = 0$ dès que $k < 0$ ou $k > 3$. Par exemple,

$$(u * h)(3) = u_0 d + u_1 c + u_2 b + u_3 a$$

et donc la convolution telle que définie plus haut correspond au produit scalaire de u avec une rotation du filtre h. On fera également usage d'une couche dite de *pooling*. Une telle couche P agit pour réduire la dimension de la manière suivante.

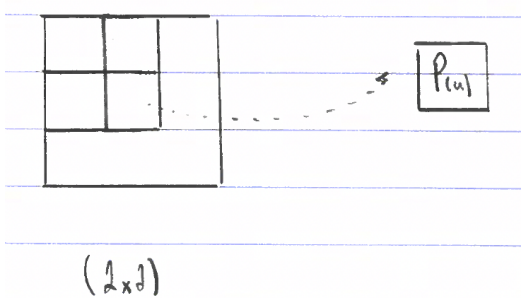

Ici, $P(u) = \max u_0, u_1, u_2, u_3$.

Définition 6.1 : Réseau de convolution

Un **réseau de convolution** U_θ est un réseau de la forme

$$U_\theta = \mathrm{FC} \circ \left(C_{\Gamma^{(*)}} \circ P \circ \ldots \circ P \circ C_{\Gamma^{(1)}}\right),$$

où une couche convolutionnelle $g = C_\Gamma(x)$ agit sur une entrée p-dimensionnelle $x = (x_1, x_2, \ldots, x_p)$ en appliquant une banque de **filtres**

$$\Gamma = \left(h_{\ell,\ell'}\right),$$

avec $\ell = 1, \ldots, q$ et $\ell' = 1, \ldots, p$.

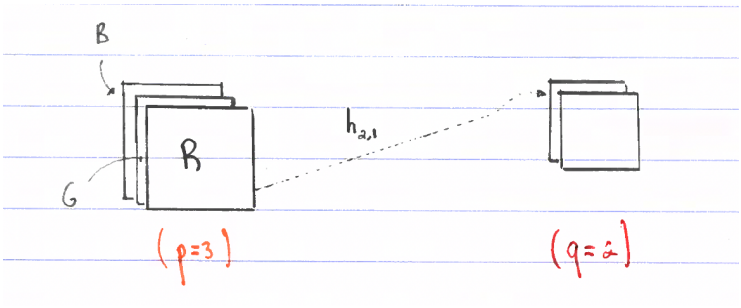

Il est naturel de maintenant se questionner sur la possibilité de définir un tel réseau de convolution lorsque les données d'entrée ne sont pas organisées en grille, comme c'est le cas par exemple avec un graphe ou une variété. Ce sera notre objectif pour la suite de ce chapitre.

6.2 Préliminaires mathématiques

Soit E un espace vectoriel sur $\mathbb{R}$ euclidien et donc muni d'un produit scalaire et soit $\{e_1, e_2, \ldots, e_n\}$ une base orthonormale (ONB) de E. Alors, pour tout $u \in E$, il existe $\alpha_1, \ldots, \alpha_n \in \mathbb{R}$ tels que

$$u = \sum_{i=1}^{n} \alpha_i e_i$$

et

$$(u, e_i) = \alpha_i.$$

On rappelle maintenant le théorème spectral vu au chapitre I.

Théorème 6.1 : Théorème spectral

Soit A une matrice symétrique. Alors, il existe une base orthonormale de vecteurs propres de A et on peut écrire

$$D = Q^{-1} A Q$$

où $Q \in O(n)$ est une matrice orthogonale.

Soit maintenant $X \subset \mathbb{R}^n$ compact (i.e. fermé et borné) et

$$L^2(X) = \left\{ f : X \to \mathbb{R} \text{ telles que } \int_X f^2 dV < \infty \right\}$$

l'espace des fonctions de carré intégrable sur X.

Définition 6.2 : Laplacien euclidien

Le **laplacien** est l'opérateur différentiel

$$\Delta : L^2(X) \to L^2(X)$$

défini par

$$\Delta = -\text{div}\,\nabla = \sum_{i=1}^{n} \frac{\partial^2}{\partial x_i^2}.$$

Théorème 6.2 : Hilbert-Schmidt

Il existe une base orthonormale de $L^2(X)$ formée par les fonctions propres ϕ_i du laplacien.

Les fonctions propres satisfont

$$\Delta\phi_i = \lambda_i \phi_i,\ i = 1, 2...$$

et on a alors que pour toute fonction $u \in L^2(X)$,

$$u = \sum_i \alpha_i \phi_i,$$

avec

$$(\phi_i, \phi_j) = \int_X \phi_i \phi_j dV = \delta_{ij}$$

et

$$0 \leq \lambda_1 \leq \lambda_2 \leq ... \nearrow \infty.$$

On rappelle désormais brièvement certains éléments de la théorie de Fourier. On remarque d'abord que

$$\Delta\left(e^{-2\pi i\xi t}\right) = -\frac{\partial^2}{\partial t^2}\left(e^{-2\pi i\xi t}\right) = -(-2\pi i\xi)^2\left(e^{-2\pi i\xi t}\right) = (4\pi^2\xi^2)e^{-2\pi i\xi t}.$$

Ainsi, les fonctions $e^{-2\pi i\xi t}$ sont des fonctions propres du laplacien sur $\mathbb{R}$.

Définition 6.3 : Transformée de Fourier et transformée inverse

- La **transformée de Fourier** d'une fonction f est donnée par

$$\hat{f}(\xi) = \mathscr{F}(f)(\xi) = \int_{\mathbb{R}} f(t) e^{2\pi i\xi t} dt = \left(f, e^{-2\pi i\xi t}\right).$$

- La **transformée de Fourier inverse** d'une fonction $\hat{f}$ est donnée par

$$f(x) = \mathscr{F}^{-1}(\hat{f})(x) = \int_{\mathbb{R}} f(t) e^{-2\pi i\xi t} dt = \left(f, e^{-2\pi i\xi t}\right).$$

On remarque donc qu'on peut définir une théorie de Fourier à partir d'un produit scalaire et des fonctions propres du laplacien. Cette idée nous guidera dans la construction d'une théorie similaire sur des graphes.

Théorème 6.3 : Convolution

Soit f, g deux fonctions. Alors,

$$\mathscr{F}(f * g) = \hat{f} \cdot \hat{g}.$$

Conséquemment,

$$f * h = \mathscr{F}^{-1}\left(\hat{f} \cdot \hat{g}\right).$$

À nouveau, on remarque que l'on peut donc définir la convolution à partir d'une théorie de Fourier.

6.3 Introduction à la théorie spectrale des graphes

On considère un graphe $G = (V, E, W)$ connexe et non-orienté. Ici, V est l'ensemble des sommets, E l'ensemble des arêtes et W est une matrice d'adjacence pondérée.

Définition 6.4 : Fonction sur un graphe

Une fonction sur g est une application

$$f : V \to \mathbb{R},$$

que l'on peut voir comme un vecteur $f \in \mathbb{R}^n$ où $n = |V|$.

Exemple 6.1

On considère le graphe suivant :

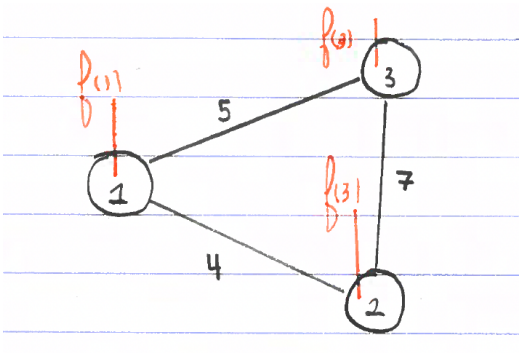

Ici, $V = \{1,2,3\}$, $W = \begin{pmatrix} 0 & 4 & 5 \\ 4 & 0 & 7 \\ 5 & 7 & 0 \end{pmatrix}$ et $W = W^T$.

Quand les arêtes n'ont pas de poids, (par exemple si G est le squelette d'une surface tridimensionnelle), on peut considérer un seuil K.

- *Noyaux gaussiens :*

$$W_{i,j} = \begin{cases} \exp\left(\frac{-d^2(i,j)}{2\theta^2}\right) & \text{si } d(i,j) \leq K, \\ 0 \quad \text{sinon.} \end{cases}$$

- *K plus proches voisins :*

$$W_{i,j} = \begin{cases} 1 & \text{si } d(i,j) \leq K, \\ 0 & \text{sinon.} \end{cases}$$

Il faut maintenant développer une théorie spectrale du laplacien Δ sur G.

Définition 6.5 : Théorie spectrale du laplacien sur un graphe

- *g-gradient :*

$$\nabla : L^2(V) \to L^2(E)$$
$$(\nabla f)_{ij} = \big(f(i) - f(j)\big).$$

- *g-divergence :*

$$\operatorname{div} : L^2(E) \to L^2(V)$$
$$(\operatorname{div} F)_i = \sum_{j:(i,j)\in E} W_{ij} F_{ij}.$$

- *g-laplacien :*

$$\Delta : L^2(V) \to L^2(V); \quad \Delta = -\operatorname{div} \nabla$$
$$(\Delta f)_i = \sum_{j:(i,j)\in E} W_{ij}(f(i) - f(j)).$$

Puisque $L^2(V) = \mathbb{R}^n$, Δ est une matrice que l'on peut écrire

$$\Delta = D - W,$$

où

$$D = \operatorname{diag}\big(\deg(1), ..., \deg(n)\big)$$

et $\deg(i) = \sum_j W_{ij}$. Ainsi, Δ est symétrique et, en vertu du théorème spectral, il existe

$$\Phi = \{\varphi_1, ..., \varphi_n\}$$

une base orthonormale de $\mathbb{R}^n$ telle que

$$\Delta\varphi_i = \lambda_i \varphi_i$$

et

$$0 \leq \lambda_1 \leq ... \leq \lambda_n.$$

Par analogie avec le laplacien usuel, nous sommes désormais en mesure de construire une graphe théorie de Fourier.

Définition 6.6 : Théorie de Fourier sur un graphe

- *g-Transformée de Fourier :*

$$\mathscr{F}(f) = \hat{f}(\lambda_k) = (f, \varphi_k) = \sum_{i=1}^{n} f(i)\bar{\varphi_k}(i).$$

  En notation matricielle, on obtient

$$\hat{f} = \Phi^T f.$$

- *g-Transformée de Fourier inverse :*

$$\mathscr{F}^{-1}(\hat{f}) = f(i) = \sum_{k=1}^{n} \hat{f}(\lambda_k)\varphi_k(i).$$

  En notation matricielle, on obtient

$$f = \Phi \hat{f}.$$

Et nous voilà capable d'enfin définir la convolution sur un graphe.

Définition 6.7 : Convolution sur un graphe

La convolution de deux signaux $f, h \in L^2(V)$ est définie par

$$(f * h) = \mathscr{F}^{-1}(\hat{f} \cdot \hat{g}),$$

c'est-à-dire

$$(f * h)(i) = \sum_{k=1}^{n} \hat{f}(\lambda_k)\hat{h}(\lambda_k)\varphi_k(i),$$

que l'on peut écrire matriciellement par

$$(f * h) = \left(\Phi \cdot \mathrm{diag}(\hat{h}(\lambda_1), ..., \hat{h}(\lambda_n) \cdot \Phi^T\right).$$

Chapitre 7

Réduction spectrale de la dimension

Les données d'entrées fournies à un réseau de neurones habitent typiquement dans un espace de dimension très élevée. Elles se logent par contre pas de manière uniforme dans cet espace et il est souhaite de vouloir réduire la dimension dans lesquelles elles existent, notamment pour des raisons d'efficacité. Dans ce chapitre, nous verrons différentes techniques pour tenter de réduire la dimension des données d'entrée.

7.1 L'hypothèse de la variété

On considère encore une fois la tâche de classification de chiffres manuscrits de la base de données MNIST. Après aplatissement, une image de cette banque de données est un point $x \in \mathbb{R}^{28\times 28} = \mathbb{R}^{784}$. Est-ce que c'est vraiment l'espace dans lequel vivent ces images ?

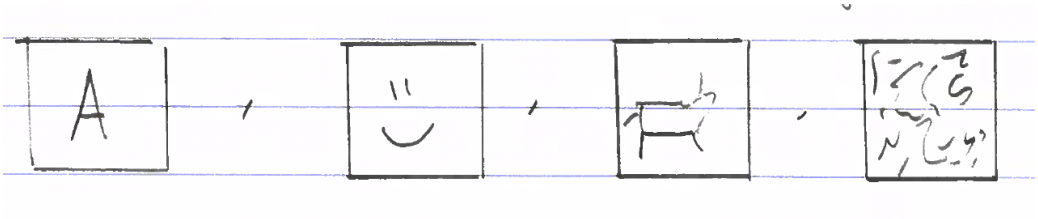

L'*hypothèse de la variété* stipule la chose suivante :

> « *Les données de haute dimension sont disposées sur une variété de basse dimension, qui est plongée dans l'espace de haute dimension.* »

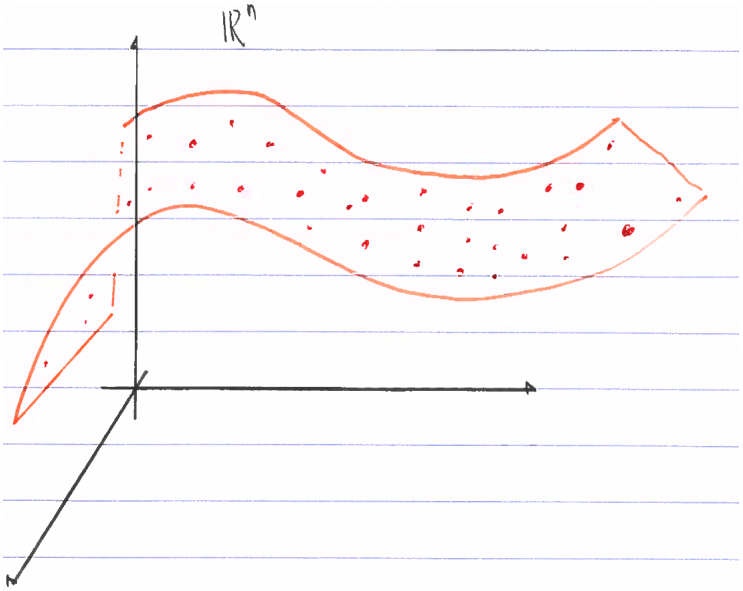

7.2 Variétés

Définition 7.1

- Une **variété** M^n de dimension n est un collage lisse de morceaux ressemblant à $\mathbb{R}^n$.

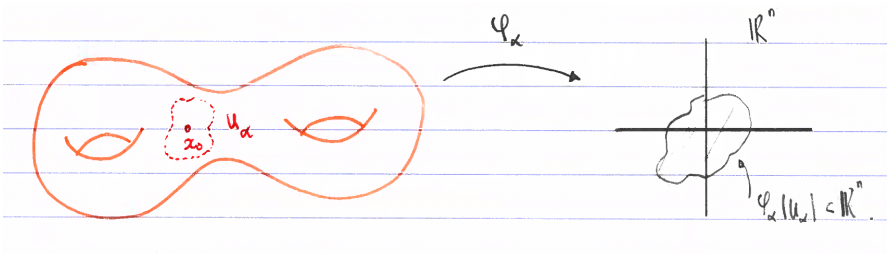

- Les **cartes de coordonnées** sont des applications

$$\varphi_\alpha : U_\alpha \subset M \to \mathbb{R}^n,$$

qui permettent de donner des coordonnées à tout point $p \in M$.

Si les fonctions de transition entre les cartes de coordonnées sont suffisamment régulières, on peut faire du calcul sur ces variétés : dérivées directionnelles, plan tangent etc. Si on équipe M d'une *métrique riemannienne*, on peut alors construire l'opérateur de Laplace-Beltrami

$$\Delta_g : C^\infty(M) \to C^\infty(M),$$

lequel donne lieu à des modes propres, c'est-à-dire des paires de fonctions et valeurs propres qui satisfont l'équation

$$\Delta_g \varphi_\lambda = \lambda \varphi_\lambda.$$

Si M est compacte, alors le spectre $\sigma(\Delta_g)$ est discret et composé d'une suite infinie de valeurs propres

$$0 \leq \lambda_0 \leq \lambda_1 \leq \ldots \nearrow \infty.$$

On veut montrer en quoi les fonctions propres de Δ_g permettent un plongement

$$\begin{aligned} \Pi_k : M &\to \mathbb{R}^k \\ x &\mapsto (\varphi_1(x), \ldots, \varphi_k(x)). \end{aligned}$$

7.3 Analyse en composantes principales

On débute en explorant la *caractérisation variationnelle des valeurs propres*. Soit $A = A^T$ une matrice symétrique de dimension n. Alors, il existe

$$\Phi = \{\varphi_1, \ldots, \varphi_n\}$$

une base orthonormale de vecteurs propres de A. Aussi, pour $u \in \mathbb{R}^n$, on

$$u = \sum_{i=1}^{n} \alpha_i \varphi_i$$

et

$$Au = \sum_{i=1}^{n} \lambda_i \alpha_i \phi_i.$$

Définition 7.2 : Quotient de Rayleigh

Le **quotient de Rayleigh** de $u \in \mathbb{R}^n$ est défini par

$$\mathscr{R}_A(u) = \frac{(Au, u)}{(u, u)} = \frac{u^T Au}{u^T u}.$$

Si $||u|| = 1$, on a donc $u^T u = 1$ et

$$\mathscr{R}_A(u) = (Au, u) = \left(\sum_{i=1}^{n} \lambda_i \alpha_i \phi_i, \sum_{i=1}^{n} \alpha_i \varphi_i \right) = \sum_{i=1}^{n} \lambda_i \alpha_i^2,$$

avec $\sum_{i=1}^{n} \alpha_i^2 = 1$.

Donc,

$$\arg \max_{u, ||u||=1} \mathscr{R}_A(u) = \phi_n,$$

le vecteur propre associé à λ_n et

$$\arg \min_{u, ||u||=1} \mathscr{R}_A(u) = \phi_1,$$

le vecteur propre associé à λ_1.

On considère maintenant un nuage de points $\{x^{(1)}, \ldots, x^{(k)}\} \subset \mathbb{R}^n$. Quelle est la direction (unitaire) $\tilde{w}$ le long de laquelle la variance est maximale? Pour ce faire, on voudrait maximiser

$$\sum_{i=1}^{k} \left(x^{(i)} \cdot w \right)^2 = ||Xw||^2,$$

où X est la matrice dont les k rangées sont les $x^{(i)}$ du nuage de points. On remarque aussi que $X^T X$ est symétrique

$$(X^T X)^T = X^T (X^T)^T = X^T X.$$

On a donc

$$\tilde{w} = \arg \max_{w:||w||=1} w^T (X^T X) w = \arg \max_{w:||w||=1} R_{X^T X}(w)$$

qui est donc le vecteur propre correspondant à la valeur propre la plus élevée de $X^T X$. On pose $w^{(1)} := \tilde{w}$ que l'on appelle *composante principale* du nuage de points. On peut continuer et trouver

$$w^{(1)}, w^{(2)}, ..., w^{(n)}$$

composantes principales (i.e. vecteurs propres de $X^T X$) et réduire la dimension via les projections

$$\begin{aligned} \Pi_k : &\mathbb{R}^n \to \mathbb{R}^m \\ &x \mapsto \text{proj}_{\text{sp}\{w^{(1)},...,w^{(n)}\}} x \end{aligned}$$

Cela revient à écrire un point $x \in \mathbb{R}^n$ du nuage de points dans la base des vecteurs propres de $X^T X$ et de considérer les m premières coordonnées.

7.4 Réduction spectrale de la dimension

On débute avec un exemple qui va nous permettre d'illustrer la stratégie générale que nous allons employer dans cette section dont l'objectif est d'utiliser la théorie spectrale du laplacien pour définir un plongement de réduction de dimension. On pourra ensuite démontrer que ce plongement est optimal selon une certaine métrique naturelle.

Exemple 7.1

On considère 4 points x_1, x_2, x_3 et x_4 quelconques dans $\mathbb{R}^n$. Avec ces points, nous formons un graphe $\mathcal{G}$. On discutera par la suite des détails de la construction de ce graphe.

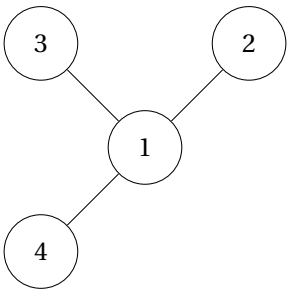

On peut ensuite créer les matrices W des poids et $D = \text{diag}\{\deg(1), \deg(2), \deg(3), \deg(4)\}$ des degrés associés à ce graphe. On a donc

$$W = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \end{bmatrix}, \quad D = \begin{bmatrix} 3 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}.$$

Le *g-laplacien* Δ sur $\mathcal{G}$ est donné par

$$\Delta = D - W.$$

On considère maintenant le problème aux valeurs propres généralisé suivant

$$\Delta\varphi = \lambda\varphi.$$

On calcule aisément les valeurs propres

$$\lambda_0 = 0, \lambda_1 = \lambda_2 = 1, \lambda_3 = 2.$$

Si on exclut le premier vecteur propre constant associé à la valeur propre nulle, un vecteur propre associé à la première valeur propre non-nulle λ_1 est

$$\varphi_1 = \begin{pmatrix} 0 \\ -3 \\ 1 \\ 2 \end{pmatrix}.$$

On peut l'utiliser pour opérer une réduction de la dimension de $d = 4$ vers $d = 1$ en associant nos points initiaux $x_1, ..., x_4$ à des points dans $\mathbb{R}$:

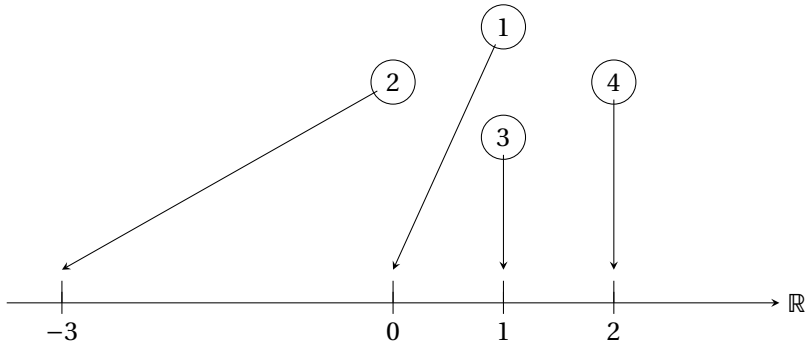

La stratégie générale suivra celle de cet exemple, c'est-à-dire que nous allons créer un graphe à partir d'un nuage de points pour ensuite utiliser la théorie spectrale sur ce graphe afin d'envoyer les points vers un espace de dimension inférieur en utilisant les vecteurs propres du laplacien. On peut déjà se demander: pourquoi est-ce pertinent de choisir cette manière de faire?

7.4.1 L'algorithme de Belkin-Niyogi

Soit un nuage de points $x_1, x_2, ..., x_k$ dans $\mathbb{R}^n$. On veut d'abord construire un graphe pondéré $\mathcal{G} = (V, \mathcal{E}, W)$ associé à ce nuage de points. Évidemment, ce graphe aura un sommet par point du nuage et on a donc $V = \{1, 2, ..., k\}$.

I. CHOIX D'UNE FONCTION DISTANCE.

On veut ici connecter par une arête les sommets qui sont « proches. » Deux approches principales possibles:

- n plus proches voisins.
- On fixe $\epsilon > 0$ et on connecte si $||x_i - x_j|| < \epsilon$.

II. ASSIGNATION DES POIDS.

On peut procéder de manière binaire ou alors en utilisant la méthode dite des noyaux de la chaleur.

- $W_{ij} = 1$ si $(i, j) \in \mathscr{E}$
- Noyaux de la chaleur au temps $t > 0$:

$$W_{ij} = exp(-||x_i - x_j||^2 / t).$$

III. CALCUL DES MODES PROPRES.

On considère l'équation aux valeurs propres normalisées

$$\Delta\varphi = \lambda D\varphi.$$

On obtient une suite de valeurs propres

$$0 = \lambda_0 \leq \lambda_1 \leq ..\lambda_{n-1} = 2.$$

Pour $m < n$, on définit la projection

$$\begin{aligned} \Pi_m : \mathbb{R}^n &\to \mathbb{R}^m \\ x_i &\mapsto (\varphi_1(i), ..., \varphi_m(i)). \end{aligned}$$

On exclut la fonction propre $\varphi_0 \equiv cst$.

7.4.2 Optimalité de la projection spectrale

On considère le cas $m = 1$. On a un graphe $G = (V, \mathscr{E}, W)$, avec $|V| = n$. Soit

$$y = (y_1, y_2, ..., y_k)$$

la sortie de la projection spectrale.On pose la fonction de coût

$$C(y) = \frac{1}{2}\sum_{i,j}(y_i - y_j)^2 W_{ij}.$$

On remarque donc qu'il y a une grosse pénalité lorsque W_{ij} est gros, c'est-à-dire que les points initiaux sont proches et que $(y_i - y_j)^2$ est également gros, ce qui correspond au fait que les projections

correspondantes sont éloignées et donc que la transformation n'a pas préservé le voisinage.

On considère maintenant $y^T \Delta y = y^T (D - W) y$. D'une part, on a

$$D = \text{diag}\left(\sum_j W_{1j}, .., W_{nj} \right)$$

et donc

$$Dy = \text{diag}\left(\sum_j y_1 W_{1j}, .., y_n W_{nj} \right).$$

Ainsi

$$y^T Dy = \sum_{i,j} y_i^2 W_{ij} = \frac{1}{2} \sum_{i,j} y_i^2 W_{ij} + \frac{1}{2} \sum_{i,j} y_j^2 W_{ij}.$$

D'autre part,

$$Wy = \begin{pmatrix} -w_1- \\ -w_2- \\ \cdots \\ -w_n- \end{pmatrix} y = \begin{pmatrix} \sum_j W_{1j} y_j \\ \sum_j W_{2j} y_j \\ \cdots \\ \sum_j W_{nj} y_j \end{pmatrix},$$

de sorte que

$$y^T Wy = \sum_{i,j} y_i y_j W_{ij} = \frac{1}{2} \sum 2 y_i y_j W_{ij}.$$

Donc

$$\mathscr{R}_\Delta(y) = y^T \Delta y = C(y).$$

Ainsi,

$$\arg\min_{||u||=1} C(y) = \varphi_1,$$

soit le premier vecteur propre non-nul de Δ.

Rédigé par Guillaume Roy-Fortin,
2021-2025,
Département des enseignements généraux,
École de technologie supérieure.

Ce document est mis à disposition selon les termes de la licence Creative Commons Attribution - Pas d'Utilisation Commerciale - Pas de Modification 4.0 International.

1.2 Exercices avec solutions

École de technologie supérieure
Service des enseignements généraux
Local B-2500 514-396-8938
Site internet : `http://www.etsmtl.ca/`

MTI881
ASPECTS MATHÉMATIQUES DE L'APPRENTISSAGE PROFOND

SOLUTIONS DES EXERCICES

RÉDIGÉES PAR
GUILLAUME ROY-FORTIN

HIVER 2024

Ce document est mis à disposition selon les termes de la licence Creative Commons Attribution - Pas d'Utilisation Commerciale - Pas de Modification 4.0 International.

Table des matières

1 RAPPELS D'ALGÈBRE LINÉAIRE ET DE CALCUL DIFFÉRENTIEL 2

2 RÉSEAUX DE NEURONES PROFONDS 12

3 PROBLÈMES D'APPRENTISSAGE 17

4 UNIVERSALITÉ ET PUISSANCE EXPRESSIVE 22

5 RÔLE DE LA PROFONDEUR DANS LA PUISSANCE EXPRESSIVE 25

6 INTRODUCTION À L'APPRENTISSAGE PROFOND GÉOMÉTRIQUE 28

7 RÉDUCTION SPECTRALE DE LA DIMENSION 40

8 AUTOENCODEURS VARIATIONNELS 48

1 RAPPELS D'ALGÈBRE LINÉAIRE ET DE CALCUL DIFFÉRENTIEL

Exercice 1.1. Soit $\mathbf{u} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \mathbf{v} = \begin{pmatrix} -1 \\ 1 \end{pmatrix}$ et $\mathbf{w} = \begin{pmatrix} 0 \\ 2 \end{pmatrix}$ des vecteurs de $\mathbb{R}^2$ ainsi que $\mathbf{a} = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}, \mathbf{b} = \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix}$ des vecteurs de $\mathbb{R}^3$. On considère aussi $k \in \mathbb{R}$ un scalaire. Calculez le résultat des opérations suivantes et expliquez, le cas échéant, pourquoi celles-ci ne sont pas définies.

a. $3\mathbf{u} - 2\mathbf{v} + \mathbf{w}$

$$3\mathbf{u} - 2\mathbf{v} + \mathbf{w} = 3\begin{pmatrix} 2 \\ 1 \end{pmatrix} - 2\begin{pmatrix} -1 \\ 1 \end{pmatrix} + \begin{pmatrix} 0 \\ 2 \end{pmatrix} = \begin{pmatrix} 6 \\ 3 \end{pmatrix} - \begin{pmatrix} -2 \\ 2 \end{pmatrix} + \begin{pmatrix} 0 \\ 2 \end{pmatrix} = \begin{pmatrix} 8 \\ 3 \end{pmatrix}.$$

b. $(\mathbf{u}, \mathbf{u}) + (\mathbf{u}, \mathbf{v})$

$$(\mathbf{u}, \mathbf{u}) + (\mathbf{u}, \mathbf{v}) = 2 \cdot 2 + 1 \cdot 1 + 2(-1) + 1 \cdot 1 = 4.$$

c. $||\mathbf{u}||$

$$||\mathbf{u}|| = \sqrt{(\mathbf{u}, \mathbf{u})} = \sqrt{2^2 + 1^2} = \sqrt{5}.$$

d. $3 + \mathbf{w}$

Cette opération n'est pas définie puisque $\mathbf{w}$ *est un vecteur de* $\mathbb{R}^2$ *et* 3 *un scalaire.*

e. $\mathbf{z} = \dfrac{1}{||\mathbf{w}||}\mathbf{w}$

On calcule d'abord

$$||\mathbf{w}|| = \sqrt{(\mathbf{w}, \mathbf{w})}\sqrt{0^2 + 2^2} = 2.$$

Ainsi,

$$\mathbf{z} = \frac{1}{||\mathbf{w}||}\mathbf{w} = \frac{1}{2}\begin{pmatrix} 0 \\ 2 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}.$$

f. $||\mathbf{z}||$

$$||\mathbf{z}|| = \sqrt{(\mathbf{z},\mathbf{z})} = \sqrt{0^2+1^2} = 1.$$

On remarque donc que l'opération précédente a permis de normaliser le vecteur $\mathbf{z}$.

Exercice 1.2. Quelle est la valeur de l'angle θ entre les vecteurs $\mathbf{a}$ et $\mathbf{b}$ de l'exercice précédent ?

On sait que l'angle aigu θ *entre* $\mathbf{a}$ *et* $\mathbf{b}$ *satisfait*

$$(\mathbf{a},\mathbf{b}) = ||\mathbf{a}|| \cdot ||\mathbf{b}|| \cos\theta.$$

On calcule donc respectivement

- $||\mathbf{a}|| = \sqrt{0^2+1^2+0^2} = 1$
- $||\mathbf{b}|| = \sqrt{0^2+1^2+1^2} = \sqrt{2}$
- $(\mathbf{a},\mathbf{b}) = 1$

Ainsi, on a

$$\theta = \arccos\left(\frac{1}{\sqrt{2}}\right) = \frac{\pi}{4}.$$

Exercice 1.3. Soit $\mathbf{u} \in \mathbb{R}^m$ et on pose $\mathbf{n} = \frac{1}{||\mathbf{u}||}\mathbf{u}$. Montrer que $||\mathbf{n}|| = 1$.

En utilisant les propriétés du produit scalaire et de la norme, on obtient directement

$$(\mathbf{n},\mathbf{n}) = \left(\frac{1}{||\mathbf{u}||}\mathbf{u}, \frac{1}{||\mathbf{u}||}\mathbf{u}\right) = \frac{1}{||\mathbf{u}||^2}(\mathbf{u},\mathbf{u}) = \frac{||\mathbf{u}||^2}{||\mathbf{u}||^2} = 1.$$

Exercice 1.4. Soit $\mathfrak{B} = \{\mathbf{u_1}, \mathbf{u_2}\}$ une base de $\mathbb{R}^2$ avec $\mathbf{u_1} = \begin{pmatrix}1\\1\end{pmatrix}$ et $\mathbf{u_2} = \begin{pmatrix}-1\\2\end{pmatrix}$. Exprimez chacun des vecteurs suivants comme combinaison linéaire des vecteurs de cette base.

$$\mathbf{a} = \begin{pmatrix}-3\\-3\end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix}0\\3\end{pmatrix} \text{ et } \quad \mathbf{c} = \begin{pmatrix}3\\0\end{pmatrix}.$$

On considère la matrice $A = (\mathbf{u_1}\ \mathbf{u_2})$ dont les colonnes sont les vecteurs de la base $\mathfrak{B}$. Les coordonnées d'un vecteur $\mathbf{b} \in \mathbb{R}^2$ dans cette base sont les coefficients de la combinaison linéaire de ces colonnes qui génère $\mathbf{b}$. Autrement dit, on peut les obtenir en solutionnant l'équation matricielle $A\mathbf{x} = \mathbf{b}$.

On calcule d'abord la matrice inverse de A, soit manuellement ou à l'aide de la TI. On obtient

$$A^{-1} = \begin{bmatrix} \frac{2}{3} & \frac{1}{3} \\ -\frac{1}{3} & \frac{1}{3} \end{bmatrix}$$

On obtient les coordonnées en multipliant les vecteurs fournis par l'inverse. Par exemple,

$$A^{-1}\mathbf{a} = \begin{pmatrix} -3 \\ 0 \end{pmatrix}$$

et on vérifie aisément que $\mathbf{a} = -3\mathbf{u_1}$. On écrit alors

$$(\mathbf{a})_{\mathfrak{B}} = \begin{pmatrix} -3 \\ 0 \end{pmatrix}.$$

De manière tout à fait similaire, on obtient enfin

$$(\mathbf{b})_{\mathfrak{B}} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad (\mathbf{c})_{\mathfrak{B}} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}.$$

Exercice 1.5. Soit $T : \mathbb{R}^2 \to \mathbb{R}^2$ la transformation donnée par $T(x, y) = (3x + y, 2x - 5y)$. Montrer que T est une transformation linéaire.

Soit $\mathbf{u}, \mathbf{v} \in \mathbb{R}^2$ *ainsi que des scalaires* $\alpha, \beta \in \mathbb{R}$, *avec* $\mathbf{u} = \begin{pmatrix} u_1 \\ u_2 \end{pmatrix}$ *et* $\mathbf{v} = \begin{pmatrix} v_1 \\ v_2 \end{pmatrix}$. *Alors,*

$$\alpha\mathbf{u} + \beta\mathbf{v} = \begin{pmatrix} \alpha u_1 + \beta v_1 \\ \alpha u_2 + \beta v_2 \end{pmatrix}.$$

Ainsi,

$$\begin{aligned} T(\alpha\mathbf{u} + \beta\mathbf{v}) &= (3x + y, 2x - 5y) \\ &= (3(\alpha u_1 + \beta v_1) + \alpha u_2 + \beta v_2, 2(\alpha u_1 + \beta v_1) - 5(\alpha u_2 + \beta v_2)) \\ &= \alpha T(\mathbf{u}) + \beta T(\mathbf{v}). \end{aligned}$$

Remarquons que nous aurions également pu fournir la matrice canonique de T *dont les colonnes sont l'image par la transformation* T *des vecteurs* $\{\mathbf{e_1}, \mathbf{e_2}\}$ *de la base canonique de* $\mathbb{R}^2$ *et vérifier que la transformation correspond bel et bien à la multiplication d'un vecteur par celle-ci.*

Exercice 1.6. Soit les matrices

$$A = \begin{pmatrix} 1 & -1 & 0 \\ 1 & 0 & 2 \end{pmatrix}, \; B = \begin{pmatrix} 1 & 2 \\ 0 & -1 \\ 1 & 3 \end{pmatrix} \text{ et } C = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$$

ainsi que les vecteurs $\mathbf{u} = \begin{pmatrix} 1 \\ 2 \end{pmatrix} \in \mathbb{R}^2$ et $\mathbf{v} = \begin{pmatrix} 1 \\ 0 \\ -2 \end{pmatrix} \in \mathbb{R}^3$.

Calculez le résultat des opérations suivantes et expliquez, le cas échéant, pourquoi celles-ci ne sont pas définies.

a. $A\mathbf{u}$

La multiplication d'un vecteur par une matrice est définie si la dimension du vecteur coïncide avec le nombre de colonnes de la matrice, ce qui n'est pas le cas ici.

b. $A\mathbf{v}$

$$A\mathbf{v} = \begin{pmatrix} 1 & -1 & 0 \\ 1 & 0 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \\ -2 \end{pmatrix} = \begin{pmatrix} 1 \\ -3 \end{pmatrix}.$$

c. $B\mathbf{u}$

$$B\mathbf{u} = \begin{pmatrix} 1 & 2 \\ 0 & -1 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 3 \\ -2 \\ 7 \end{pmatrix}.$$

d. $A^T\mathbf{u}$

$$A^T\mathbf{u} = \begin{pmatrix} 1 & 1 \\ -1 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 3 \\ -1 \\ 4 \end{pmatrix}.$$

e. $A^T A$.

$$A^T A = \begin{pmatrix} 1 & 1 \\ -1 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 1 & -1 & 0 \\ 1 & 0 & 2 \end{pmatrix} = \begin{pmatrix} 2 & -1 & 2 \\ -1 & 1 & 0 \\ 2 & 0 & 4 \end{pmatrix}.$$

f. $C^T C$.

$$C^T C = \begin{pmatrix} a & c \\ b & d \end{pmatrix} \begin{pmatrix} a & b \\ c & d \end{pmatrix} = \begin{pmatrix} a^2+c^2 & ab+cd \\ ab+cd & b^2+d^2 \end{pmatrix}.$$

Exercice 1.7. Montrer que la matrice $A^{-1} = \begin{pmatrix} 1 & -1 \\ 0 & 1 \end{pmatrix}$ est l'inverse de la matrice $A = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$.

Il s'agit simplement de vérifier que $A \cdot A^{-1} = A^{-1} \cdot A = I_2$. On a effectivement

$$\begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & -1 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = I_2.$$

Exercice 1.8. Expliquez en vos mots la différence entre une transformation linéaire et une transformation affine.

Une transformation linéaire entre deux espaces vectoriels euclidiens en est une qui satisfait la propriété démontrée à l'exercice 1.5. De manière équivalente, elle peut être réalisée par la multiplication matricielle. Cela exclut donc tout translation non-nulle, puisqu'une transformation linéaire doit avoir $\mathbf{0}$ *comme point-fixe, autrement dit* $T(\mathbf{0}) = \mathbf{0}$.

Par ailleurs, une transformation affine W *est une transformation linéaire suivie d'une translation. On peut donc l'écrire de manière vectorielle comme*

$$W(\mathbf{x}) = A\mathbf{x} + \mathbf{b},$$

où A *est la matrice canonique de la partie linéaire de la transformation et* $\mathbf{b}$ *le vecteur de translation.*

Exercice 1.9. Soit la matrice de rotation

$$O_\theta = \begin{pmatrix} \cos\theta & \sin\theta \\ -\sin\theta & \cos\theta \end{pmatrix}.$$

Montrer que O_θ est une matrice orthogonale, pour tout $\theta \in [0, 2\pi)$.

On voudrait montrer que $O_\theta^T = O_\theta^{-1}$. *On calcule donc le produit*

$$\begin{aligned} O_\theta \cdot O_\theta^T &= \begin{pmatrix} \cos\theta & \sin\theta \\ -\sin\theta & \cos\theta \end{pmatrix} \begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix} \\ &= \begin{pmatrix} \cos^2\theta + \sin^2\theta & \sin\theta\cos\theta - \sin\theta\cos\theta \\ \sin\theta\cos\theta - \sin\theta\cos\theta & \cos^2\theta + \sin^2\theta \end{pmatrix} \\ &= \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = I_2. \end{aligned}$$

Exercice 1.10. Soit $A = \begin{pmatrix} 1 & -2 \\ -2 & 1 \end{pmatrix}$. Vérifier que A est symétrique et qu'elle satisfait au théorème spectral, c'est-à-dire qu'elle admet un base orthonormale $\mathfrak{B} = \{\mathbf{u_1}, \mathbf{u_2}\}$ de vecteurs propres.

Indication : vous pouvez faire appel à un logiciel de calcul symbolique (TI ou Wolfram, notamment) pour calculer les vecteurs propres de A. Ensuite, il s'agit de vérifier qu'il s'agit bien de vecteurs propres et qu'ils sont orthogonaux.

Exercice 1.11. Soit les fonctions suivantes

$$f(x) = \sin(x),\ g(x) = x^3 + 2x + 1 \text{ et } h(x) = \ln(2x).$$

a. Que vaut la composition $f \circ g$? Et $g \circ f$?

On a directement

$$(f \circ g)(x) = f(g(x)) = \sin(x^3 + 2x + 1)$$

et

$$(g \circ f) = g(f(x)) = \sin^3(x) + 2\sin(x) + 1.$$

b. Calculer la dérivée $(f \circ g)$'(x).

En vertu de la règle de la chaîne, on a

$$(f \circ g)'(x) = f'(g(x))g'(x) = \cos(x^3 + 2x + 1)(3x^2 + 2).$$

c. Calculer la dérivée $(g \circ f)$'(x).

Similairement au numéro précédent, on a

$$(g \circ f)'(x) = g'(f(x))f'(x) = (3\sin^2(x)+2)(\cos(x)) = 3\sin^2(x)\cos(x)+2\cos(x).$$

d. Calculer la dérivée $(h \circ g \circ f)$'(x).

Il est plus simple ici de définir directement la fonction obtenue par la double composition et de la dériver ensuite. Nommons là $w(x)$. On a

$$w(x) = (h \circ g \circ f)(x) = h(g(f(x))) = \ln(2(\sin^3(x) + 2\sin(x) + 1)).$$

En utilisant les propriétés du logarithme, le facteur constant $\ln 2$ *se détache et devient nul après la dérivation. On a ainsi*

$$w'(x) = \frac{3\sin^2(x)\cos(x) + 2\cos(x)}{\sin^3(x) + 2\sin(x) + 1}.$$

e. Calculer la dérivée $(h \circ f \circ g)$'(x).

En procédant de manière similaire, on pose

$$w(x) = h(f(g(x)) = \ln(2\sin(x^3+2x+1)).$$

On calcule ensuite

$$w'(x) = \frac{(3x^2+2)\cos(x^3+2x+1)}{\sin(x^3+2x+1)} = (3x^2+2)\cot(x^3+2x+1).$$

Exercice 1.12. Soit $x : \mathbb{R}^2 \to \mathbb{R}$ donnée par

$$x(u,v) = u^2 + 2v$$

et $y : \mathbb{R}^2 \to \mathbb{R}$ donnée par

$$y(u,v) = \sin(u+v).$$

Soit également $z : \mathbb{R}^2 \to \mathbb{R}$ une fonction de (x,y) donnée par

$$z(x,y) = (xy)^2 + x + 2y.$$

À l'aide de la règle de la chaîne, calculer les dérivées partielles suivantes :

$$\frac{\partial z}{\partial x}, \frac{\partial z}{\partial y}, \frac{\partial z}{\partial u}, \frac{\partial z}{\partial v}.$$

On calcule directement les dérivées partielles

$$\frac{\partial z}{\partial x} = 2xy^2 + 1, \quad \frac{\partial z}{\partial y} = 2x^2y + 2.$$

Aussi, en vertu de la règle de la chaîne en plusieurs variables, on a

$$\begin{aligned}\frac{\partial z}{\partial u} &= \frac{\partial z}{\partial x}\frac{\partial x}{\partial u} + \frac{\partial z}{\partial y}\frac{\partial y}{\partial u} \\ &= (2xy^2+1)2u + (2x^2y+2)\cos(u+v) \\ &= 2u\left[2(u^2+2v)\sin^2(u+v)+1\right] + \left[2(u^2+2v)^2\sin(u+v)+2\right]\cos(u+v).\end{aligned}$$

Pareillement,

$$\begin{aligned}\frac{\partial z}{\partial v} &= \frac{\partial z}{\partial x}\frac{\partial x}{\partial v} + \frac{\partial z}{\partial y}\frac{\partial y}{\partial v} \\ &= (2xy^2+1)\cdot 2 + (2x^2y+2)\cos(u+v) \\ &= 2\left[2(u^2+2v)\sin^2(u+v)+1\right] + \left[2(u^2+2v)^2\sin(u+v)+2\right]\cos(u+v).\end{aligned}$$

Exercice 1.13. Soit $x : \mathbb{R}^2 \to \mathbb{R}$ donnée par

$$x(u, v) = u + v^2$$

et $y : \mathbb{R}^2 \to \mathbb{R}$ donnée par

$$y(u, v) = -\cos(u + v).$$

Soit également $z : \mathbb{R}^2 \to \mathbb{R}$ une fonction de (x, y) donnée par

$$z(x, y) = x^2 y + 2x + y.$$

Enfin, on poste $u(t) = t^2$ et $v(t) = 2t$. À l'aide de la règle de la chaîne, calculer la dérivée totale $z'(t)$.

Cet exercice est très similaire au précédent dans sa première partie. On calcule d'abord directement les dérivées partielles

$$\frac{\partial z}{\partial x} = 2xy + 2, \quad \frac{\partial z}{\partial y} = x^2 + 1.$$

Aussi, en vertu de la règle de la chaîne en plusieurs variables, on a

$$\begin{aligned}\frac{\partial z}{\partial u} &= \frac{\partial z}{\partial x}\frac{\partial x}{\partial u} + \frac{\partial z}{\partial y}\frac{\partial y}{\partial u} \\ &= (2xy + 2)1 + (x^2 + 1)\sin(u + v) \\ &= 2u\left[2(u^2 + 2v)\sin^2(u + v) + 1\right] + \left[2(u^2 + 2v)^2 \sin(u + v) + 2\right]\cos(u + v).\end{aligned}$$

Pareillement,

$$\begin{aligned}\frac{\partial z}{\partial v} &= \frac{\partial z}{\partial x}\frac{\partial x}{\partial v} + \frac{\partial z}{\partial y}\frac{\partial y}{\partial v} \\ &= (2xy^2 + 1)\cdot 2 + (2x^2 y + 2)\cos(u + v) \\ &= 2\left[2(u^2 + 2v)\sin^2(u + v) + 1\right] + \left[2(u^2 + 2v)^2 \sin(u + v) + 2\right]\cos(u + v).\end{aligned}$$

Enfin, il s'agit de remarquer que

$$\begin{aligned}z'(t) &= \frac{\partial z}{\partial t} \\ &= \frac{\partial z}{\partial x}\frac{\partial x}{\partial u}\frac{\partial u}{\partial t} + \frac{\partial z}{\partial x}\frac{\partial x}{\partial v}\frac{\partial v}{\partial t} \\ &\quad + \frac{\partial z}{\partial y}\frac{\partial y}{\partial u}\frac{\partial u}{\partial t} + \frac{\partial z}{\partial y}\frac{\partial y}{\partial v}\frac{\partial v}{\partial t}.\end{aligned}$$

On remarque finalement que

$$u'(t) = 2t, \quad v'(t) = 2.$$

Exercice 1.14. On considère la fonction

$$f(x,y) = x^2 + y^2$$

et le point initial $x_0 = (3,-2) \in \mathbb{R}^2$. Complétez les 2 premières itérations d'une descente de gradient visant à converger vers le minimum local (et global) de f en $(0,0)$, avec le taux d'apprentissage fixé à $\eta = 1$.

La fonction donnée est $f(x,y) = x^2 + y^2$ dont le gradient est $\nabla f(x,y) = (2x,2y)$. Notre point initial quant à lui est $(6,-4)$ et le pas est fixé à $\frac{1}{4}$.

Les itérations de descente de gradient sont donc les suivantes :

1. *Point de départ $(6,-4)$. En ce point, on a $\nabla f(6,-4) = (12,-8)$. Notre second point est donc*

$$(6,-4) - \frac{1}{4}(12,-8) = (6,-4) - (3,-2) = (3,-2).$$

2. *Point de départ $(3,-2)$. En ce point, on a $\nabla f(3,-2) = (6,-4)$. Notre second point est donc*

$$(3,-2) - \frac{1}{4}(6,-4) = (3,-2) - (1.5,-1) = (1.5,-1).$$

On remarque bien qu'on se rapproche graduellement du minimum local (et absolu) situé à l'origine.

2 RÉSEAUX DE NEURONES PROFONDS

Exercice 2.1. Soit un réseau de neurones complètement connexe $\mathscr{F}$ contenant 4 couches de largeurs respectives $d_1 = 100, d_2 = 50, d_3 = 10$ et $d_4 = 20$.

a. La réseau est représenté par la fonction $\mathscr{F}$ qui est définie sur quel domaine? Et à valeur dans quel espace?

Le réseau est représenté par une fonction

$$\mathscr{F} : \mathbb{R}^{100} \to \mathbb{R}^{20}.$$

b. Quelle est la profondeur de ce réseau?

La profondeur du réseau est de $L = 4$.

c. Combien de biais b_j^ℓ ce réseau compte-t-il? Et quel est le nombre total de poids w_{jk}^ℓ de $\mathscr{F}$?

Ce réseau contient

$$\sum_{i=1}^{4} d_i = 100 + 50 + 10 + 20 = 180$$

neurones, donc tout autant de biais au total. Pour les poids, on peut procéder couche par couche.

- *De la première à la seconde, on a :* $100 \cdot 50 = 5000$ *poids.*
- *De la seconde à la troisième, on a :* $50 \cdot 10 = 500$ *poids.*
- *De la troisième à la dernière, on a :* $10 \cdot 20 = 200$ *poids.*

Ainsi, le réseau possède un total de 5700 *poids.*

d. Combien de paramètres doit-on initialiser avant de faire une première propagation avant?

Avant de faire la première propagation avant, il faut initialiser tous les poids et les biais, soit donc un total de 5880 *paramètres.*

Exercice 2.2. Soit le réseau de neurones $\mathscr{F}$ représenté ci-dessous.

Pour l'initialiser, nous fixons tout d'abord les poids suivants :

$$w_{11}^2 = 2, w_{21}^2 = 0.5, w_{11}^3 = -1, w_{12}^3 = 1,$$

ainsi que les biais suivants

$$b_1^1 = 2, b_1^2 = 0, b_2^2 = 1, b_1^3 = -1.$$

Pour les besoins de l'exercice, on utilise la fonction identité comme fonction d'activation $\sigma(z) = z$.

a. Placer les différents paramètres à l'endroit approprié sur le graphe du réseau.

b. Quelle fonction $\mathscr{F}$ calcule-t-il? Fournir le domaine, l'ensemble d'arrivée ainsi que la définition explicite de $\mathscr{F}$.

On a d'abord

$$x \mapsto x + 2.$$

Puisque la fonction d'activation est l'identité, on peut calculer respectivement

- $a_1^1 = \sigma(x+2) = x+2$
- $a_1^2 = 2(x+2)+0 = 2x+4$
- $a_2^2 = \frac{1}{2}(x+2)+1 = \frac{1}{2}x+2.$

Finalement,

$$\begin{aligned} a_1^3 &= w_{11}^3 a_1^2 + w_{21}^3 a_2^2 + b_1^3 \\ &= (-1)(2x+4) + 1\left(\frac{1}{2}x+2\right) - 1 \\ &= -2x - 4 + \frac{1}{2}x + 2 - 1 \\ &= -\frac{3}{2}x - 3. \end{aligned}$$

Donc, on a $\mathscr{F} : \mathbb{R} \to \mathbb{R}$ avec

$$\mathscr{F}(x) = \frac{-3x}{2} - 3.$$

On suppose maintenant que l'on voudrait faire apprendre à ce réseau à multiplier par deux. Plus formellement, la fonction idéale que cherche à approximer $\mathscr{F}$ est donnée par $y : \mathbb{R} \to \mathbb{R}$ avec $y(x) = 2x$. On suppose aussi que nos données d'entraînement sont les nombres entiers naturels, i.e. $X_n = n,\ n \in \mathbb{N}$.

c. Donner la définition de la fonction de coût basée sur l'erreur quadratique moyenne (MSE), c'est-à-dire celle vue en classe.

On suppose la donnée d'entrée $x = n \in \mathbb{N}$ est fixée. Alors,

$$\begin{aligned} C(x) &= \frac{1}{2}(y(x) - a_1^3)^2 \\ &= \frac{1}{2}\left(2x - \left(\frac{-3x}{2} - 3\right)\right)^2 \\ &= \frac{1}{2}\left(2x + \frac{3}{2}x + 3\right)^2 \\ &= \frac{1}{2}\left(\frac{7}{2}x + 3\right)^2. \end{aligned}$$

d. Calculer les sorties $a^L(X_n)$ du réseau pour $n = 1,2$ de même que les sorties attendues $y(X_n)$ pour ces mêmes données d'entraînement.

· *Pour $n = 1$, on a*

$$a^3(1) = \mathscr{F}(1) = \frac{-3}{2}(1) - 3 = \frac{-9}{2}; \quad y(1) = 2.$$

· *Pour $n = 2$, on a*

$$a^3(2) = \mathscr{F}(2) = \frac{-3}{2}(2) - 3 = -6; \quad y(1) = 4.$$

e. Calculer l'erreur du réseau sur ce mini-groupe de données.

On peut procéder directement à partir de la définition ponctuelle de la fonction d'erreur calculée précédemment. On obtient donc

$$\begin{aligned} C &= \frac{1}{2n}\sum_x C(x) = \frac{1}{2\cdot 2}\left(C(1)+C(2)\right) \\ &= \frac{1}{4}\left[\left(y(1)-a^2(1)\right)^2+\left(y(2)-a^2(2)\right)^2\right] \\ &= \frac{1}{4}\left[\left(2-\frac{9}{2}\right)^2+(4--6)^2\right] \\ &= \frac{1}{4}\left((\frac{13}{2})^2+10^2\right) \\ &\approx 8.89. \end{aligned}$$

Exercice 2.3. Donner la définition de l'erreur associée au j-ème neurone de la couche ℓ. Expliquer en vos mots ce que celle-ci mesure à partir de la définition.

L'erreur du j-ème neurone de la couche ℓ est

$$\delta_j^\ell := \frac{\partial C}{\partial z_j^\ell},$$

où z est la préactivation de ce neurone. Elle mesure la possibilité d'améliorer le réseau en modifiant les paramètres en interaction avec ce neurone, i.e. les poids $w_{\cdot j}^\ell$ et le biais b_j^ℓ.

- *Si δ_j^ℓ est « petit », alors ces paramètres sont bien ajustés.*
- *Si δ_j^ℓ est « grand », alors au moins un de ces paramètres est mal ajusté et peut-être modifié de manière à faire significativement diminuer l'erreur C du réseau, via l'opération de descente de gradient.*

Exercice 2.4. Énoncer les quatre équations de la rétropropagation. De quelle manière pouvons-nous les utiliser pour calculer le gradient d'une fonction de coût ?

Les 4 équations de la rétropropagation sont respectivement

- *(RP1)*

$$\delta_j^L = \frac{\partial C}{\partial a_j^\ell} \cdot \sigma'(z_j^\ell)$$

- *(RP2)*

$$\delta_j^\ell = \sum_k w_{kj}^{\ell+1} \cdot \delta_k^{\ell+1} \cdot \sigma'(z_j^\ell)$$

- *(RP3)*

$$\frac{\partial C}{\partial b_j^\ell} = \delta_j^\ell$$

- *(RP4)*

$$\frac{\partial C}{\partial w_{jk}^\ell} = \delta_j^\ell \cdot a_k^{\ell-1}$$

On utilise d'abord (RP1) pour calculer les erreurs δ_j^L associées aux neurones de la couche de sortie. Ensuite, on utilise successivement (RP2) pour calculer les erreurs δ_j^ℓ d'une couche à partir de celles $\delta_j^{\ell+1}$ de la couche qui la suit.

C'est en ce sens que nous pouvons parler de rétropropagation, puisque cette manière de procéder débute avec la toute dernière couche et propage vers l'arrière jusqu'à l'atteinte de la couche d'entrée.

Finalement, on utilise (RP3) et (RP4) pour calculer les dérivées partielles $\frac{\partial C}{\partial b_j^\ell}, \frac{\partial C}{\partial w_{jk}^\ell}$ qui composent le vecteur gradient ∇C.

3 PROBLÈMES D'APPRENTISSAGE

Exercice 3.1 Nous voulons poursuivre notre exploration de la fonction de coût d'entropie-croisée, donnée par

$$C = -\frac{1}{n}\sum_x y\ln(a) + (1-y)\ln(1-a),$$

où $a = a(x)$ est la sortie du réseau associée à l'entrée x et $y = y(x)$ est la sortie souhaitée pour x.

a. Vérifier que la fonction de coût produit une sortie proche de 0 lorsque $y = 0.5$ et $a \approx 0.5$.

Si $y = \frac{1}{2}$ et $a \approx \frac{1}{2}$, alors on a $1-a \approx \frac{1}{2}$ de telle sorte que

$$\ln(a) \approx \ln(1-a) \approx \ln\left(\frac{1}{2}\right) = \ln(1) - \ln(2) = -\ln(2).$$

Ainsi, pour x fixé, on a

$$\begin{aligned} C_x &= -\left(\frac{1}{2}(-\ln(2)) + \frac{1}{2}(-\ln(2))\right) \\ &= \ln(2). \end{aligned}$$

Il s'agit de l'entropie croisée minimale dans ce cas.

b. On considère un biais quelconque b_j^ℓ du réseau. Calculer la dérivée partielle

$$\frac{\partial C}{\partial b_j^\ell}.$$

On pose $a = \sigma(z)$ et $y = y(x)$. Ainsi

$$\begin{aligned}
\frac{\partial C}{\partial b_j} &= \frac{\partial}{\partial b_j}\left(-\frac{1}{n}\sum_x y\ln(a) + (1-y)\ln(1-a)\right) \\
&= -\frac{1}{n}\sum_x y\cdot\frac{1}{\sigma(z)}\cdot\sigma'(z) + \frac{1-y}{1-\sigma(z)}\cdot(-\sigma'(z)) \\
&= -\frac{1}{n}\sum_x \frac{y\sigma'(z)(1-\sigma(z)) - (1-y)\sigma(z)\sigma'(z)}{\sigma(z)(1-\sigma(z))} \\
&= -\frac{1}{n}\sum_x y - y\sigma(z) - \sigma(z) + y(z) \\
&= \frac{1}{n}\sum_x (\sigma(z) - y).
\end{aligned}$$

Dans le traitement plus haut, nous avons utilisé le fait que

$$\sigma'(z) = \sigma(z)(1-\sigma(z)).$$

c. Est-ce que l'expression obtenue permet d'éviter les problèmes d'apprentissage causés par l'usage conjoint de la fonction d'erreur quadratique (MSE) et de la sigmoïde de la section 3.1 ?

Oui, car la dérivée partielle est contrôlée par $(a^L - y)$ et n'est pas affectée par une éventuelle petite dérivée $\sigma'(z)$ de l'activation, comme c'était le cas en 3.1.

Exercice 3.2 On se propose d'explorer le concept d'initialisation aléatoire des paramètres en considèrant le réseau de neurones suivant :

Soit également la distribution discrète W de support $\{0,1\}$ et dont la fonction de masse $p(x)$ est uniforme, i.e

$$p(0) = p(1) = \frac{1}{2}.$$

On considère également la distribution discrètre B de support $\{0,1,2\}$ et dont la fonction de masse $q(x)$ est également uniforme, c'est-à-dire donnée par

$$q(0) = q(1) = q(2) = \frac{1}{3}.$$

Rappel : la fonction de masse décrit les probabilités qu'une variable aléatoire suivant cette distribution prenne les différentes valeurs possibles de son support. Par exemple, dans les distributions que l'onv vient de présenter, $p(0) = \frac{1}{2}$ veut dire qu'une variable aléatoire suivant la distribution W a une chance sur deux de prendre la valeur 0.

Finalement, on fixe la donnée d'entrée $x = 1$ et on n'utilise pas de fonction d'activation (autrement dit $\sigma(z) = z$). On suppose que seul le neurone du centre possède un biais b et on note par w_1 et w_2 les deux poids du réseau.

a. On initialise le réseau en échantillonant $w_1 \sim W$, $w_2 \sim W$ et $b \sim B$. Le réseau est maintenant une variable aléatoire Y. Donner le support ainsi que la fonction de masse de Y.

On a $w_i \sim W$, avec fonction de masse $p(x)$; $p(0) = p(1) = \frac{1}{2}$. Autrement dit,

$$P(w_i = 0) = P(w_i = 1) = \frac{1}{2}.$$

Aussi, $b \sim B$, avec fonction de masse $q(x)$; $q(0) = q(1) = q(2) = \frac{1}{3}$. Autrement dit,

$$P(b = 0) = P(b = 1) = P(b = 2) = \frac{1}{3}.$$

Puisque $\sigma = Id$, le réseau calcule

$$y(x) = w_2(w_1 x + b) = w_2 w_1 x + w_2 b.$$

Comme w_1, w_2, b sont des variables aléatoires, la sortie du réseau est aussi une variable aléatoire. Chacune des sorties possible survient avec une probabilité de $\frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{3} = \frac{1}{12}$. En effectuant le dénombrement, on obtient que le support de la variable aléatoire de sortie Y est $\{0,1,2,3\}$. Sa fonction de masse est donnée par

$$p(0) = \frac{7}{12},\ p(1) = \frac{2}{12} = \frac{1}{6},\ p(2) = \frac{2}{12} = \frac{1}{6},\ \text{et } p(3) = \frac{1}{12}.$$

b. Calculer l'espérance de w_1 et de b.

À partir de la définition de l'espérance mathématique, on calcule

$$\mathbb{E}(w_1) = 0 \cdot P(w_1 = 0) + 1P(w_1 = 1) = \frac{1}{2}.$$

De manière similaire,

$$\mathbb{E}(b_1) = 0 \cdot P(b = 0) + 1 \cdot P(b = 1) + 2 \cdot P(b = 2) = 1.$$

c. Calculer la variance de w_1 et de b.

À partir de la définition de la variance, on a

$$\begin{aligned} Var(w_1) &= \mathbb{E}(w_1^2) - (\mathbb{E}(w_1))^2 \\ &= (0^2 \cdot p(0) + 1^2 \cdot p(1)) - (\frac{1}{2})^2 = 1 - \frac{1}{4} \\ &= \frac{3}{4}. \end{aligned}$$

Similairement,

$$\begin{aligned} Var(b) &= \mathbb{E}(b^2) - (\mathbb{E}(b))^2 \\ &= (0^2 \cdot p(0) + 1^2 \cdot p(1) + 2^2 \cdot p(2)) - 1^2 = \frac{5}{3} - 1 \\ &= \frac{2}{3}. \end{aligned}$$

d. Est-ce que l'initialisation de ce réseau aléatoire satisfait le troisème critère du théorème de Hanin-Rolnick?

Pour satisfaire le 3ème critère du théorème de Hanin-Rolnick, il faut que la variance d'un paramètre associé à la couche ℓ soit égale à

$$\frac{2}{fan\text{-}in} = \frac{2}{d_{\ell-1}}.$$

Ici, $d \equiv 1$ pour les 3 couches et il faudrait donc des variances de $\frac{2}{1} = 2$, ce qui n'est pas le cas après les calculs du numéro précédents.

Exercice 3.3 Soit le réseau profond suivant, qui prend en entrée un vecteur de $\mathbb{R}^4$ et produit un nombre réel en sortie.

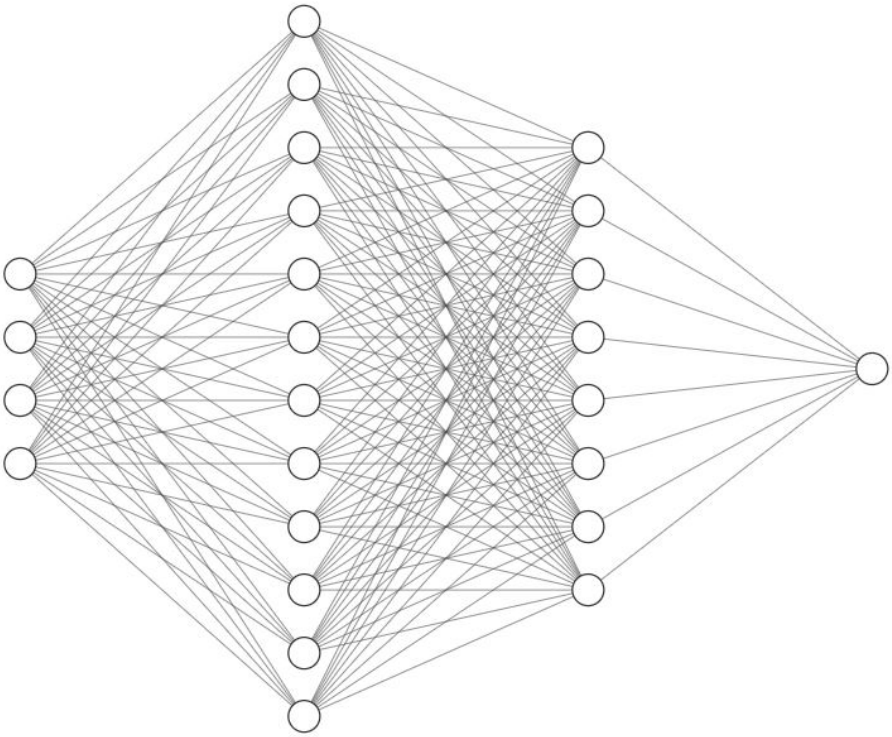

On désire intialiser aléatoirement les paramètres de ce réseau de manière à respecter les critères du théorème de Hanin-Rolnick. Pour chaque poids w^{ℓ}_{jk} et biais b^{ℓ}_{j} du réseau, fournir une distribution probabiliste qui soit telle que ces conditions d'application du théorème sont remplies.

Ce réseau a $L = 4$ couches avec $d_1 = 4, d_2 = 12, d_3 = 8, d_4 = 1$..

- *Pour les paramètres associés à la couche $\ell = 2$, i.e. b^2_j et w^2_{ij}, il faut que*
$$Var = \frac{2}{"fan\text{-}in"} = \frac{2}{d_1} = \frac{2}{4} = \frac{1}{2}.$$
- *Pour les paramètres associés à la couche $\ell = 3$, i.e. b^3_j et w^3_{ij}, il faut que*
$$Var = \frac{2}{"fan\text{-}in"} = \frac{2}{d_2} = \frac{2}{12} = \frac{1}{6}.$$
- *Enfin, pour les paramètres associés à la couche $\ell = 3$, i.e. b^3_j et w^3_{ij}, il faut que*
$$Var = \frac{2}{"fan\text{-}in"} = \frac{2}{d_3} = \frac{2}{8} = \frac{1}{4}.$$

Pour tous ces paramètres, on peut choisir une distribution normale de variance approprié, soit $\frac{1}{2}, \frac{1}{6}$ ou $\frac{1}{4}$ selon le cas.

4 UNIVERSALITÉ ET PUISSANCE EXPRESSIVE

Exercice 4.1 Répondre par *vrai* ou *faux* à chacun des énoncés suivants portant sur le théorème de Cybenko. Lorsque vous répondez *faux*, justifiez.

On rappelle d'abord ici le type de réseaux utilisés dans le théorème Cybenko :

$$S = \left\{ G(x) = \sum_{j=1}^{D} \alpha_j \sigma(w^j \cdot x + b_j) \,:\, w^j \in \mathbb{R}^n; \alpha_j, b_j \in \mathbb{R} \right\}.$$

a. Pour toute fonction continue $f^*(x)$, il existe un réseau $G(x) \in S$ tel que $f^*(x) = G(x)$.

Faux. On peut approximer arbitrairement près, mais rien ne garantit qu'un réseau $G(x)$ existe tel que $G(x) \equiv f^*(x)$.

b. L'énoncé du théorème nous dit que plus $\epsilon > 0$ est petit, plus l'approximation d'une fonction idéale f^* par un réseau $G(x) \in S$ est précise.

Vrai.

c. Il est possible d'appliquer tel quel le théorème de Cybenko en choisissant ReLU comme fonction d'activation, i.e. en fixant $\sigma(z) = \max 0, z$.

Faux, car $\sigma = ReLU$ n'est pas sigmoïdale :

$$\lim_{z \to \infty} ReLU(z) = \infty.$$

d. On peut approximer n'importe quelle fonction continue à un degré arbitrairement précis avec un réseau $G(x) \in S$ qui contient un nombre fixe de neurones.

Faux. Pour améliorer l'approximation, il faut typiquement augmenter le nombre de neurones de la couche du milieu. Autrement dit

$$N = N(\epsilon) \to \infty \;\; si \;\; \epsilon \to 0.$$

e. Les réseaux $G(x) \in S$ du théorème de Cybenko sont profonds mais peu larges.

Faux. Ils sont peu profonds $L = 3$ mais larges.

Exercice 4.2 On rappelle qu'une *fonction simple* est une combinaison linéaire de fonctions indicatrices, c'est-à-dire qu'elles sont de la forme

$$s(x) = \sum_{i=1}^{N} \alpha_i \chi_{(a_i,b_i)},$$

et où $\alpha_i \chi_{(a_i,b_i)}$ est la fonction indicatrice de l'intervalle (a_i, b_i), c'est-à-dire la fonction qui prend la valeur 1 si $x \in (a_i, b_i)$ et 0 sinon.

Soit maintenant la fonction $f : [0,2] \to \mathbb{R}$ donnée par $f(x) = x^2$.

a. Approximez f par une fonction simple qui contient un morceau.

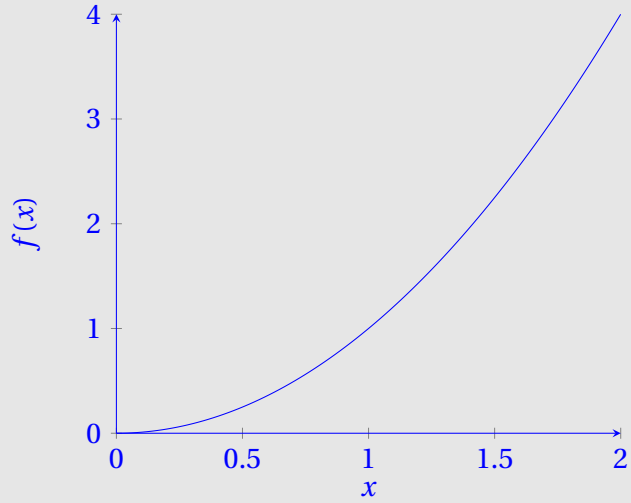

On veut donc approximer cette fonction avec une expression de la forme

$$s(x) = \sum_{i=1}^{N} \alpha_i \chi_i(a_i, b_i),$$

où $\chi_i(a_i, b_i)$ est la fonction indicatrice de l'intervalle (a_i, b_i). On commence donc avec un seul morceau et on cherche

$$s_1(x) = \alpha_1.$$

Quelle amplitude α_1 choisir? Il semble raisonnable de choisir la valeur moyenne de f sur $[0,2]$:

$$\alpha_1 = \frac{1}{2-0} \int_0^2 x^2 \, dx = \frac{4}{3}.$$

Donc, $s_1(x) = \frac{4}{3}$.

b. Approximez f par une fonction simple qui contient deux morceaux.

Même chose, mais avec $s_2(x) = \alpha_1\chi_{(0,1)} + \alpha_2\chi_{(1,2)}$. Les coefficients α_1 et α_2 correspondant à la valeur moyenne respective de f sur les intervalles $(0,1)$ et $(1,2)$. On calcule

$$\alpha_1 = \frac{1}{1-0}\int_0^1 x^2\,dx = \frac{1}{3},\quad \alpha_2 = \frac{1}{2-1}\int_1^2 x^2\,dx = \frac{7}{3}.$$

On obtient donc la fonction simple d'ordre 2 suivante

$$s_2(x) = \frac{1}{3}\chi_{(0,1)} + \frac{7}{3}\chi_{(1,2)}.$$

c. Approximez f par une fonction simple qui contient quatre morceaux.

Même chose, mais cette fois-ci avec $n = 4$ morceaux. On partitionne l'intervalle ainsi $(0,\frac{1}{2}),(\frac{1}{2},1),(1,\frac{3}{2})$ et enfin $(\frac{3}{2},2)$. On aura

$$s_4(x) = \alpha_1\chi_{(0,\frac{1}{2})} + \alpha_2\chi_{(\frac{1}{2},1)} + \alpha_3\chi_{(1,\frac{3}{2})} + \alpha_4\chi_{(\frac{3}{2},1)}.$$

On calcule les ampltudes de manière similaire aux exemples précédents. On a

$$\alpha_1 = \frac{1}{\frac{1}{2}-0}\int_0^{\frac{1}{2}} x^2\,dx = \frac{1}{12};\quad \alpha_2 = \frac{1}{1-\frac{1}{2}}\int_{\frac{1}{2}}^1 x^2\,dx = \frac{7}{12}$$

ainsi que

$$\alpha_3 = \frac{1}{\frac{3}{2}-1}\int_1^{\frac{3}{2}} x^2\,dx = \frac{19}{12};\quad \alpha_2 = \frac{1}{2-\frac{3}{2}}\int_{\frac{3}{2}}^2 x^2\,dx = \frac{37}{12}.$$

On obtient finalement la fonction simple d'ordre 4 suivante

$$s_4(x) = \frac{1}{12}\chi_{(0,\frac{1}{2})} + \frac{7}{12}\chi_{(\frac{1}{2},1)} + \frac{19}{12}\chi_{(1,\frac{3}{2})} + \frac{37}{12}\chi_{(\frac{3}{2},1)}.$$

5 RÔLE DE LA PROFONDEUR DANS LA PUISSANCE EXPRESSIVE

Exercice 5.1 Soit la fonction

$$f(x) = \begin{cases} 1-2x & \text{si } 0 \le x \le \frac{1}{2} \\ 2x-1 & \text{si } \frac{1}{2} \le x \le 1 \end{cases}$$

a. Tracez le graphe de f.

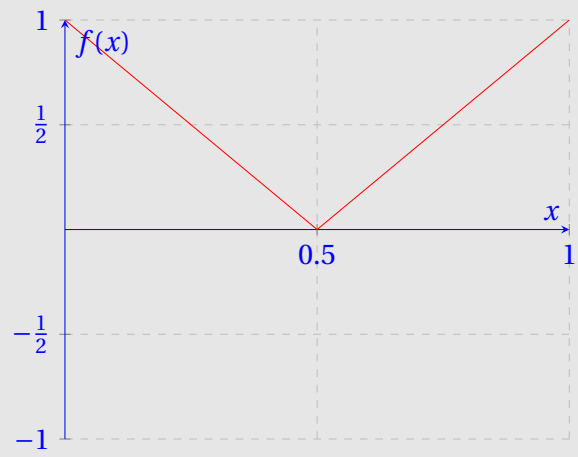

On remarque par ailleurs que

$$f(x) = -m(x) + 1.$$

b. Créez un réseau de neurones qui calcule exactement f, i.e. dont la sortie est $a^L = f(x)$.

On fixe d'abord $\sigma = ReLU$. Aussi, nous avons vu que

$$m(x) = \sigma(2\sigma(x) - 4\sigma(x - 1/2)).$$

Ainsi, $f(x) = -m(x) + 1$ peut être calculé en rajoutant une couche de 1 neurone au réseau qui calculaitm(x) avec un poids de $w = -1$ et un biais associé au nouveau neurone de 1.. Ainsi

$$a^L = \sigma(-m(x) + 1) = f(x).$$

c. Approximez f par une fonction simple qui contient quatre morceaux.

Il s'agit de considérer

$$s_4(x) = \alpha_1 \chi(0, \frac{1}{4}) + \alpha_2 \chi(\frac{1}{2}, \frac{1}{4}) + \alpha_3 \chi(\frac{1}{2}, \frac{3}{4}) + \alpha_4 \chi(\frac{3}{4}, 1),$$

avec

$$\alpha_1 = \frac{3}{4}, \ \alpha_2 = \frac{1}{4}, \ \alpha_3 = \frac{1}{4}, \ \alpha_1 = \frac{3}{4}.$$

d. Tracez le graphe de la composition $f^{(2)}(x) = (f \circ f)(x)$.

Il s'agit d'une fonction en dents de scie définie sur (0,1) et qui prend la valeur 1 *en* $0, 1/2, 1$ *et* 0 *en* $1/4$ *et* $3/4$.

e. Créez un réseau de neurones qui calcule exactement $f^{(2)}(x)$.

Il s'agit simplement de coller horizontalement deux fois le RN obtenu en (b).

f. Les fonctions $f^{(n)}$ sont linéaires par morceaux. Combien de morceaux possède $f^{(n)}$?

- $f^{(1)}$ *possède* 2 *morceaux (on se restreint à l'intervalle* $[0,1]$*.)*
- $f^{(2)}$ *possède* $4 = 2^2$ *morceaux.*

Exercice 5.2 On se place dans le contexte du test de classification à n-points dont nous avons discuté en classe en prélude au théorème de Telgarsky. On rappelle que la discrétisation $\tilde{f}$ d'une fonction $f : [0,1] \to \mathbb{R}$ est donnée par

$$\tilde{f}(x) = \begin{cases} 1 & \text{si } f(x) \geq \frac{1}{2} \\ 0 & \text{si } f(x) < \frac{1}{2} \end{cases}$$

L'erreur $E(f)$ associé à f est alors définie comme la proportion des n-points qui ont été mal classés par cette discrétisation, c'est-à-dire

$$E(f) = \frac{1}{2^n} \sum \chi \left\{ \tilde{f}(x_i) \neq y_i \right\}.$$

On considère la fonction $f(x) = x^2$ sur l'intervalle $[0,1]$. Calculez $E(f)$ pour le test de classification avec $n = 1, 2, 3$.

La discrétisation de $f(x)$ est

$$\tilde{f}(x) = \begin{cases} 1 & si\ x^2 \geq \frac{1}{2} \\ 0 & si\ x^2 < \frac{1}{2} \end{cases}$$

Le seuil est donc ici d'environ 0.7. *L'erreur $\mathscr{E}(f)$ de $f(x) = x^2$ au test de classification est la proportion des points qui ne sont pas traversés par la discrétisation $\tilde{f}$. On a donc*

$$\mathscr{E}(f) = \begin{cases} \frac{1}{2} & si\ n = 1 \\ \frac{1}{4} & si\ n = 2 \\ \frac{4}{8} = \frac{1}{2} & si\ n = 4. \end{cases}$$

Exercice 5.3 Expliquez en vos mots la signification et la portée théorique du théorème de Telgarsky.

6 INTRODUCTION À L'APPRENTISSAGE PROFOND GÉOMÉTRIQUE

Exercice 6.1. On suppose qu'un réseau de convolution reçoit en entrée une image de format de 32×32 pixels.

a. Combien de neurones possède la couche d'entrée de ce réseau ?

On a

$$d_1 = 32 \times 32 = 1024.$$

b. Si vous créez un filtre h de taille 5×5, quelles dimensions aura la sortie obtenue par la convolution de l'image initiale avec h ?

La sortie aura alors une dimension de $28 \times 28 = 784$.

Note : on suppose ici que la couche convolutionnelle ne fait pas de padding et a un stride *(pas) unitaire.*

c. Quelle propriété structurelle des images les distingue des graphes et nous permet d'implémenter naturellement une couche de convolution sur celles-ci ?

Organisation en grille, c'est-à-dire structure euclidienne sous-jacente.

Exercice 6.2. On rappelle que le *laplacien*, noté Δ, est un opérateur différentiel qui agit sur des fonctions $f(x_1, x_2, ..., x_n)$ de n variables de la manière suivante

$$\Delta f(x) = -\sum_{i=1}^{n} \frac{\partial^2 f}{\partial x_i^2}(x).$$

Par exemple, pour une fonction de deux variables $f(x, y)$, le laplacien devient

$$\Delta f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}.$$

Note : le signe négatif devant la somme est une convention qui nous permet de s'assurer d'avoir des valeurs propres non-négatives.

a. Que devient le laplacien lorsque $n = 1$, c'est-à-dire lorsqu'on le fait agir sur des fonctions d'une seule variable ?

Si $n = 1$, on a

$$\Delta = -\frac{d^2}{dx^2},$$

soit l'opérateur de dérivée seconde pour les fonctions d'une variable.

b. Vérifier que $\sin(\lambda x)$ et $\cos(\lambda x)$ sont des fonctions propres de Δ et identifier la valeur propre associée.

On calcule directement

$$\Delta(\sin(\lambda x)) = -\frac{d^2}{dx^2}\sin(\lambda x) = -\frac{d}{dx}\lambda\cos(\lambda x) = \lambda^2\sin(\lambda x),$$

et donc la fonction $\sin(\lambda x)$ *est une fonction propre de valeur propre* λ^2*. De manière tout à a fait similaire, on a*

$$\Delta(\cos(\lambda x)) = -\frac{d^2}{dx^2}\cos(\lambda x) = \frac{d}{dx}\lambda\sin(\lambda x) = \lambda^2\cos(\lambda x).$$

c. Soit $f(x,y) = x^2 + y^2$. Calculer Δf.

Pour une fonction de deux variables, le laplacien devient

$$\Delta f(x,y) = -\left(\frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}\right).$$

Puisque,

$$\frac{\partial^2 f}{\partial x^2} = \frac{\partial^2 f}{\partial y^2} = 2,$$

on a donc que $\Delta f(x,y) = 4$.

d. On considère la famille de fonctions

$$\varphi_{m,n}(x,y) = \sin(mx)\sin(ny),$$

indexées par $(m,n) \in \mathbb{Z}^2$, c'est-à-dire que (m,n) est n'importe quel couple d'entiers relatifs. Montrer que $\varphi_{m,n}$ est une fonction propre du laplacien et donner la valeur propre correspondante.

On calcule

$$\frac{\partial \varphi}{\partial x} = m\cos(mx)\sin(ny); \quad \frac{\partial^2 \varphi}{\partial x^2} = -m^2\sin(mx)\sin(ny).$$

Les dérivées par rapport à la variable y se calculent de manière similaire

$$\frac{\partial \varphi}{\partial y} = n\sin(mx)\cos(ny); \quad \frac{\partial^2 \varphi}{\partial y^2} = -n^2\sin(mx)\sin(ny).$$

Ainsi,

$$\begin{aligned}\Delta\varphi_{m,n} &= -\left(\frac{\partial^2 \varphi}{\partial x^2} + \frac{\partial^2 \varphi}{\partial y^2}\right) = (m^2+n^2)\sin(mx)\sin(ny) \\ &= \lambda_{m,n}\varphi_{m,n}.\end{aligned}$$

Donc, les éléments de la famille $\varphi_{m,n}$ sont des fonctions propres du Δ avec valeur propre $\lambda_{m.n} = (m^2+n^2)$.

Exercice 6.3. Un *champ vectoriel* est une fonction dont la sortie est un vecteur, par oppositon aux fonctions usuelles dont les sorties sont des nombres (ou scalaires). Par exemple, l'application $F : \mathbb{R}^2 \to \mathbb{R}^2$ donnée par

$$F(x,y) = (2x, 2y)$$

est un champ vectoriel.

a. Calculer le gradient ∇f de la fonction $f(x,y) = x^2 + y^2$. Que remarquez-vous?

On a directement

$$\nabla f = (2x, 2y)$$

qui est donc un champ vectoriel sur $\mathbb{R}^2$.

On souligne donc que le gradient transforme des fonctions en champs vectoriels. L'opérateur de *divergence*, noté div agit quant à lui dans la direction opposée et transforme des champs vectoriels en fonctions. Plus précisément, étant donné un champ vectoriel F, la divergence de ce champ est donnée par

$$\operatorname{div} F = \sum_{i=1}^{n} \frac{\partial}{\partial x_i} = \frac{\partial}{\partial x_1} + \frac{\partial}{\partial x_2} + \ldots + \frac{\partial}{\partial x_n}.$$

b. Calculer la divergence du champ vectoriel F tel que défini au début de cette question. Que remarquez-vous?

On a

$$\begin{aligned}\operatorname{div} F &= \sum_{i=1}^{2} \frac{\partial}{\partial x_i} = \frac{\partial F_1}{\partial x} + \frac{\partial F_2}{\partial y} \\ &= \frac{\partial}{\partial x}(2x) + \frac{\partial}{\partial y}(2y) = 2 + 2 = 4.\end{aligned}$$

Donc, $-\operatorname{div} F = -\operatorname{div}\nabla f = -4$, tout comme lorsque nous avions calculé le laplacien de $f(x,y)$. Ce n'est pas un hasard comme nous allons le démontrer au prochain exercice.

c. Montrer que $\Delta = -\operatorname{div}\nabla$, i.e. montrer que

$$-\operatorname{div}\nabla f = -\sum_{i=1}^{n} \frac{\partial^2 f}{\partial x_i^2}.$$

À partir des définitions respectives, on a

$$-\operatorname{div}\nabla f = -\sum_{i=1}^{n} \frac{\partial}{\partial x_i}(\nabla f_i) = -\sum_{i=1}^{n} \frac{\partial}{\partial x_i}\left(\frac{\partial f}{\partial x_i}\right) = -\sum_{i=1}^{n} \frac{\partial^2 f}{\partial x_i^2} = \Delta f.$$

Exercice 6.4. Expliquez en vos mots en quoi le théorème de Hilbert-Schmidt est analogue au théorème spectral pour les matrices symétriques.

Il permet d'établir que les fonctions propres du laplacien forment une base orthonormale de l'espace $L^2(X)$, où $X \subset \mathbb{R}^n$ est le domaine des fonction sur lequel agit le laplacien.

Exercice 6.5. Soit $X \subset \mathbb{R}$. On rappelle que l'espace $L^2(X)$ contient l'ensemble des fonctions de carré intégrable à valeurs réelles et définies sur $\mathbb{X}$. Autrement dit, $u \in L^2(X)$ si et seulement si

$$\int_X |f(x)|^2 \, \mathrm{d}x < \infty.$$

L'espace $L^2(\mathbb{X})$ est un espace dit hilbertien parce qu'il porte un *produit scalaire*, en tout point analogue à celui que vous utilisez usuellement avec les vecteurs de $\mathbb{R}^n$. Ce produit scalaire est défini avec l'aide de l'intégrale. En effet, pour tout $u, v \in L^2(\mathbb{X})$, on a

$$(u,v)_X := \int_X u(x) \cdot v(x) \, \mathrm{d}x.$$

On considère maintenant les 4 fonctions suivantes

$$f(x) = e^{-x^2}, \; g(x) = \frac{1}{x^2+1}, \; u(x) = e^{-x}, \; h(x) = x.$$

Note : pour calculer les intégrales nécessaires pour répondre aux prochaines sous-questions, vous pouvez et devriez utiliser la TI ou un logiciel de calcul symbolique!

a. Parmi les 4 fonctions présentées ci-haut, dire lesquelles font partie de L^2R et justifier sa réponse.

> *Pour appartenir à $L^2(\mathbb{R})$, une fonction doit satisfaire*
>
> $$\int_{\mathbb{R}} |f|^2 \, dx < \infty.$$
>
> *On vérifie aisément que $f, g \in L^2(\mathbb{R})$, mais que $u, h \notin L^2(\mathbb{R})$.*

b. Parmi les 4 fonctions présentées ci-haut, dire lesquelles font partie de $L^2[0,1]$ et justifier sa réponse.

> *Toutes les fonctions, i.e. f, g, u et h, sont dans $L^2([0,1])$ car pour chacune de ces fonctions, on a*
>
> $$\int_0^1 |f|^2 \, dx < \infty.$$

c. Calculer le produit scalaire suivant

$$(h,u)_{[0,1]}.$$

> *Il s'agit de calculer l'intégrale*
>
> $$(h,u)_{[0,1]} = \int_0^1 h(x)u(x)\,dx = \int_0^1 xe^{-x}\,dx \approx 0.26.$$

d. Calculer le produit scalaire suivant

$$(f,g)_{\mathbb{R}}.$$

> *Il faut cette fois-ci calculer l'intégrale*
>
> $$(f,g)_{\mathbb{R}} = \int_{\mathbb{R}} f(x)g(x)\,dx = \int_{\mathbb{R}} e^{-x^2}\frac{1}{1+x^2}\,dx \approx 1.34.$$

Exercice 6.6. On rappelle que la *transformée de Fourier* $\hat{f}$ d'une fonction $f : \mathbb{R} \to \mathbb{R}$ est la fonction définie par

$$\mathscr{F}\{f\} = \hat{f}(\xi) = \int_{\mathbb{R}} f(t)e^{2\pi i \xi t}\,\mathrm{d}t.$$

De plus, la *transformée inverse de Fourier* est obtenu via

$$\mathscr{F}^{-1}\{\hat{f}\} = f(x) = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} \hat{f}(\xi) e^{-2\pi i \xi t} \, \mathrm{d}\xi.$$

a. Écrire l'expression de la transformée de Fourier comme un produit scalaire sur $\mathbb{R}$.

On a

$$\hat{f}(\xi) = \mathscr{F}(f)(\xi) = \int_{\mathbb{R}} f(t) e^{2\pi i \xi t} \, dt = (f(t), e^{2\pi i \xi t})_{t \in \mathbb{R}},$$

où la dernière notation indique que la variable libre sur laquelle est pris le produit scalaire est $t \in \mathbb{R}$.

b. Écrire l'expression de la transformée de Fourier inverse comme un produit scalaire sur $\mathbb{R}$.

On a

$$f(x) = \mathscr{F}^{-1}(\hat{f})(x) = \int_{\mathbb{R}} \hat{f}(\xi) e^{-2\pi i \xi t} \, d\xi = (\hat{f}(\xi), e^{-2\pi i \xi t})_{\xi \in \mathbb{R}},$$

où la dernière notation indique que la variable libre sur laquelle est pris le produit scalaire est $\xi \in \mathbb{R}$.

c. Vérifier que les exponentielles complexes qui apparaissent dans ces produits scalaires sont des fonctions propres du laplacien en 1 dimension, agissant sur la variable t pour $\mathscr{F}$ et sur ξ pour la transformée inverse $\mathscr{F}^{-1}$.

Il s'agit d'un calcul direct, dans les deux directions. On

$$\begin{aligned} \Delta_t(e^{2\pi i \xi t}) &= \frac{d^2}{dt^2}(e^{2\pi i \xi t}) \\ &= (2\pi i \xi)^2 e^{2\pi i \xi t} \\ &= (-4\pi^2 \xi^2) e^{2\pi i \xi t} = \lambda \varphi_s. \end{aligned}$$

Du côté de la transformée inverse, on a plutôt

$$\begin{aligned} \Delta_\xi(e^{-2\pi i \xi t}) &= \frac{d^2}{d\xi^2}(e^{-2\pi i \xi t}) \\ &= (-2\pi i t)^2 e^{-2\pi i \xi t} \\ &= (-4\pi^2 t^2) e^{-2\pi i \xi t} = \lambda \varphi_t. \end{aligned}$$

Exercice 6.7 Soit le graphe G donné par les sommets $V = \{1, 2, 3\}$ et la matrice d'adjacence

des poids

$$W = \begin{pmatrix} 0 & 1 & 2 \\ 1 & 0 & -1 \\ 2 & -1 & 0 \end{pmatrix}.$$

a. Dessiner le le graphe G en indiquant les poids reliés à chacune des arêtes qu'il possède.
b. Une fonction sur G est une fonction définie sur les sommets, soit une application $f : V \to \mathbb{R}$. L'ensemble $L^2(V)$ est l'ensemble de toutes ces fonctions, qui sont en fait des vecteurs de $\mathbb{R}^n$ et on écrit alors

$$L^2(V) \cong \mathbb{R}^n.$$

Quelle est la valeur de n ici ?

On a l'isomorphisme suivant

$$L^2(V) \cong \mathbb{R}^n,$$

avec $n = |V| = 3$.

c. On rappelle que le gradient est une application

$$\nabla : L^2(V) \to L^2(\mathscr{E})$$

donnée par

$$(\nabla u)_{i,j} = u(i) - u(j),$$

et où $L^2(\mathscr{E})$ est l'ensemble des fonctions défines sur les arêtes de G. Autrement dit, le gradient transforme des fonctions prenant comme un argument un sommet $i \in V$ en fonctions prenant en argument une arête $(i, j) \in \mathscr{E}$. On considère maintenant la fonction $u \in L^2(V)$, donnée par $u = (1, -1, 2)^T$. Calculer ∇u.

On a

$$\mathscr{E} = \{(1,2); (2,1); (1,3); (3,1); (2,3); (3,2)\}.$$

et le gradient est l'opérateur $\nabla : L^2(V) \to L^2(\mathscr{E})$*.Ainsi, pour* $\boldsymbol{u} = \begin{pmatrix} 1 \\ -1 \\ 2 \end{pmatrix}$*,, on a*

- $(\nabla u)_{(1,2)} = u(1) - u(2) = 1 - -1 = 2.$
- $(\nabla u)_{(1,3)} = u(1) - u(3) = 1 - 2 = -1.$
- $(\nabla u)_{(2,3)} = u(2) - u(3) = 1 - 2 = -3.$

On complète finalement en remarquant que, par antisymétrie, on a

$$(\nabla u)_{(i,j)} = -(\nabla u)_{(j,i)}.$$

d. L'opérateur de divergence est quant à lui un opérateur $\mathrm{div} : Ł^2(\mathscr{E}) \to L^2(V)$ qui transforme des fonctions définies sur les arêtes en fonctions définies sur les sommets. Cet opérateur est agit sur $F \in L^2(\mathscr{E})$ par

$$\mathrm{div}\, F(i) = \sum_{j:(i,j)\in\mathscr{E}} W_{ij} \cdot F_{ij}.$$

Calculer $-\mathrm{div}\nabla u$.

Pour $F \in L^2(\mathscr{E})$, on a

$$div\, F(i) = \sum_{j:(i,j)\in\mathscr{E}} W_{ij} \cdot F_{ij}.$$

Ainsi,

$$-div\nabla u(1) = -\sum_{j:(1,j)\in\mathscr{E}} W_{1j}\cdot\nabla_{1j} u = -(W_{12}\cdot\nabla_{12}u + W_{13}\cdot\nabla_{13}u) = -(2-2) = 0.$$

Similairement,

$$-div\nabla u(2) = -\sum_{j:(2,j)\in\mathscr{E}} W_{2j}\cdot\nabla_{2j} u = -(W_{21}\cdot\nabla_{21}u + W_{23}\cdot\nabla_{23}u) = -(2+3) = -1.$$

Enfin,

$$-div\nabla u(3) = -\sum_{j:(3,j)\in\mathscr{E}} W_{3j}\cdot\nabla_{3j} u = -(W_{31}\cdot\nabla_{13}u + W_{32}\cdot\nabla_{32}u) = -2+3 = 1.$$

On peut donc conclure que

$$-div\nabla u = \begin{pmatrix} 0 \\ -1 \\ 1 \end{pmatrix}.$$

e. Par analogie avec le laplacien usuel, le *g-laplacien* $\Delta : L^2(V) \to L^2(V)$ est défini par

$$\Delta u = -\mathrm{div}\nabla u,$$

ce qui revient à

$$\Delta u(i) = -\sum_{j:(i,j)\in\mathscr{E}} W_{ij}(u(i) - u(j)).$$

Vérifier que vous obtenez la même réponse qu'en (d) en utilisant plutôt cette définition pour calculer directement Δu.

On a par définition

$$\Delta u(i) = -\sum_{j:(i,j)\in\mathcal{E}} W_{ij}(u(i)-u(j))$$

avec $\boldsymbol{u} = \begin{pmatrix} 1 \\ -1 \\ 2 \end{pmatrix}$. *Nous allons calculer sommet par sommet, indviduellement. D'abord,*

$$\begin{aligned}\Delta u(1) &= -(W_{12}(u(1)-u(2)) + W_{13}(u(1)-u(3))) \\ &= -(1(1--1)+2(1-2)) = -(2-2) = 0.\end{aligned}$$

On passe au sommet suivant :

$$\begin{aligned}\Delta u(2) &= -(W_{21}(u(2)-u(1)) + W_{23}(u(2)-u(3))) \\ &= -(1(-2)+(-1)\cdot(-3)) = -1.\end{aligned}$$

Enfin,

$$\begin{aligned}\Delta u(3) &= -(W_{31}(u(3)-u(1)) + W_{32}(u(3)-u(2))) \\ &= -(2\cdot(2-1)-1\cdot(2--1)) = 1.\end{aligned}$$

On obtient donc bel et bien le même vecteur de sortie qu'avec l'autre méthode de calcul, soit $\begin{pmatrix} 0 \\ -1 \\ 1 \end{pmatrix}$.

f. Puisque le g-laplacien transforme linéairement des vecteurs de $L^2(V) \cong \mathbb{R}^n$ en vecteurs de $\mathbb{R}^n$, il peut-être représenté par une matrice. En effet, on a

$$-\Delta = D - W,$$

où W est la matrice adjacente des poids et

$$D = \text{diag}\{\deg(1), \deg(2), ..., \deg(n)\}.$$

On rappelle $\deg(i) = \sum_j W_{ij}$ retourne la somme de tous les poids qui connectent avec le sommet i. Utiliser cette définition matricielle pour calculer une nouvelle fois Δu.

Dans notre contexte, la définition matricielle du laplacien devient $-\Delta = D - W$, avec la matrice diagonale des degrés obtenue via

$$D = diag\{.\deg(1), \deg(2), \deg(3)\}.$$

Le calcul des degrés nous donne d'abord

- $\deg(1) = W_{12} + W_{13} = 3$,
- $\deg(2) = W_{23} + W_{21} = 0$,
- $\deg(3) = W_{31} + W_{32} = 1$.

Ainsi,

$$-\Delta = \begin{pmatrix} 3 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix} - \begin{pmatrix} 0 & 1 & 2 \\ 1 & 0 & -1 \\ 2 & -1 & 0 \end{pmatrix} = \begin{pmatrix} 3 & -1 & 2 \\ -1 & 0 & 1 \\ -2 & 1 & 1 \end{pmatrix}.$$

Une simple multiplication matricielle permet enfin une nouvelle fois de confirmer que

$$-\Delta u = -\begin{pmatrix} 3 & -1 & 2 \\ -1 & 0 & 1 \\ -2 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \\ 2 \end{pmatrix} = \begin{pmatrix} 0 \\ -1 \\ 1 \end{pmatrix}.$$

Il est donc clair qu'il existe plusieurs manières distinctes d'envisager le laplacien sur un graphe. Les premières définitions ont l'avantage d'être similaire à la version usuelle continue du laplacien, tandis que la dernière est défintiviement plus pratique du point de vue calculatoire. Il s'agit en effet de réduire directement le travail de cet opérateur à la simple multiplication matricielle.

Exercice 6.8 On veut vérifier que le g-laplacien est une matrice symétrique. Soit D une matrice diagonale et W une matrice symétrique. Montrer que $D - W$ est symétrique.

Les éléments hors de la diagonale sont ceux de $-W$ qui est elle-même symétrique. Donc,

$$\Delta = -(D - W)$$

est symétrique. Sinon, en utilisant les propriétés de la transposée, on a

$$\Delta^T = -(D - W)^T = -(D^T - W^T) = -(D - W) = \Delta,$$

où on a respectivement utilisé le fait que tant W que D sont des matrices symétriques.

Exercice 6.9 Calculer la base orthogonale Φ de vecteurs propres du g-laplacien $\Delta = -(D - W)$ de l'exercice 6.7.

Note : pour calculer les vecteurs propres, utilisez un logiciel de calcul!

On veut donc calculer 3 *vecteurs propres de*

$$\Delta = \begin{pmatrix} -3 & 1 & -2 \\ 1 & 0 & -1 \\ 2 & -1 & -1 \end{pmatrix}$$

Avec un logiciel, on calcule directement

- $\varphi_1 = \left(-\frac{3+\sqrt{7}}{1+\sqrt{7}}, \frac{2}{1+\sqrt{7}}, 1\right)^T$
- $\varphi_2 = \left(-\frac{3-\sqrt{7}}{1+\sqrt{7}}, \frac{-2}{1+\sqrt{7}}, 1\right)^T$
- $\varphi_3 = (1,1,1)^T$

Donc, une base orthogonale de vecteurs propres est donnée par

$$\Phi = \{\varphi_1, \varphi_2, \varphi_3\}.$$

Exercice 6.10 Nous avons développé une g-théorie de Fourier qui nous a permis de définir la transformée de Fourier et son inverse par

$$\mathscr{F}(f)(k) = \hat{f}(k) = \sum_{i=1}^{n} f(i) \cdot \phi_k(i)$$

et

$$\mathscr{F}^{-1}(f)(i) = f(i) = \sum_{k=1}^{n} \hat{f}(k) \cdot \phi_k(i),$$

respectivement. Dans les expressions ci-haut, ϕ_k est le $k-$ème vecteur propre de Δ. En notation matricielle, on a

$$\hat{f} = \Phi^T f, \;\; f = \Phi \hat{f}.$$

a. On travaille toujours avec le graphe G de l'exercice 6.7. Soit un signal d'entrée $f \in L^2(V)$ donné par $f = (1,1,3)^T$. Calculer $\hat{f}$.

On pose Φ la matrice dont les colonnes sont les vecteurs propres de l'exercice précédent et $f = \begin{pmatrix} 1 \\ 1 \\ 3 \end{pmatrix}$. Alors, la transformée de Fourier de f est

$$\hat{f} = \Phi^T f = \begin{pmatrix} \varphi_1 \cdot f \\ \varphi_2 \cdot f \\ \varphi_3 \cdot f \end{pmatrix}.$$

b. Soit maintenant un filtre $h \in L^2(V)$, donné par $h = (1,1,0)$. Calculer $\hat{h}$.

Similairement,

$$\hat{h} = \Phi^T h = \begin{pmatrix} \varphi_1 \cdot h \\ \varphi_2 \cdot h \\ \varphi_3 \cdot h \end{pmatrix}.$$

c. Calculer la convolution $f * h$.

On utilise finalement le théorème de la convolution pour obtenir

$$\begin{aligned} f * h = \mathscr{F}^{-1} &= \left(\hat{f} \bullet \hat{h}\right) \\ &= \Phi \begin{pmatrix} (\varphi_1 \cdot f) \cdot (\varphi_1 \cdot h) \\ (\varphi_2 \cdot f) \cdot (\varphi_2 \cdot h) \\ (\varphi_3 \cdot f) \cdot (\varphi_3 \cdot h) \end{pmatrix}. \end{aligned}$$

7 RÉDUCTION SPECTRALE DE LA DIMENSION

Exercice 7.1 On considère la matrice symétrique A donnée par

$$A = \begin{pmatrix} 1 & 1 & 2 \\ 1 & 2 & -1 \\ 2 & -1 & 1 \end{pmatrix}.$$

a. Soit le vecteur $u = \begin{pmatrix} 1 \\ 2 \\ 1 \end{pmatrix}$. Calculer le quotient de Rayleigh $\mathscr{R}_A(u)$.

On rappelle que le quotient de Rayleigh est défini par

$$\mathscr{R}_A(u) = \frac{u^T Au}{u^T u}.$$

On calcule d'abord $Au = \begin{pmatrix} 5 \\ 5 \\ 1 \end{pmatrix}$. *Donc*

$$u^T Au = 1 \cdot 5 + 2 \cdot 5 + 1 \cdot 1 = 16.$$

De plus,

$$u^T u = ||u||^2 = 1^2 + 2^2 + 1^2 = 6.$$

Donc, le quotient de Rayleigh demandé est $R_A(u) = \frac{16}{6} = \frac{8}{3}$.

b. À l'aide d'un logiciel de calcul, trouvez les modes propres (i.e. les vecteurs et valeurs propres) de la matrice A.

On obtient

$$\lambda_1 = 3,\ \lambda_2 \approx 2.56,\ \lambda_3 \approx -1.56$$

et des vecteurs propres correspondants sont

$$\varphi_1 = \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix},\ \varphi_2 = \begin{pmatrix} -1 \\ -3.56 \\ 1 \end{pmatrix},\ \varphi_3 = \begin{pmatrix} -1 \\ 0.56 \\ 1 \end{pmatrix}.$$

On remarque enfin qu'on peut vérifier que ces vecteurs propres sont orthogonaux entre eux.

c. Pour chacun de ces vecteurs propres φ_i, $i = 1,2,3$, calculer le quotient de Rayleigh $\mathscr{R}_A(\varphi_i)$. Que remarquez-vous ?

On calcule directement

$$A\varphi_1 = 3\varphi_1 = \begin{pmatrix} 3 \\ 0 \\ 3 \end{pmatrix}$$

et donc $\varphi_1^T A\varphi_1 = 6$ *de telle sorte que*

$$\mathscr{R}_A(\varphi_1) = \frac{\varphi_1^T A\varphi_1}{\varphi_1^T \varphi_1} = \frac{6}{2} = 3 = \lambda_1.$$

De manière générale, si on a $Au = \lambda u$*, alors on obtient*

$$\mathscr{R}_A(u) = \frac{u^T Au}{u^T u} = \frac{u^T \lambda u}{u^T u} = \lambda \frac{u^T u}{u^T u} = \lambda.$$

Exercice 7.2 On considère le nuage de points $x^{(i)}$, $i = 1, 2, ..k$ suivant dans $\mathbb{R}^2$:

$$N = \{(1,1); (2,3); (0,0); (-1,-2), (3,4); (1,0)\}.$$

a. Représenter graphiquement le nuage de points dans le plan.

Notre nuage de points est le suivant :

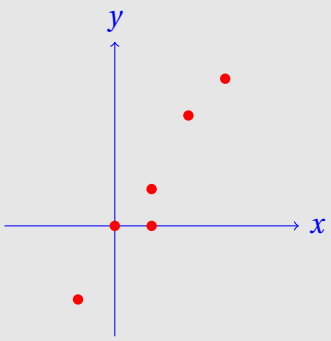

b. Procéder à l'analyse en composantes principales de N. Combien de composantes principales possède-t-il?

On forme d'abord la matrice

$$X = \begin{pmatrix} x^{(1)} \\ x^{(2)} \\ \cdots \\ x^{(6)} \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 2 & 3 \\ 0 & 0 \\ -1 & -2 \\ 3 & 4 \\ 1 & 0 \end{pmatrix}.$$

On peut ensuite considérer la matrice carrée de dimension 2

$$X^T X = \begin{pmatrix} 1 & 2 & 0 & -1 & 3 & 1 \\ 1 & 3 & 0 & -2 & 4 & 0 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 2 & 3 \\ 0 & 0 \\ -1 & -2 \\ 3 & 4 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 16 & 21 \\ 21 & 30 \end{pmatrix}.$$

Les composantes principales $w^{(1)}$ et $w^{(2)}$ sont les espaces propres de $X^T X$. On a

$$w^{(1)} = \begin{pmatrix} 0.7 \\ 1 \end{pmatrix}, \quad w^{(2)} = \begin{pmatrix} -1.4 \\ 1 \end{pmatrix}.$$

c. Utiliser la première composante principale pour définir l'application de réduction de la dimension

$$\Pi_1 : \mathbb{R}^2 \to \mathbb{R}.$$

L'espace engendré par la première composante principale est la droite L d'équation $y = 1.4 \cdot x$.

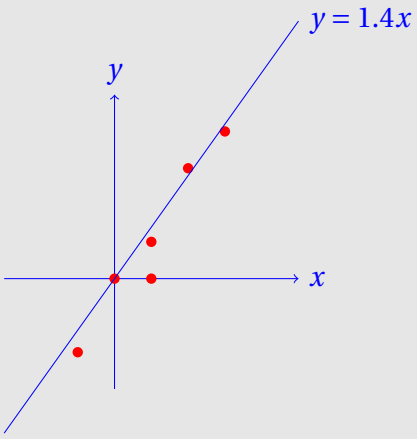

L'application de réduction de dimension est la projection orthogonale sur cette droite. Plus précisément, on a

$$\Pi_1 : \mathbb{R}^2 \to L \cong \mathbb{R}$$

avec

$$x^{(i)} \mapsto proj_L x^{(i)}.$$

d. Utiliser la projection Π_1 pour projeter le points $x^{(3)}$ sur un espace de dimension 1.

Puisque $x^{(3)}$ appartient à la droite L, sa projection sur celle-ci est triviale. On a donc

$$proj_L x^{(3)} = (0,0).$$

Exercice 7.3 On considère un nuage contenant m points de $\mathbb{R}^n$.

a. Au plus, combien de composantes principales possède-t-il?

Au plus n composantes principales.

b. On veut définir une projection Π_k pour réduire la dimension vers $\mathbb{R}^k$. Quelles sont les valeurs possibles pour k?

Il faut bien sûr que k soit strictement plus petit que n.

Exercice 7.4 On considère le nuage contenant les 4 points suivants

$$(1,2);(2,1);(0,0);(1,0).$$

On se propose de développer l'algorithme de Belkin-Niyagi pour réduire la dimension de ces points en les projetant sur un espace de dimension 1.

a. Calculer les distances entre les points et déterminer si chaque paire potentielle fait partie de l'ensemble $\mathscr{E}$ des arêtes en fixant le seuil à $\epsilon = 2$.

On calcule les distances

$$d(i,j) = ||x^{(i)} - x^{j}||$$

entre $x^{(i)}$ et $x^{(j)}$ pour toute paire i, j avec $i \neq j$. On a

- $d(1,2) = \left((1-2)^2 + (2-1)^2\right)^{\frac{1}{2}} = \sqrt{2} \approx 1.41 \leq \epsilon = 2$ ✓ $(1,2) \in \mathscr{E}$.
- $d(1,3) = \left((2^2 + (1^2)\right)^{\frac{1}{2}} = \sqrt{5} > \epsilon = 2$.
- $d(1,4) = \left((1-1)^2 + (2-0)^2\right)^{\frac{1}{2}} = 2 \leq \epsilon = 2$ ✓ $(1,4) \in \mathscr{E}$.
- $d(2,3) = \sqrt{5} > \epsilon$.
- $d(2,4) = \left((2-1)^2 + (1-0)^2\right)^{\frac{1}{2}} = \sqrt{2} \approx 1.41 \leq \epsilon = 2$ ✓ $(2,4) \in \mathscr{E}$.
- $d(3,4) = 1 < \epsilon$ ✓ $(3,4) \in \mathscr{E}$.

b. En utilisant les noyaux de la chaleur, assigner un poids à chacun des éléments de $\mathscr{E}$.

On rappelle que la technique du noyau de la chaleur pour fournir un poids entre deux sommets connectés d'un graphe vise à établir une analogie avec la quantité de chaleur qui pourrait se transmettre entre les deux. On définit la quantité suivante

$$W_{ij} = e^{-\frac{d^2(i,j)}{t}},$$

où $t > 0$ est le temps écoulé de diffusion de la chaleur. On fixe ici

$$t = 1$$

pour simplifier les calculs. On a donc

- $W_{12} = e^{-2} \approx 0.14$.
- $W_{14} = e^{-4} \approx 0.02$.
- $W_{24} = e^{-2} \approx 0.14$.
- $W_{34} = e^{-1} \approx 0.37$.

c. Calculer les degrés des sommets pour construire la matrice diagonale des degrés, la matrice d'adjacence des poids et enfin trouver les modes propres du laplacien normalisé Δ sur ce graphe.

On calcule d'abord les degrés :

- $\deg(1) = 0.14 + 0.02 = 0.16.$
- $\deg(2) = 0.14 + 0.14 = 0.28.$
- $\deg(3) = 0.37.$
- $\deg(4) = 0.02 + 0.14 + 0.37 = 0.53.$

La matrice D est simplement la matrice diagonale de dimension 4 telle que

$$D_{ii} = \deg(i), \ \ i = 1, ..., 4.$$

Donc $\Delta = D - W$ et on considère l'équation aux valeurs propres normalisée sur ce graphe

$$\Delta\varphi = \lambda D\varphi.$$

On note d'abord que cette équation peut-être réécrite ainsi

$$\left(D^{-1}\Delta\right)\varphi = \lambda\varphi.$$

On calcule d'abord

$$D^{-1}\Delta = \begin{pmatrix} (0,16)^{-1} & 0 & 0 & 0 \\ 0 & (0,28)^{-1} & 0 & 0 \\ 0 & 0 & (0,37)^{-1} & 0 \\ 0 & 0 & 0 & (0,57)^{-1} \end{pmatrix} \cdot \begin{pmatrix} 0,16 & -0.14 & 0 & -0.02 \\ -0.14 & 0,28 & 0 & -0.14 \\ 0 & 0 & 0,37 & -0.37 \\ -0.02 & -0.14 & -0.37 & 0.53 \end{pmatrix} = \begin{pmatrix} 1 & -0.5 & 0 & -0.04 \\ -0.88 & 1 & 0 & -0.26 \\ 0 & 0 & 1 & -0.7 \\ -0.13 & -0.5 & -1 & 1 \end{pmatrix}.$$

On obtient

$$0 = \lambda_0 < \lambda_1 \approx 0.46 < \lambda_2 \approx 1.6 < \lambda_3 = 2.$$

Les vecteurs propres correspondants sont

$$\varphi_0 = \begin{pmatrix} 0.2 \\ 0.3 \\ 0.5 \\ 0.7 \end{pmatrix}, \varphi_1 = \begin{pmatrix} 0.5 \\ 0.5 \\ -0.6 \\ -0.4 \end{pmatrix}, \varphi_2 = \begin{pmatrix} 0.5 \\ -0.6 \\ 0.5 \\ -0.4 \end{pmatrix}, \varphi_3 = \begin{pmatrix} 0.1 \\ -0.3 \\ -0.5 \\ 0.7 \end{pmatrix}.$$

d. Définir la projection spectrale ainsi obtenue.

Suivant l'algorithme de Belkin-Niyogi, on définit la projection $\Pi_1 : \mathbb{R}^2 \to \mathbb{R}$ *par*

$$x^{(i)} \mapsto \varphi_1(i).$$

8 AUTOENCODEURS VARIATIONNELS

Exercice 8.1 Calculer l'entropie H des distributions probabilistes suivantes. On rappelle que l'entropie d'une distribution discrète est donnée par

$$H(p) = -\sum_i p(x_i)\log_2(p(x_i)).$$

Pour la version continue supportée sur $\mathbb{R}$, il faut remplacer la somme par une intégrale et on obtient

$$H(p) = -\int_{\mathbb{R}} p(x)\log_2(p(x))\,\mathrm{d}x.$$

a. La distribution du lancer d'une pièce de monnaie équilibrée.

On définit les événements

$$x_1 = \text{"pile"}, x_2 = \text{"face"}.$$

On a évidemment

$$p(x_1) = p(x_2) = \frac{1}{2}.$$

Donc, l'entropie H de p est donnée par

$$H(p) = \frac{1}{2}\log_2(2)\frac{1}{2}\log_2(2) = 1.$$

b. La distribution d'un lancer de dé à 6 faces.

On définit l'événement

$$x(i) = \text{"obtenir i"},$$

et on a $p(x_i) = \frac{1}{6}$. L'entropie H de la distribution p est donnée par

$$H(p) = -\sum_{i=1}^{6} p(x_i)\log_2 p(x_i) = 6\left(\frac{1}{6}\log_2(6)\right) \approx 2.6.$$

c. La distribution $p(x)$ décrite par la fonction de masse suivante

$$p(x_1) = \frac{1}{8},\ p(x_2) = \frac{3}{8},\ p(x_3) = \frac{1}{2}.$$

On calcule directement

$$\begin{aligned} H(p) &= -\sum_{i=1}^{3} p(x_i)\log(p(x_i)) \\ &= \frac{1}{8}\log_2(8) = \frac{3}{8}\log_2\left(\frac{8}{3}\right) + \frac{1}{2}\log_2(2) \\ &= \frac{1}{8}\cdot 3 + \frac{3}{8}\cdot(1.41) + \frac{1}{2}\cdot 2 \\ &\approx 1,4. \end{aligned}$$

d. Une distribution discrète uniforme supportée sur n événements, i.e.

$$p(x_i) = \frac{1}{n}, \text{ pour } i = 1,2...n.$$

On utilise l'uniformité de la distribution pour directement calculer

$$H(p) = -\sum_{i=1}^{n} p(x_i)\log_2(p(x_i)) = n\left(\frac{1}{n}\log_2(n)\right) = \log_2(n).$$

Dans un tel contexte de distribution uniforme, on constate donc que l'entropie est monotone croissante en n.

e. Une gaussienne $N(0,1)$, c'est-à-dire une loi normale centrée réduite.

La densité $p(x)$ de la normale centrée réduite $N(0,1)$ est

$$p(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}.$$

Ainsi, l'entropie de cette gaussienne est

$$-\int_{\mathbb{R}} p(x)\log(p(x))\,dx \approx 1.42.$$

Exercice 8.2 Soit les distributions discrètes p, q, r supportées sur l'ensemble $\{1,2,3\}$ et respectivement données par les fonctions de masse suivantes

$$p(1) = p(2) = p(3) = \frac{1}{3},$$

$$q(1) = q(3) = \frac{1}{6}, q(2) = \frac{2}{3}$$

et

$$r(1) = r(2) = \frac{1}{12}, r(3) = \frac{5}{6}$$

On rappelle que l'entropie croisée d'une distribution q par rapport à une distribution p est donnée par

$$H(p,q) = -\sum_i p(x_i)\log_2(q(x_i)).$$

De plus, la divergence de Kullback-Leibler est donnée par

$$D_{KL}(p||q) = H(p,q) - H(p).$$

Calculez les quantités demandées.

a. $H(p,q)$.

On calcule directement

$$\begin{aligned} H(p,q) = -E_{x\sim p}(\log_2 q) &= -\sum_{i=1}^{3} p(x_i)\log_2(q(x_i)) \\ &= \frac{1}{3}\left(\log_2 12 + \log_2 12 + \log_2 \frac{6}{5}\right) \\ &\approx 2.48. \end{aligned}$$

b. $H(p,r)$.

Cette fois-ci, on a

$$\begin{aligned} H(p,q) = -E_{x\sim p}(\log_2 q) &= -\sum_{i=1}^{3} p(x_i)\log_2(q(x_i)) \\ &= \frac{1}{3}\left(\log_2 6 + \log_2 6 + \log_2 \frac{3}{2}\right) \\ &\approx 1.92. \end{aligned}$$

c. $H(q,p)$.

Cette fois-ci, on a

$$\begin{aligned} H(p,q) = -E_{x\sim q}(\log_2 p) &= -\sum_{i=1}^{3} q(x_i)\log_2(p(x_i)) \\ &= \frac{1}{6}\log_2(3) + \frac{2}{3}\log_2(3) + \frac{1}{6}\log_2(3) \\ &\approx 1.58. \end{aligned}$$

d. $D_{KL}(p||p)$.

On calcule directement la KL-divergence

$$D_{KL}(p||p) = H(p,p) - H(p) = H(p) - H(p) = 0.$$

e. $D_{KL}(p||q)$.

Ici, on a

$$D_{KL}(p||q) = H(p,q) - H(p) = 1.92 - \log_2(3) \approx 0.36$$

f. $D_{KL}(q||p)$.

On a

$$D_{KL}(q||p) = H(q,p) - H(q) = \approx 0.33$$

g. $D_{KL}(p||r)$.

Finalement,

$$D_{KL}(p||r) = H(p,r) - H(p) = \approx 0.9.$$

Exercice 8.3 Donnez les 4 distributions théoriques sous-jacentes au développement d'un autoencodeur variationnel et indiquez de quelle manière elles sont reliées entre elles par le théorème de Bayes.

On a les distributions théoriques suivantes

- $p(x)$ *: évidence.*
- $p(x|z)$ *: vraisemblance.*
- $p(z|x)$ *: postérieure.*
- $p(z)$ *: antérieure.*

Dans ce contexte, on considère x comme une donnée et z comme une variable latente. C'est le théorème de Bayes qui nous permet de relier ces distributions théoriques, via la formule

$$p(z|x) = \frac{p(x|z)p(z)}{p(x)}.$$

© Guillaume Roy-Fortin, 2024.

1.3 Plan de cours

École de technologie supérieure

Le génie pour l'industrie

Responsable(s) de cours : Eric Paquette

PLAN DE COURS

Été 2023

MTI881 : Sujets spéciaux I : technologies de l'information (3 crédits)

Aspects mathématiques de l'apprentissage profond

Préalables

Aucun préalable requis

Descriptif du cours

Sujets d'intérêt majeur dans le domaine des technologies de l'information et familiarisation avec les derniers développements technologiques dans un ou plusieurs domaines de pointe. Sujets particuliers dans différentes spécialités du domaine des technologies de l'information. Le sujet proposé peut varier à chaque fois que cette activité est mise à l'horaire.
Cours offerts à la **session d'été 2023** :

- Aspects mathématiques de l'apprentissage profond

Objectifs du cours

L'objectif du cours est d'utiliser les mathématiques pour explorer certains aspects du fonctionnement des réseaux de neurones profonds.

Plus précisément, au terme de ce cours, l'étudiant sera notamment en mesure

- De comprendre les fondements du fonctionnement des réseaux de neurones profonds et d'interpréter mathématiquement la mécanique de ceux-ci.
- D'utiliser différents outils mathématiques pour améliorer l'implémentation d'un réseau de neurones.
- D'identifier et de comprendre certains obstacles à l'apprentissage et d'expliquer mathématiquement le fonctionnement de certaines techniques de régularisation.
- De comprendre différents aspects théoriques des réseaux de neurones, notamment leur universalité et le rôle de la profondeur dans l'expressivité.
- De comprendre les fondements de l'apprentissage géométrique et d'identifier les aspects mathématiques à considérer dans la confection d'un réseau qui vise à apprendre sur des espaces non-euclidiens.
- D'expliquer le fonctionnement mathématique de certaines techniques de réduction de la dimension.
- De comprendre les principes probabilistes permettant la réalisation d'un autoencodeur variationnel.
- D'expliquer certains concepts mis de l'avant dans la recherche récente sur l'apprentissage géométrique tel que décrit dans l'article de Bronstein et al.
- D'expliquer les principes mathématiques qui permettent la conception de larges modèles de language comme ChatGPT.
- De lire certains articles scientifiques de pointe sur la recherche active en *deep learning* et d'en expliquer les idées principales.

Les thèmes suivants seront abordés :
Rappels d'algèbre linéaire et de calcul différentiel. Structure d'un réseau de neurones, hyperparamètres, activation et propagation avant. Équations de la propagation arrière. Problèmes d'apprentissage, régularisation, fonctions de coût, distance et entropie croisée. Problèmes de grands et petits gradients. Universalité, théorème de Cybenko. Rôle de la profondeur dans la puissance expressive, théorème de Telgarsky. Apprentissage profond géométrique, théorie spectrale du graphe-Laplacien. Réduction de la dimension, analyse en composantes principales. Séparation, astuce du noyau, algorithmes de Belkin-Niyogi. Introduction aux variétés différentielles, espaces et plongements hyperboliques. Éléments de la théorie des probabilités, distributions, théorème de Bayes. Entropie croisée, divergence de Kullback-Liebler, maximum de vraisemblance. Autoencodeurs et autoencodeurs variationnels. Apprentissage géométrique : grilles, groupes, graphes et géodésiques. Transformers. Modèle de diffusion.

Stratégies pédagogiques

Le cours se donne sous forme magistrale (3 heures par semaine) en classe et parfois sur Zoom. Lorsque le cours aura lieu en ligne, les étudiants seront avertis quelques jours d'avance. Les notes de cours seront écrites au tableau (ou au tableau blanc) et du matériel numérique sera également offert au besoin. Un feuillet hebdomadaire d'exercices sera distribué sur Moodle.

Utilisation d'appareils électroniques

Les ordinateurs sont permis lors de l'enseignement magistral.
Aucun enregistrement (photographie, film ou audio) n'est permis sans permission préalable de l'enseignant.

Horaire

Groupe	Jour	Heure	Activité
01	Jeudi	13:30 - 17:00	Activité de cours

Coordonnées de l'enseignant

Groupe	Nom	Activité	Courriel	Local	Disponibilité
01	Guillaume Roy-Fortin	Activité de cours	Guillaume.Roy-Fortin@etsmtl.ca	B-1606	

Cours

Cette section présente le plan de cours prévu. Il est à noter que l'ordre des thématiques abordées et des laboratoires peut changer au cours du trimestre. Référez-vous au site web du cours (Moodle) pour le calendrier à jour. À noter également que les durées pour chacun des sujets sont fournies à titre indicatif seulement.

I. L'APPRENTISSAGE DES RÉSEAUX DE NEURONES PROFONDS

- Introduction aux réseaux de neurones profonds et rappels d'algèbre linéaire et de calcul différentiel. (4 heures)
- Propagation avant, descente de gradient et équations de la rétropropagation. (3 heures)
- Problèmes d'apprentissage : régularisation, fonctions de coût, grands et petits gradients. (3 heures)

II. ASPECTS THÉORIQUES

- Universalité : théorèmes de Cybenko et Hornik. (2 heures)
- Puissance expressive et profondeur : théorèmes de Telgarsky et Eldan-Shamir. (3 heures)

III. RÉDUCTION DE LA DIMENSION

- Analyse en composantes principales, autoencodeurs. Algorithme de Belkin-Niyogi, opérateurs symétriques, plongements et décomposition spectrale. (5 heures)

IV. APPRENTISSAGE GÉOMÉTRIQUE

- Apprentissage non-euclidien : réseaux de convolution, théorie spectrale du graphe-Laplacien, théorie de Fourier. (4 heures)
- Autoencodeurs variationnels: distributions, divergence, théorie de l'information, entropie. (4 heures)
- Apprentissage géométrique : Grilles, Groupes, Graphes et Géodésques (l'approche de Bronstein et al.) (3 heures)

V. MODÈLES AVANCÉS

- Modèles génératifs de diffusion stable (DALL-E, Midjourney). (2 heures)
- Structure mathématique des transformers. (3 heures)

V. PRÉSENTATIONS

- Présentation par équipe des projets de session. (3 heures)

Laboratoires et travaux pratiques

Projet de session

- Le projet de session consiste à choisir un article scientifique relié aux thèmes vus dans le cours, de l'explorer et en tirer une présentation qui décrira : le contexte de l'article, les résultats principaux, les applications ainsi que les possibilités de continuation.
- Ce projet devra être effectué en équipe de 3 ou 4 et la dernière séance de la session sera consacrée à vos présentations.
- Les équipes seront libres de choisir un article de leur choix, qui devra être approuvé. Une liste d'articles potentiels parmi lesquels vous pourriez éventuellement choisir vous sera également transmise.

Projet de recherche	40 %
Proposition (choix de l'article, thème général)	5 % semaine 4
Revue de littérature (livres, autres articles)	5 % semaine 7
Rapport écrit	15 % semaine 13
Présentation	15 % semaine 13

De plus, vous serez évalués individuellement sur ce projet de recherche à la fin de la session, pour obtenir une note qui vaudra pour 20 % de la note finale.

Évaluation

En équipe :

- Travail de session : 40 %

Individuellement (60 %) :

- Examen intra : 15 %
- Examen final : 25 %
- Présentation individuelle du travail de session : 20 %

Notons que l'examen final est un *take home* dont les modalités exactes de retour seront annoncées vers la fin de la session.

Dates des examens intra

Groupe(s)	Date
1	15 juin 2023

Politique de retard des travaux

Tout travail (devoir pratique, rapport de laboratoire, rapport de projet, etc.) remis en retard sans motif valable, c'est-à-dire autre que ceux mentionnés dans le Règlement des études (1er cycle, article 7.2.7 b / cycles supérieurs, article 6.5.4 b) se verra attribuer la note zéro, à moins que d'autres dispositions ne soient communiquées par écrit par l'enseignant dans les consignes de chaque travail à remettre ou dans le plan de cours pour l'ensemble des travaux.

Dispositions additionnelles

Les dates de remise des travaux doivent être respectées. Une pénalité de 20 % par jour de retard sera applicable aux travaux qui ne sont pas remis à temps.

Absence à un examen

Dans les cinq (5) jours ouvrables suivant la tenue de son examen, l'étudiant devra justifier son absence d'un examen durant le trimestre auprès de la coordonnatrice – Affaires départementales qui en référera au directeur de département. Pour un examen final, l'étudiant devra justifier son absence auprès du Bureau du registraire. Toute absence non justifiée par un motif majeur (maladie certifiée par un billet de médecin, décès d'un parent immédiat ou autre) à un examen entraînera l'attribution de la note (0).

Plagiat et fraude

Les clauses du « Règlement sur les infractions de nature académique de l'ÉTS » s'appliquent dans ce cours ainsi que dans tous les cours du département. Les étudiants doivent consulter le *Règlement sur les infractions de nature académique* (https://www.etsmtl.ca/docs/ETS/Gouvernance/Secretariat-general/Cadre-reglementaire/Documents/Infractions-nature-academique) pour identifier les actes considérés comme étant des infractions de nature académique ainsi que prendre connaissance des sanctions prévues à cet effet. À l'ÉTS, le respect de la propriété intellectuelle est une valeur essentielle et les étudiants sont invités à consulter la page *Citer, pas plagier !* (https://www.etsmtl.ca/Etudiants-actuels/Baccalaureat/Citer-pas-plagier).

Documentation obligatoire

Aucune documentation obligatoire. Les notes de cours seront écrites au tableau et sont la seule documentation nécessaire pour le cours.

Ouvrages de références

Livres

- Goodfellow, I., Bengio, Y., Courville, A. and Bengio, Y., 2016. *Deep learning* (Vol. 1, No. 2). Cambridge: MIT press.
- Nielsen, M.A., 2015. *Neural networks and deep learning* (Vol. 2018). San Francisco, CA: Determination press.
- Barber, D., 2012. *Bayesian reasoning and machine learning*. Cambridge University Press.
- Lay, D.C., 2003. Linear algebra and its applications.
- Stewart, J., 2009. *Calculus: Concepts and contexts*. Cengage Learning.

Articles

- Cybenko, G., 1989. Approximation by superpositions of a sigmoidal function. *Mathematics of control, signals and systems*, *2*(4), pp.303-314.
- Hornik, K., 1991. Approximation capabilities of multilayer feedforward networks. *Neural networks*, *4*(2), pp.251-257.
- Telgarsky, M., 2015. Representation benefits of deep feedforward networks. *arXiv preprint arXiv:1509.08101*.
- Eldan, R. and Shamir, O., 2016, June. The power of depth for feedforward neural networks. In *Conference on learning theory* (pp. 907-940).
- Hanin, B., 2018. Which neural net architectures give rise to exploding and vanishing gradients?. In *Advances in Neural Information Processing Systems* (pp. 582-591).
- Bronstein, M.M., Bruna, J., LeCun, Y., Szlam, A. and Vandergheynst, P., 2017. Geometric deep learning: going beyond euclidean data. *IEEE Signal Processing Magazine*, *34*(4), pp.18-42.
- Belkin, M. and Niyogi, P., 2003. Laplacian eigenmaps for dimensionality reduction and data representation. *Neural computation*, *15*(6), pp.1373-1396.
- Kingma, D.P. and Welling, M., 2019. An introduction to variational autoencoders. *arXiv preprint arXiv:1906.02691*.
- Creswell, A., White, T., Dumoulin, V., Arulkumaran, K., Sengupta, B. and Bharath, A.A., 2018. Generative adversarial networks: An overview. *IEEE Signal Processing Magazine*, *35*(1), pp.53-65.
- Morizet, N., 2020. *Introduction to Generative Adversarial Networks* (Doctoral dissertation, Advestis).
- Nickel, M. and Kiela, D., 2017. Poincaré embeddings for learning hierarchical representations. In *Advances in neural information processing systems* (pp. 6338-6347).
- Mathieu, E., Le Lan, C., Maddison, C.J., Tomioka, R. and Teh, Y.W., 2019. Continuous hierarchical representations with poincaré variational auto-encoders. In *Advances in neural information processing systems* (pp. 12565-12576).
- Goodfellow, I., 2016. NIPS 2016 tutorial: Generative adversarial networks. *arXiv preprint arXiv:1701.00160*.

Adresse internet du site de cours et autres liens utiles

Moodle: https://ena.etsmtl.ca/
Site web de l'enseignant: https://groyfortin.github.io

1.4 Évaluations

MTI880 - MATHÉMATIQUES DE L'APPRENTISSAGE PROFOND

Examen intra

HIVER 2021

DIRECTIVES :
- La durée totale de l'examen intra est de 3 heures.
- Cet intra est sur 100 et compte pour 20% de la note finale.
- Indiquer clairement votre démarche.
- Documentation permise : toute documentation permise.
- Aucun acte de plagiat, de tentative de plagiat ou de participation à un plagiat ne sera toléré.

Question 1 (6pts.)

Soit la matrice

$$A = \begin{pmatrix} 3 & 2 & 4 \\ 2 & 0 & 2 \\ 4 & 2 & 3 \end{pmatrix}.$$

Vérifier que A est symétrique. De plus, pour chacun des vecteurs suivants, dire s'il s'agit d'un vecteur propre de A et, le cas échéant, fournir la valeur propre correspondante.

$$\vec{u} = \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix}, \vec{v} = \begin{pmatrix} 2 \\ 1 \\ 2 \end{pmatrix}, \vec{w} = \begin{pmatrix} -1 \\ 0 \\ 2 \end{pmatrix}.$$

Question 2 (10pts.)

Soit la fonction

$$g(x, y, z) = x^2 + y^2 + z^4,$$

définie pour tous les $(x, y, z) \in \mathbb{R}^3$. On fixe un point initial

$$x_0 = (1, 0, -1).$$

Compléter les deux premières itérations d'une descente de gradient visant à converger vers le minimum local (et global) de g à l'origine, avec le taux d'apprentissage fixé à $\eta = \frac{1}{4}$.

Question 3 (6pts.)

À votre avis, laquelle des quatre équations fondamentales vues en classe justifie le plus le nom de *rétropropagation* ou de *propagation arrière*, le processus utilisé pour mettre efficacement à jour les poids et biais pendant l'apprentissage d'un réseau ? Écrire l'équation et justifier.

Question 4 (20pts.)

Soit le réseau de neurones $\mathscr{F}$ représenté ci-dessous.

Pour l'initialiser, nous fixons tout d'abord les poids suivants :

$$w_{11}^2 = 1, w_{11}^3 = 2,$$

ainsi que le biais suivants

$$b_1^2 = 1.$$

On suppose donc que seul le neurone du centre possède un biais. Pour les besoins de cette question, on utilise la fonction identité comme fonction d'activation $\sigma(z) = z$.

a. Placer les différents paramètres à l'endroit approprié sur le graphe du réseau.

b. Quelle fonction $\mathscr{F}$ calcule-t-il? Fournir le domaine, l'ensemble d'arrivée ainsi que la définition explicite de $\mathscr{F}$.

On suppose maintenant que l'on voudrait faire apprendre à ce réseau à diviser par deux. Plus formellement, la fonction idéale que cherche à approximer $\mathscr{F}$ est donnée par $y : \mathbb{R} \to \mathbb{R}$ avec $y(x) = \frac{x}{2}$. On suppose aussi que nos données d'entraînement sont les nombres entiers naturels, i.e. $X_n = n,\ n \in \mathbb{N}$.

c. Donner la définition de la fonction de coût basée sur l'erreur quadratique moyenne (MSE), c'est-à-dire celle vue en classe.

d. Calculer les sorties $a^L(X_n)$ du réseau pour $n = 1,2$ de même que les sorties attendues $y(X_n)$ pour ces mêmes données d'entraînement.

On veut maintenant modifier les réglages de notre réseau de manière à améliorer ses performances. Plus précisément, on veut mettre à jour les poids et biais pour diminuer l'erreur C. Pour ce faire, nous devrons procéder à une descente de gradient.

e. Calculer le vecteur gradient ∇C en considérant la fonction de coût C comme une fonction des deux poids et du biais.

Note : comme ce réseau est très petit, il n'y a pas lieu ici d'utiliser les équations de la rétropropagation pour calculer les dérivées partielles composant le gradient.

f. Fixer le taux d'apprentissage $\eta = \frac{1}{10}$ et faire une première itération de la descente de gradient en mettant à jour les poids et biais.

Note : On suppose ici et pour le reste de l'exercice qu'il n'y a qu'une seule donnée d'entraînement fixée, soit x=2.

g. Quelle est la nouvelle fonction $\mathscr{F}_1$ que calcule désormais le réseau ainsi mis à jour? Cette fonction est-elle effectivement plus *proche* de la fonction cible $y = \frac{1}{2}x$? Expliquer.

Question 5 (12pts.)

Soit un réseau de neurones complètement connexe $\mathscr{F}$ contenant 4 couches de largeurs respectives $d_1 = 10, d_2 = 20, d_3 = 100$ et $d_4 = 20$.

a. La réseau est représenté par la fonction $\mathscr{F}$ qui est définie sur quel domaine? Et à valeur dans quel espace?

b. Quelle est la profondeur de ce réseau?

c. Combien de biais b_j^ℓ ce réseau compte-t-il? Et quel est le nombre total de poids w_{jk}^ℓ de $\mathscr{F}$?

d. Combien de paramètres doit-on initialiser avant de faire une première propagation avant?

e. Donner un exemple de distribution probabiliste à partir de laquelle vous pourriez initialiser les poids w_{jk}^3 entrant dans la troisième couche de manière à respecter les hypothèses du théorème de Hanin-Rolnick permettant d'éviter l'échec d'apprentissage du premier type.

Question 6 (12pts.)

On rappelle qu'une *fonction simple* est une combinaison linéaire de fonctions indicatrices, c'est-à-dire qu'elles sont de la forme

$$s(x) = \sum_{i=1}^{N} \alpha_i \chi_{(a_i,b_i)},$$

et où $\alpha_i \chi_{(a_i,b_i)}$ est la fonction indicatrice de l'intervalle (a_i, b_i), c'est-à-dire la fonction qui prend la valeur 1 si $x \in (a_i, b_i)$ et 0 sinon.

Soit maintenant la fonction $f : [0, \pi] \to \mathbb{R}$ donnée par $f(x) = \sin(x)$.

a. Approximez f par une fonction simple qui contient un morceau.

b. Approximez f par une fonction simple qui contient deux morceaux.

c. Approximez f par une fonction simple qui contient quatre morceaux.

Note : vous pouvez utiliser la TI ou un logiciel de calcul pour évaluer les intégrales donnant l'amplitude des fonctions indicatrices formant la fonction simple demandée.

Question 7 (10pts.)

On se place dans le contexte du test de classification à n-points dont nous avons discuté en classe en prélude au théorème de Telgarsky. On rappelle que la discrétisation $\tilde{f}$ d'une fonction $f : [0,1] \to \mathbb{R}$ est donnée par

$$\tilde{f}(x) = \begin{cases} 1 & \text{si } f(x) \geq \frac{1}{2} \\ 0 & \text{si } f(x) < \frac{1}{2} \end{cases}$$

L'erreur $E(f)$ associé à f est alors définie comme la proportion des n-points qui ont été mal classés par cette discrétisation, c'est-à-dire

$$E(f) = \frac{1}{2^n} \sum \chi \left\{ \tilde{f}(x_i) \neq y_i \right\}.$$

On considère la fonction $f(x) = 2x^3$ sur l'intervalle $[0,1]$. Calculez $E(f)$ pour le test de classification avec $n = 1, 2, 3$.

Question 8 (12pts.)

On suppose qu'un réseau de convolution reçoit en entrée une image de format de 16×16 pixels.

a. Combien de neurones possède la couche d'entrée de ce réseau?

b. Si vous créez un filtre h de taille $4x4$, quelles dimensions aura la sortie obtenue par la convolution de l'image initiale avec h?

c. Quelle propriété typique des images vise-t-on à exploiter lorsqu'on implémente une couche de pooling dans un réseau de convolution?

Question 9 (12pts.)

Pour chacun des énoncés suivants, répondre par VRAI ou FAUX. Lorsque vous répondez faux, justifiez.

a. Pour éviter l'échec d'apprentissage du premier type d'un réseau contenant L couches de 20 neurones chacune, on peut choisir d'initialiser les poids et biais à partir de distribution normales de moyenne zéro et de variance égale à $\frac{1}{10}$.

b. La fonction d'entropie-croisée a l'avantage de faire disparaître la dérivée de l'activation comme facteur multiplicatif dans les composantes de son gradient, soit les dérivées partielles par rapport aux poids et biais, et c'est précisément pourquoi elle permet d'éviter les problèmes d'apprentissage qui affectaient l'usage conjoint de la fonction d'erreur quadratique moyenne et d'une activation sigmoïdale.

c. Il est possible d'appliquer le théorème de Cybenko en choisissant tout simplement la fonction identité comme activation, i.e. en fixant $\sigma(z) = z$.

d. Soit un réseau qui calcule une fonction $f(x)$. Alors, le réseau obtenu en recopiant 3 fois le premier calcule $3f(x)$.

e. Un réseau complètement connexe qui contient L couches toutes de dimension d possède $d^2(L-1)+dL$ paramètres.

f. Le cours MTI880 est merveilleux, exaltant et une source intense de bonheur dans cette vie pandémique!

© Guillaume Roy-Fortin, 2021.

MTI880 - MATHÉMATIQUES DE L'APPRENTISSAGE PROFOND

Examen final

HIVER 2021

DIRECTIVES :
- Indiquer clairement votre démarche.
- Documentation permise : toute documentation permise.
- Aucun acte de plagiat, de tentative de plagiat ou de participation à un plagiat ne sera toléré.

Question 1 (18pts.)

Soit le graphe G donné par les sommets $V = \{1,2,3,4\}$ et la matrice d'adjacence des poids

$$W = \begin{pmatrix} 0 & 1 & 1 & 3 \\ 1 & 0 & 2 & 0 \\ 1 & 2 & 0 & 1 \\ 3 & 0 & 1 & 0 \end{pmatrix}.$$

a. Dessiner le le graphe G en indiquant les poids reliés à chacune des arêtes qu'il possède.

b. Soit la fonction $u \in L^2(V)$, donnée par $u = (1,0,2,-1)^T$. Calculer ∇u.

c. Calculer le g-laplacien de u, soit $-\Delta u = -\text{div}\nabla u$.

d. Calculer la matrice diagonale des degrés, soit

$$D = \text{diag}\{\text{deg}(1), \text{deg}(2), \text{deg}(3), \text{deg}(4)\}.$$

e. Donner l'expression matricielle du g-laplacien $\Delta = -(D - W)$ et utiliser celle-ci pour calculer de nouveau le vecteur Δu.

f. Est-ce que les vecteurs propres de D sont orthogonaux? Justifier.

g. Est-ce que les vecteurs propres de Δ sont orthogonaux? Justifier.

Question 2 (10pts.)

Soit deux fonctions $f, h \in \mathbb{R}^4$ définies sur un graphe à 4 sommets et telles que leur transformée de Fourier sont respectivement données par

$$\hat{f} = (1,-1,2,0)^T, \quad \text{et } \hat{h} = (2,1,0,3)^T.$$

Calculer la transformée de Fourier de la convolution de f et h, soit $\mathscr{F}(f * h)$.

Question 3 (14pts.)

On considère le nuage de points $x^{(i)}$, $i = 1,2,..5$ suivant dans $\mathbb{R}^3$:

$$N = \{(1,1,0);(0,2,3);(0,0,0);(-1,0,1),(1,3,4)\}.$$

a. Faire l'analyse en composantes principales de N. Combien de composantes principales possède-t-il?

b. Utiliser la première composante principale pour définir l'application de réduction de la dimension

$$\Pi_1 : \mathbb{R}^3 \to \mathbb{R}.$$

c. Similairement, utiliser les deux premières composantes principales pour définir l'application de réduction de la dimension

$$\Pi_2 : \mathbb{R}^3 \to \mathbb{R}^2.$$

Question 4 (18pts.)

On considère le nuage de points $x^{(i)}$, $i = 1,2,..5$ suivant dans $\mathbb{R}^2$:

$$N = \{(-1,-2);(1,1);(3,0);(-1,-1);(0,0)\}.$$

a. En fixant $\epsilon = 3$, construire le graphe non-pondéré G associé à ces points en connectant deux sommets i et j si

$$||x^{(i)} - x^{(j)}|| \leq \epsilon.$$

Décrire explicitement les éléments de l'ensemble $\mathscr{E}$ des arêtes ainsi créé.

b. On veut utiliser les noyaux de la chaleur pour donner des poids aux arêtes que l'on vient de créer. Plus précisément, calculer

$$W_{ij} = e^{-\frac{||x^{(i)} - x^{(j)}||^2}{t}}$$

pour $(i,j) \in \mathscr{E}$ et avec $t = 1$.

c. Nous avons maintenant complètement construit le graphe $G = (V, \mathscr{E}, W)$ qui représente le nuage de points N. Calculer les modes propres du laplacien Δ associé à ce graphe.

d. Définir explicitement le plongement

$$\Pi_1 : \mathbb{R}^2 \to \mathbb{R}^1$$

et s'en servir pour réduire la dimension des éléments de N.

Question 5 (12pts.)

Soit les distributions discrètes p, q supportées sur l'ensemble $\{1,2,3,4\}$ et respectivement données par les fonctions de masse suivantes

$$p(1) = p(2) = \frac{1}{4}, p(3) = \frac{1}{8}, p(4) = \frac{3}{8};$$

et

$$q(1) = q(2) = q(3) = \frac{1}{12}, q(4) = \frac{3}{4}.$$

Calculer les quantités demandées.

a. $I(p(1))$.
b. $H(p,q)$.
c. $H(q,p)$.
d. $H(p,p)$.
e. $D_{KL}(p||q)$.
f. $D_{KL}(q||p)$.

Question 6 (18pts.)

Expliquer en vos mots et en une page tout au plus les grandes lignes du fonctionnement de base d'un autoencodeur variationnel. Au besoin, produire un dessin ou un schéma pour supporter votre explication.

Question 7 (10pts.)

Pour chacun des énoncés suivants, répondre par VRAI ou FAUX. Lorsque vous répondez faux, justifiez.

a. De toutes les distributions discrètes supportées sur $\{1,2,...,n\}$, c'est la distribution uniforme dont la fonction de masse est donnée par

$$p(i) = \frac{1}{n},\ i = 1,2,...,n.$$

qui minimise l'entropie $H(p)$.

b. Il existe deux distributions continues p, q supportées sur $\mathbb{R}$ et telles que pour au moins un $x \in \mathbb{R}$, on a $p(x) \neq q(x)$ et pour lesquelles la divergence de Kullback-Leibler $D_{KL}(p||q)$ est égale à 0.

c. Soit une distribution discrète p. Alors, pour toute distribution q ayant le même support que p, on a

$$H(p,q) \geq H(p).$$

d. Dans le contexte d'un autoencodeur variationnel, minimiser ELBO revient à maximiser la fonction de coût

$$l_i(\theta, \phi) := H(q_\theta(z|x_i), p_\phi(x_i|z)) - D_{KL}(q_\theta(z|x_i) \,||\, p(z)).$$

e. Pour toute matrice A de dimension $m \times n$, il est possible de définir le quotient de Rayleigh $\mathscr{R}_A$ associé à A.

© Guillaume Roy-Fortin, 2021.

2

Cours MAT472

2.1 Exercices pour la portion algèbre linéaire

École de technologie supérieure
Département des enseignements généraux
Local B-2500 514-396-8938
Site internet : `http://www.etsmtl.ca/`

MAT472
Algèbre linéaire et géométrie de l'espace

Exercices d'algèbre linéaire

Rédigées par
Guillaume Roy-Fortin

HIVER 2025

Ce document est mis à disposition selon les termes de la licence Creative Commons Attribution - Pas d'Utilisation Commerciale - Pas de Modification 4.0 International.

Table des matières

1 Semaine 8 **5**
1.1 Systèmes d'équations linéaires 5
1.2 Algèbre matricielle 6

2 Semaine 9 **9**
2.1 Matrices inverses de dimension 2 et l'équation matricielle 9
2.2 Espaces vectoriels euclidiens 10
2.3 Méthode du pivot de Gauss 11

3 Semaine 10 **15**
3.1 Transformations linéaires et matrices canoniques 15
3.2 Transformations linéaires du plan 17
3.3 Coordonnées homogènes 17

4 Semaine 11 **19**
4.1 Combinaisons linéaires, espaces engendrés 19
4.2 Indépendance linéaire 20
4.3 Sous-espaces vectoriels, bases, coordonnées. 21

5 Semaine 12 **25**
5.1 Noyau et image d'une transformation linéaire 25

6 Semaine 13 **27**
6.1 Valeurs et vecteurs propres 27
6.2 Polynôme caractéristique 28
6.3 Espaces propres, diagonalisation et puissances de matrices 29

Semaine 8

1.1 Systèmes d'équations linéaires

Problème 1.1.1.
On considère le système d'équations linéaires suivant :

$$\begin{cases} 2x + 3y = 1 \\ -3x + y = 4 \end{cases}$$

Résoudre ce système. Autrement dit, trouver, si possible, toutes les solutions du système. Ensuite, représenter graphiquement votre solution.

Problème 1.1.2.
On considère le système d'équations linéaires suivant :

$$\begin{cases} 5x - y = 3 \\ -10x + 2y = 0 \end{cases}$$

Résoudre ce système. Autrement dit, trouver, si possible, toutes les solutions du système. Ensuite, représenter graphiquement votre solution.

Problème 1.1.3.
On considère le système d'équations linéaires suivant :

$$\begin{cases} 2x + y = -1 \\ 4x + 2y = -2 \end{cases}$$

Résoudre ce système. Autrement dit, trouver, si possible, toutes les solutions du système. Ensuite, représenter graphiquement votre solution.

Problème 1.1.4.
On considère le système d'équations linéaires suivant :

$$\begin{cases} 2x + y + z = 1 \\ 2x + y = 0 \\ x + y + z = -1 \end{cases}$$

Résoudre ce système. Autrement dit, trouver, si possible, toutes les solutions du système. Ensuite, représenter graphiquement votre solution.

1.2 Algèbre matricielle

Pour les problèmes de cette section, on considère les matrices suivantes.

$$A = \begin{pmatrix} 1 & -2 & 5 \\ -3 & 1 & -4 \end{pmatrix}, \quad B = \begin{pmatrix} 0 & 4 & 1 \\ 2 & -1 & 3 \end{pmatrix}, \quad C = \begin{pmatrix} 4 & 1 \\ 2 & -3 \end{pmatrix},$$

$$D = \begin{pmatrix} -2 & 0 \\ 1 & -6 \end{pmatrix}, \quad E = \begin{pmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{pmatrix}.$$

Problème 1.2.1. Effectuer, si possible, les calculs suivants. Si une opération n'est pas définie, justifier.

$$(a) \ -3A \quad (b) \ A+B \quad (c) \ 2A+D \quad (d) \ -4C+4D \quad (e) \ D-E \quad (f) \ -3A+B$$

Problème 1.2.2. Effectuer, si possible, les multiplications matricielles suivantes. Si une opération n'est pas définie, justifier.

$$(a) \ CD \quad (b) \ DC \quad (c) \ AB \quad (d) \ AE.$$

Problème 1.2.3. Effectuer, si possible, les transpositions matricielles suivantes. Si une opération n'est pas définie, justifier.

$$(a)\ \ A^T \quad (b)\ \ (A+B)^T \quad (c)\ \ 2A^T \quad (d)\ \ (AB)^T.$$

Problème 1.2.4. (TI) On considère les deux matrices 3×3 suivantes :

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 0 & 1 & 4 \\ 5 & 6 & 0 \end{pmatrix}, \quad B = \begin{pmatrix} -24 & 18 & 5 \\ 20 & -15 & -4 \\ -5 & 4 & 1 \end{pmatrix}$$

Calculer AB et BA. Que remarquez-vous ?

Problème 1.2.5. On considère la matrice $A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$. Montrer que la matrice

$$A^{-1} = \frac{1}{ad-bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

est l'inverse de la matrice A.

Problème 1.2.6. Soit A une matrice 7×3 et B une matrice telle que le produit AB est une matrice 7×5. Quelles sont les dimensions de la matrice B ?

Problème 1.2.7. Combien la matrice A compte-t-elle de lignes si AB est une matrice 3×6 ?

Problème 1.2.8. On pose $A = \begin{pmatrix} 3 & -6 \\ -1 & 2 \end{pmatrix}$. Construire une matrice B de dimension 2×2 et constituée de deux colonnes non-nulles distinctes telles que que le produit AB soit la matrice nulle.

Semaine 9

2.1 Matrices inverses de dimension 2 et l'équation matricielle

Problème 2.1.1. Déterminer, si possible, l'inverse des matrices suivantes.

$$(a)\begin{pmatrix}7 & 5\\ 3 & -1\end{pmatrix} \quad (b)\begin{pmatrix}1 & 2\\ 3 & 4\end{pmatrix} \quad (c)\begin{pmatrix}-2 & 3\\ -4 & 6\end{pmatrix} \quad (d)\begin{pmatrix}3 & -4\\ 7 & -8\end{pmatrix}$$

.

Problème 2.1.2. On considère le système d'équations linéaires suivant

$$\begin{cases}3x - 2y = 2\\ x - 2y = 5\end{cases}$$

On se propose d'utiliser la matrice inverse A^{-1} de la matrice des coefficients A pour trouver, si possible, la solution de ce système.

(a) Écrire ce S.E.L. sous la forme d'une équation matricielle $A\boldsymbol{x} = \boldsymbol{b}$.

(b) Calculer la matrice inverse A^{-1}.

(c) Donner la solution du système

Problème 2.1.3. Soit le système d'équations linéaires suivant

$$\begin{cases}x_1 + 2x_2 = -4\\ 3x_1 - x_2 = 5,\end{cases}$$

(a) En utilisant l'algorithme du pivot de Gauss, trouver, si possible, la solution de ce système.

(b) En utilisant la méthode de la matrice inverse, trouver, si possible, la solution de ce système.

Problème 2.1.4. Soit le système d'équations linéaires suivant

$$\begin{cases} ax_1 + bx_2 = b_1 \\ cx_1 + dx_2 = b_2, \end{cases}$$

où a, b, c, d et b_1, b_2 sont des nombres réels.

(a) Sous quelle condition le système admet-il une solution unique ?

(b) Sous quelle condition le système admet-il une infinité de solutions ?

(c) Sous quelle condition le système n'admet-il aucune solution ?

2.2 Espaces vectoriels euclidiens

Problème 2.2.1. Exprimer les vecteurs suivants comme combinaison linéaire des vecteurs de la base canonique de $\mathbb{R}^d$.

Remarque : un objectif secondaire de cet exercice est de souligner à quel point il existe différentes manières d'écrire la même information, le même vecteur.

(a) $\boldsymbol{u} = (1, -2, 0, 3)$

(b) $\boldsymbol{w} = \begin{pmatrix} 1 \\ -2 \\ 0 \\ 3 \end{pmatrix}$

(c) $\boldsymbol{x} = \begin{pmatrix} x_1 & x_2 & x_3 \end{pmatrix}$

(d) $\boldsymbol{u} = \begin{pmatrix} 1 & -1 & 2 & 1 & 4 \end{pmatrix}^T$

2.3 Méthode du pivot de Gauss

Problème 2.3.1. Dire quels sont les critères pour qu'une matrice soit dans une forme échelonnée. Et quels sont les critères *supplémentaires* pour qu'on puisse dire que celle-ci est échelonnée réduite ?

Problème 2.3.2. Dire si les matrices suivantes sont dans une forme échelonnée, échelonnée réduite ou ni un ni l'autre. Justifier ses réponses.

(a) $\begin{pmatrix} 1 & 2 & 0 & 1 \\ 0 & 1 & 2 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$ (b) $\begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \end{pmatrix}$ (c) $\begin{pmatrix} 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 \end{pmatrix}$ (d) $\begin{pmatrix} 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 1 \end{pmatrix}$

Problème 2.3.3. Dire si les matrices suivantes sont dans une forme échelonnée, échelonnée réduite ou ni un ni l'autre. Justifier ses réponses.

(a) $\begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$ (b) $\begin{pmatrix} 3 & 0 & 0 \\ 0 & 0 & -1 \\ 0 & 0 & 0 \end{pmatrix}$ (c) $\begin{pmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix}$ (d) $\begin{pmatrix} 1 & 0 & 0 & 3 & 0 \\ 0 & 1 & 0 & 1 & 1 \end{pmatrix}$

Problème 2.3.4. Dire quelles sont les opérations élémentaires que l'on peut effectuer sur les lignes d'une matrice pour échelonner celle-ci. Pourquoi dit-on que ce sont des opérations *élémentaires* ?

Problème 2.3.5. Utiliser l'algorithme de Gauss pour donner la forme échelonnée réduite de chacune des matrices suivantes. Donner le rang de chacune des matrices.

(a) $\begin{pmatrix} 3 & 2 \\ 6 & 1 \end{pmatrix}$ (b) $\begin{pmatrix} 2 & -1 \\ -4 & 2 \end{pmatrix}$ (c) $\begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{pmatrix}$ (d) $\begin{pmatrix} 1 & 0 & 2 & 0 \\ -2 & 3 & 1 & 1 \end{pmatrix}$

Problème 2.3.6. Soit le système d'équations linéaires suivant

$$\begin{cases} x + 2y + 3z = 6 \\ 2x - y + z = 3 \\ 3x + y - 2z = 4. \end{cases}$$

(a) Écrire ce système sous forme d'une matrice augmentée $[A|\boldsymbol{b}]$.

(b) Appliquer l'algorithme de Gauss pour obtenir la forme échelonnée réduite de $[A|\boldsymbol{b}]$.

(c) Décrire l'espace de solutions du système initial.

Problème 2.3.7. Soit le système d'équations linéaires suivant

$$\begin{cases} x_1 + 2x_2 - 5x_3 = 2 \\ -x_2 + x_3 = -1. \end{cases}$$

(a) Écrire ce système sous forme d'une matrice augmentée $[A|\boldsymbol{b}]$.

(b) Appliquer l'algorithme de Gauss pour obtenir la forme échelonnée réduite de $[A|\boldsymbol{b}]$.

(c) Décrire l'espace de solutions du système initial.

Problème 2.3.8. Soit le système d'équations linéaires suivant

$$\begin{cases} 2x_1 + 4x_2 = 2 \\ -x_1 + x_2 = 0 \\ 3x_1 - 5x_2 = 1 \end{cases}$$

(a) Écrire ce système sous forme d'une matrice augmentée $[A|\boldsymbol{b}]$.

(b) Appliquer l'algorithme de Gauss pour obtenir la forme échelonnée réduite de $[A|\boldsymbol{b}]$.

(c) Décrire l'espace de solutions du système initial.

Problème 2.3.9. (TI) Soit le système d'équations linéaires suivant

$$\begin{cases} 2x_1 + 4x_2 - x_3 + x_4 - x_5 + x_6 = 1 \\ -6x_1 + x_2 + 3x_3 - 2x_4 + 3x_5 + 2x_6 = 5 \\ -2x_1 + 3x_2 + x_3 - 5x_4 - x_5 + 3x_6 = -2 \\ 4x_1 - 2x_2 + 3x_3 - x_4 + x_5 + 2x_6 = 0 \end{cases}$$

(a) Supposons que ce système est représenté par une matrice augmentée $[A|\boldsymbol{b}]$. Quelles sont les dimensions de A ? et de $(A|\boldsymbol{b})$?

(b) Est-il possible que ce système possède une solution unique ?

(c) Utiliser la commande *rref* de la TI pour obtenir la forme échelonnée réduite de la matrice $[A|\boldsymbol{b}]$ et décrire la nature de l'espace de solution de ce système.

Problème 2.3.10. Répondre par VRAI ou FAUX. Justifier.

(a) Si un système de m équations à n inconnues possède une solution unique, alors $m = n$.

(b) Si un système possède plus d'équations que d'inconnues, alors il ne peut pas admettre une solution unique.

(c) Si un système possède plus d'inconnues que d'équations, alors il ne peut pas admettre une solution unique.

(d) Soit A une matrice 2×2 dont le déterminant vaut zéro. Alors, tout S.E.L. dont A est la matrice des coefficients ne possède aucune solution.

Semaine 10

3.1 Transformations linéaires et matrices canoniques

Problème 3.1.1. Soit la matrice

$$A = \begin{pmatrix} 3 & 1 \\ -1 & 7 \end{pmatrix}.$$

On considère la transformation linéaire T donnée par $T(\boldsymbol{x}) = A\boldsymbol{x}$.

(a) Donner le domaine et l'ensemble d'arrivée de T.

(b) Donner l'image par T des vecteurs suivants :

$$\boldsymbol{u} = \begin{pmatrix} -3 \\ 1 \end{pmatrix}, \boldsymbol{v} = \begin{pmatrix} 1 \\ 4 \end{pmatrix}, \mathbf{0} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

(c) Trouver un vecteur $\boldsymbol{x}$ tel que

$$T(\boldsymbol{x}) = \begin{pmatrix} 20 \\ 8 \end{pmatrix}.$$

(d) Soit deux scalaires arbitraires $\alpha, \beta \in \mathbb{R}$ et deux vecteurs

$$\boldsymbol{u} = \begin{pmatrix} u_1 \\ u_2 \end{pmatrix}, \text{ et } \boldsymbol{v} = \begin{pmatrix} v_1 \\ v_2 \end{pmatrix}.$$

Montrer que T est une transformation linéaire, c'est-à-dire montrer que

$$T(\alpha\boldsymbol{u} + \beta\boldsymbol{v}) = \alpha T(\boldsymbol{u}) + \beta T(\boldsymbol{v}).$$

Problème 3.1.2. Soit la matrice

$$A = \begin{pmatrix} 1 & 2 & 1 \\ -1 & 2 & 5 \end{pmatrix}.$$

On considère la transformation linéaire T donnée par $T(\boldsymbol{x}) = A\boldsymbol{x}$.

(a) Donner le domaine et l'ensemble d'arrivée de T.

(b) Donner l'image par T des vecteurs suivants :

$$\boldsymbol{u} = \begin{pmatrix} 1 \\ 7 \\ 0 \end{pmatrix}, \boldsymbol{v} = \begin{pmatrix} -4 \\ 1 \\ 1 \end{pmatrix}, \mathbf{0} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}.$$

(c) Trouver, si possible, un vecteur $\boldsymbol{x}$ tel que

$$T(\boldsymbol{x}) = \begin{pmatrix} 8 \\ 18 \end{pmatrix}.$$

(d) Soit deux scalaires arbitraires $\alpha, \beta \in \mathbb{R}$ et deux vecteurs

$$\boldsymbol{u} = \begin{pmatrix} u_1 \\ u_2 \\ u_3 \end{pmatrix}, \text{ et } \boldsymbol{v} = \begin{pmatrix} v_1 \\ v_2 \\ v_3 \end{pmatrix}.$$

Montrer que T est une transformation linéaire, c'est-à-dire montrer que

$$T(\alpha\boldsymbol{u} + \beta\boldsymbol{v}) = \alpha T(\boldsymbol{u}) + \beta T(\boldsymbol{v}).$$

Problème 3.1.3. Soit A une matrice 12×3. Donner les valeurs de m et n pour que l'on puisse considérer A comme la matrice canonique d'une transformation

$$T : \mathbb{R}^n \to \mathbb{R}^m,$$

donnée par $T(\boldsymbol{x}) = A\boldsymbol{x}$.

Problème 3.1.4. Donner la matrice canonique des transformations linéaires suivantes.

(a) $T : \mathbb{R}^4 \to \mathbb{R}^2$, avec

$$T(\boldsymbol{e_1}) = \begin{pmatrix} -1 \\ 1 \end{pmatrix}, T(\boldsymbol{e_2}) = \begin{pmatrix} 3 \\ 0 \end{pmatrix}, T(\boldsymbol{e_3}) = \begin{pmatrix} -4 \\ 3 \end{pmatrix}, T(\boldsymbol{e_4}) = \begin{pmatrix} 6 \\ 1 \end{pmatrix}.$$

(b) $T : \mathbb{R}^2 \to \mathbb{R}^3$, avec

$$T\left[\begin{pmatrix}1\\0\end{pmatrix}\right] = \begin{pmatrix}1\\2\\3\end{pmatrix}, \quad T\left[\begin{pmatrix}0\\1\end{pmatrix}\right] = \begin{pmatrix}-2\\6\\0\end{pmatrix}.$$

(c) $T : \mathbb{R}^3 \to \mathbb{R}^3$, avec

$$T\left[\begin{pmatrix}1\\0\\4\end{pmatrix}\right] = \begin{pmatrix}-2\\1\\1\end{pmatrix}, \quad T\left[\begin{pmatrix}4\\1\\1\end{pmatrix}\right] = \begin{pmatrix}4\\1\\1\end{pmatrix}, \quad T\left[\begin{pmatrix}1\\6\\0\end{pmatrix}\right] = \begin{pmatrix}2\\-3\\1\end{pmatrix}.$$

(d) $T : \mathbb{R}^4 \to \mathbb{R}^2$, donnée par

$$T(x, y, z, w) = (x + y + z, x + 3y - 2z - w).$$

(e) $T : \mathbb{R}^2 \to \mathbb{R}^5$, donnée par

$$T(x, y) = (2x - y, 3x + 4y, x, 3y, 5x - 2y).$$

3.2 Transformations linéaires du plan

Problème 3.2.1. Donner la matrice canonique des transformations linéaires suivantes du plan.

(a) La transformation effectue une rotation de 45° autour de l'origine dans le sens anti-horaire.

(b) La transformation effectue une symétrie par rapport à l'axe horizontal x_1.

(c) La transformation effectue une symétrie par rapport à la droite $x_1 = x_2$.

(d) La transformation effectue d'abord une transvection horizontale qui laisse $\boldsymbol{e}_1$ inchangé et transforme $\boldsymbol{e}_2$ en $3\boldsymbol{e}_1 + \boldsymbol{e}_2$. Ensuite, la transformation effectue une homothétie de facteur $k = 4$.

(e) La transformation effectue d'abord une rotation d'angle $\frac{\pi}{6}$ pour ensuite effectuer un changement d'échelle de facteur $k_1 = 4$ sur l'axe horizontal pour enfin effectuer une symétrie verticale d'axe x_2.

3.3 Coordonnées homogènes

Problème 3.3.1. Supposons que la matrice canonique d'une transformation linéaire du plan est donnée par

$$A = \begin{pmatrix}a & b\\c & d\end{pmatrix}.$$

Donner la matrice qui représente cette transformation en coordonnées homogènes.

Problème 3.3.2. Donner une matrice 3×3 qui représente la transformation du plan en coordonnées homogènes.

(a) La translation de vecteur $(1, 4)$.

(b) La rotation de $90°$ autour du point $C(-1, 3)$.

(c) Rotation d'angle $45°$ autour de l'origine, suivie d'une symétrie verticale d'axe x_2.

(d) La translation de vecteur $(2, 5)$ suivie d'une symétrie d'axe $x_1 = -x_2$.

Semaine 11

4.1 Combinaisons linéaires, espaces engendrés

Problème 4.1.1. On considère la famille suivante de vecteurs

$$H = \{\boldsymbol{u}_1, \boldsymbol{u}_2\} = \left\{ \begin{pmatrix} 1 \\ 3 \end{pmatrix}, \begin{pmatrix} -2 \\ 4 \end{pmatrix} \right\}.$$

Exprimer chacun des vecteurs suivants comme une combinaison linéaire des vecteurs de H.

(a) $\boldsymbol{b} = \begin{pmatrix} -3 \\ 11 \end{pmatrix}$,

(b) $\boldsymbol{w} = \begin{pmatrix} 0 \\ 5 \end{pmatrix}$,

(c) $\mathbf{0} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$,

(d) $\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$.

Enfin, quel est $\text{span}(H)$, l'espace engendré par la famille H ?

Problème 4.1.2. (TI) On considère la famille suivante de vecteurs

$$H = \{\boldsymbol{u}_1, \boldsymbol{u}_2\} = \left\{ \begin{pmatrix} -1 \\ 2 \\ 3 \end{pmatrix}, \begin{pmatrix} 2 \\ 0 \\ 4 \end{pmatrix} \right\}.$$

Exprimer, si possible, les vecteurs suivants comme une combinaison linéaire des vecteurs de H.

(a) $\boldsymbol{b} = \begin{pmatrix} 3 \\ 5 \\ -2 \end{pmatrix}$,

(b) $\boldsymbol{w} = \begin{pmatrix} 1 \\ 2 \\ 7 \end{pmatrix}$,

(c) $\mathbf{0} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$.

Enfin, quel est span(H), l'espace engendré par la famille H ?

Problème 4.1.3. (TI) On considère la famille suivante de vecteurs

$$H = \{\boldsymbol{u}_1, \boldsymbol{u}_2, \boldsymbol{u}_3\} = \left\{ \begin{pmatrix} -1 \\ 2 \\ 3 \end{pmatrix}, \begin{pmatrix} 2 \\ 0 \\ 4 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} \right\}.$$

Exprimer, si possible, les vecteurs suivants comme une combinaison linéaire des vecteurs de H.

(a) $\boldsymbol{b} = \begin{pmatrix} 3 \\ 5 \\ -2 \end{pmatrix}$,

(b) $\boldsymbol{w} = \begin{pmatrix} 1 \\ 2 \\ 7 \end{pmatrix}$,

(c) $\mathbf{0} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$.

Problème 4.1.4. Construire *trois* exemples de matrices de dimensions différentes et pour chacune d'elle montrer que la multiplication matricielle $A\boldsymbol{x}$ revient à former une combinaison linéaire des vecteurs colonnes de A, combinaison pour laquelle les coefficients sont précisément les composantes du vecteur $\boldsymbol{x}$ qui est multiplié.

4.2 Indépendance linéaire

Problème 4.2.1. Soit $H = \{\boldsymbol{u}_1, \boldsymbol{u}_2, ..., \boldsymbol{u}_k\}$ une collection de k vecteurs de $\mathbb{R}^n$. Donner deux définitions équivalentes qui caractérisent l'indépendance linéaire de la famille de vecteurs H.

Problème 4.2.2. Comment déterminer directement si une famille contenant précisément 2 vecteurs est linéairement indépendante, peu importe la dimension de ceux-ci ?

Problème 4.2.3. Supposons que le famille H contient k vecteurs de $\mathbb{R}^n$, avec $k > n$. Que peut-on affirmer sur l'indépendance linéaire des vecteurs de H ?

Problème 4.2.4. Dire si les familles de vecteurs suivantes sont linéairement indépendantes ou non.

(a) $H = \left\{ \begin{pmatrix} 2 \\ 11 \end{pmatrix}, \begin{pmatrix} -1 \\ 3 \end{pmatrix} \right\}$,

(b) $H = \left\{ \begin{pmatrix} 1 \\ 4 \end{pmatrix}, \begin{pmatrix} -5 \\ 3 \end{pmatrix}, \begin{pmatrix} 7 \\ 1 \end{pmatrix}, \begin{pmatrix} -4 \\ 0 \end{pmatrix} \right\}$,

(c) $H = \left\{ \begin{pmatrix} 2 \\ -5 \end{pmatrix}, \begin{pmatrix} -4 \\ 10 \end{pmatrix} \right\}$,

(d) $H = \left\{ \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \begin{pmatrix} -1 \\ 0 \\ 5 \end{pmatrix} \right\}$,

(e) $H = \left\{ \begin{pmatrix} -1 \\ 2 \\ 3 \end{pmatrix}, \begin{pmatrix} -3 \\ 6 \\ 9 \end{pmatrix} \right\}$,

(f) $H = \left\{ \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} \right\}$,

(g) $H = \left\{ \begin{pmatrix} -1 \\ 5 \\ 2 \end{pmatrix}, \begin{pmatrix} 0 \\ -1 \\ 1 \end{pmatrix}, \begin{pmatrix} -1 \\ 3 \\ 4 \end{pmatrix} \right\}$.

4.3 Sous-espaces vectoriels, bases, coordonnées.

Problème 4.3.1. Soit une famille de vecteurs $H = \{\boldsymbol{u}_1, \boldsymbol{u}_2, ..., \boldsymbol{u}_k\}$ de $\mathbb{R}^n$. Soit aussi un sous-espace vectoriel $E \subset \mathbb{R}^n$. Quelles sont les deux conditions que doit remplir la famille de vecteurs H pour être considérée comme une base de E ?

Problème 4.3.2. Combien de vecteurs exactement doit posséder une base de $\mathbb{R}^n$?

Problème 4.3.3. Quel test peut-on appliquer pour montrer directement que $\mathcal{B} = \{\boldsymbol{u}_1, \boldsymbol{u}_2\}$ forme une base de $\mathbb{R}^2$?

Problème 4.3.4. Quel test peut-on appliquer pour montrer directement que $\mathcal{B} = \{\boldsymbol{u}_1, \boldsymbol{u}_2, \boldsymbol{u}_3\}$ forme une base de $\mathbb{R}^3$?

Problème 4.3.5. On considère

$$\mathcal{B} = \left\{ \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \begin{pmatrix} -1 \\ 3 \end{pmatrix} \right\}.$$

(a) Montrer que $\mathcal{B}$ est une base de $\mathbb{R}^2$.

(b) Donner les coordonnées $(\boldsymbol{w})_{\mathcal{B}}$ du vecteur $\boldsymbol{w} = 3\boldsymbol{e_1} + 5\boldsymbol{e_2}$ dans cette base.

(c) Donner les coordonnées $(\boldsymbol{x})_{\mathcal{B}}$ d'un vecteur arbitraire $\boldsymbol{x} = x_1\boldsymbol{e}_1 + x_2\boldsymbol{e}_2$ dans cette base.

Problème 4.3.6. (TI) On considère

$$\mathcal{B} = \left\{ \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} -1 \\ 2 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \\ 2 \end{pmatrix} \right\}.$$

(a) Montrer que $\mathcal{B}$ est une base de $\mathbb{R}^3$.

(b) Donner les coordonnées $(\boldsymbol{w})_{\mathcal{B}}$ du vecteur $\boldsymbol{w} = \boldsymbol{e}_1 - 2\boldsymbol{e}_2 + \boldsymbol{e}_3$ dans cette base.

(c) Donner les coordonnées $(\boldsymbol{x})_{\mathcal{B}}$ d'un vecteur arbitraire $\boldsymbol{x} = x_1\boldsymbol{e}_1 + x_2\boldsymbol{e}_2 + x_3\boldsymbol{e}_3$ dans cette base.

Problème 4.3.7. (TI) Dire si les familles de vecteurs suivantes forment une base de l'espace indiqué ou non. Justifier.

(a) $H = \left\{ \begin{pmatrix} 2 \\ 11 \end{pmatrix}, \begin{pmatrix} -1 \\ 3 \end{pmatrix} \right\}$, $\mathbb{R}^2$.

(b) $H = \left\{ \begin{pmatrix} 1 \\ 4 \end{pmatrix}, \begin{pmatrix} -5 \\ 3 \end{pmatrix}, \begin{pmatrix} 7 \\ 1 \end{pmatrix}, \begin{pmatrix} -4 \\ 0 \end{pmatrix} \right\}$, $\mathbb{R}^2$.

(c) $H = \left\{ \begin{pmatrix} 2 \\ -5 \end{pmatrix}, \begin{pmatrix} -4 \\ 10 \end{pmatrix} \right\}$, $\mathbb{R}^2$.

(d) $H = \left\{ \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \begin{pmatrix} -1 \\ 0 \\ 5 \end{pmatrix} \right\}$, $\mathbb{R}^3$.

(e) $H = \left\{ \begin{pmatrix} 1 \\ -2 \\ -3 \end{pmatrix}, \begin{pmatrix} -3 \\ 6 \\ 9 \end{pmatrix} \right\}$, $\mathbb{R}^3$.

(f) $H = \left\{ \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} \right\}$, $\mathbb{R}^3$.

(g) $H = \left\{ \begin{pmatrix} -1 \\ 5 \\ 2 \end{pmatrix}, \begin{pmatrix} 0 \\ -1 \\ 1 \end{pmatrix}, \begin{pmatrix} -1 \\ 3 \\ 4 \end{pmatrix} \right\}$, $\mathbb{R}^3$.

Semaine 12

5.1 Noyau et image d'une transformation linéaire

Problème 5.1.1. On considère une matrice A ayant 11 lignes et 4 colonnes.

(a) Donner les dimensions du domaine et de l'ensemble d'arrivée de la transformation linéaire T dont A est la matrice canonique.

(b) L'espace nul (ou *noyau*) $\ker(A)$ est un sous-espace vectoriel de quel espace ?

(c) L'espace colonnes (ou *image*) $\mathrm{im}(A)$ est un sous-espace vectoriel de quel espace ?

Problème 5.1.2. Soit la matrice

$$A = \begin{pmatrix} -1 & 2 & 1 \\ 2 & -4 & 0 \\ 4 & -8 & 1 \end{pmatrix}.$$

(a) Est-ce que le vecteur $\boldsymbol{v} = \begin{pmatrix} 1 \\ -1 \\ 4 \end{pmatrix}$ fait partie de $\ker A$?

(b) Est-ce que le vecteur $\boldsymbol{w} = \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix}$ fait partie de $\ker A$?

(c) **(T.I.)** Est-ce que le vecteur $\boldsymbol{u} = \begin{pmatrix} 1 \\ -5 \\ 0 \end{pmatrix}$ fait partie de $\mathrm{im}A$?

(d) **(T.I.)** Est-ce que le vecteur $\boldsymbol{b} = \begin{pmatrix} 6 \\ -6 \\ 9 \end{pmatrix}$ fait partie de $\mathrm{im}A$?

Problème 5.1.3. Pour chacune des matrices suivantes, donner une base pour l'espace nul $\ker(A)$.

(a) $A = \begin{pmatrix} -1 & 3 & 2 & 1 \\ 2 & -2 & 1 & 4 \end{pmatrix}$,

(b) **(T.I.)** $A = \begin{pmatrix} -1 & 6 & 3 & 0 \\ 0 & 0 & 1 & 0 \end{pmatrix}$,

(c) **(T.I.)** $A = \begin{pmatrix} 1 & -2 & -3 \\ -2 & 1 & 0 \\ 3 & 1 & 5 \end{pmatrix}$,

(d) **(T.I.)** $A = \begin{pmatrix} 1 & -2 & 1 & 0 & 1 \\ 0 & 1 & 0 & -1 & 2 \\ 2 & 3 & 1 & 3 & 0 \end{pmatrix}$,

(e) $A = \begin{pmatrix} 1 & -2 & 1 \\ 3 & 2 & 0 \end{pmatrix}$.

Semaine 13

6.1 Valeurs et vecteurs propres

Problème 6.1.1. On considère la matrice

$$A = \begin{pmatrix} 4 & 1 \\ 2 & 3 \end{pmatrix}.$$

(a) Est-ce que le scalaire $\lambda = -3$ est une valeur propre de A ?

(b) Est-ce que le scalaire $\lambda = 5$ est une valeur propre de A ?

(c) Est-ce que le vecteur $\boldsymbol{v} = \begin{pmatrix} 1 \\ -2 \end{pmatrix}$ est un vecteur propre de A ? Si oui, à quelle valeur propre est-il associé ?

(d) Est-ce que le vecteur $\boldsymbol{w} = \begin{pmatrix} 2 \\ -5 \end{pmatrix}$ est un vecteur propre de A ? Si oui, à quelle valeur propre est-il associé ?

(e) Est-ce que le vecteur $\mathbf{0} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$ est un vecteur propre de A ? Si oui, à quelle valeur propre est-il associé ?

Problème 6.1.2. On considère la matrice

$$A = \begin{pmatrix} 3 & 7 & 9 \\ -4 & -5 & 1 \\ 2 & 4 & 4 \end{pmatrix}.$$

(a) Est-ce que le scalaire $\lambda = 7$ est une valeur propre de A ?

(b) Est-ce que le vecteur $\boldsymbol{v} = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$ est un vecteur propre de A ? Si oui, à quelle valeur propre est-il associé ?

(c) Est-ce que le vecteur $\boldsymbol{w} = \begin{pmatrix} 4 \\ -3 \\ 1 \end{pmatrix}$ est un vecteur propre de A ? Si oui, à quelle valeur propre est-il associé ?

6.2 Polynôme caractéristique

Problème 6.2.1. Soit la matrice

$$A = \begin{pmatrix} 7 & 4 \\ -3 & -1 \end{pmatrix}.$$

(a) Donner le polynôme caractéristique de la matrice A.

(b) Factoriser ce polynôme pour dresser une liste de toutes les valeurs propres de A, avec multiplicité le cas échéant.

Problème 6.2.2. Soit la matrice

$$B = \begin{pmatrix} 4 & -2 \\ -3 & 9 \end{pmatrix}.$$

(a) Donner le polynôme caractéristique de la matrice B.

(b) Factoriser ce polynôme pour dresser une liste de toutes les valeurs propres de B, avec multiplicité le cas échéant.

Problème 6.2.3. (T.I.) Soit la matrice

$$A = \begin{pmatrix} 4 & 0 & 1 \\ -2 & 1 & 0 \\ -2 & 0 & 1 \end{pmatrix}.$$

(a) Donner le polynôme caractéristique de la matrice A.

(b) Factoriser ce polynôme pour dresser une liste de toutes les valeurs propres de A, avec multiplicité le cas échéant.

Problème 6.2.4. (T.I.) Soit la matrice

$$D = \begin{pmatrix} 3 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}.$$

(a) Donner le polynôme caractéristique de la matrice A.

(b) Factoriser ce polynôme pour dresser une liste de toutes les valeurs propres de D, avec multiplicité le cas échéant.

6.3 Espaces propres, diagonalisation et puissances de matrices

Problème 6.3.1. On considère la matrice

$$A = \begin{pmatrix} 7 & 0 \\ 4 & 3 \end{pmatrix}.$$

(a) Vérifier que A admet deux valeurs propres distinctes, soit $\lambda_1 = 3$ et $\lambda_2 = 7$.

(b) Donner une base de l'espace propre E_7 qui contient tous les vecteurs propres associés à la valeur propre $\lambda = 7$.

(c) Donner une base de l'espace propre E_3.

(d) Diagonaliser la matrice A. Autrement dit, trouver une matrice inversible P et une matrice diagonale D telles que l'on puisse écrire $A = PDP^{-1}$.

(e) Donner une formule explicite pour A^k, la k-ème puissance de la matrice A, où $k \in \mathbb{N}$.

Problème 6.3.2. (T.I.) Soit la matrice

$$A = \begin{pmatrix} 4 & 0 & 1 \\ -2 & 1 & 0 \\ -2 & 0 & 1 \end{pmatrix}$$

(a) Trouver les valeurs propres de la matrice A.

(b) Donner une base de chacun des espaces propres associés.

(c) Diagonaliser la matrice A.

(d) Calculer A^5.

Problème 6.3.3. (T.I.) Soit la matrice

$$A = \begin{pmatrix} -1 & 4 & -2 \\ -3 & 4 & 0 \\ -3 & 1 & 3 \end{pmatrix}$$

Sachant que les valeurs propres de la matrice A sont $\lambda = 1, 2, 3$, trouver une base de chacun des espaces propres associés pour ensuite diagonaliser A.

Problème 6.3.4. (T.I.) Soit la matrice

$$A = \begin{pmatrix} 2 & 2 & 1 \\ 1 & 3 & 1 \\ 1 & 2 & 2 \end{pmatrix}$$

Diagonaliser la matrice A.

2.2 Solutions complètes des exercices

École de technologie supérieure
Département des enseignements généraux
Local B-2500 514-396-8938
Site internet : `http://www.etsmtl.ca/`

MAT472
Algèbre linéaire et géométrie de l'espace

Exercices et solutions d'algèbre linéaire

Rédigées par
Guillaume Roy-Fortin

HIVER 2025

Ce document est mis à disposition selon les termes de la licence Creative Commons Attribution - Pas d'Utilisation Commerciale - Pas de Modification 4.0 International.

Table des matières

1 Semaine 8 **5**
1.1 Systèmes d'équations linéaires 5
1.2 Algèbre matricielle 8

2 Semaine 9 **13**
2.1 Matrices inverses de dimension 2 et l'équation matricielle 13
2.2 Espaces vectoriels euclidiens 16
2.3 Méthode du pivot de Gauss 17

3 Semaine 10 **25**
3.1 Transformations linéaires et matrices canoniques 25
3.2 Transformations linéaires du plan 30
3.3 Coordonnées homogènes 33

4 Semaine 11 **37**
4.1 Combinaisons linéaires, espaces engendrés 37
4.2 Indépendance linéaire 43
4.3 Sous-espaces vectoriels, bases, coordonnées. 45

5 Semaine 12 **51**
5.1 Noyau et image d'une transformation linéaire 51

6 Semaine 13 **59**
6.1 Valeurs et vecteurs propres 59
6.2 Polynôme caractéristique 62
6.3 Espaces propres, diagonalisation et puissances de matrices 64

Semaine 8

1.1 Systèmes d'équations linéaires

Problème 1.1.1.
On considère le système d'équations linéaires suivant :

$$\begin{cases} 2x + 3y = 1 \\ -3x + y = 4 \end{cases}$$

Résoudre ce système. Autrement dit, trouver, si possible, toutes les solutions du système. Ensuite, représenter graphiquement votre solution.

Solution.
De la seconde équation, on obtient directement que

$$y = 4 + 3x.$$

En remplaçant, la première devient

$$2x + 3(4 + 3x) = 1.$$

Ainsi, on peut résoudre et obtenir $x = -1$, d'où on tire $y = 1$. Le système possède donc une solution unique $x = -1$, $y = 1$. Chaque équation représente une droite dans le plan. Ici, les droites ne sont pas parallèles et donc elles vont posséder un unique point d'intersection. Les coordonnées (x, y) de ce point indiquent la solution du système.

Problème 1.1.2.
On considère le système d'équations linéaires suivant :

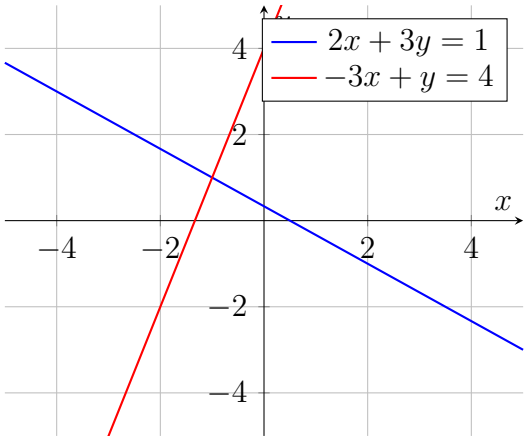

$$\begin{cases} 5x - y = 3 \\ -10x + 2y = 0 \end{cases}$$

Résoudre ce système. Autrement dit, trouver, si possible, toutes les solutions du système. Ensuite, représenter graphiquement votre solution.

SOLUTION. Comme cela arrivera souvent en algèbre linéaire, la manière de procéder n'est pas unique. Nous en proposons une parmi plusieurs. De la seconde équation, on obtient directement que

$$y = 5x.$$

Or, en remplaçant dans la première équation, on obtient $5x - 5x = 3$, c'est-à-dire $0 = 3$ ce qui est évidemment impossible. On dit alors que le système initial est *incompatible*.

Nous aurions également pu multiplier la première équation par -2, pour obtenir

$$-10x + 2y = -6,$$

et nous aurions alors eu deux équations dont le membre de gauche est identique mais avec une valeur numérique distincte dans le membre de droite.

Comment cela se représente-t-il visuellement ? Ici encore, chaque équation linéaire à deux inconnues représente une droite. Nous avons donc deux droites qui ne peuvent pas avoir d'intersection. La seule manière de réaliser une telle chose est d'avoir deux droites dans le plan qui sont parallèles.

Problème 1.1.3.

On considère le système d'équations linéaires suivant :

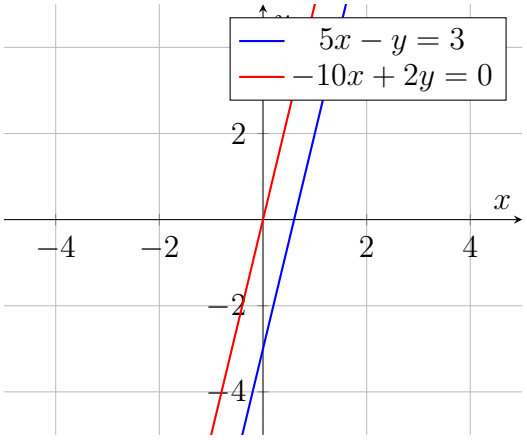

$$\begin{cases} 2x + y = -1 \\ 4x + 2y = -2 \end{cases}$$

Résoudre ce système. Autrement dit, trouver, si possible, toutes les solutions du système. Ensuite, représenter graphiquement votre solution.

Solution.

On remarque que si l'on multiplie la première égalité par deux, on obtient directement la seconde. Concrètement, cela veut dire que les deux équations sont équivalentes : *si une paire* (x, y) *est une solution de la première équation, elle est aussi une solution de l'autre et vice-versa.* En solutionnant, on obtient que tous les (x, y) tels que

$$y = -2x - 1$$

satisfont le système. Celui-ci possède donc une *infinité* de solutions, qui sont représentés géométriquement par la droite d'équation $y = -2x - 1$.

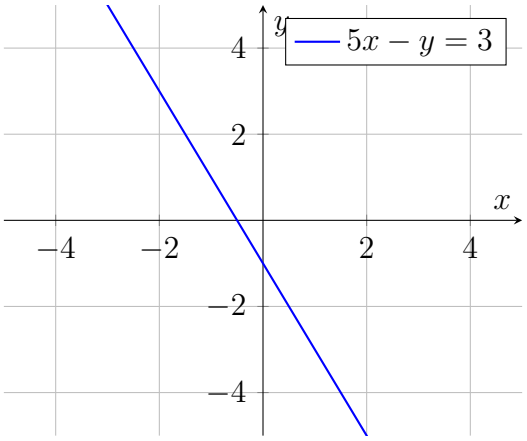

Problème 1.1.4.
On considère le système d'équations linéaires suivant :

$$\begin{cases} 2x + y + z = 1 \\ 2x + y = 0 \\ x + y + z = -1 \end{cases}$$

Résoudre ce système. Autrement dit, trouver, si possible, toutes les solutions du système. Ensuite, représenter graphiquement votre solution.

SOLUTION. Lorsqu'on fait face à un système d'équations linéaires général, il est important de considérer sa *typologie* : combien d'équations (lignes) avons-nous ? Et combien d'inconnues (colonnes) chaque équation possède-t-elle ? Dans le cas qui nous occupe, nous avons affaire à un système de 3 équations à 3 inconnues. Chaque équation linéaire à 3 inconnues définit un plan dans l'espace. Le système actuel décrit donc 3 plans dans $\mathbb{R}^3$ et nous devons chercher à déterminer la nature de l'intersection de ces plans.

Pour le moment, nous n'avons pas encore de méthode systématique pour résoudre de tels systèmes. Par contre, l'idée de base reste toujours la même : on utilise une équation pour isoler une variable par rapport aux autres. Ensuite, on utilise la simplification pour faire de même avec une autre équation et ainsi de suite.

La seconde équation nous donne

$$y = -2x,$$

et donc l'équation 3 devient

$$x - 2x + z = 1,$$

d'où on conclut que $z = 1 + x$. En remplaçant tout cela dans l'équation 1, on a enfin

$$2x + y + z = 2x - 2x + (1 + x) = 1 + x = 1.$$

Ainsi, $x = 1,\ y = -2$ et $z = 2$. Donc, le triple $(x, y, z) = (1, -2, 2)$ est l'unique solution de ce système. On peut voir ce point comme l'unique point d'intersection des 3 plans dont a discuté plus haut dans l'espace tridimensionnel $\mathbb{R}^3$.

1.2 Algèbre matricielle

Pour les problèmes de cette section, on considère les matrices suivantes.

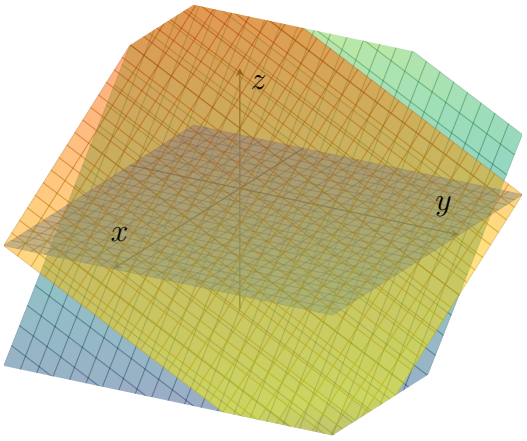

$$A = \begin{pmatrix} 1 & -2 & 5 \\ -3 & 1 & -4 \end{pmatrix}, \quad B = \begin{pmatrix} 0 & 4 & 1 \\ 2 & -1 & 3 \end{pmatrix}, \quad C = \begin{pmatrix} 4 & 1 \\ 2 & -3 \end{pmatrix},$$

$$D = \begin{pmatrix} -2 & 0 \\ 1 & -6 \end{pmatrix}, \quad E = \begin{pmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{pmatrix}.$$

Problème 1.2.1. Effectuer, si possible, les calculs suivants. Si une opération n'est pas définie, justifier.

$$(a)\ -3A \quad (b)\ A+B \quad (c)\ 2A+D \quad (d)\ -4C+4D \quad (e)\ D-E \quad (f)\ -3A+B$$

SOLUTION. Chacun de ces exercices est un calcul direct.

(a)
$$-3A = -3\begin{pmatrix} 1 & -2 & 5 \\ -3 & 1 & -4 \end{pmatrix} = \begin{pmatrix} -3 & 6 & -15 \\ 3 & -3 & 12 \end{pmatrix}.$$

(b)
$$A+B = \begin{pmatrix} 1 & -2 & 5 \\ -3 & 1 & -4 \end{pmatrix} + \begin{pmatrix} 0 & 4 & 1 \\ 2 & -1 & 3 \end{pmatrix} = \begin{pmatrix} 1 & 2 & 6 \\ -1 & 0 & -1 \end{pmatrix}.$$

(c) Les dimensions des matrices sont incompatibles pour l'addition.

(d)
$$-4C+4D = -4(C-D) = -4\left(\begin{pmatrix} 4 & 1 \\ 2 & -3 \end{pmatrix} - \begin{pmatrix} -2 & 0 \\ 1 & -6 \end{pmatrix}\right) = -4\begin{pmatrix} 6 & 1 \\ 1 & 3 \end{pmatrix} = \begin{pmatrix} -24 & -4 \\ -4 & -12 \end{pmatrix}.$$

(e) Dimensions incompatibles.

(f)
$$-3A + B = \begin{pmatrix} -3 & 6 & -15 \\ 3 & -3 & 12 \end{pmatrix} + \begin{pmatrix} 0 & 4 & 1 \\ 2 & -1 & 3 \end{pmatrix} = \begin{pmatrix} -3 & 10 & -14 \\ 5 & -4 & 15 \end{pmatrix}.$$

Problème 1.2.2. Effectuer, si possible, les multiplications matricielles suivantes. Si une opération n'est pas définie, justifier.

$$(a)\ CD \quad (b)\ DC \quad (c)\ AB \quad (d)\ AE.$$

SOLUTION.

(a)
$$CD = \begin{pmatrix} 4 & 1 \\ 2 & -3 \end{pmatrix} \begin{pmatrix} -2 & 0 \\ 1 & -6 \end{pmatrix} = \begin{pmatrix} -7 & -6 \\ -7 & 18 \end{pmatrix}.$$

(b)
$$DC = \begin{pmatrix} -2 & 0 \\ 1 & -6 \end{pmatrix} \begin{pmatrix} 4 & 1 \\ 2 & -3 \end{pmatrix} = \begin{pmatrix} -8 & -2 \\ -8 & 19 \end{pmatrix}.$$

On remarque en particulier que $CD \neq DC$ et que la multiplication matricielle n'est pas commutative.

(c) Comme A et B sont des matrices 2×3, la multiplication AB n'est pas définie.

(d)
$$AE = \begin{pmatrix} 1 & -2 & 5 \\ -3 & 1 & -4 \end{pmatrix} \begin{pmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{pmatrix} = \begin{pmatrix} 20 & 24 \\ -20 & -26 \end{pmatrix}.$$

Problème 1.2.3. Effectuer, si possible, les transpositions matricielles suivantes. Si une opération n'est pas définie, justifier.

$$(a)\ A^T \quad (b)\ (A+B)^T \quad (c)\ 2A^T \quad (d)\ (AB)^T.$$

SOLUTION.

(a)
$$A^T = \begin{pmatrix} 1 & -2 & 5 \\ -3 & 1 & -4 \end{pmatrix}^T = \begin{pmatrix} 1 & -3 \\ -2 & 1 \\ 5 & -4 \end{pmatrix}.$$

(b)
$$(A+B)^T = A^T + B^T = \begin{pmatrix} 1 & -3 \\ -2 & 1 \\ 5 & -4 \end{pmatrix} + \begin{pmatrix} 0 & 2 \\ 4 & -1 \\ 1 & 3 \end{pmatrix} = \begin{pmatrix} 1 & -1 \\ 2 & 0 \\ 6 & -1 \end{pmatrix}.$$

(c)
$$2A^T = 2\begin{pmatrix} 1 & -2 & 5 \\ -3 & 1 & -4 \end{pmatrix}^T = \begin{pmatrix} 2 & -6 \\ -4 & 2 \\ 10 & -8 \end{pmatrix}.$$

(d) La multiplication AB n'étant pas définie, cette opération est impossible.

Problème 1.2.4. (TI) On considère les deux matrices 3×3 suivantes :

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 0 & 1 & 4 \\ 5 & 6 & 0 \end{pmatrix}, \quad B = \begin{pmatrix} -24 & 18 & 5 \\ 20 & -15 & -4 \\ -5 & 4 & 1 \end{pmatrix}$$

Calculer AB et BA. Que remarquez-vous ?

SOLUTION. Avec la TI, on remarque directement que

$$AB = BA = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} = I_3$$

où I_3 désigne la matrice identité d'ordre 3. Ainsi, on remarque que B est la matrice inverse de A et que A est la matrice inverse de B. Autrement dit,

$$A^{-1} = B \quad \text{ et } B^{-1} = A.$$

Problème 1.2.5. On considère la matrice $A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$. Montrer que la matrice

$$A^{-1} = \frac{1}{ad - bc}\begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

est l'inverse de la matrice A.

SOLUTION. En utilisant les propriétés de la multiplication d'une matrice par un scalaire, on calcule directement

$$\begin{aligned} A^{-1}A &= \frac{1}{ad - bc}\begin{pmatrix} d & -b \\ -c & a \end{pmatrix}\begin{pmatrix} a & b \\ c & d \end{pmatrix} = \frac{1}{ad - bc}\begin{pmatrix} da - bc & -ba + ab \\ -ac + ac & -bc + ad \end{pmatrix} \\ &= \frac{1}{ad - bc}\begin{pmatrix} ad - bc & 0 \\ 0 & ad - bc \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = I_2, \end{aligned}$$

ce qui complète la démonstration.

Problème 1.2.6. Soit A une matrice 7×3 et B une matrice telle que le produit AB est une matrice 7×5. Quelles sont les dimensions de la matrice B ?

SOLUTION. La matrice B est de dimension 3×5.

Problème 1.2.7. Combien la matrice A compte-t-elle de lignes si AB est une matrice 3×6 ?

SOLUTION. La matrice A compte 3 lignes. On peut aussi déduire que la matrice B compte 6 colonnes.

Problème 1.2.8. On pose $A = \begin{pmatrix} 3 & -6 \\ -1 & 2 \end{pmatrix}$. Construire une matrice B de dimension 2×2 et constituée de deux colonnes non-nulles distinctes telles que que le produit AB soit la matrice nulle.

SOLUTION. On pose

$$B \begin{pmatrix} a & b \\ c & d \end{pmatrix}.$$

On a

$$AB = \begin{pmatrix} 3 & -6 \\ -1 & 2 \end{pmatrix} \begin{pmatrix} a & b \\ c & d \end{pmatrix} = \begin{pmatrix} 3a - 6c & 3b - 6d \\ -a + 2c & -b + 2d \end{pmatrix}.$$

Pour que le produit AB donne la matrice nulle, il faut donc que nous ayons $3a-6c = -a+2c = 0$ et $3b - 6d = -b + 2d = 0$. Ainsi, toute matrice de la forme

$$B = \begin{pmatrix} 2c & 2d \\ c & d \end{pmatrix},$$

avec $c, d \neq 0$ fera l'affaire.

Semaine 9

2.1 Matrices inverses de dimension 2 et l'équation matricielle

Problème 2.1.1. Déterminer, si possible, l'inverse des matrices suivantes.

$$(a)\begin{pmatrix}7 & 5\\ 3 & -1\end{pmatrix} \quad (b)\begin{pmatrix}1 & 2\\ 3 & 4\end{pmatrix} \quad (c)\begin{pmatrix}-2 & 3\\ -4 & 6\end{pmatrix} \quad (d)\begin{pmatrix}3 & -4\\ 7 & -8\end{pmatrix}$$

.

SOLUTION. On rappelle que l'inverse d'une matrice $\begin{pmatrix}a & b\\ c & d\end{pmatrix}$ est donnée par

$$A^{-1} = \frac{1}{\det(A)}\begin{pmatrix}d & -b\\ -c & a\end{pmatrix},$$

où $\det(A) = ad - bc$.

(a) On calcule $\det(A) = -7 - 15 = -22$. Ainsi,

$$A^{-1} = -\frac{1}{22}\begin{pmatrix}-1 & -5\\ -3 & 7\end{pmatrix} = \begin{pmatrix}\frac{1}{22} & \frac{5}{22}\\ \frac{3}{22} & \frac{-7}{22}\end{pmatrix}.$$

(b) On calcule $\det(A) = 4 - 6 = -2$. Ainsi,

$$A^{-1} = -\frac{1}{2}\begin{pmatrix}4 & -2\\ -3 & 1\end{pmatrix} = \begin{pmatrix}-2 & 1\\ \frac{3}{2} & \frac{-1}{2}\end{pmatrix}.$$

(c) Le déterminant de cette matrice est nul et donc celle-ci n'est pas inversible.

(d) On calcule $\det(A) = -24 - -28 = 4$. Ainsi,

$$A^{-1} = \frac{1}{4}\begin{pmatrix} -8 & 4 \\ -7 & 3 \end{pmatrix} = \begin{pmatrix} -2 & 1 \\ -\frac{7}{4} & \frac{3}{4} \end{pmatrix}.$$

Problème 2.1.2. On considère le système d'équations linéaires suivant

$$\begin{cases} 3x - 2y = 2 \\ x - 2y = 5 \end{cases}$$

On se propose d'utiliser la matrice inverse A^{-1} de la matrice des coefficients A pour trouver, si possible, la solution de ce système.

(a) Écrire ce S.E.L. sous la forme d'une équation matricielle $A\boldsymbol{x} = \boldsymbol{b}$.

(b) Calculer la matrice inverse A^{-1}.

(c) Donner la solution du système

SOLUTION.

(a) On pose $A = \begin{pmatrix} 3 & -2 \\ 1 & -2 \end{pmatrix}$, $\boldsymbol{x} = \begin{pmatrix} x \\ y \end{pmatrix}$ et $\boldsymbol{b} = \begin{pmatrix} 2 \\ 5 \end{pmatrix}$. Ainsi, le S.E.L. peut être écrit comme $A\boldsymbol{x} = \boldsymbol{b}$.

(b) On calcule directement $\det(A) = -6 - -2 = -4$. Donc,

$$A^{-1} = -\frac{1}{4}\begin{pmatrix} -2 & 2 \\ -1 & 3 \end{pmatrix}.$$

(c) On peut isoler le vecteur $\boldsymbol{x}$ des inconnues en multipliant à gauche chaque côté de l'équation matricielle $A\boldsymbol{x} = \boldsymbol{b}$. On obtient alors

$$\boldsymbol{x} = A^{-1}\boldsymbol{b} = -\frac{1}{4}\begin{pmatrix} -2 & 2 \\ -1 & 3 \end{pmatrix}\begin{pmatrix} 2 \\ 5 \end{pmatrix} = -\frac{1}{4}\begin{pmatrix} 6 \\ 13 \end{pmatrix} = \begin{pmatrix} -\frac{3}{2} \\ -\frac{13}{4} \end{pmatrix}.$$

Problème 2.1.3. Soit le système d'équations linéaires suivant

$$\begin{cases} x_1 + 2x_2 = -4 \\ 3x_1 - x_2 = 5, \end{cases}$$

(a) En utilisant l'algorithme du pivot de Gauss, trouver, si possible, la solution de ce système.

(b) En utilisant la méthode de la matrice inverse, trouver, si possible, la solution de ce système.

SOLUTION.

(a) La matrice augmentée qui représente ce système est

$$[A|\boldsymbol{b}] = \left(\begin{array}{cc|c} 1 & 2 & -4 \\ 3 & -1 & 5 \end{array}\right).$$

On applique la méthode du pivot de Gauss :

$$[A|\boldsymbol{b}] = \left(\begin{array}{cc|c} 1 & 2 & -4 \\ 3 & -1 & 5 \end{array}\right) \underset{L_2 - 3L_1 \to L_2}{\sim} \left(\begin{array}{cc|c} 1 & 2 & -4 \\ 0 & -7 & 17 \end{array}\right)$$

$$\underset{\frac{1}{-7}L_2 \to L_2}{\sim} \left(\begin{array}{cc|c} 1 & 2 & -4 \\ 0 & 1 & -\frac{17}{7} \end{array}\right) \underset{L_1 - 2L_2 \to L_1}{\sim} \left(\begin{array}{cc|c} 1 & 0 & \frac{6}{7} \\ 0 & 1 & -\frac{17}{7} \end{array}\right).$$

Ce système possède donc une solution unique $\begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 6/7 \\ -17/7 \end{pmatrix}$.

(b) Le déterminant de la matrice A des coefficients est $\det(A) = -1 - 6 = -7$ et donc

$$A^{-1} = -\frac{1}{7}\begin{pmatrix} -1 & -2 \\ -3 & 1 \end{pmatrix}.$$

Ainsi, en procédant comme dans le problème précédent, on obtient

$$\boldsymbol{x} = \begin{pmatrix} x \\ y \end{pmatrix} = A^{-1}\boldsymbol{b} = -\frac{1}{7}\begin{pmatrix} -1 & -2 \\ -3 & 1 \end{pmatrix}\begin{pmatrix} -4 \\ 5 \end{pmatrix} = \begin{pmatrix} 6/7 \\ -17/7 \end{pmatrix}.$$

Problème 2.1.4. Soit le système d'équations linéaires suivant

$$\begin{cases} ax_1 + bx_2 = b_1 \\ cx_1 + dx_2 = b_2, \end{cases}$$

où a, b, c, d et b_1, b_2 sont des nombres réels.

(a) Sous quelle condition le système admet-il une solution unique ?

(b) Sous quelle condition le système admet-il une infinité de solutions ?

(c) Sous quelle condition le système n'admet-il aucune solution ?

SOLUTION.

(a) Le système admet une solution unique si et seulement si le déterminant de la matrice des coefficients $A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$ est non-nul, autrement dit si et seulement si

$$\det(A) = ad - bc \neq 0.$$

(b) Chaque équation définit une droite du plan. L'unique manière d'avoir une infinité de solutions est que les deux équations décrivent la même droite, ce qui revient à dire qu'il existe un scalaire non-nul k tel que

$$a = kc, \quad b = kd, \quad b_1 = kb_2.$$

(c) Pour n'avoir aucune solution, il faut que les équations décrivent deux droites distinctes et parallèles. Ainsi, il faut qu'il existe un scalaire non-nul k tel que

$$a = kc, \quad b = kd,$$

mais pour lequel on a $b_1 \neq kb_2$.

2.2 Espaces vectoriels euclidiens

Problème 2.2.1. Exprimer les vecteurs suivants comme combinaison linéaire des vecteurs de la base canonique de $\mathbb{R}^d$.

Remarque : un objectif secondaire de cet exercice est de souligner à quel point il existe différentes manières d'écrire la même information, le même vecteur.

(a) $\boldsymbol{u} = (1, -2, 0, 3)$

(b) $\boldsymbol{w} = \begin{pmatrix} 1 \\ -2 \\ 0 \\ 3 \end{pmatrix}$

(c) $\boldsymbol{x} = \begin{pmatrix} x_1 & x_2 & x_3 \end{pmatrix}$

(d) $\boldsymbol{u} = \begin{pmatrix} 1 & -1 & 2 & 1 & 4 \end{pmatrix}^T$

SOLUTION. On rappelle que la base canonique de $\mathbb{R}^d$ est une collection de d vecteurs $\{e_1, e_2, ..., e_d\}$, où e_i est un vecteur à d composantes, toutes nulles sauf la i-me qui vaut 1.

(a) $\boldsymbol{u} = e_1 - 2e_2 + 3e_4$.

(b) $\boldsymbol{w} = e_1 - 2e_2 + 3e_4$.

(c) $\boldsymbol{x} = x_1e_1 + x_2e_2 + x_3e_3$.

(d) $\boldsymbol{u} = e_1 - e_2 + 2e_3 + e_4 + 4e_5$.

2.3 Méthode du pivot de Gauss

Problème 2.3.1. Dire quels sont les critères pour qu'une matrice soit dans une forme échelonnée. Et quels sont les critères *supplémentaires* pour qu'on puisse dire que celle-ci est échelonnée réduite ?

SOLUTION. Pour qu'une matrice soit dans une forme échelonnée (F.E.) il faut d'abord vérifier que toute ligne contenant seulement des zéros est au bas de la matrice. Autrement dit, il est impossible d'avoir une ligne non-nulle en-dessous d'une ligne nulle. Ensuite, il faut que les pivots soit en échelons. Cela veut dire que lorsqu'on passe d'une ligne à l'autre du haut vers le bas, le pivot se déplace strictement vers la droite.

Pour obtenir la forme échelonnée réduite (F.E.R.) d'une matrice, il faut d'abord que celle-ci soit sous forme échelonnée. Il faut de plus que les pivots soient tous égaux à 1 et que les colonnes qui les contiennent soient toutes nulles, outre le pivot lui-même.

On remarque finalement que si la forme échelonnée d'une matrice n'est pas unique, la forme échelonné réduite, elle, est unique.

Problème 2.3.2. Dire si les matrices suivantes sont dans une forme échelonnée, échelonnée réduite ou ni un ni l'autre. Justifier ses réponses.

(a) $\begin{pmatrix} 1 & 2 & 0 & 1 \\ 0 & 1 & 2 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$ (b) $\begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \end{pmatrix}$ (c) $\begin{pmatrix} 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 \end{pmatrix}$ (d) $\begin{pmatrix} 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 1 \end{pmatrix}$

SOLUTION.

(a) On remarque que les pivots sont échelonnés. En effet, chaque pivot est strictement à la droite du pivot d'une ligne précédente. De plus, il n'y a pas de ligne contenant que des zéros. Ainsi, la matrice est sous forme échelonnée. Elle n'est pas réduite cependant, parce que la seconde colonne contient un nombre non-nul au dessus du pivot.

(b) Les pivots ne sont pas échelonnés : celui de la deuxième ligne est à droite de celui de la troisième. La matrice n'est donc pas en forme échelonnée.

(c) La matrice est en forme échelonnée, mais non-réduite, puisque que les colonnes 2 et 3 possèdent des entrées non-nulles au dessus du pivot.

(d) Cette matrice contient une ligne de zéros qui n'est tout en bas de la matrice et donc celle-ci n'est pas sous forme échelonnée.

Problème 2.3.3. Dire si les matrices suivantes sont dans une forme échelonnée, échelonnée réduite ou ni un ni l'autre. Justifier ses réponses.

(a) $\begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$ (b) $\begin{pmatrix} 3 & 0 & 0 \\ 0 & 0 & -1 \\ 0 & 0 & 0 \end{pmatrix}$ (c) $\begin{pmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix}$ (d) $\begin{pmatrix} 1 & 0 & 0 & 3 & 0 \\ 0 & 1 & 0 & 1 & 1 \end{pmatrix}$

SOLUTION.

(a) La matrice est sous forme échelonnée réduite. On remarque par ailleurs que, dans le cas des matrices carrées de taille n, la forme échelonnée réduite correspond toujours à la matrice identité I_n.

(b) La matrice est échelonnée car la ligne de 0 est au bas de la matrice et que les pivots sont placés en échelons. Par contre, les pivots ne valent pas tous 1 et donc nous n'avons pas la forme réduite.

(c) Cette matrice n'est pas échelonnée : le pivot de la 4ème ligne est dans la même colonne que celui de la première.

(d) Cette matrice est sous forme échelonnée : les deux pivots sont en échelons et il n'y a pas de ligne de zéros. De plus, les pivots valent 1 et sont les uniques éléments non-nuls de leur colonne respective. La matrice est donc sous forme échelonnée réduite.

Problème 2.3.4. Dire quelles sont les opérations élémentaires que l'on peut effectuer sur les lignes d'une matrice pour échelonner celle-ci. Pourquoi dit-on que ce sont des opérations *élémentaires* ?

SOLUTION. Les opérations élémentaires doivent être pensées dans le contexte où une matrice représente un système d'équations linéaires. Les opérations élémentaires que l'on effectue sur les lignes sont donc alors des opérations effectuées sur les équations du système. On peut :

— Échanger deux lignes.

— Multiplier une ligne par une constante.

— Ajouter (soustraire) une ligne à une autre.

Nous pouvons effectuer ces opérations parce que, bien qu'elles changent évidemment la matrice, elles ne modifient pas les solutions du système d'équations sous-jacent.

Problème 2.3.5. Utiliser l'algorithme de Gauss pour donner la forme échelonnée réduite de chacune des matrices suivantes. Donner le rang de chacune des matrices.

$$(a)\begin{pmatrix}3 & 2\\ 6 & 1\end{pmatrix} \quad (b)\begin{pmatrix}2 & -1\\ -4 & 2\end{pmatrix} \quad (c)\begin{pmatrix}1 & 2 & 3\\ 4 & 5 & 6\\ 7 & 8 & 9\end{pmatrix} \quad (d)\begin{pmatrix}1 & 0 & 2 & 0\\ -2 & 3 & 1 & 1\end{pmatrix}$$

SOLUTION.

(a)

$$\begin{pmatrix}3 & 2\\ 6 & 1\end{pmatrix} \underset{L_2 - 2L_1 \to L_2}{\sim} \begin{pmatrix}3 & 2\\ 0 & -3\end{pmatrix} \underset{\substack{\frac{1}{3}L_1 \to L_1\\ -\frac{1}{3}L_2 \to L_2}}{\sim} \begin{pmatrix}1 & \frac{2}{3}\\ 0 & 1\end{pmatrix} \underset{L_1 - \frac{2}{3}L_2 \to L_1}{\sim} \begin{pmatrix}1 & 0\\ 0 & 1\end{pmatrix}.$$

Le rang de cette matrice est 2.

(b)

$$\begin{pmatrix}2 & -1\\ -4 & 2\end{pmatrix} \underset{L_2 + 2L_1 \to L_2}{\sim} \begin{pmatrix}2 & -1\\ 0 & 0\end{pmatrix} \underset{\frac{1}{2}L_1 \to L_1}{\sim} \begin{pmatrix}1 & -\frac{1}{2}\\ 0 & 0\end{pmatrix}.$$

Cette matrice est de rang 1.

(c)
$$\begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{pmatrix} \underset{L_3 - 7L_1 \to L_3}{\overset{L_2 - 4L_1 \to L_2}{\sim}} \begin{pmatrix} 1 & 2 & 3 \\ 0 & -3 & -6 \\ 0 & -6 & -12 \end{pmatrix}$$
$$\overset{\frac{1}{-3}L_2 \to L_2}{\sim} \begin{pmatrix} 1 & 2 & 3 \\ 0 & 1 & 2 \\ 0 & -6 & -12 \end{pmatrix} \overset{L_3 + 6L_2 \to L_3}{\sim} \begin{pmatrix} 1 & 2 & 3 \\ 0 & 1 & 2 \\ 0 & 0 & 0 \end{pmatrix}$$
$$\overset{L_1 - 2L_2 \to L_1}{\sim} \begin{pmatrix} 1 & 0 & -1 \\ 0 & 1 & 2 \\ 0 & 0 & 0 \end{pmatrix}.$$

Le rang de cette matrice est 2.

(d)
$$\begin{pmatrix} 1 & 0 & 2 & 0 \\ -2 & 3 & 1 & 1 \end{pmatrix} \overset{L_2 + 2L_1 \to L_2}{\sim} \begin{pmatrix} 1 & 0 & 2 & 0 \\ 0 & 3 & 5 & 1 \end{pmatrix}$$
$$\overset{\frac{1}{3}L_2 \to L_2}{\sim} \begin{pmatrix} 1 & 0 & 2 & 0 \\ 0 & 1 & \frac{5}{3} & \frac{1}{3} \end{pmatrix} \overset{L_1 - 2L_2 \to L_1}{\sim} \begin{pmatrix} 1 & 0 & 0 & -\frac{2}{3} \\ 0 & 1 & \frac{5}{3} & \frac{1}{3} \end{pmatrix}.$$

Le rang de cette matrice est 2.

Problème 2.3.6. Soit le système d'équations linéaires suivant

$$\begin{cases} x + 2y + 3z = 6 \\ 2x - y + z = 3 \\ 3x + y - 2z = 4. \end{cases}$$

(a) Écrire ce système sous forme d'une matrice augmentée $[A|\boldsymbol{b}]$.

(b) Appliquer l'algorithme de Gauss pour obtenir la forme échelonnée réduite de $[A|\boldsymbol{b}]$.

(c) Décrire l'espace de solutions du système initial.

Solution.

(a) La matrice augmentée qui représente ce système est

$$[A|\boldsymbol{b}] = \left(\begin{array}{ccc|c} 1 & 2 & 3 & 6 \\ 2 & -1 & 1 & 3 \\ 3 & 1 & -2 & 4 \end{array}\right).$$

(b)

$$\left(\begin{array}{ccc|c} 1 & 2 & 3 & 6 \\ 2 & -1 & 1 & 3 \\ 3 & 1 & -2 & 4 \end{array}\right) \begin{array}{l} \\ L_2 - 2L_1 \to L_2 \\ L_3 - 3L_1 \to L_3 \end{array} \left(\begin{array}{ccc|c} 1 & 2 & 3 & 6 \\ 0 & -5 & -5 & -9 \\ 0 & -5 & -11 & -14 \end{array}\right)$$

$$\tfrac{1}{-5}L_2 \to L_2 \left(\begin{array}{ccc|c} 1 & 2 & 3 & 6 \\ 0 & 1 & 1 & \frac{9}{5} \\ 0 & -5 & -11 & -14 \end{array}\right) L_3 + 5L_2 \to L_3 \left(\begin{array}{ccc|c} 1 & 2 & 3 & 6 \\ 0 & 1 & 1 & \frac{9}{5} \\ 0 & 0 & -6 & -5 \end{array}\right)$$

$$\tfrac{1}{-6}L_3 \to L_3 \left(\begin{array}{ccc|c} 1 & 2 & 3 & 6 \\ 0 & 1 & 1 & \frac{9}{5} \\ 0 & 0 & 1 & \frac{5}{6} \end{array}\right) L_2 - L_3 \to L_2 \left(\begin{array}{ccc|c} 1 & 2 & 3 & 6 \\ 0 & 1 & 0 & \frac{29}{30} \\ 0 & 0 & 1 & \frac{5}{6} \end{array}\right)$$

$$L_1 - 3L_3 \to L_1 \left(\begin{array}{ccc|c} 1 & 0 & 0 & \frac{47}{30} \\ 0 & 1 & 0 & \frac{29}{30} \\ 0 & 0 & 1 & \frac{5}{6} \end{array}\right)$$

(c) Ce système admet une solution unique, qui correspond au point d'intersection de trois plans dans l'espace. On a effectivement $\operatorname{rang}(A) = \operatorname{rang}(A|\boldsymbol{b}) = 3$.

Problème 2.3.7. Soit le système d'équations linéaires suivant

$$\begin{cases} x_1 + 2x_2 - 5x_3 = 2 \\ -x_2 + x_3 = -1. \end{cases}$$

(a) Écrire ce système sous forme d'une matrice augmentée $[A|\boldsymbol{b}]$.

(b) Appliquer l'algorithme de Gauss pour obtenir la forme échelonnée réduite de $[A|\boldsymbol{b}]$.

(c) Décrire l'espace de solutions du système initial.

SOLUTION.

(a) La matrice augmentée qui représente ce système est

$$[A|\boldsymbol{b}] = \left(\begin{array}{ccc|c} 1 & 2 & -5 & 2 \\ 0 & -1 & 1 & -1 \end{array}\right).$$

(b)
$$\left(\begin{array}{ccc|c} 1 & 2 & -5 & 2 \\ 0 & -1 & 1 & -1 \end{array}\right) -L_2 \overset{\sim}{\to} L_2 \left(\begin{array}{ccc|c} 1 & 2 & -5 & 2 \\ 0 & 1 & -1 & 1 \end{array}\right).$$
$$L_1 - 2\overset{\sim}{L_2} \to L_1 \left(\begin{array}{ccc|c} 1 & 0 & -3 & 0 \\ 0 & 1 & -1 & 1 \end{array}\right)$$

(c) On a $\text{rang}(A) = \text{rang}(A|\boldsymbol{b}) = 2 < 3$, où 3 est le nombre d'inconnues, c'est-à-dire le nombre de colonnes de la matrice A des coefficients. Nous avons donc un système qui présente une infinité de solutions. On peut interpréter ce système géométriquement : chaque équation représente un plan dans $\mathbb{R}^3$ et comme les plans ne sont pas parallèles, leur intersection forme une droite dont chacun des points est donc une solution du système initial. Pour obtenir l'équation de cette droite, on peut exprimer les variables liées x_1, x_2 comme fonction de la variable libre x_3. On obtient alors les équations paramétriques suivantes

$$\begin{cases} x_1 = 3t, \\ x_2 = 1 + t, \\ x_3 = t. \end{cases} .$$

Problème 2.3.8. Soit le système d'équations linéaires suivant

$$\begin{cases} 2x_1 + 4x_2 = 2 \\ -x_1 + x_2 = 0 \\ 3x_1 - 5x_2 = 1 \end{cases}$$

(a) Écrire ce système sous forme d'une matrice augmentée $[A|\boldsymbol{b}]$.

(b) Appliquer l'algorithme de Gauss pour obtenir la forme échelonnée réduite de $[A|\boldsymbol{b}]$.

(c) Décrire l'espace de solutions du système initial.

Solution.

(a) La matrice augmentée qui représente ce système est

$$[A|\boldsymbol{b}] = \left(\begin{array}{cc|c} 2 & 4 & 2 \\ -1 & 1 & 0 \\ 3 & -5 & 1 \end{array}\right).$$

(b)

$$\left(\begin{array}{cc|c} 2 & 4 & 2 \\ -1 & 1 & 0 \\ 3 & -5 & 1 \end{array}\right) \overset{\frac{1}{2}L_1 \to L_1}{\sim} \left(\begin{array}{cc|c} 1 & 2 & 1 \\ -1 & 1 & 0 \\ 3 & -5 & 1 \end{array}\right) \overset{\substack{L_2 + L_1 \to L_2 \\ L_3 - 3L_1 \to L_3}}{\sim} \left(\begin{array}{cc|c} 1 & 2 & 1 \\ 0 & 3 & 1 \\ 0 & -11 & -2 \end{array}\right)$$

$$\overset{\frac{1}{3}L_2 \to L_2}{\sim} \left(\begin{array}{cc|c} 1 & 2 & 1 \\ 0 & 1 & \frac{1}{3} \\ 0 & -11 & -2 \end{array}\right) \overset{L_3 + 11L_2 \to L_3}{\sim} \left(\begin{array}{cc|c} 1 & 2 & 1 \\ 0 & 1 & \frac{1}{3} \\ 0 & 0 & \frac{1}{3} \end{array}\right) .$$

$$\overset{3L_3 \to L_3}{\sim} \left(\begin{array}{cc|c} 1 & 2 & 1 \\ 0 & 1 & \frac{1}{3} \\ 0 & 0 & 1 \end{array}\right) \overset{L_2 - \frac{1}{3}L_3 \to L_2}{\sim} \left(\begin{array}{cc|c} 1 & 2 & 1 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{array}\right) \overset{L_1 - 2L_2 \to L_1}{\sim} \left(\begin{array}{cc|c} 1 & 0 & 1 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{array}\right)$$

(c) La dernière ligne de la forme échelonnée réduite est incompatible. On peut directement conclure que le S.E.L. n'admet donc aucune solution. De manière plus formelle, on voit que $\text{rang}(A) = 2 < 3 = \text{rang}(A|\boldsymbol{b})$ et donc le S.E.L. n'a pas de solution.

Problème 2.3.9. (TI) Soit le système d'équations linéaires suivant

$$\begin{cases} 2x_1 + 4x_2 - x_3 + x_4 - x_5 + x_6 = 1 \\ -6x_1 + x_2 + 3x_3 - 2x_4 + 3x_5 + 2x_6 = 5 \\ -2x_1 + 3x_2 + x_3 - 5x_4 - x_5 + 3x_6 = -2 \\ 4x_1 - 2x_2 + 3x_3 - x_4 + x_5 + 2x_6 = 0 \end{cases}$$

(a) Supposons que ce système est représenté par une matrice augmentée $[A|\boldsymbol{b}]$. Quelles sont les dimensions de A ? et de $(A|\boldsymbol{b})$?

(b) Est-il possible que ce système possède une solution unique ?

(c) Utiliser la commande *rref* de la TI pour obtenir la forme échelonnée réduite de la matrice $[A|\boldsymbol{b}]$ et décrire la nature de l'espace de solution de ce système.

Solution.

(a) La matrice des coefficients A est 4×6 tandis que la matrice augmentée est 4×7.

(b) Le système possède une solution unique si et seulement si $\text{rang}(A) = \text{rang}(A|\boldsymbol{b}) = 6$, où 6 est ici le nombre d'inconnues. Or, comme il n'y a que 4 équations, il ne peut y avoir

au maximum 4 pivots. Il est donc impossible que ce système admette une solution unique.

(c) On a $\text{rang}(A) = \text{rang}(A|\boldsymbol{b}) = 4 < 6$ et donc le système admet une infinité de solutions.

Problème 2.3.10. Répondre par VRAI ou FAUX. Justifier.

(a) Si un système de m équations à n inconnues possède une solution unique, alors $m = n$.

(b) Si un système possède plus d'équations que d'inconnues, alors il ne peut pas admettre une solution unique.

(c) Si un système possède plus d'inconnues que d'équations, alors il ne peut pas admettre une solution unique.

(d) Soit A une matrice 2×2 dont le déterminant vaut zéro. Alors, tout S.E.L. dont A est la matrice des coefficients ne possède aucune solution.

Solution.

(a) On peut imaginer trois droites distinctes qui se croisent au même point. Chaque droite détermine une équation linéaire et donc on peut aisément avoir un système de 3 équations à 2 inconnues qui admet une solution unique. L'énoncé est donc faux.

(b) Cet énoncé est également faux, pour la même raison que celle de la question précédente.

(c) Un système admet une solution unique si et seulement si $\text{rang}(A) = \text{rang}(A|\boldsymbol{b}) = n$, où n est le nombre de colonnes de la matrice des coefficients, qui correspond au nombre d'inconnues. Or, s'il y a moins d'équations que d'inconnues, alors le nombre de pivots de A est strictement plus petit que n. Il est alors impossible qu'un tel système possède une solution unique.

(d) Faux, si le déterminant est nul, le système pourrait aussi avoir une infinité de solutions.

Semaine 10

3.1 Transformations linéaires et matrices canoniques

Problème 3.1.1. Soit la matrice

$$A = \begin{pmatrix} 3 & 1 \\ -1 & 7 \end{pmatrix}.$$

On considère la transformation linéaire T donnée par $T(\boldsymbol{x}) = A\boldsymbol{x}$.

(a) Donner le domaine et l'ensemble d'arrivée de T.

(b) Donner l'image par T des vecteurs suivants :

$$\boldsymbol{u} = \begin{pmatrix} -3 \\ 1 \end{pmatrix}, \boldsymbol{v} = \begin{pmatrix} 1 \\ 4 \end{pmatrix}, \mathbf{0} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

(c) Trouver un vecteur $\boldsymbol{x}$ tel que

$$T(\boldsymbol{x}) = \begin{pmatrix} 20 \\ 8 \end{pmatrix}.$$

(d) Soit deux scalaires arbitraires $\alpha, \beta \in \mathbb{R}$ et deux vecteurs

$$\boldsymbol{u} = \begin{pmatrix} u_1 \\ u_2 \end{pmatrix}, \text{ et } \boldsymbol{v} = \begin{pmatrix} v_1 \\ v_2 \end{pmatrix}.$$

Montrer que T est une transformation linéaire, c'est-à-dire montrer que

$$T(\alpha\boldsymbol{u} + \beta\boldsymbol{v}) = \alpha T(\boldsymbol{u}) + \beta T(\boldsymbol{v}).$$

Solution.

(a) Le domaine est $\mathbb{R}^2$ et l'ensemble d'arrivée aussi.

(b) On calcule

$$T(\boldsymbol{u}) = A\boldsymbol{u} = \begin{pmatrix} -8 \\ 10 \end{pmatrix}, T(\boldsymbol{v}) = A\boldsymbol{v} = \begin{pmatrix} 7 \\ 27 \end{pmatrix}, \; T(\mathbf{0}) = A \cdot \mathbf{0} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

(c) On cherche $\boldsymbol{x}$ tel que

$$T(\boldsymbol{x}) = A\boldsymbol{x} = \begin{pmatrix} 20 \\ 8 \end{pmatrix}.$$

Il s'agit d'une équation matricielle qui représente donc un système d'équations linéaires à deux inconnues. On peut utilise la méthode du pivot ou celle de la matrice inverse pour trouver l'unique solution de ce système, soit

$$\boldsymbol{x} = A^{-1} \begin{pmatrix} 20 \\ 8 \end{pmatrix} = \begin{pmatrix} 6 \\ 2 \end{pmatrix}.$$

(d) On calcule

$$\alpha\boldsymbol{u} + \beta\boldsymbol{v} = \begin{pmatrix} \alpha u_1 \\ \alpha u_2 \end{pmatrix} + \begin{pmatrix} \beta v_1 \\ \beta v_2 \end{pmatrix} = \begin{pmatrix} \alpha u_1 + \beta v_1 \\ \alpha u_2 + \beta v_2 \end{pmatrix}.$$

Ainsi,

$$T(\alpha\boldsymbol{u} + \beta\boldsymbol{v}) = \begin{pmatrix} 3 & 1 \\ -1 & 7 \end{pmatrix} \begin{pmatrix} \alpha u_1 + \beta v_1 \\ \alpha u_2 + \beta v_2 \end{pmatrix} = \begin{pmatrix} 3\alpha u_1 + 3\beta v_1 + \alpha u_2 + \beta v_2 \\ -\alpha u_1 - \beta v_1 + 7\alpha u_2 + \beta v_2 \end{pmatrix}$$

De plus, on a

$$\alpha T(\boldsymbol{u}) = \alpha \begin{pmatrix} 3 & 1 \\ -1 & 7 \end{pmatrix} \begin{pmatrix} u_1 \\ u_2 \end{pmatrix} = \alpha \begin{pmatrix} 3u_1 + u_2 \\ -u_1 + 7u_2 \end{pmatrix} = \begin{pmatrix} 3\alpha u_1 + \alpha u_2 \\ -\alpha u_1 + 7\alpha u_2 \end{pmatrix}.$$

Similairement,

$$\beta T(\boldsymbol{v}) = \beta \begin{pmatrix} 3 & 1 \\ -1 & 7 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \beta \begin{pmatrix} 3v_1 + v_2 \\ -v_1 + 7v_2 \end{pmatrix} = \begin{pmatrix} 3\beta u_1 + \beta u_2 \\ -\beta u_1 + 7\beta u_2 \end{pmatrix}.$$

On conclut donc que

$$T(\alpha\boldsymbol{u} + \beta\boldsymbol{v}) = \alpha T(\boldsymbol{u}) + \beta T(\boldsymbol{v}).$$

Problème 3.1.2. Soit la matrice

$$A = \begin{pmatrix} 1 & 2 & 1 \\ -1 & 2 & 5 \end{pmatrix}.$$

On considère la transformation linéaire T donnée par $T(\boldsymbol{x}) = A\boldsymbol{x}$.

(a) Donner le domaine et l'ensemble d'arrivée de T.

(b) Donner l'image par T des vecteurs suivants :

$$\boldsymbol{u} = \begin{pmatrix} 1 \\ 7 \\ 0 \end{pmatrix}, \boldsymbol{v} = \begin{pmatrix} -4 \\ 1 \\ 1 \end{pmatrix}, \mathbf{0} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}.$$

(c) Trouver, si possible, un vecteur $\boldsymbol{x}$ tel que

$$T(\boldsymbol{x}) = \begin{pmatrix} 8 \\ 18 \end{pmatrix}.$$

(d) Soit deux scalaires arbitraires $\alpha, \beta \in \mathbb{R}$ et deux vecteurs

$$\boldsymbol{u} = \begin{pmatrix} u_1 \\ u_2 \\ u_3 \end{pmatrix}, \text{ et } \boldsymbol{v} = \begin{pmatrix} v_1 \\ v_2 \\ v_3 \end{pmatrix}.$$

Montrer que T est une transformation linéaire, c'est-à-dire montrer que

$$T(\alpha\boldsymbol{u} + \beta\boldsymbol{v}) = \alpha T(\boldsymbol{u}) + \beta T(\boldsymbol{v}).$$

Solution.

(a) La matrice est de dimension 2×3 et elle définit donc une application de $\mathbb{R}^3$ vers $\mathbb{R}^2$.

(b) On calcule directement

$$T(\boldsymbol{u}) = A\boldsymbol{u} = \begin{pmatrix} 15 \\ 13 \end{pmatrix}, \; T(\boldsymbol{v}) = A\boldsymbol{v} = \begin{pmatrix} -1 \\ 11 \end{pmatrix}, \; T(\mathbf{0}) = A \cdot \mathbf{0} = \mathbf{0} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

(c) On cherche $\boldsymbol{x}$ tel que

$$T(\boldsymbol{x}) = A\boldsymbol{x} = \begin{pmatrix} 8 \\ 18 \end{pmatrix}.$$

Il s'agit d'une équation matricielle qui correspond à un système d'équation linéaire de deux équations à trois inconnues. La forme échelonnée réduite de la matrice augmentée qui représente ce système est

$$\left(\begin{array}{ccc|c} 1 & 0 & -2 & -5 \\ 0 & 1 & 3/2 & 13/2 \end{array}\right).$$

Ce système admet donc une infinité de solutions. La variable libre est x_3 et on a les relations

$$\begin{cases} x_1 = 2x_3 - 5 \\ x_2 = -\frac{3}{2}x_3 + \frac{13}{2} \end{cases}$$

Un vecteur $\boldsymbol{x}$ solution du système peut donc être écrit

$$\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = x_3 \begin{pmatrix} 2 \\ -3/2 \\ 1 \end{pmatrix} + \begin{pmatrix} -5 \\ 13/2 \\ 0 \end{pmatrix},$$

où x_3 est un paramètre scalaire libre. On peut par exemple choisir $x_3 = 1$ pour obtenir une solution

$$\boldsymbol{x} = \begin{pmatrix} 2 \\ -3/2 \\ 1 \end{pmatrix} + \begin{pmatrix} -5 \\ 13/2 \\ 0 \end{pmatrix} = \begin{pmatrix} -3 \\ 5 \\ 1 \end{pmatrix}.$$

Problème 3.1.3. Soit A une matrice 12×3. Donner les valeurs de m et n pour que l'on puisse considérer A comme la matrice canonique d'une transformation

$$T : \mathbb{R}^n \to \mathbb{R}^m,$$

donnée par $T(\boldsymbol{x}) = A\boldsymbol{x}$.

SOLUTION. La matrice A peut mutliplier des vecteurs de dimension $n = 3$ pour les transformer en vecteurs de taille $m = 12$.

Problème 3.1.4. Donner la matrice canonique des transformations linéaires suivantes.

(a) $T : \mathbb{R}^4 \to \mathbb{R}^2$, avec

$$T(\boldsymbol{e_1}) = \begin{pmatrix} -1 \\ 1 \end{pmatrix}, T(\boldsymbol{e_2}) = \begin{pmatrix} 3 \\ 0 \end{pmatrix}, T(\boldsymbol{e_3}) = \begin{pmatrix} -4 \\ 3 \end{pmatrix}, T(\boldsymbol{e_4}) = \begin{pmatrix} 6 \\ 1 \end{pmatrix}.$$

(b) $T : \mathbb{R}^2 \to \mathbb{R}^3$, avec

$$T\left[\begin{pmatrix} 1 \\ 0 \end{pmatrix}\right] = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \quad T\left[\begin{pmatrix} 0 \\ 1 \end{pmatrix}\right] = \begin{pmatrix} -2 \\ 6 \\ 0 \end{pmatrix}.$$

(c) $T : \mathbb{R}^3 \to \mathbb{R}^3$, avec

$$T\left[\begin{pmatrix} 1 \\ 0 \\ 4 \end{pmatrix}\right] = \begin{pmatrix} -2 \\ 1 \\ 1 \end{pmatrix}, \quad T\left[\begin{pmatrix} 4 \\ 1 \\ 1 \end{pmatrix}\right] = \begin{pmatrix} 4 \\ 1 \\ 1 \end{pmatrix}, \quad T\left[\begin{pmatrix} 1 \\ 6 \\ 0 \end{pmatrix}\right] = \begin{pmatrix} 2 \\ -3 \\ 1 \end{pmatrix}.$$

(d) $T : \mathbb{R}^4 \to \mathbb{R}^2$, donnée par

$$T(x, y, z, w) = (x + y + z, x + 3y - 2z - w).$$

(e) $T : \mathbb{R}^2 \to \mathbb{R}^5$, donnée par

$$T(x, y) = (2x - y, 3x + 4y, x, 3y, 5x - 2y).$$

SOLUTION. On rappelle que le principal élément théorique à considérer ici est le fait que la matrice canonique d'une transformation linéaire est celle dont les colonnes sont l'image par la transformation des vecteurs de la base canonique du domaine.

(a) La matrice canonique est

$$A = (T(\boldsymbol{e}_1)\ \ T(\boldsymbol{e}_2)\ \ T(\boldsymbol{e}_3)\ \ T(\boldsymbol{e}_4)) = \begin{pmatrix} -1 & 3 & -4 & 6 \\ 1 & 0 & 3 & 1 \end{pmatrix}.$$

(b) La matrice canonique est

$$A = (T(\boldsymbol{e}_1)\ \ T(\boldsymbol{e}_2)) = \begin{pmatrix} 1 & -2 \\ 2 & 6 \\ 3 & 0 \end{pmatrix}.$$

(c) On doit ici employer une stratégie différente, puisque les vecteurs dont on connaît l'image ne sont pas ceux de la base canonique. On pose d'abord les matrices suivantes

$$B = \begin{pmatrix} 1 & 4 & 1 \\ 0 & 1 & 6 \\ 4 & 1 & 0 \end{pmatrix}, \quad C = \begin{pmatrix} -2 & 4 & 2 \\ 1 & 1 & -3 \\ 1 & 1 & 1 \end{pmatrix}.$$

Les colonnes de ces matrices sont respectivement constituées des vecteurs de l'énoncé et de leur image par la transformation. On cherche la matrice canonique A. En vertu des propriétés de la multiplication matricielle, on sait que

$$AB = C$$

et on peu donc isoler la matrice canonique en multipliant de chaque côté de cette équation par la matrice inverse de B. Celle-ce est donnée par

$$B^{-1} = \frac{1}{86} \begin{pmatrix} -6 & 1 & 23 \\ 24 & -4 & -6 \\ -4 & 15 & 1 \end{pmatrix},$$

d'où on calcule directement

$$A = B^{-1}C = \frac{1}{43}\begin{pmatrix} 18 & 0 & 4 \\ -29 & 1 & 27 \\ 12 & 0 & -26. \end{pmatrix}.$$

On remarque au passage que la seconde colonne de cette matrice canonique est le vecteur $\boldsymbol{e}_2$. Pourquoi ?

(d) On doit calculer l'image par la transformation T des vecteurs de la base canonique du domaine $\mathbb{R}^4$. On a

$$T(\boldsymbol{e_1}) = T(1,0,0,0) = (1,1) = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad T(\boldsymbol{e_2}) = T(0,1,0,0) = (1,3) = \begin{pmatrix} 1 \\ 3 \end{pmatrix}$$

et

$$T(\boldsymbol{e_3}) = T(0,0,1,0) = (1,-2) = \begin{pmatrix} 1 \\ -2 \end{pmatrix}, \quad T(\boldsymbol{e_4}) = T(0,0,0,1) = (0,-1) = \begin{pmatrix} 0 \\ -1 \end{pmatrix}.$$

Ainsi, la matrice canonique de T est

$$A = (T(\boldsymbol{e}_1) \;\; T(\boldsymbol{e}_2) \;\; T(\boldsymbol{e}_3) \;\; T(\boldsymbol{e}_4)) = \begin{pmatrix} 1 & 1 & 1 & 0 \\ 1 & 3 & -2 & -1 \end{pmatrix}.$$

(e) On calcule l'image par la transformation T des 2 vecteurs de la base canonique de $\mathbb{R}^2$. On a

$$T(\boldsymbol{e}_1) = T(1,0) = (2,3,1,0,5) \quad et T(\boldsymbol{e}_2) = T(0,1) = (-1,4,0,3,-2).$$

La matrice canonique est donc

$$A = (T(\boldsymbol{e}_1) \quad T(\boldsymbol{e}_2)) = \begin{pmatrix} 2 & -1 \\ 3 & 4 \\ 1 & 0 \\ 0 & 3 \\ 5 & -2 \end{pmatrix}.$$

3.2 Transformations linéaires du plan

Problème 3.2.1. Donner la matrice canonique des transformations linéaires suivantes du plan.

(a) La transformation effectue une rotation de 45° autour de l'origine dans le sens anti-horaire.

(b) La transformation effectue une symétrie par rapport à l'axe horizontal x_1.

(c) La transformation effectue une symétrie par rapport à la droite $x_1 = x_2$.

(d) La transformation effectue d'abord une transvection horizontale qui laisse $\boldsymbol{e}_1$ inchangé et transforme $\boldsymbol{e}_2$ en $3\boldsymbol{e}_1 + \boldsymbol{e}_2$. Ensuite, la transformation effectue une homothétie de facteur $k = 4$.

(e) La transformation effectue d'abord une rotation d'angle $\frac{\pi}{6}$ pour ensuite effectuer un changement d'échelle de facteur $k_1 = 4$ sur l'axe horizontal pour enfin effectuer une symétrie verticale d'axe x_2.

SOLUTION.

(a) La matrice canonique d'une rotation d'angle θ est

$$R_\theta = \begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix}.$$

En fixant $\theta = 45°$, on a donc

$$R_{45°} = \begin{pmatrix} \cos 45° & -\sin 45° \\ \sin 45° & \cos 45° \end{pmatrix} = \frac{\sqrt{2}}{2} \begin{pmatrix} 1 & 1 \\ -1 & 1 \end{pmatrix}.$$

(b) Le vecteur $\boldsymbol{e}_1$ est invariant par la symétrie horizontale et le vecteur $\boldsymbol{e}_2$ est quand à lui appliqué sur $\begin{pmatrix} 0 \\ -1 \end{pmatrix}$, de sorte que la matrice canonique de la transformation est

$$A = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}.$$

(c) La droite $x_1 = x_2$ est la droite de pente 1 qui passe par l'origine. La symétrie du vecteur $\boldsymbol{e}_1$ par rapport à cet axe est $\boldsymbol{e}_2$ et vice-versa. Ainsi, la matrice canonique de cette symétrie est

$$A = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}.$$

(d) Cette transformation est composée de deux étapes intermédiaires. La matrice canonique de la transvection est

$$A_1 = \begin{pmatrix} 1 & 3 \\ 0 & 1 \end{pmatrix}.$$

La matrice canonique de l'homothétie est

$$A_2 = \begin{pmatrix} 4 & 0 \\ 0 & 4 \end{pmatrix}.$$

Ainsi, la matrice canonique de la transformation est

$$A = A_2 A_1 = \begin{pmatrix} 4 & 0 \\ 0 & 4 \end{pmatrix} \begin{pmatrix} 1 & 3 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 4 & 12 \\ 0 & 4 \end{pmatrix}.$$

(e) On peut traiter ce genre de problème de deux manières. On propose d'abord une approche algébrique, similaire à celle du numéro précédent. La matrice de la rotation est

$$A_1 = R_{\pi/6} = \begin{pmatrix} \sqrt{3}/2 & -1/2 \\ 1/2 & \sqrt{3}/2 \end{pmatrix}.$$

La matrice du changement d'échelle de facteur 4 sur l'axe horizontal est

$$A_2 = \begin{pmatrix} 4 & 0 \\ 0 & 1 \end{pmatrix}$$

et la matrice canonique de la symétrie verticale est

$$A_3 = \begin{pmatrix} -1 & 0 \\ 0 & 1 \end{pmatrix}.$$

La matrice de la transformation globale est donc obtenue par

$$A = A_3 A_2 A_1 = \begin{pmatrix} -2\sqrt{3} & 2 \\ 1/2 & \sqrt{3}/2 \end{pmatrix}.$$

On peut également simplement suivre l'évolution des deux vecteurs de la base canonique du plan le long des transformations intermédiaires, comme dans le graphe suivant.

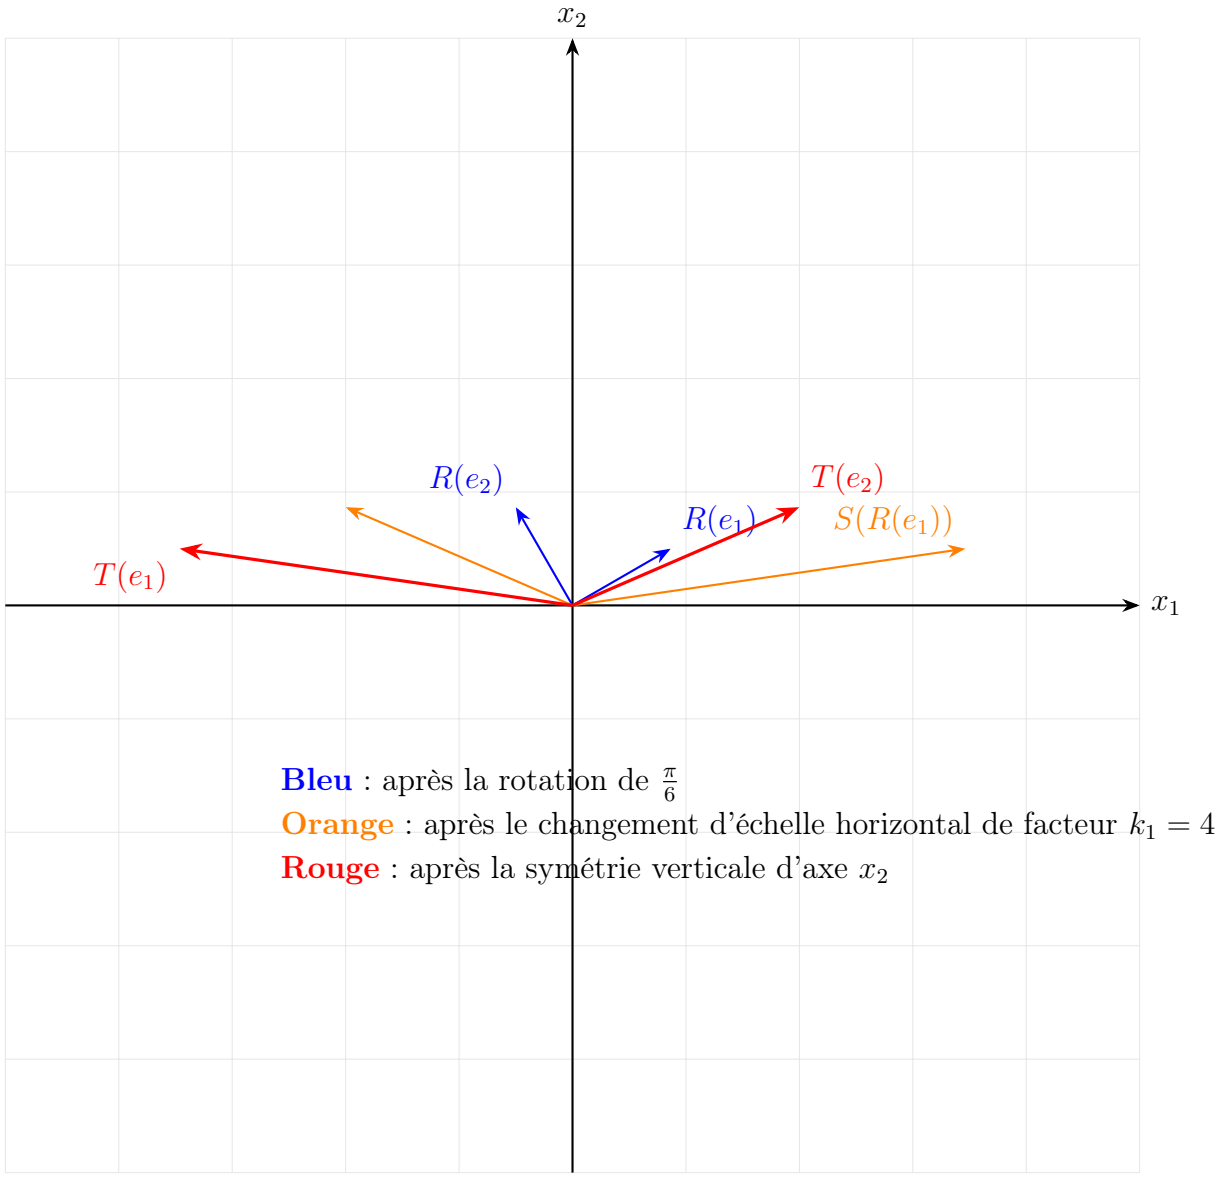

3.3 Coordonnées homogènes

Problème 3.3.1. Supposons que la matrice canonique d'une transformation linéaire du plan est donnée par

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}.$$

Donner la matrice qui représente cette transformation en coordonnées homogènes.

SOLUTION. La matrice qui représente cette transformation en coordonnées homogènes est

$$A = \begin{pmatrix} a & b & 0 \\ c & d & 0 \\ 0 & 0 & 1 \end{pmatrix}.$$

Problème 3.3.2. Donner une matrice 3×3 qui représente la transformation du plan en coordonnées homogènes.

(a) La translation de vecteur $(1, 4)$.

(b) La rotation de $90°$ autour du point $C(-1, 3)$.

(c) Rotation d'angle $45°$ autour de l'origine, suivie d'une symétrie verticale d'axe x_2.

(d) La translation de vecteur $(2, 5)$ suivie d'une symétrie d'axe $x_1 = -x_2$.

Solution.

(a) La matrice qui représente une translation de $(1, 4)$ en coordonnées homogènes est

$$A = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 4 \\ 0 & 0 & 1 \end{pmatrix}.$$

Une remarque sur la terminologie : on n'emploie pas ici le terme *canonique* pour décrire la matrice puisque ce terme est réservé dans notre contexte aux transformations linéaires. Or, toute translation non-triviale ne peut être linéaire, puisque l'image de l'origine n'est pas l'origine.

(b) On peut décomposer une rotation autour d'un point autre que l'origine en trois étapes.

i. Translation vers l'origine. La matrice d'une telle translation est

$$A_1 = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & -3 \\ 0 & 0 & 1 \end{pmatrix}.$$

En effet, si l'on veut partir du point $C(-1, 3)$ et revenir à l'origine, on doit se déplacer selon un vecteur $(1, -3)$.

ii. Rotation de 90°. Une fois à l'origine, on peut effectuer la rotation de 90°, dont la matrice est

$$A_2 = \begin{pmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}.$$

iii. Retour au point de départ. Enfin, une fois cette rotation effectuée, nous devons retourner là où nous étions, soit avec une translation de $(-1, 3)$. On a donc

$$A_3 = \begin{pmatrix} 1 & 0 & -1 \\ 0 & 1 & 3 \\ 0 & 0 & 1 \end{pmatrix}.$$

La combinaison de ces étapes successives nous permet d'obtenir la matrice recherchée

$$A = A_3 A_2 A_1 = \begin{pmatrix} 0 & -1 & 2 \\ 1 & 0 & 4 \\ 0 & 0 & 1 \end{pmatrix}.$$

(c) On décompose comme à l'habitude selon les étapes décrites.

i. Translation de vecteur $(2, 5)$
La matrice de cette translation est

$$A_1 = \begin{pmatrix} 1 & 0 & 2 \\ 0 & 1 & 5 \\ 0 & 0 & 1 \end{pmatrix}.$$

ii. Symétrie d'axe $x_1 = -x_2$
La matrice canonique de la symétrie est

$$\begin{pmatrix} 0 & -1 \\ -1 & 0 \end{pmatrix}.$$

La matrice correspondante en coordonnées homogènes est donc

$$A_2 = \begin{pmatrix} 0 & -1 & 0 \\ -1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}.$$

Ainsi, la matrice globale est

$$A = A_2 A_1 = \begin{pmatrix} 0 & -1 & -5 \\ -1 & 0 & -2 \\ 0 & 0 & 1 \end{pmatrix}.$$

Semaine 11

4.1 Combinaisons linéaires, espaces engendrés

Problème 4.1.1. On considère la famille suivante de vecteurs

$$H = \{\boldsymbol{u}_1, \boldsymbol{u}_2\} = \left\{ \begin{pmatrix} 1 \\ 3 \end{pmatrix}, \begin{pmatrix} -2 \\ 4 \end{pmatrix} \right\}.$$

Exprimer chacun des vecteurs suivants comme une combinaison linéaire des vecteurs de H.

(a) $\boldsymbol{b} = \begin{pmatrix} -3 \\ 11 \end{pmatrix}$,

(b) $\boldsymbol{w} = \begin{pmatrix} 0 \\ 5 \end{pmatrix}$,

(c) $\mathbf{0} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$,

(d) $\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$.

Enfin, quel est $\text{span}(H)$, l'espace engendré par la famille H ?

Solution.
On construit d'emblée la matrice

$$A = (\boldsymbol{u}_1\ \boldsymbol{u}_2) = \begin{pmatrix} 1 & -2 \\ 3 & 4 \end{pmatrix},$$

dont les colonnes sont les membres de la famille H.

Dans ce problème, on cherche des coefficients c_1, c_2 tel que l'on puisse exprimer un vecteur $\boldsymbol{w}$

comme combinaison linéaire des éléments de H :

$$\boldsymbol{w} = c_1\boldsymbol{u}_1 + c_2\boldsymbol{u}_2.$$

Cela revient à trouver une solution $\boldsymbol{c} = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix}$ de l'équation matricielle

$$A\boldsymbol{c} = \boldsymbol{w}.$$

Comme une telle équation représente un S.E.L., on peut bien sûr considérer la matrice augmentée $(A|\boldsymbol{w})$ du système et appliquer la méthode du pivot. Par contre, ici, il semble plus pratique de simplement utiliser la matrice inverse des coefficients A^{-1}. On calcule

$$A^{-1} = \frac{1}{\det(A)} \begin{pmatrix} 4 & 2 \\ -3 & 1 \end{pmatrix} = \frac{1}{10} \begin{pmatrix} 4 & 2 \\ -3 & 1 \end{pmatrix}.$$

(a) On a

$$\boldsymbol{c} = A^{-1}\boldsymbol{b} = \frac{1}{10} \begin{pmatrix} 4 & 2 \\ -3 & 1 \end{pmatrix} \begin{pmatrix} -3 \\ 11 \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}.$$

On peut effectivement vérifier que

$$\boldsymbol{u}_1 + 2\boldsymbol{u}_2 = \boldsymbol{b}.$$

(b) Similairement,

$$\boldsymbol{c} = A^{-1}\boldsymbol{b} = \frac{1}{10} \begin{pmatrix} 4 & 2 \\ -3 & 1 \end{pmatrix} \begin{pmatrix} 0 \\ 5 \end{pmatrix} = \begin{pmatrix} 1 \\ 1/2 \end{pmatrix}.$$

On vérifie que

$$\boldsymbol{u}_1 + \frac{1}{2}\boldsymbol{u}_2 = \begin{pmatrix} 0 \\ 5 \end{pmatrix} = \boldsymbol{w}.$$

(c) Avec des méthodes semblables, on trouve $c_1 = c_2 = 0$.

(d) On cherche ici une formule générale pour déterminer directement les coefficients de la combinaison linéaire de $\boldsymbol{u}_1, \boldsymbol{u}_2$ qui produire un vecteur arbitraire $\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$. En multipliant par l'inverse comme plus haut, on obtient

$$c_1 = \frac{2x_1 + x_2}{5}, \quad c_2 = \frac{x_2 - 3x_1}{10}.$$

La partie (d) que l'on vient de compléter montre qu'il est possible d'exprimer un vecteur quelconque $\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$ de $\mathbb{R}^2$ comme combinaison linéaire des deux vecteurs de H. On a donc

$$\text{span}(H) = \mathbb{R}^2.$$

Problème 4.1.2. (TI) On considère la famille suivante de vecteurs

$$H = \{\boldsymbol{u}_1, \boldsymbol{u}_2\} = \left\{ \begin{pmatrix} -1 \\ 2 \\ 3 \end{pmatrix}, \begin{pmatrix} 2 \\ 0 \\ 4 \end{pmatrix} \right\}.$$

Exprimer, si possible, les vecteurs suivants comme une combinaison linéaire des vecteurs de H.

(a) $\boldsymbol{b} = \begin{pmatrix} 3 \\ 5 \\ -2 \end{pmatrix}$,

(b) $\boldsymbol{w} = \begin{pmatrix} 1 \\ 2 \\ 7 \end{pmatrix}$,

(c) $\mathbf{0} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$.

Enfin, quel est $\text{span}(H)$, l'espace engendré par la famille H ?

Solution.
Pour chacun des numéros suivants, nous cherchons des coefficients inconnus $c_1, c_2 \in \mathbb{R}$ tels que l'on peut exprimer le vecteur demandé comme $c_1\boldsymbol{u}_1 + c_2\boldsymbol{u}_2$. Cela revient à trouver une solution

$$\boldsymbol{c} = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix}$$

de l'équation matricielle correspondante. Contrairement au problème précédent, on ne pourra pas ici utiliser la matrice inverse des coefficients pour solutionner cette équation matricielle. On utilisera donc l'algorithme du pivot. Pour tous les sous-problèmes, on aura la matrice A dont les colonnes sont les éléments de la famille H, c'est-à-dire

$$A = [\boldsymbol{u}_1\, \boldsymbol{u}_2] = \begin{pmatrix} -1 & 2 \\ 2 & 0 \\ 3 & 4 \end{pmatrix}.$$

(a) La matrice augmentée du système que l'on veut solutionner est $[A|\boldsymbol{b}] = \left(\begin{array}{cc|c} -1 & 2 & 3 \\ 2 & 0 & 5 \\ 3 & 4 & -2 \end{array}\right)$

On peut utiliser la commande *rref* de la T.I. pour obtenir la forme échelonnée réduite de cette matrice augmentée $[A|\boldsymbol{b}] = \left(\begin{array}{cc|c} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{array}\right)$. On remarque la dernière ligne est incompatible et il est donc impossible d'exprimer $\boldsymbol{b}$ comme combinaison linéaire des vecteurs de H.

(b) La matrice augmentée du système que l'on veut solutionner est $[A|\boldsymbol{b}] = \left(\begin{array}{cc|c} -1 & 2 & 1 \\ 2 & 0 & 2 \\ 3 & 4 & 7 \end{array}\right)$ et sa forme échelonnée réduite est $[A|\boldsymbol{b}] = \left(\begin{array}{cc|c} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \end{array}\right)$. On a donc une solution unique $c_1 = c_2 = 1$, que l'on peut aisément vérifier :

$$\boldsymbol{u}_1 + \boldsymbol{u}_2 = \begin{pmatrix} -1 \\ 2 \\ 3 \end{pmatrix} + \begin{pmatrix} 2 \\ 0 \\ 4 \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \\ 7 \end{pmatrix}.$$

(c) Les deux vecteurs de H n'étant pas parallèles, ils sont linéairement indépendants. Ainsi, la seule manière de les combiner linéairement pour obtenir le vecteur $\mathbf{0}$ est la combinaison linéaire triviale

$$c_1 = c_2 = 0.$$

Le lecteur pourra, au besoin, confirmer ce résultat avec les méthodes des exemples précédents.

Le sous-espace vectoriel engendré par les membres de la famille H est le plan de $\mathbb{R}^3$ qui passe par l'origine et qui est contient à la fois à $\boldsymbol{u}_1$ et $\boldsymbol{u}_2$.

Problème 4.1.3. (TI) On considère la famille suivante de vecteurs

$$H = \{\boldsymbol{u}_1, \boldsymbol{u}_2, \boldsymbol{u}_3\} = \left\{ \begin{pmatrix} -1 \\ 2 \\ 3 \end{pmatrix}, \begin{pmatrix} 2 \\ 0 \\ 4 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} \right\}.$$

Exprimer, si possible, les vecteurs suivants comme une combinaison linéaire des vecteurs de H.

(a) $\boldsymbol{b} = \begin{pmatrix} 3 \\ 5 \\ -2 \end{pmatrix}$,

(b) $\boldsymbol{w} = \begin{pmatrix} 1 \\ 2 \\ 7 \end{pmatrix}$,

(c) $\mathbf{0} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$.

SOLUTION. On pose

$$A = (\boldsymbol{u}_1\, \boldsymbol{u}_2\, \boldsymbol{u}_3) = \begin{pmatrix} -1 & 2 & 0 \\ 2 & 0 & 0 \\ 3 & 4 & 1 \end{pmatrix}.$$

Avec la méthode du pivot ou alors la TI, on trouve directement que la matrice inverse existe et qu'elle est donnée par

$$A^{-1} = \frac{1}{4} \begin{pmatrix} 0 & 2 & 0 \\ 2 & 1 & 0 \\ -8 & -10 & 4 \end{pmatrix}.$$

Cela nous assure que l'on pourra trouver l'unique vecteur inconnu des coefficients en multipliant par cette matrice inverse.

(a) On a

$$\boldsymbol{c} = A^{-1}\boldsymbol{b} = A^{-1} \begin{pmatrix} 3 \\ 5 \\ -2 \end{pmatrix} = \frac{1}{4} \begin{pmatrix} 10 \\ 11 \\ -82 \end{pmatrix}.$$

On vérifie aisément que

$$\frac{10}{4}\boldsymbol{u}_1 + \frac{11}{4}\boldsymbol{u}_2 - \frac{82}{4}\boldsymbol{u}_3 = \begin{pmatrix} 3 \\ 5 \\ -2 \end{pmatrix} = \boldsymbol{b}.$$

(b) Avec une méthode similaire, on obtient $c_1 = c_2 = 1$ et $c_3 = 0$, c'est-à-dire que

$$\boldsymbol{u}_1 + \boldsymbol{u}_2 = \begin{pmatrix} 1 \\ 2 \\ 7 \end{pmatrix} = \boldsymbol{w}.$$

(c) Comme la matrice inverse existe, la seule combinaison linéaire qui engendre le vecteur nul

est la combinaison linéaire triviale $c_1 = c_2 = c_3 = 0$.

Problème 4.1.4. Construire *trois* exemples de matrices de dimensions différentes et pour chacune d'elle montrer que la multiplication matricielle $A\boldsymbol{x}$ revient à former une combinaison linéaire des vecteurs colonnes de A, combinaison pour laquelle les coefficients sont précisément les composantes du vecteur $\boldsymbol{x}$ qui est multiplié.

SOLUTION.

1. Prenons pour débuter la combinaison linéaire suivante

$$c_1\boldsymbol{u}_1 + c_2\boldsymbol{u}_2 = 2\begin{pmatrix}-1\\3\end{pmatrix} - \begin{pmatrix}4\\5\end{pmatrix} = \begin{pmatrix}-6\\1\end{pmatrix}.$$

   En construisant une matrice $A = (\boldsymbol{u}_1\,\boldsymbol{u}_2)$ dont les colonnes sont les vecteurs utilisés dans la combinaison et en multipliant le vecteur $\boldsymbol{c} = \begin{pmatrix}c_1\\c_2\end{pmatrix}$ des coefficients par cette matrice, on vérifie que

$$A\boldsymbol{c} = \begin{pmatrix}-1 & 4\\3 & 5\end{pmatrix}\begin{pmatrix}2\\-1\end{pmatrix} = \begin{pmatrix}-6\\1\end{pmatrix}.$$

2. On considère

$$c_1\boldsymbol{u}_1 + c_2\boldsymbol{u}_2 + c_3\boldsymbol{u}_3 + c_4\boldsymbol{u}_4 = -5\begin{pmatrix}1\\2\\3\end{pmatrix} + 6\begin{pmatrix}9\\0\\-1\end{pmatrix} - 3\begin{pmatrix}2\\-1\\-1\end{pmatrix} + 2\begin{pmatrix}1\\1\\6\end{pmatrix} = \begin{pmatrix}45\\-5\\-6\end{pmatrix}.$$

   De manière similaire, en posant $A = (\boldsymbol{u}_1\,\boldsymbol{u}_2\,\boldsymbol{u}_3\,\boldsymbol{u}_4)$ et $\boldsymbol{c} = (-5,\,6,\,-3,\,2\,)^T$, on a

$$A\boldsymbol{c} = \begin{pmatrix}45\\-5\\-6\end{pmatrix}.$$

3. On propose au lecteur de plutôt essayer de prouver le résultat de manière générale :

$$c_1\boldsymbol{u}_1 + c_2\boldsymbol{u}_2 + ... + c_k\boldsymbol{u}_k = \boldsymbol{b}$$

   si et seulement si

$$A\boldsymbol{c} = \boldsymbol{b},$$

   où $A = (\boldsymbol{u}_1\,\boldsymbol{u}_2\,...\,\boldsymbol{u}_k)$ *et* $\boldsymbol{c} = (c_1\,c_2\,...c_k)^T$.

4.2 Indépendance linéaire

Problème 4.2.1. Soit $H = \{\boldsymbol{u}_1, \boldsymbol{u}_2, ..., \boldsymbol{u}_k\}$ une collection de k vecteurs de $\mathbb{R}^n$. Donner deux définitions équivalentes qui caractérisent l'indépendance linéaire de la famille de vecteurs H.

SOLUTION.
La famille H de vecteurs est dite *linéairement indépendante* si, dès lors qu'on peut trouver des coefficients $c_1, c_2, ..., c_k$ tels que

$$c_1\boldsymbol{u}_1 + c_2\boldsymbol{u}_2 + ... + c_k\boldsymbol{u}_k = \mathbf{0},$$

cela implique

$$c_1 = c_2 = ... = c_k = 0.$$

Autrement dit, toute combinaison linéaire des vecteurs de H qui engendre le vecteur nul doit être la combinaison linéaire triviale.

De manière équivalente, les vecteurs de H sont linéairement indépendants si et seulement si $\mathbf{0}$ est l'unique solution de l'*équation homogène*

$$A\boldsymbol{x} = \mathbf{0},$$

où A est la matrice dont les colonnes sont les vecteurs de H.

Problème 4.2.2. Comment déterminer directement si une famille contenant précisément 2 vecteurs est linéairement indépendante, peu importe la dimension de ceux-ci ?

SOLUTION. Une famille de deux vecteurs est linéairement indépendante si et seulement si ces deux vecteurs ne sont pas parallèles.

Problème 4.2.3. Supposons que le famille H contient k vecteurs de $\mathbb{R}^n$, avec $k > n$. Que peut-on affirmer sur l'indépendance linéaire des vecteurs de H ?

SOLUTION. On forme une matrice A dont les colonnes sont les vecteurs de H. La matrice augmentée $(A|\mathbf{0})$ de l'équation homogène a n lignes et $k + 1$ colonnes. Comme la dernière colonne est nulle, on a

$$\text{rang}(A) = \text{rang}(A|\mathbf{0}).$$

De plus, ce rang ne peut excéder le nombre de lignes n et est donc strictement plus petit que le nombre de colonnes n. Ainsi, l'équation homogène possède une infinité de solutions et cette famille de vecteurs est linéairement dépendante.

Problème 4.2.4. Dire si les familles de vecteurs suivantes sont linéairement indépendantes ou non.

(a) $H = \left\{ \begin{pmatrix} 2 \\ 11 \end{pmatrix}, \begin{pmatrix} -1 \\ 3 \end{pmatrix} \right\}$,

(b) $H = \left\{ \begin{pmatrix} 1 \\ 4 \end{pmatrix}, \begin{pmatrix} -5 \\ 3 \end{pmatrix}, \begin{pmatrix} 7 \\ 1 \end{pmatrix}, \begin{pmatrix} -4 \\ 0 \end{pmatrix} \right\}$,

(c) $H = \left\{ \begin{pmatrix} 2 \\ -5 \end{pmatrix}, \begin{pmatrix} -4 \\ 10 \end{pmatrix} \right\}$,

(d) $H = \left\{ \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \begin{pmatrix} -1 \\ 0 \\ 5 \end{pmatrix} \right\}$,

(e) $H = \left\{ \begin{pmatrix} -1 \\ 2 \\ 3 \end{pmatrix}, \begin{pmatrix} -3 \\ 6 \\ 9 \end{pmatrix} \right\}$,

(f) $H = \left\{ \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} \right\}$,

(g) $H = \left\{ \begin{pmatrix} -1 \\ 5 \\ 2 \end{pmatrix}, \begin{pmatrix} 0 \\ -1 \\ 1 \end{pmatrix}, \begin{pmatrix} -1 \\ 3 \\ 4 \end{pmatrix} \right\}$.

Solution.

(a) Famille linéairement indépendante : deux vecteurs non parallèles.

(b) Famille de 4 vecteurs de $\mathbb{R}^2$: linéairement dépendante.

(c) Ces deux vecteurs sont parallèles et donc ils sont linéairement dépendants.

(d) Linéairement indépendants : deux vecteurs non parallèles.

(e) Linéairement dépendants.

(f) Nous avons 3 vecteurs de $\mathbb{R}^3$. Soit A la matrice des vecteurs de H. On considère la matrice augmentée $(A|\mathbf{0})$ de l'équation homogène $A\boldsymbol{x} = \mathbf{0}$:

$$(A|\mathbf{0}) = \left(\begin{array}{ccc|c} 1 & 0 & 1 & 0 \\ 2 & 1 & 0 & 0 \\ 3 & 1 & 0 & 0 \end{array}\right).$$

En obtenant sa forme échelonnée réduite (via l'algorithme du pivot ou la T.I.), on obtient que $\mathbf{0}$ est l'unique solution de l'équation homogène et donc que la famille H est linéairement indépendante.

(g) Nous avons encore une fois 3 vecteurs de $\mathbb{R}^3$. Soit A la matrice des vecteurs de H. On considère la matrice augmentée $(A|\mathbf{0})$ de l'équation homogène $A\boldsymbol{x} = \mathbf{0}$:

$$(A|\mathbf{0}) = \left(\begin{array}{ccc|c} -1 & 0 & -1 & 0 \\ 5 & -1 & 3 & 0 \\ 2 & 1 & 4 & 0 \end{array}\right).$$

Sa forme échelonnée réduite est

$$\left(\begin{array}{ccc|c} 1 & 0 & 1 & 0 \\ 0 & 1 & 2 & 0 \\ 0 & 0 & 0 & 0 \end{array}\right).$$

On a que $\text{rang}(A) = \text{rang}(A|\mathbf{0}) = 2 < 3$ et donc l'équation homogène admet une infinité de solutions. On en conclut que la famille est linéairement dépendante. On peut en effet aisément vérifier que, par exemple :

$$\begin{pmatrix} -1 \\ 5 \\ 2 \end{pmatrix} + 2\begin{pmatrix} 0 \\ -1 \\ 1 \end{pmatrix} - \begin{pmatrix} -1 \\ 3 \\ 4 \end{pmatrix} = \mathbf{0}$$

est une combinaison linéaire non-triviale du vecteur nul.

4.3 Sous-espaces vectoriels, bases, coordonnées.

Problème 4.3.1. Soit une famille de vecteurs $H = \{\boldsymbol{u}_1, \boldsymbol{u}_2, ..., \boldsymbol{u}_k\}$ de $\mathbb{R}^n$. Soit aussi un sous-espace vectoriel $E \subset \mathbb{R}^n$. Quelles sont les deux conditions que doit remplir la famille de vecteurs H pour être considérée comme une base de E ?

SOLUTION. La famille H est une base de E si

1. Elle engendre E, c'est-à-dire que chaque vecteur de E peut-être exprimé comme combinaison linéaire des vecteurs de H :

$$\text{span}(H) = E.$$

2. La famille H est linéairement indépendante.

Problème 4.3.2. Combien de vecteurs exactement doit posséder une base de $\mathbb{R}^n$?

SOLUTION. Une base $\mathcal{B}$ de $\mathbb{R}^n$ doit posséder *exactement* n vecteurs.

Problème 4.3.3. Quel test peut-on appliquer pour montrer directement que $\mathcal{B} = \{\boldsymbol{u}_1, \boldsymbol{u}_2\}$ forme une base de $\mathbb{R}^2$?

SOLUTION. On forme la matrice carrée A de dimension 2 dont les colonnes sont les vecteurs $\boldsymbol{u}_1, \boldsymbol{u}_2$. Alors, $\mathcal{B}$ est une base de $\mathbb{R}^2$ si et seulement si

$$\det(A) \neq 0.$$

Problème 4.3.4. Quel test peut-on appliquer pour montrer directement que $\mathcal{B} = \{\boldsymbol{u}_1, \boldsymbol{u}_2, \boldsymbol{u}_3\}$ forme une base de $\mathbb{R}^3$?

SOLUTION. C'est exactement la même chose qu'au problème précédent, seulement nous devons plutôt dans ce cas calculer le déterminant d'une matrice 3×3.

Problème 4.3.5. On considère

$$\mathcal{B} = \left\{ \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \begin{pmatrix} -1 \\ 3 \end{pmatrix} \right\}.$$

(a) Montrer que $\mathcal{B}$ est une base de $\mathbb{R}^2$.

(b) Donner les coordonnées $(\boldsymbol{w})_{\mathcal{B}}$ du vecteur $\boldsymbol{w} = 3\boldsymbol{e_1} + 5\boldsymbol{e_2}$ dans cette base.

(c) Donner les coordonnées $(\boldsymbol{x})_{\mathcal{B}}$ d'un vecteur arbitraire $\boldsymbol{x} = x_1\boldsymbol{e}_1 + x_2\boldsymbol{e}_2$ dans cette base.

SOLUTION.

(a) On forme la matrice

$$A = \begin{pmatrix} 1 & -1 \\ 2 & 3 \end{pmatrix},$$

dont les colonnes sont les vecteurs de $\mathcal{B}$. Comme

$$\det(A) = 3 - -2 = 5 \neq 0,$$

on conclut directement que $\mathcal{B}$ est une base de $\mathbb{R}^2$. Remarquons au passage que ceci est très puissant, car cela implique directement que $\text{span}(B) = \mathbb{R}^2$ et que les vecteurs de $\mathcal{B}$ sont linéairement indépendants.

(b) Les coordonnées $(\boldsymbol{w})_{\mathcal{B}}$ de $\boldsymbol{w}$ sont les coefficients c_1, c_2 de la combinaison linéaire des vecteurs de $\mathcal{B}$ qui l'engendre. On cherche donc la solution $\boldsymbol{c} = (c_1\,, c_2)^T$ du système $A\boldsymbol{c} = \boldsymbol{w}$. La matrice inverse des coefficients est

$$A^{-1} = \frac{1}{5}\begin{pmatrix} 3 & 1 \\ -2 & 1 \end{pmatrix}$$

et on obtient donc

$$\boldsymbol{c} = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix} = A^{-1}\boldsymbol{w} = \frac{1}{5}\begin{pmatrix} 3 & 1 \\ -2 & 1 \end{pmatrix}\begin{pmatrix} 3 \\ 5 \end{pmatrix} = \begin{pmatrix} 14/5 \\ -1/5 \end{pmatrix}.$$

Cela veut donc dire que,

$$\boldsymbol{w} = \frac{14}{5}\begin{pmatrix} 1 \\ 2 \end{pmatrix} - \frac{1}{5}\begin{pmatrix} -1 \\ 3 \end{pmatrix}$$

et les coordonnées de ce vecteur dans la base $\mathcal{B}$ sont donc

$$(w)_{\mathcal{B}} = \begin{pmatrix} 14/5 \\ -1/5 \end{pmatrix}.$$

(c) On applique la même méthode sur le vecteur arbitraire $\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$ pour obtenir

$$(\boldsymbol{x})_{\mathcal{B}} = A^{-1}\boldsymbol{x} = \frac{1}{5}\begin{pmatrix} 3 & 1 \\ -2 & 1 \end{pmatrix}\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} \frac{3x_1+x_2}{5} \\ \frac{-2x_1+x_2}{5} \end{pmatrix}.$$

Problème 4.3.6. (TI) On considère

$$\mathcal{B} = \left\{ \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} -1 \\ 2 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \\ 2 \end{pmatrix} \right\}.$$

(a) Montrer que $\mathcal{B}$ est une base de $\mathbb{R}^3$.

(b) Donner les coordonnées $(\boldsymbol{w})_{\mathcal{B}}$ du vecteur $\boldsymbol{w} = \boldsymbol{e}_1 - 2\boldsymbol{e}_2 + \boldsymbol{e}_3$ dans cette base.

(c) Donner les coordonnées $(\boldsymbol{x})_{\mathcal{B}}$ d'un vecteur arbitraire $\boldsymbol{x} = x_1\boldsymbol{e}_1 + x_2\boldsymbol{e}_2 + x_3\boldsymbol{e}_3$ dans cette base.

SOLUTION.

(a) On forme la matrice carrée dont les colonnes sont les vecteurs de $\mathcal{B}$:

$$A = \begin{pmatrix} 1 & -1 & 1 \\ 1 & 2 & 2 \\ 0 & 1 & 0 \end{pmatrix}$$

Son déterminant est $\det(A) = 7 \neq 0$ et donc $\mathcal{B}$ est une base de l'espace $\mathbb{R}^3$. Le déterminant non-nul implique également l'existence de la matrice inverse

$$A^{-1} = \frac{1}{7}\begin{pmatrix} 4 & 3 & -2 \\ -2 & 2 & 1 \\ 1 & -1 & 3 \end{pmatrix},$$

dont on pourra désormais se servir pour calculer les coordonnées de vecteurs de $\mathbb{R}^3$ dans cette base.

(b) On a directement

$$(w)_{\mathcal{B}} = A^{-1}\boldsymbol{b} = \begin{pmatrix} -4/7 \\ -5/7 \\ 6/7 \end{pmatrix}.$$

(c) De manière similaire, les coordonnées $(x)_{\mathcal{B}}$ d'un vecteur arbitraire $\boldsymbol{x} \in \mathbb{R}^3$ dans la base $\mathcal{B}$ sont

$$(x)_{\mathcal{B}} = A^{-1}\boldsymbol{x} = A^{-1}\begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \frac{1}{7}\begin{pmatrix} 4x_1 + 3x_2 - 2x_3 \\ -2x_1 + 2x_2 + x_3 \\ x_1 - x_2 + 3x_3 \end{pmatrix}.$$

Problème 4.3.7. (TI) Dire si les familles de vecteurs suivantes forment une base de l'espace indiqué ou non. Justifier.

(a) $H = \left\{ \begin{pmatrix} 2 \\ 11 \end{pmatrix}, \begin{pmatrix} -1 \\ 3 \end{pmatrix} \right\}$, $\mathbb{R}^2$.

(b) $H = \left\{ \begin{pmatrix} 1 \\ 4 \end{pmatrix}, \begin{pmatrix} -5 \\ 3 \end{pmatrix}, \begin{pmatrix} 7 \\ 1 \end{pmatrix}, \begin{pmatrix} -4 \\ 0 \end{pmatrix} \right\}$, $\mathbb{R}^2$.

(c) $H = \left\{ \begin{pmatrix} 2 \\ -5 \end{pmatrix}, \begin{pmatrix} -4 \\ 10 \end{pmatrix} \right\}$, $\mathbb{R}^2$.

(d) $H = \left\{ \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \begin{pmatrix} -1 \\ 0 \\ 5 \end{pmatrix} \right\}$, $\mathbb{R}^3$.

(e) $H = \left\{ \begin{pmatrix} 1 \\ -2 \\ -3 \end{pmatrix}, \begin{pmatrix} -3 \\ 6 \\ 9 \end{pmatrix} \right\}$, $\mathbb{R}^3$.

(f) $H = \left\{ \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} \right\}$, $\mathbb{R}^3$.

(g) $H = \left\{ \begin{pmatrix} -1 \\ 5 \\ 2 \end{pmatrix}, \begin{pmatrix} 0 \\ -1 \\ 1 \end{pmatrix}, \begin{pmatrix} -1 \\ 3 \\ 4 \end{pmatrix} \right\}$, $\mathbb{R}^3$.

SOLUTION.

(a) Le déterminant de la matrice

$$A = \begin{pmatrix} 2 & -1 \\ 11 & 3 \end{pmatrix}$$

est $\det(A) = 6 - -11 = 17 \neq 0$ et donc H est une base de $\mathbb{R}^2$.

(b) La famille contient 4 vecteurs et ne peut donc pas être une base de $\mathbb{R}^2$.

(c) Le déterminant de la matrice

$$A = \begin{pmatrix} 2 & -4 \\ -5 & 10 \end{pmatrix}$$

est $\det(A) = 20 - 20 = 0$ et donc cette famille n'est pas une base. En particulier, on remarque directement que les deux vecteurs qui la composent sont linéairement dépendants.

(d) Cette famille contient 2 vecteurs de $\mathbb{R}^3$ et ne peut donc être une base. En particulier, il est impossible que $\text{span}(H) = \mathbb{R}^3$.

(e) Même argument que pour le sous-numéro précédent. En plus, on remarque ici que les vecteurs sont linéairement dépendants. Ils engendrent donc une droite alors que ceux du sous-numéro précédent, ne l'étant pas, engendrent plutôt un plan.

(f) On construit la matrice A dont les colonnes sont les vecteurs de la famille H. On a donc

$$A = \begin{pmatrix} 1 & 0 & 1 \\ 2 & 1 & 0 \\ 3 & 1 & 0 \end{pmatrix}.$$

Le déterminant de cette matrice est $\det(A) = -1 \neq 0$ et donc on conclut directement que cette famille est une base de $\mathbb{R}^3$.

(g) On peut remarquer directement que $\boldsymbol{u}_3 = \boldsymbol{u}_1 + 2\boldsymbol{u}_2$ et donc que cette famille de vecteurs n'est pas linéairement indépendante, ce qui implique qu'elle n'est pas une base de $\mathbb{R}^3$. On aurait également pu procéder avec le critère du déterminant. On construit la matrice A dont les colonnes sont les vecteurs de la famille H. On a donc

$$A = \begin{pmatrix} -1 & 0 & -1 \\ 5 & -1 & 3 \\ 2 & 1 & 4 \end{pmatrix}.$$

Le déterminant de cette matrice est nul et donc la famille n'est pas une base.

Semaine 12

5.1 Noyau et image d'une transformation linéaire

Problème 5.1.1. On considère une matrice A ayant 11 lignes et 4 colonnes.

(a) Donner les dimensions du domaine et de l'ensemble d'arrivée de la transformation linéaire T dont A est la matrice canonique.

(b) L'espace nul (ou *noyau*) $\ker(A)$ est un sous-espace vectoriel de quel espace ?

(c) L'espace colonnes (ou *image*) $\mathrm{im}(A)$ est un sous-espace vectoriel de quel espace ?

Solution.

(a) La matrice A définit une transformation linéaire $T : \mathbb{R}^4 \to \mathbb{R}^{11}$ par la multiplication $T(\boldsymbol{x}) = A\boldsymbol{x}$.

(b) L'espace nul d'une matrice (qui correspond au noyau de la transformation linéaire associée) est le sous-espace du domaine contenant toutes les solutions $\boldsymbol{x}$ de l'équation homogène

$$A\boldsymbol{x} = \mathbf{0}.$$

Il s'agit donc ici d'un sous-espace vectoriel de $\mathbb{R}^4$.

(c) L'espace colonne d'une matrice (qui correspond à l'image de la transformation linéaire associée) est le sous-espace de l'ensemble d'arrivée qui contient tous les vecteurs $\boldsymbol{b}$ tels que $A\boldsymbol{x} = \boldsymbol{b}$ pour un certain $\boldsymbol{x}$ du domaine. Il s'agit donc ici d'un sous-espace vectoriel de $\mathbb{R}^{11}$.

Problème 5.1.2. Soit la matrice

$$A = \begin{pmatrix} -1 & 2 & 1 \\ 2 & -4 & 0 \\ 4 & -8 & 1 \end{pmatrix}.$$

(a) Est-ce que le vecteur $\boldsymbol{v} = \begin{pmatrix} 1 \\ -1 \\ 4 \end{pmatrix}$ fait partie de $\ker A$?

(b) Est-ce que le vecteur $\boldsymbol{w} = \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix}$ fait partie de $\ker A$?

(c) **(T.I.)** Est-ce que le vecteur $\boldsymbol{u} = \begin{pmatrix} 1 \\ -5 \\ 0 \end{pmatrix}$ fait partie de $\mathrm{im}A$?

(d) **(T.I.)** Est-ce que le vecteur $\boldsymbol{b} = \begin{pmatrix} 6 \\ -6 \\ 9 \end{pmatrix}$ fait partie de $\mathrm{im}A$?

Solution.

(a) On calcule directement

$$A\boldsymbol{v} = \begin{pmatrix} -1 & 2 & 1 \\ 2 & -4 & 0 \\ 4 & -8 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \\ 4 \end{pmatrix} = \begin{pmatrix} 1 \\ 6 \\ 16 \end{pmatrix} \neq \mathbf{0}.$$

Donc, $\boldsymbol{v}$ n'appartient pas à l'espace nul de A.

(b) De manière similaire, on calcule

$$A\boldsymbol{w} = \begin{pmatrix} -1 & 2 & 1 \\ 2 & -4 & 0 \\ 4 & -8 & 1 \end{pmatrix} \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} = \mathbf{0}.$$

Donc, $\boldsymbol{w} \in \ker A$.

(c) Pour vérifier si le vecteur $\boldsymbol{u}$ appartient à l'espace colonne de A, on cherche un vecteur $\boldsymbol{x}$ tel que $A\boldsymbol{x} = \boldsymbol{u}$. Comme on le sait, une telle équation matricielle correspond à un système d'équations linéaires dont on peut considérer la matrice augmentée $(A|\boldsymbol{u})$. On obtient sa

forme échelonnée réduite avec la T.I. ou manuellement avec la méthode du pivot. On a alors

$$(A|\boldsymbol{u}) \sim \left(\begin{array}{ccc|c} -1 & 2 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{array}\right).$$

La dernière ligne est incompatible et le système n'admet aucune solution, d'où on conclut que $\boldsymbol{u}$ n'appartient pas à l'image de A.

(d) On utilise une approche similaire et on considère l'équation matricielle $A\boldsymbol{x} = \boldsymbol{b}$. La forme échelonnée réduite de la matrice augmentée associée est

$$(A|\boldsymbol{b}) \sim \left(\begin{array}{ccc|c} 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 2 \\ 0 & 0 & 1 & 3 \end{array}\right).$$

Ainsi, en posant $\boldsymbol{x} = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$, on a $A\boldsymbol{x} = \boldsymbol{b}$ et donc $\boldsymbol{b}$ est un élément de l'espace colonne de A.

Problème 5.1.3. Pour chacune des matrices suivantes, donner une base pour l'espace nul $\ker(A)$.

(a) $A = \begin{pmatrix} -1 & 3 & 2 & 1 \\ 2 & -2 & 1 & 4 \end{pmatrix}$,

(b) **(T.I.)** $A = \begin{pmatrix} -1 & 6 & 3 & 0 \\ 0 & 0 & 1 & 0 \end{pmatrix}$,

(c) **(T.I.)** $A = \begin{pmatrix} 1 & -2 & -3 \\ -2 & 1 & 0 \\ 3 & 1 & 5 \end{pmatrix}$,

(d) **(T.I.)** $A = \begin{pmatrix} 1 & -2 & 1 & 0 & 1 \\ 0 & 1 & 0 & -1 & 2 \\ 2 & 3 & 1 & 3 & 0 \end{pmatrix}$,

(e) $A = \begin{pmatrix} 1 & -2 & 1 \\ 3 & 2 & 0 \end{pmatrix}$.

SOLUTION.

(a) Pour former une base de l'espace nul de la matrice A, on considère la matrice augmentée de l'équation homogène $A\boldsymbol{x} = \mathbf{0}$. À l'aide de la méthode du pivot, on peut obtenir sa forme échelonnée réduite

$$(A|\mathbf{0}) = \left(\begin{array}{cccc|c} -1 & 3 & 2 & 1 & 0 \\ 2 & -2 & 1 & 4 & 0 \end{array}\right) \sim \left(\begin{array}{cccc|c} 1 & 0 & \frac{7}{4} & \frac{7}{2} & 0 \\ 0 & 1 & \frac{5}{4} & \frac{3}{2} & 0 \end{array}\right).$$

Les colonnes pivots sont donc associées aux variables liées x_1, x_2 tandis que x_3 et x_4 sont des variables libres. On utilise maintenant les équations associées aux lignes de la F.E.R. pour isoler les variables liées et les exprimer en fonction des variables libres. On obtient

$$\begin{cases} x_1 = -\frac{7}{4}x_3 - \frac{7}{2}x_4 \\ x_2 = -\frac{5}{4}x_3 - \frac{3}{2}x_4. \end{cases}$$

Ces équations sont satisfaites pour tout élément $\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix}$ de l'espace nul de A. On utilise les variables libres comme coefficients d'une combinaison linéaire pour ainsi écrire un tel vecteur $\boldsymbol{x}$ appartenant au noyau :

$$\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = x_3 \begin{pmatrix} -7/4 \\ -5/4 \\ 1 \\ 0 \end{pmatrix} + x_4 \begin{pmatrix} -7/2 \\ -3/2 \\ 0 \\ 1 \end{pmatrix}.$$

Une base de l'espace nul de A est donc donnée par

$$\mathcal{B} = \{\boldsymbol{v}_1, \boldsymbol{v}_2\} = \left\{ \begin{pmatrix} -7/4 \\ -5/4 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} -7/2 \\ -3/2 \\ 0 \\ 1 \end{pmatrix} \right\}.$$

La dimension de l'espace nul est donc $\dim \operatorname{nul} A = 2$.

Enfin, pour former une base de l'espace colonne, il s'agit simplement de considérer les colonnes pivots de la matrice initiale, soit

$$\left\{ \begin{pmatrix} -1 \\ 2 \end{pmatrix}, \begin{pmatrix} 3 \\ -2 \end{pmatrix} \right\}.$$

(b) L'approche est toujours la même. Ici, la F.E.R. de la matrice augmentée de l'équation homogène est

$$(A|\mathbf{0}) \sim \left(\begin{array}{cccc|c} 1 & -6 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \end{array}\right).$$

Les colonnes pivots sont associés aux variables liées x_1, x_3 tandis que x_2 et x_4 sont libres. On a $x_1 = 6x_2$ et $x_3 = 0$. Ainsi, un élément $\boldsymbol{x}$ du noyau peut-être écrit

$$\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = x_2 \begin{pmatrix} 6 \\ 1 \\ 0 \\ 0 \end{pmatrix} + x_4 \begin{pmatrix} 0 \\ 0 \\ 0 \\ 1 \end{pmatrix}.$$

Le noyau de A est de dimension 2 et admet donc la base suivante

$$\mathcal{B} = \left\{ \begin{pmatrix} 6 \\ 1 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 0 \\ 1 \end{pmatrix} \right\}.$$

Une base de l'espace colonne est formée par les colonnes 1 et 3 de la matrice initiale, soit

$$\left\{ \begin{pmatrix} -1 \\ 0 \end{pmatrix}, \begin{pmatrix} 3 \\ 1 \end{pmatrix} \right\}.$$

(c) La F.E.R. de la matrice augmentée de l'équation homogène est

$$\left(\begin{array}{ccc|c} 1 & 0 & 1 & 0 \\ 0 & 1 & 2 & 0 \\ 0 & 0 & 0 & 0 \end{array}\right).$$

On obtient donc les variables liées x_1, x_2 que l'on exprime en fonction de la variable libre x_3 :

$$\begin{cases} x_1 = -x_3 \\ x_2 = -2x_3. \end{cases}$$

Un élément $\boldsymbol{x}$ de l'espace nul peut dont être écrit

$$\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = x_3 \begin{pmatrix} -1 \\ -2 \\ 1 \end{pmatrix} = \boldsymbol{v_1}.$$

Cet espace nul est de dimension 1 et correspond à la droite de $\mathbb{R}^3$ passant par l'origine

parallèle à $\boldsymbol{v}_1$. Une base est

$$\left\{ \begin{pmatrix} -1 \\ -2 \\ 1 \end{pmatrix} \right\}.$$

Une base de l'espace colonne est

$$\left\{ \begin{pmatrix} 1 \\ -2 \\ 3 \end{pmatrix}, \begin{pmatrix} -2 \\ 1 \\ 1 \end{pmatrix} \right\}.$$

(d) Encore une fois, bien que la matrice soit un peu plus grande, l'approche est identique. La F.E.R. de la matrice augmentée associée à l'équation homogène est

$$\left(\begin{array}{ccccc|c} 1 & 0 & 0 & 8 & -11 & 0 \\ 0 & 1 & 0 & -1 & 2 & 0 \\ 0 & 0 & 1 & -10 & 16 & 0 \end{array} \right).$$

Les colonnes pivots sont associées aux variables liées x_1, x_2, x_3 tandis que les variables libres sont x_4 et x_5. On a

$$\begin{cases} x_1 = -8x_4 + 11x_5, \\ x_2 = x_4 - 2x_5, \\ x_3 = 10x_4 - 16x_5. \end{cases}$$

Ainsi, un vecteur $\boldsymbol{x}$ appartenant à l'espace nul de A peut être écrit

$$\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{pmatrix} = x_4 \begin{pmatrix} -8 \\ 1 \\ 10 \\ 1 \\ 0 \end{pmatrix} + x_5 \begin{pmatrix} 11 \\ -2 \\ -16 \\ 0 \\ 1 \end{pmatrix} = x_4 \boldsymbol{v}_1 + x_5 \boldsymbol{v}_2.$$

L'espace nul est de dimension 2 et une base est

$$\mathcal{B} = \{\boldsymbol{v}_1, \boldsymbol{v}_2\}.$$

Une base de l'image de A est quant à elle donnée par

$$\left\{ \begin{pmatrix} 1 \\ 0 \\ 2 \end{pmatrix}, \begin{pmatrix} -2 \\ 1 \\ 3 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} \right\}.$$

(e) La forme échelonnée réduite de la matrice augmentée de l'équation homogène est

$$\left(\begin{array}{ccc|c} 1 & 0 & 1/4 & 0 \\ 0 & 1 & -3/8 & 0 \end{array}\right).$$

Les variables liées sont x_1, x_2 et la variable libre est x_3. On a également

$$\begin{cases} x_1 = -\frac{1}{4}x_3 \\ x_2 = \frac{3}{8}x_3. \end{cases}$$

On peut donc utiliser ces relations pour écrire un élément $\boldsymbol{x}$ du noyau par

$$\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = x_3 \begin{pmatrix} -1/4 \\ 3/8 \\ 1 \end{pmatrix}.$$

Le noyau est de dimension 1 et admet la base

$$\mathcal{B} = \left\{ \begin{pmatrix} -1/4 \\ 3/8 \\ 1 \end{pmatrix} \right\}.$$

Une base de l'espace colonne est donnée par les colonnes de la matrice initiale dans lesquelles se sont retrouvées les pivots de la forme échelonnée réduite. On a donc

$$\left\{ \begin{pmatrix} 1 \\ 3 \end{pmatrix}, \begin{pmatrix} -2 \\ 2 \end{pmatrix} \right\}.$$

Semaine 13

6.1 Valeurs et vecteurs propres

Problème 6.1.1. On considère la matrice

$$A = \begin{pmatrix} 4 & 1 \\ 2 & 3 \end{pmatrix}.$$

(a) Est-ce que le scalaire $\lambda = -3$ est une valeur propre de A ?

(b) Est-ce que le scalaire $\lambda = 5$ est une valeur propre de A ?

(c) Est-ce que le vecteur $\boldsymbol{v} = \begin{pmatrix} 1 \\ -2 \end{pmatrix}$ est un vecteur propre de A ? Si oui, à quelle valeur propre est-il associé ?

(d) Est-ce que le vecteur $\boldsymbol{w} = \begin{pmatrix} 2 \\ -5 \end{pmatrix}$ est un vecteur propre de A ? Si oui, à quelle valeur propre est-il associé ?

(e) Est-ce que le vecteur $\mathbf{0} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$ est un vecteur propre de A ? Si oui, à quelle valeur propre est-il associé ?

Solution.

(a) Le scalaire $\lambda = -3$ est une valeur propre de A si et seulement si

$$\det(A - -3I) = \det(A + 3I) = 0.$$

On calcule

$$A+3I=\begin{pmatrix}4&1\\2&3\end{pmatrix}+3\begin{pmatrix}1&0\\0&1\end{pmatrix}=\begin{pmatrix}4+3&1\\2&3+3\end{pmatrix}=\begin{pmatrix}7&1\\2&6\end{pmatrix}.$$

Donc, $\det(A+3I)=42-2=40\neq 0$ et on conclut que -3 n'est pas une valeur propre de A.

(b) Le principe est similaire. On calcule directement

$$\det(A-5I)=\det\left(\begin{pmatrix}4-5&1\\2&3-5\end{pmatrix}\right)=\det\left(\begin{pmatrix}-1&1\\2&-2\end{pmatrix}\right)=2-2=0,$$

d'où on obtient que $\lambda=5$ est une valeur propre de la matrice A.

(c) On multiplie directement le vecteur $\boldsymbol{v}$ par la matrice A :

$$A\boldsymbol{v}=\begin{pmatrix}4&1\\2&3\end{pmatrix}\begin{pmatrix}1\\-2\end{pmatrix}=\begin{pmatrix}2\\-4\end{pmatrix}=2\boldsymbol{v}.$$

Ainsi, $\boldsymbol{v}$ est un vecteur propre de A, associé à la valeur propre $\lambda=2$.

(d) On a

$$A\boldsymbol{w}=\begin{pmatrix}4&1\\2&3\end{pmatrix}\begin{pmatrix}2\\-5\end{pmatrix}=\begin{pmatrix}3\\-11\end{pmatrix}.$$

Comme le vecteur $\begin{pmatrix}3\\-11\end{pmatrix}$ n'est pas un multiple scalaire de $\boldsymbol{w}$, on conclut que $\boldsymbol{w}$ n'est pas un vecteur propre de la matrice A.

(e) Par définition, le vecteur nul $\mathbf{0}$ n'est pas admissible comme vecteur propre.

Problème 6.1.2. On considère la matrice

$$A=\begin{pmatrix}3&7&9\\-4&-5&1\\2&4&4\end{pmatrix}.$$

(a) Est-ce que le scalaire $\lambda=7$ est une valeur propre de A ?

(b) Est-ce que le vecteur $\boldsymbol{v}=\begin{pmatrix}1\\2\\3\end{pmatrix}$ est un vecteur propre de A ? Si oui, à quelle valeur propre

est-il associé ?

(c) Est-ce que le vecteur $\boldsymbol{w} = \begin{pmatrix} 4 \\ -3 \\ 1 \end{pmatrix}$ est un vecteur propre de A ? Si oui, à quelle valeur propre est-il associé ?

SOLUTION.

(a) Le scalaire $\lambda = 7$ est une valeur propre de la matrice A si et seulement si $\det(A - 7I) = 0$. On calcule directement

$$\det(A-7I) = \det\left(\begin{pmatrix} 3-7 & 7 & 9 \\ -4 & -5-7 & 1 \\ 2 & 4 & 4-7 \end{pmatrix}\right) = \det\left(\begin{pmatrix} -4 & 7 & 9 \\ -4 & -12 & 1 \\ 2 & 4 & -3 \end{pmatrix}\right) = -126 \neq 0.$$

Ainsi, 7 n'est pas une valeur propre de la matrice A.

Remarquons au passage que nous aurions aussi pu calculer le polynôme caractéristique $p(\lambda)$ de cette matrice et vérifier que $p(7) \neq 0$.

(b) On calcule

$$A\boldsymbol{v} = \begin{pmatrix} 3 & 7 & 9 \\ -4 & -5 & 1 \\ 2 & 4 & 4 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} = \begin{pmatrix} 44 \\ -11 \\ 22 \end{pmatrix}.$$

$A\boldsymbol{v}$ n'est pas un multiple scalaire de $\boldsymbol{v}$ et ce dernier n'est donc pas un vecteur propre de A.

(c) De manière similaire, on a :

$$A\boldsymbol{w} = \begin{pmatrix} 3 & 7 & 9 \\ -4 & -5 & 1 \\ 2 & 4 & 4 \end{pmatrix} \begin{pmatrix} 4 \\ -3 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} = 0\boldsymbol{w}.$$

Ainsi, $\boldsymbol{w}$ est un vecteur propre de A, de valeur propre $\lambda = 0$. On remarque que, outre $\mathbf{0}$, les éventuels autres éléments de l'espace nul d'une matrice sont tous des vecteurs propres associés à la valeur propre 0.

6.2 Polynôme caractéristique

Problème 6.2.1. Soit la matrice

$$A = \begin{pmatrix} 7 & 4 \\ -3 & -1 \end{pmatrix}.$$

(a) Donner le polynôme caractéristique de la matrice A.

(b) Factoriser ce polynôme pour dresser une liste de toutes les valeurs propres de A, avec multiplicité le cas échéant.

Solution.

(a) Le polynôme caractéristique d'une matrice carrée de dimension n est défini par

$$p(\lambda) = \det(A - \lambda I_n),$$

où I_n est la matrice identité de taille n. Dans le cas qui nous occupe, on a donc

$$\begin{aligned} p(\lambda) &= \det(A - \lambda I_2) \\ &= \det\left(\begin{pmatrix} 7-\lambda & 4 \\ -3 & -1-\lambda \end{pmatrix}\right) \\ &= (7-\lambda)(-1-\lambda) + 12 = -7 - 6\lambda + \lambda^2 + 12 \\ &= \lambda^2 - 6\lambda + 5. \end{aligned}$$

(b) On a

$$p(\lambda) = \lambda^2 - 6\lambda + 5 = (\lambda - 5)(\lambda - 1).$$

Ainsi,

$$p(\lambda) = 0$$

si $\lambda = 5$ ou $\lambda = 1$, qui sont donc les deux valeurs propres de A.

Problème 6.2.2. Soit la matrice

$$B = \begin{pmatrix} 4 & -2 \\ -3 & 9 \end{pmatrix}.$$

(a) Donner le polynôme caractéristique de la matrice B.

(b) Factoriser ce polynôme pour dresser une liste de toutes les valeurs propres de B, avec multiplicité le cas échéant.

SOLUTION.

(a) On a

$$B - \lambda I = \begin{pmatrix} 4-\lambda & -2 \\ -3 & 9-\lambda \end{pmatrix},$$

d'où on tire que le polynôme caractéristique de B est

$$\begin{aligned} p(\lambda) &= \det(B - \lambda I) \\ &= (4-\lambda)(9-\lambda) - 6 = 36 - 4\lambda - 9\lambda + \lambda^2 - 6 \\ &= \lambda^2 - 13\lambda + 30. \end{aligned}$$

(b) On factorise directement

$$p(\lambda) = (\lambda - 10)(\lambda - 3),$$

pour conclure que $p(\lambda) = 0$ si et seulement si $\lambda = 10$ ou $\lambda = 3$, qui sont donc les deux valeurs propres de la matrice B.

Problème 6.2.3. (T.I.) Soit la matrice

$$A = \begin{pmatrix} 4 & 0 & 1 \\ -2 & 1 & 0 \\ -2 & 0 & 1 \end{pmatrix}.$$

(a) Donner le polynôme caractéristique de la matrice A.

(b) Factoriser ce polynôme pour dresser une liste de toutes les valeurs propres de A, avec multiplicité le cas échéant.

SOLUTION.

(a) Le polynôme caractéristique est donné par

$$\begin{aligned} p(\lambda) &= \det(A - \lambda I) \\ &= \det \begin{pmatrix} 4-\lambda & 0 & 1 \\ -2 & 1-\lambda & 0 \\ -2 & 0 & 1-\lambda \end{pmatrix} \\ &= -\lambda^3 + 6\lambda^2 - 11\lambda + 6. \end{aligned}$$

(b) Comme il s'agit d'un polynôme de degré 3, on utilise directement la commande *factor* de la T.I. pour obtenir

$$p(\lambda) = -(\lambda - 3)(\lambda - 2)(\lambda - 1).$$

Ainsi, $p(\lambda) = 0$ si et seulement $\lambda = 1, 2$ ou 3, qui sont donc les 3 valeurs propres (simples) de la matrice A.

Problème 6.2.4. (T.I.) Soit la matrice

$$D = \begin{pmatrix} 3 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}.$$

(a) Donner le polynôme caractéristique de la matrice A.

(b) Factoriser ce polynôme pour dresser une liste de toutes les valeurs propres de D, avec multiplicité le cas échéant.

Solution.

(a) On a

$$D - \lambda I = \begin{pmatrix} 3-\lambda & 0 & 0 \\ 0 & 1-\lambda & 0 \\ 0 & 0 & 1-\lambda \end{pmatrix},$$

d'où on tire directement que le polynôme caractéristique est

$$p(\lambda) = \det(D - \lambda I) = (3-\lambda)(1-\lambda)^2.$$

(b) Le polynôme est déjà factorisé et on conclut que la matrice D admet un valeur propre simple $\lambda = 3$ ainsi qu'une valeur propre de multiplicité double $\lambda = 1$. On remarque également que les valeurs propres de toute matrice diagonale sont précisément les éléments de la diagonale, comptés avec multiplicité s'il y a lieu.

6.3 Espaces propres, diagonalisation et puissances de matrices

Problème 6.3.1. On considère la matrice

$$A = \begin{pmatrix} 7 & 0 \\ 4 & 3 \end{pmatrix}.$$

(a) Vérifier que A admet deux valeurs propres distinctes, soit $\lambda_1 = 3$ et $\lambda_2 = 7$.

(b) Donner une base de l'espace propre E_7 qui contient tous les vecteurs propres associés à la valeur propre $\lambda = 7$.

(c) Donner une base de l'espace propre E_3.

(d) Diagonaliser la matrice A. Autrement dit, trouver une matrice inversible P et une matrice diagonale D telles que l'on puisse écrire $A = PDP^{-1}$.

(e) Donner une formule explicite pour A^k, la k-ème puissance de la matrice A, où $k \in \mathbb{N}$.

SOLUTION.

(a) Le polynôme caractéristique de A est

$$p(\lambda) = \det(A - \lambda I) = (7 - \lambda)(3 - \lambda),$$

et ses deux zéros sont donc effectivement $\lambda = 7$ et $\lambda = 3$.

(b) On calcule

$$A - 7I = \left(\begin{array}{cc|c} 7-7 & 0 & 0 \\ 4 & 3-7 & 0 \end{array}\right) = \left(\begin{array}{cc|c} 0 & 0 & 0 \\ 4 & -4 & 0 \end{array}\right).$$

La forme échelonnée réduite de la matrice augmentée $(A - 7I|\mathbf{0})$ est donc

$$\left(\begin{array}{cc|c} 1 & -1 & 0 \\ 0 & 0 & 0 \end{array}\right).$$

La première ligne permet d'écrire $x_1 = x_2$, d'où un vecteur propre de valeur propre $\lambda = 7$, c'est-à-dire un vecteur $\boldsymbol{x} \in E_7$ peut être écrit

$$\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = x_2 \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

Ainsi, une base de E_7 est donnée par $\boldsymbol{u_1} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$. L'espace propre E_7 correspond donc à la droite d'équation $x_1 = x_2$ dans le plan $\mathbb{R}^2$.

(c) L'espace propre E_3 qui contient tous les vecteurs propres associés à la valeur propre $\lambda = 3$

correspond à l'espace nul de la matrice $A - 3I$. On considère donc la matrice augmentée

$$(A - 3I|\mathbf{0}) = \left(\begin{array}{cc|c} 7-3 & 0 & 0 \\ 4 & 3-3 & 0 \end{array}\right) = \left(\begin{array}{cc|c} 4 & 0 & 0 \\ 4 & 0 & 0 \end{array}\right).$$

En soustrayant la ligne 1 de la ligne 2, on obtient directement la forme échelonnée réduite suivante

$$(A - 3I|\mathbf{0}) \sim \left(\begin{array}{cc|c} 1 & 0 & 0 \\ 0 & 0 & 0 \end{array}\right).$$

On obtient que $x_1 = 0$ et que x_2 est une variable libre. Ainsi, un vecteur $\boldsymbol{x} \in E_3$ peut être écrit

$$\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = x_2 \begin{pmatrix} 0 \\ 1 \end{pmatrix}.$$

Le vecteur $\boldsymbol{u}_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ forme donc une base de l'espace propre E_3. Celui-ci correspond donc à l'axe des x_2 dans le plan $\mathbb{R}^2$.

(d) On a trouvé deux vecteurs propres linéairement indépendants dans les étapes précédentes. On pose donc

$$P = (\boldsymbol{u}_1\, \boldsymbol{u}_2) = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix}.$$

La matrice diagonale des valeurs propres correspondante est quant à elle

$$D = \begin{pmatrix} 7 & 0 \\ 0 & 2 \end{pmatrix}.$$

On peut alors aisément vérifier que

$$PDP^{-1} = \begin{pmatrix} 7 & 0 \\ 4 & 3 \end{pmatrix} = A.$$

(e) On sait que

$$A^k = PD^kP^{-1},$$

où $D^k = \begin{pmatrix} 7^k & 0 \\ 0 & 3^k \end{pmatrix}$. On a donc

$$A^k = \begin{pmatrix} 7^k & 0 \\ 7^k - 3^k & 3^k \end{pmatrix}.$$

Problème 6.3.2. (T.I.) Soit la matrice

$$A = \begin{pmatrix} 4 & 0 & 1 \\ -2 & 1 & 0 \\ -2 & 0 & 1 \end{pmatrix}$$

(a) Trouver les valeurs propres de la matrice A.

(b) Donner une base de chacun des espaces propres associés.

(c) Diagonaliser la matrice A.

(d) Calculer A^5.

SOLUTION.

(a) Nous avons établi au problème 6.2.3 que les valeurs propres de la matrice A sont $\lambda = 1, 2, 3$.

(b) Nous devons trouver une base pour chacune des 3 espaces propres E_1, E_2, E_3.

· Base pour E_1 : La F.E.R de la matrice augmentée $(A - I|\mathbf{0})$ est

$$\left(\begin{array}{ccc|c} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 \end{array}\right).$$

Les variables liées sont x_1 et x_3, toutes deux égales à 0 tandis que la variable libre est x_2. Un vecteur propre $\boldsymbol{x}$ de valeur propre $\lambda = 1$ peut donc être écrit

$$\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = x_2 \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}.$$

Ainsi, une base de E_1 est donc donnée par

$$\{\boldsymbol{u_1}\} = \left\{ \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} \right\}.$$

· Base pour E_2 : La F.E.R de la matrice augmentée $(A - 2I|\mathbf{0})$ est

$$\left(\begin{array}{ccc|c} 1 & 0 & 1/2 & 0 \\ 0 & 1 & -1 & 0 \\ 0 & 0 & 0 & 0 \end{array}\right).$$

Les variables liées sont x_1 et x_2 et x_3 est une variable libre. De plus, on a

$$\begin{cases} x_1 = -\frac{1}{2}x_3 \\ x_2 = x_3. \end{cases}$$

Un vecteur $\boldsymbol{x} \in E_2$ de valeur propre $\lambda = 2$ peut donc être écrit

$$\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = x_3 \begin{pmatrix} -1/2 \\ 1 \\ 1 \end{pmatrix}.$$

Ainsi, une base de E_2 est donc donnée par

$$\{\boldsymbol{u_2}\} = \left\{ \begin{pmatrix} -1/2 \\ 1 \\ 1 \end{pmatrix} \right\}.$$

· Base pour E_3 : La F.E.R de la matrice augmentée $(A - 3I|\mathbf{0})$ est

$$\left(\begin{array}{ccc|c} 1 & 0 & 1 & 0 \\ 0 & 1 & -1 & 0 \\ 0 & 0 & 0 & 0 \end{array}\right).$$

Les variables liées sont x_1 et x_2 et x_3 est une variable libre. De plus, on a

$$\begin{cases} x_1 = -x_3 \\ x_2 = x_3. \end{cases}$$

Un vecteur $\boldsymbol{x} \in E_3$ de valeur propre $\lambda = 3$ peut donc être écrit

$$\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = x_3 \begin{pmatrix} -1 \\ 1 \\ 1 \end{pmatrix}.$$

Une base de E_3 est donnée par

$$\{\boldsymbol{u_3}\} = \left\{ \begin{pmatrix} -1 \\ 1 \\ 1 \end{pmatrix} \right\}.$$

(c) Nous avons pu trouver 3 vecteurs propres linéairement indépendants de A. En posant

$$P = (\boldsymbol{u}_1\, \boldsymbol{u}_2\, \boldsymbol{u}_3) = \begin{pmatrix} 0 & -1/2 & -1 \\ 1 & 1 & 1 \\ 0 & 1 & 1 \end{pmatrix}, \quad D = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 3 \end{pmatrix},$$

on peut vérifier que

$$PDP^{-1} = \begin{pmatrix} 4 & 0 & 1 \\ -2 & 1 & 0 \\ -2 & 0 & 1 \end{pmatrix} = A.$$

(d) On sait que

$$A^5 = (PDP^{-1})^5 = PD^5P^{-1}.$$

Or,

$$D^{25} = \begin{pmatrix} 1^5 & 0 & 0 \\ 0 & 2^5 & 0 \\ 0 & 0 & 3^5 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 31 & 0 \\ 0 & 0 & 243 \end{pmatrix}$$

et on a donc enfin

$$A^5 = \begin{pmatrix} 454 & 0 & 211 \\ -422 & 1 & -180 \\ -422 & 0 & -179 \end{pmatrix}.$$

Problème 6.3.3. (T.I.) Soit la matrice

$$A = \begin{pmatrix} -1 & 4 & -2 \\ -3 & 4 & 0 \\ -3 & 1 & 3 \end{pmatrix}$$

Sachant que les valeurs propres de la matrice A sont $\lambda = 1, 2, 3$, trouver une base de chacun des espaces propres associés pour ensuite diagonaliser A.

SOLUTION.
On doit trouver des bases pour les espaces propres E_1, E_2 et E_3.

· Base pour E_1 : La F.E.R de la matrice augmentée $(A - I|\mathbf{0})$ est

$$\left(\begin{array}{ccc|c} 1 & 0 & -1 & 0 \\ 0 & 1 & -1 & 0 \\ 0 & 0 & 0 & 0 \end{array}\right).$$

Les variables liées sont x_1 et x_2, tandis que la variable libre est x_3 et on a les relations

suivantes

$$\begin{cases} x_1 = x_3 \\ x_2 = x_3. \end{cases}$$

Un vecteur propre $\boldsymbol{x}$ de valeur propre $\lambda = 1$ peut donc être écrit

$$\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = x_3 \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}.$$

Une base de E_1 est alors

$$\{\boldsymbol{u_1}\} = \left\{ \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} \right\}.$$

· Base pour E_2 : La F.E.R de la matrice augmentée $(A - 2I|\mathbf{0})$ est

$$\left(\begin{array}{ccc|c} 1 & 0 & -2/3 & 0 \\ 0 & 1 & -1 & 0 \\ 0 & 0 & 0 & 0 \end{array} \right).$$

Les variables liées sont x_1 et x_2, tandis que la variable libre est x_3 et on a les relations suivantes

$$\begin{cases} x_1 = \frac{2}{3} x_3 \\ x_2 = x_3. \end{cases}$$

Un vecteur propre $\boldsymbol{x}$ de valeur propre $\lambda = 2$ peut donc être écrit

$$\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = x_3 \begin{pmatrix} 2/3 \\ 1 \\ 1 \end{pmatrix}.$$

Une base de E_2 est alors

$$\{\boldsymbol{u_2}\} = \left\{ \begin{pmatrix} 2/3 \\ 1 \\ 1 \end{pmatrix} \right\}.$$

· Base pour E_3 : La F.E.R de la matrice augmentée $(A - 3I|\mathbf{0})$ est

$$\left(\begin{array}{ccc|c} 1 & 0 & -1/4 & 0 \\ 0 & 1 & -3/4 & 0 \\ 0 & 0 & 0 & 0 \end{array} \right).$$

Les variables liées sont x_1 et x_2, tandis que la variable libre est x_3 et on a les relations

suivantes

$$\begin{cases} x_1 = \frac{1}{4}x_3 \\ x_2 = \frac{3}{4}x_3. \end{cases}$$

Un vecteur propre $\boldsymbol{x}$ de valeur propre $\lambda = 3$ peut donc être écrit

$$\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = x_3 \begin{pmatrix} 1/4 \\ 3/4 \\ 1 \end{pmatrix}.$$

Une base de E_3 est alors

$$\{\boldsymbol{u_3}\} = \left\{ \begin{pmatrix} 1/4 \\ 3/4 \\ 1 \end{pmatrix} \right\}.$$

La matrice A admet donc 3 vecteurs propres linéairement indépendants. On peut donc poser

$$P = (\boldsymbol{u}_1\, \boldsymbol{u}_2\, \boldsymbol{u}_3) = \begin{pmatrix} 1 & 2/3 & 1/4 \\ 1 & 1 & 3/4 \\ 1 & 1 & 1 \end{pmatrix}$$

ainsi que

$$D = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 3 \end{pmatrix},$$

pour obtenir

$$PDP^{-1} = \begin{pmatrix} -1 & 4 & -2 \\ -3 & 4 & 0 \\ -3 & 1 & 3 \end{pmatrix} = A,$$

soit la diagonalisation demandée.

Problème 6.3.4. (T.I.) Soit la matrice

$$A = \begin{pmatrix} 2 & 2 & 1 \\ 1 & 3 & 1 \\ 1 & 2 & 2 \end{pmatrix}$$

Diagonaliser la matrice A.

SOLUTION. Le polynôme caractéristique de cette matrice est

$$p(\lambda) = \det(A - \lambda I) = -(\lambda - 5)(\lambda - 1)^2.$$

On a donc une valeur propre simple $\lambda = 5$ et une valeur propre $\lambda = 1$ de multiplicité double. On doit donc trouver des bases pour les espaces propres E_5 et E_1.

· Base pour E_5 : La F.E.R de la matrice augmentée $(A - 5I|\mathbf{0})$ est

$$\left(\begin{array}{ccc|c} 1 & 0 & -1 & 0 \\ 0 & 1 & -1 & 0 \\ 0 & 0 & 0 & 0 \end{array}\right).$$

Les variables liées sont x_1 et x_2, tandis que la variable libre est x_3 et on a les relations suivantes

$$\begin{cases} x_1 = x_3 \\ x_2 = x_3. \end{cases}$$

Un vecteur propre $\boldsymbol{x}$ de valeur propre $\lambda = 5$ peut donc être écrit

$$\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = x_3 \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}.$$

Une base de E_5 est alors

$$\{\boldsymbol{u_1}\} = \left\{ \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} \right\}.$$

· Base pour E_1 : La F.E.R de la matrice augmentée $(A - I|\mathbf{0})$ est

$$\left(\begin{array}{ccc|c} 1 & 2 & 1 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{array}\right).$$

La variable liée est x_1 tandis que x_2 et x_3 sont libres et on a

$$x_1 = -2x_2 - x_3.$$

Comme à l'habitude, nous allons utiliser les variables libres comme coefficients des combinaisons linéaires des vecteurs de la base que nous recherchons. Un vecteur $\boldsymbol{x} \in E_1$ de valeur propre $\lambda = 1$ peut être écrit

$$\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = x_2 \begin{pmatrix} -2 \\ 1 \\ 0 \end{pmatrix} + x_3 \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix}.$$

Ainsi, une base de E_2 est donc donnée par

$$\{\boldsymbol{u_2}, \boldsymbol{u_3}\} = \left\{ \begin{pmatrix} -2 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix} \right\}.$$

On remarque au passage que cet espace propre est de dimension 2, tout comme la multiplicité algébrique de la valeur propre associée $\lambda = 1$.

La matrice A admet donc 3 vecteurs propres linéairement indépendants. Il ne suffit donc plus qu'à poser

$$P = (\boldsymbol{u}_1\, \boldsymbol{u}_2\, \boldsymbol{u}_3) = \begin{pmatrix} 1 & -2 & -1 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix}$$

ainsi que

$$D = \begin{pmatrix} 5 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix},$$

pour obtenir la diagonalisation $A = PDP^{-1}$ désirée.

3

Atelier IA

3.1 Lettre de remerciement du Collège de Maisonneuve

Collège de
Maisonneuve

Montréal, le 22 octobre 2026

M. Guillaume Roy-Fortin,
M. Xavier Provençal.

Au nom de nos étudiants et de leur personnel enseignant, je tiens à vous remercier pour la présentation de votre atelier sur « Les réseaux de neurones » aujourd'hui. Le langage utilisé était tout à fait adapté à la clientèle, l'approche ludique et l'animation, très dynamique.

Nous espérons, que de votre côté, vous avez trouvé l'organisation locale (accueil, local…) appropriée. Il sera peut-être possible, osons-nous croire, de vous recevoir à nouveau dans le cadre de nos futures activités périscolaires au collège Maisonneuve.

Au nom de toutes les personnes impliquées dans la préparation des activités périscolaire, veuillez recevoir, messieurs, nos salutations les plus respectueuses,

Joanie Laroche,
Simon Vézina
Denise Provençal

3800, rue Sherbrooke Est
Montréal (Québec) H1X 2A2
Tél. : 514-254-7131
cmaisonneuve.qc.ca

6220, rue Sherbrooke Est
Montréal (Québec) H1N 1C1
Tél. : 514-255-4444, poste 6203
Institue des procédés industriels

cmaisonneuve.qc.ca

3.2 Diapositives : principes mathématiques des réseaux de neurones

Une introduction pédagogique et interactive aux réseaux de neurones.

Xavier Provençal
Guillaume Roy-Fortin

École de technologie supérieure

Collège de Maisonneuve

22 octobre 2026

Un premier exemple

1. IA : intelligence artificielle, des logiciels capables, dans un certain sens, de réfléchir par eux-mêmes.

Un premier exemple

1. IA : intelligence artificielle, des logiciels capables, dans un certain sens, de réfléchir par eux-mêmes.

2. IA générative : une sorte d'IA spécialisée dans la *génération* de contenu : image, texte, musique, voix etc.

Un premier exemple

1. IA : intelligence artificielle, des logiciels capables, dans un certain sens, de réfléchir par eux-mêmes.

2. IA générative : une sorte d'IA spécialisée dans la *génération* de contenu : image, texte, musique, voix etc.

Deux paradigmes de l'apprentissage

Supposons qu'on veuille un programme capable d'identifier si une image est claire, grise ou foncée.

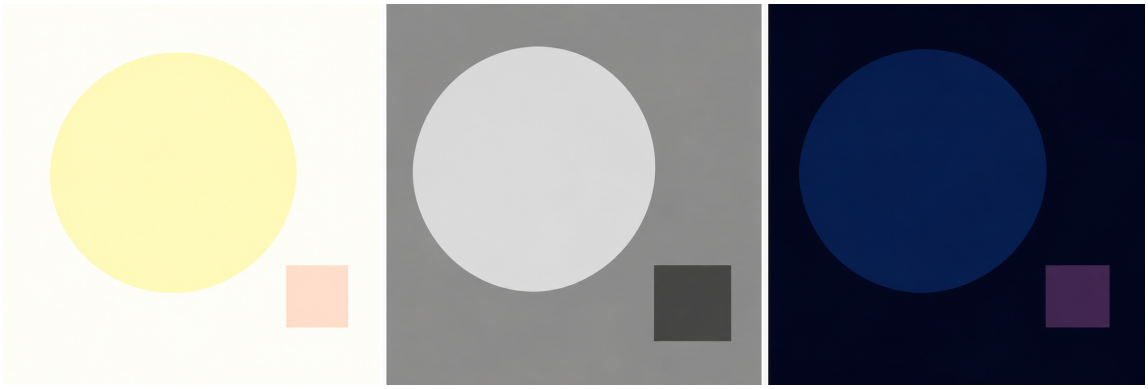

Deux paradigmes de l'apprentissage

Supposons qu'on veuille un programme capable d'identifier si une image est claire, grise ou foncée.

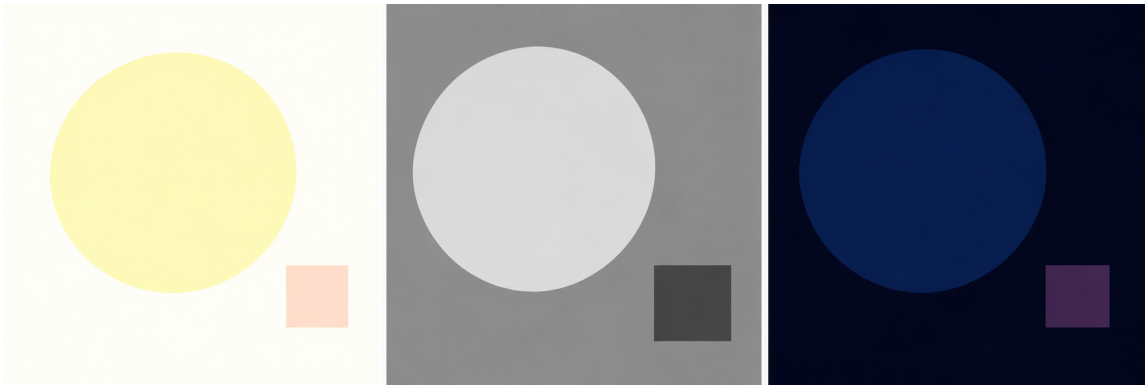

Plus difficile : identifier les formes ?

Deux paradigmes de l'apprentissage

Et si la tâche devenait vraiment plus complexe, comme par exemple identifier des images contenant des chiens ?

Deux paradigmes de l'apprentissage

Et si la tâche devenait vraiment plus complexe, comme par exemple identifier des images contenant des chiens ?

Deux paradigmes de l'apprentissage

Et si la tâche devenait vraiment plus complexe, comme par exemple identifier des images contenant des chiens ?

C'est la *complexité descriptive* de la tâche qui rend difficile l'usage du paradigme classique, direct.

Structure de l'atelier

On va vous présenter certaines idées générales qui vont vous permettre de réaliser des missions interactives.

Structure de l'atelier

On va vous présenter certaines idées générales qui vont vous permettre de réaliser, si vous les acceptez bien sûr, des missions interactives.

Mission 1

Mission 2

Mission 3

Mais comment ça marche ?

L'IA, c'est comme une vieille radio avec des milliers de boutons qu'il faut régler correctement !

Mais comment ça marche ?

L'IA, c'est comme une vieille radio avec des ~~milliers millions~~ **milliards** de boutons qu'il faut régler correctement !

Mais comment ça marche ?

L'IA, c'est comme une vieille radio avec des ~~milliers millions~~ **milliards** de boutons qu'il faut régler correctement !

Êtes-vous capables de « *syntoniser la bonne fréquence* » ?

MISSION #1

Il vous faudra ajuster les boutons pour que la courbe passe par les points affichés.

MISSION #1

Il vous faudra ajuster les boutons pour que la courbe passe par les points affichés.

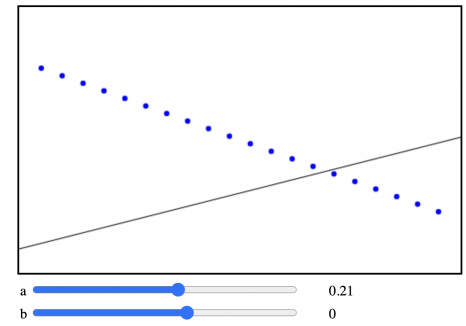

(G) : « *oups, ça ne marche pas.* »

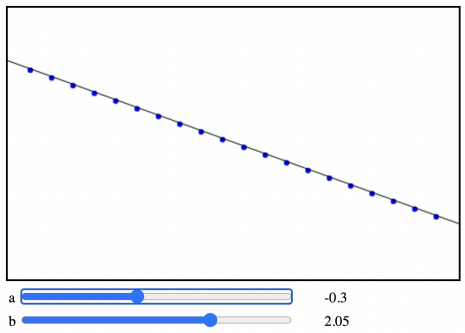

(D) : « *mission réussie !* »

MISSION #1

Il vous faudra ajuster les boutons pour que la courbe passe par les points affichés.

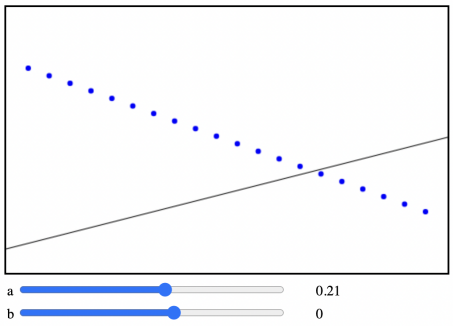

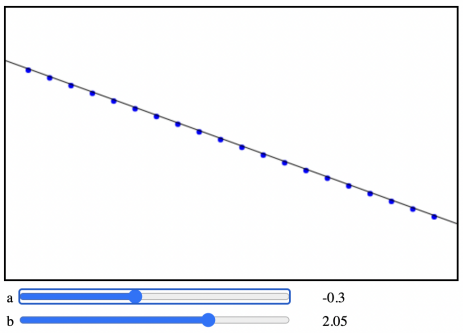

(G) : « *oups, ça ne marche pas.* » (D) : « *mission réussie !* »

À VOUS DE JOUER !

Mission 1

Un peu de théorie !

Pour pouvoir bien ajuster les boutons, il faut savoir ce qu'on cherche à faire. On a besoin d'une **tâche**.

Un peu de théorie !

Pour pouvoir bien ajuster les boutons, il faut savoir ce qu'on cherche à faire. On a besoin d'une **tâche**.

Par exemple, dans la mission précédente, la tâche était : « *faire passer la courbe par les points.* »

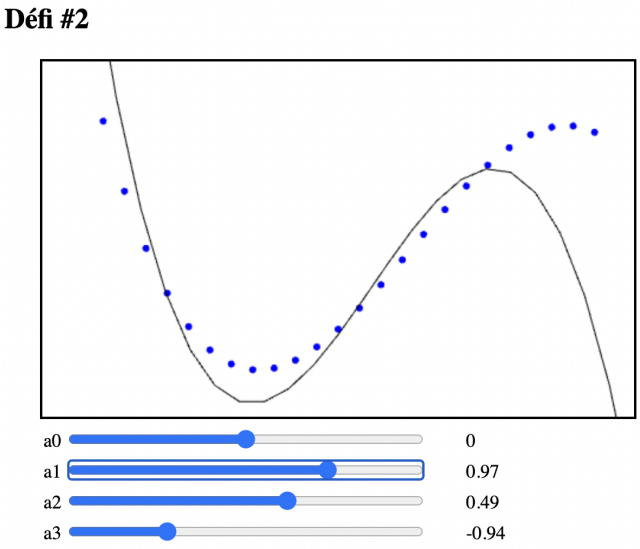

Des exemples de tâches

- Distinguer les images de chien des images de la tour Eiffel.

Des exemples de tâches

- Distinguer les images de chien des images de la tour Eiffel.

- Reconnaître des codes postaux manuscrits.

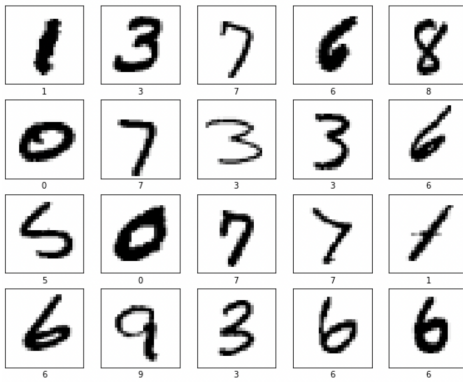

Réseau de neurones

Un réseau de neurones est un programme qui est inspiré...

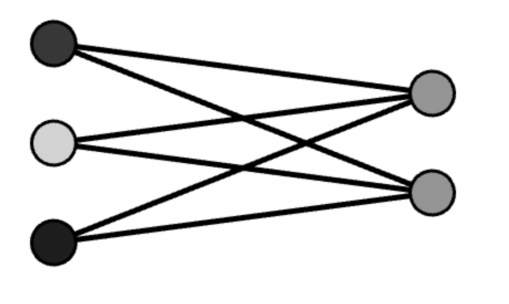

Un réseau de neurones.

Réseau de neurones

Un réseau de neurones est un programme qui est inspiré... d'un réseau de (vrais) neurones !

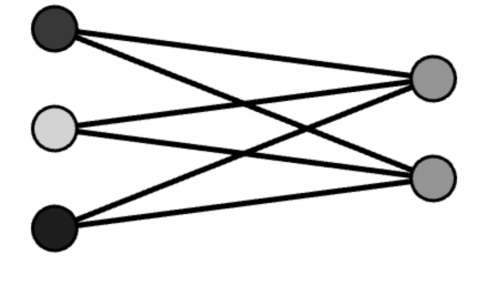

Un réseau de neurones.

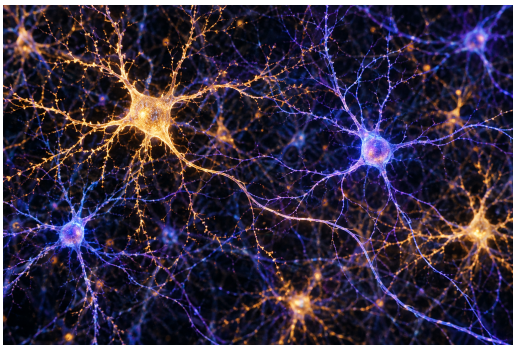

Une visualisation du cortex cérébral.

Réseau de neurones

Les neurones...

- sont connectés entre-eux, avec des connexions plus ou moins fortes.

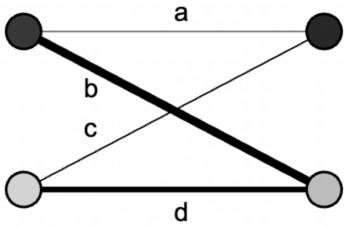

Réseau de neurones

Les neurones...

- sont connectés entre-eux, avec des connexions plus ou moins fortes.

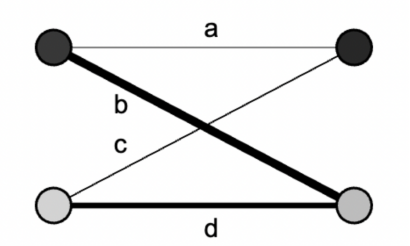

- peuvent-être plus ou moins actifs.

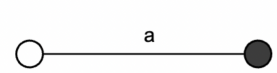

Réseau de neurones

Les neurones...

- sont connectés entre-eux, avec des connexions plus ou moins fortes.

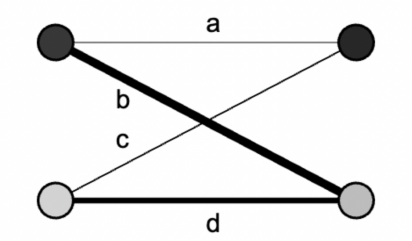

- peuvent-être plus ou moins actifs.

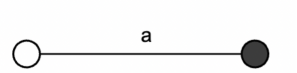

- transmettent leur activation aux neurones voisins.

MISSION #2

Il vous faudra ajuster les boutons pour que la sortie du réseau corresponde à celle demandée.

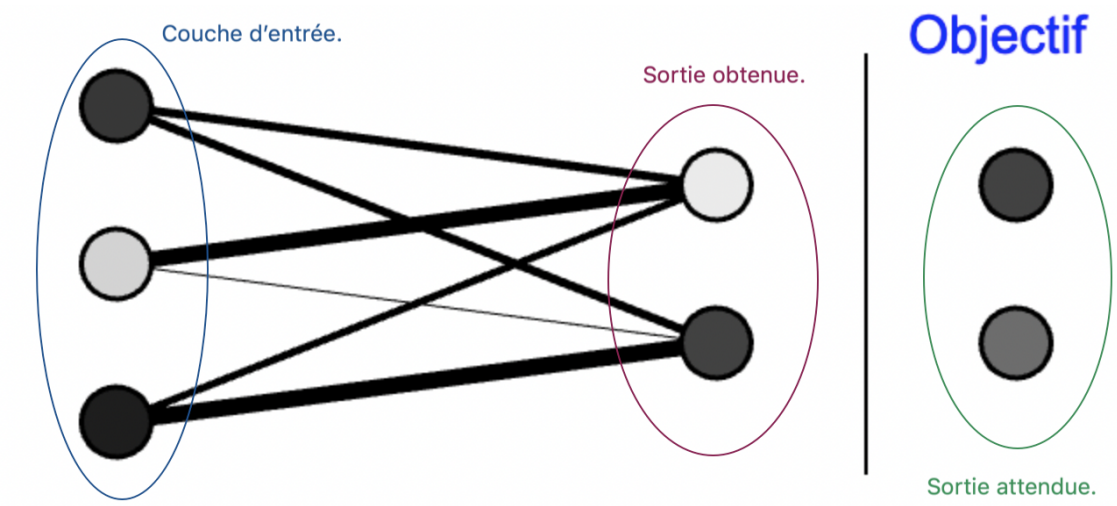

MISSION #2

Il vous faudra ajuster les boutons pour que la sortie du réseau corresponde à celle demandée.

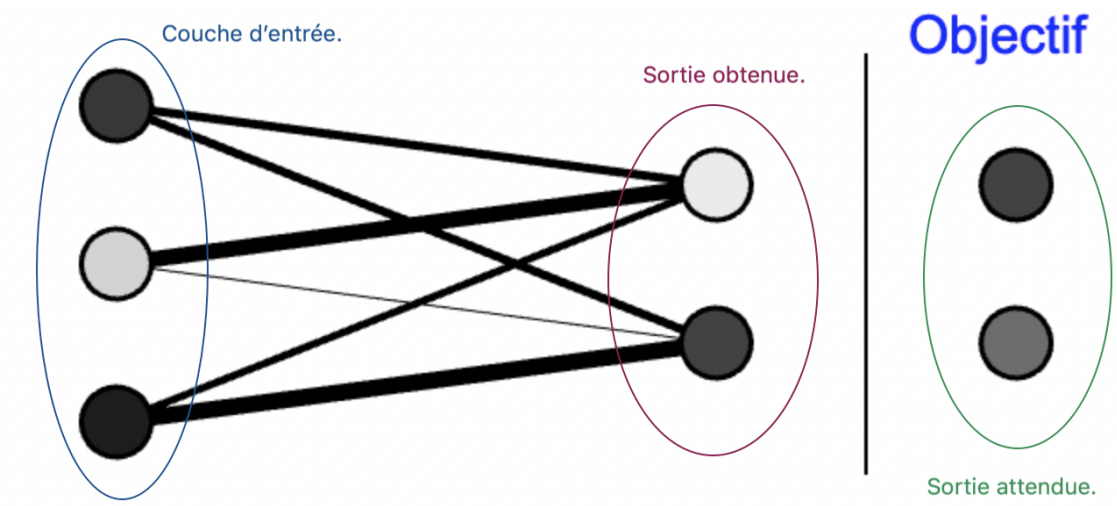

MISSION #2

En pratique, le même réseau doit être capable d'atteindre *plusieurs* cibles !

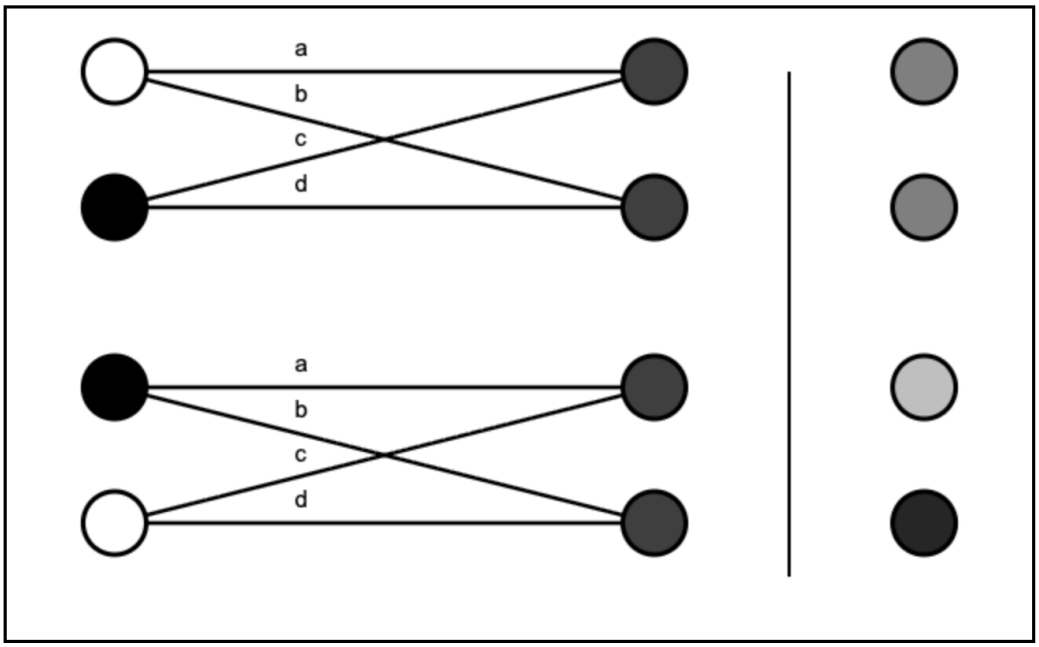

« *Un réseau, deux cibles.* »

MISSION #2

Une dernière chose : il est possible d'accorder un poids *négatif* aux liens entre les neurones. Cela correspond à l'idée *d'inverser* le signal contenu dans le neurone de départ.

À VOUS DE JOUER !

Mission 2

MISSION #2

Mais on a un problème : il faut que l'IA apprenne *par elle-même !*
Comment faire pour qu'elle puisse ajuster ses propres réglages ?

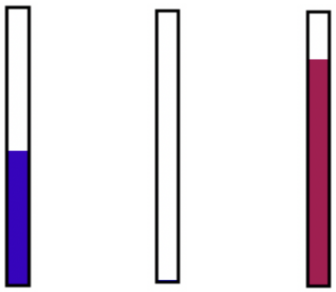

Il lui faut donc une mesure de son erreur qui lui indiquera comment se corriger !

« *Tsk, tsk, ça ne marche pas comme ça !* »

Qu'est-ce qu'une image ?

Une image peut être vue comme un tableau qui contient des pixels de différentes couleurs.

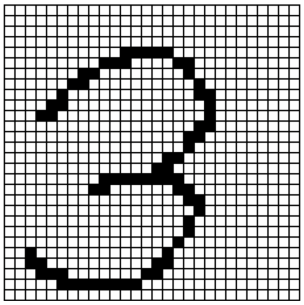

Qu'est-ce qu'une image ?

Une image peut être vue comme un tableau qui contient des pixels de différentes couleurs.

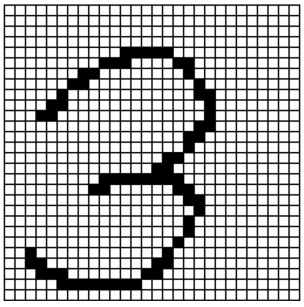

Ou encore...

Mission #3

But : créer votre propre réseau et l'entraîner à reconnaître les images 3×3 qui contiennent une ligne.

Mission #3

But : créer votre propre réseau et l'entraîner à reconnaître les images 3×3 qui contiennent une ligne.

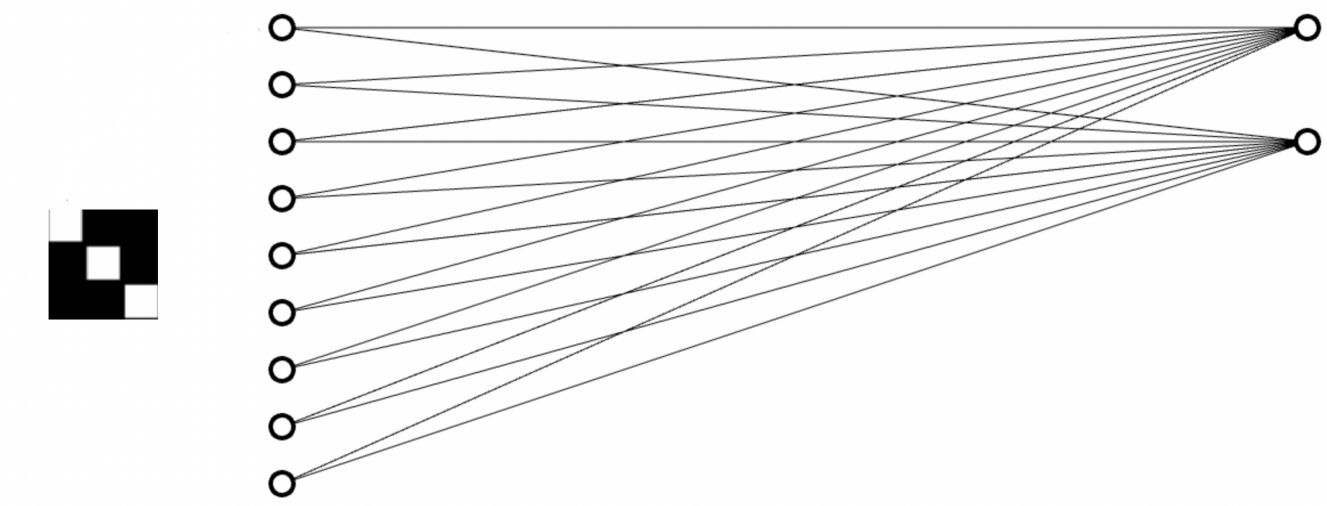

Mission #3

But : créer votre propre réseau et l'entraîner à reconnaître les images 3×3 qui contiennent une ligne.

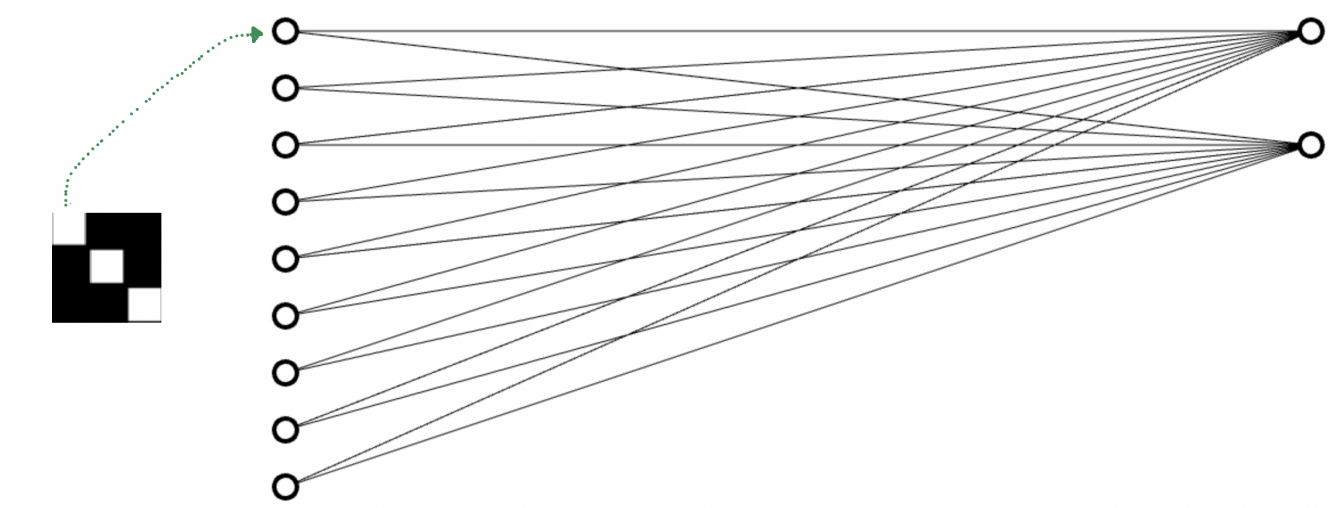

Mission #3

But : créer votre propre réseau et l'entraîner à reconnaître les images 3×3 qui contiennent une ligne.

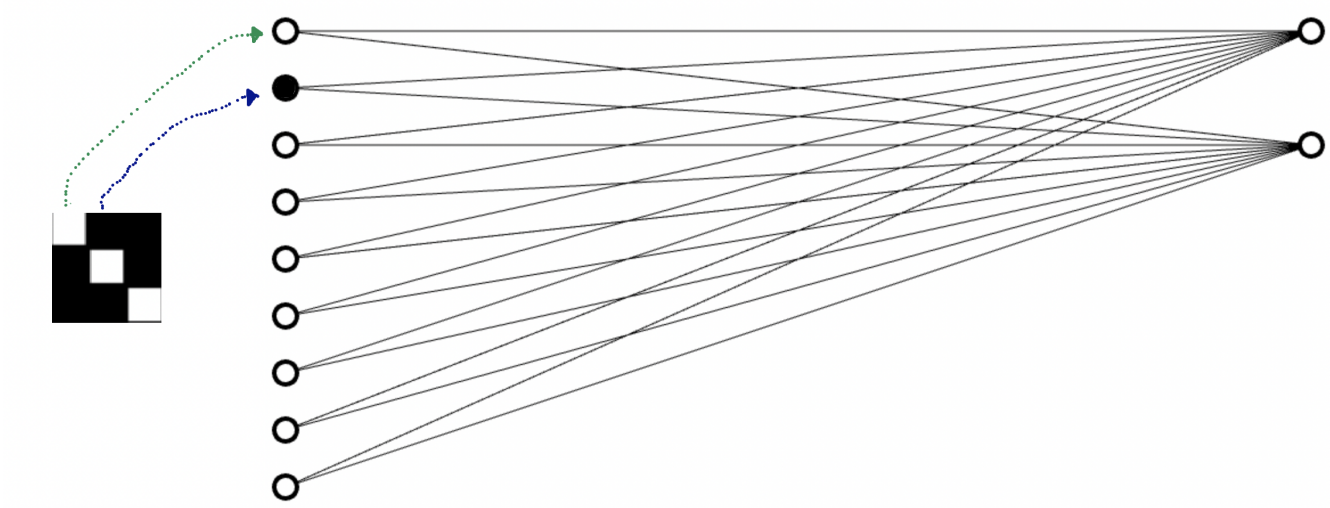

Mission #3

But : créer votre propre réseau et l'entraîner à reconnaître les images 3×3 qui contiennent une ligne.

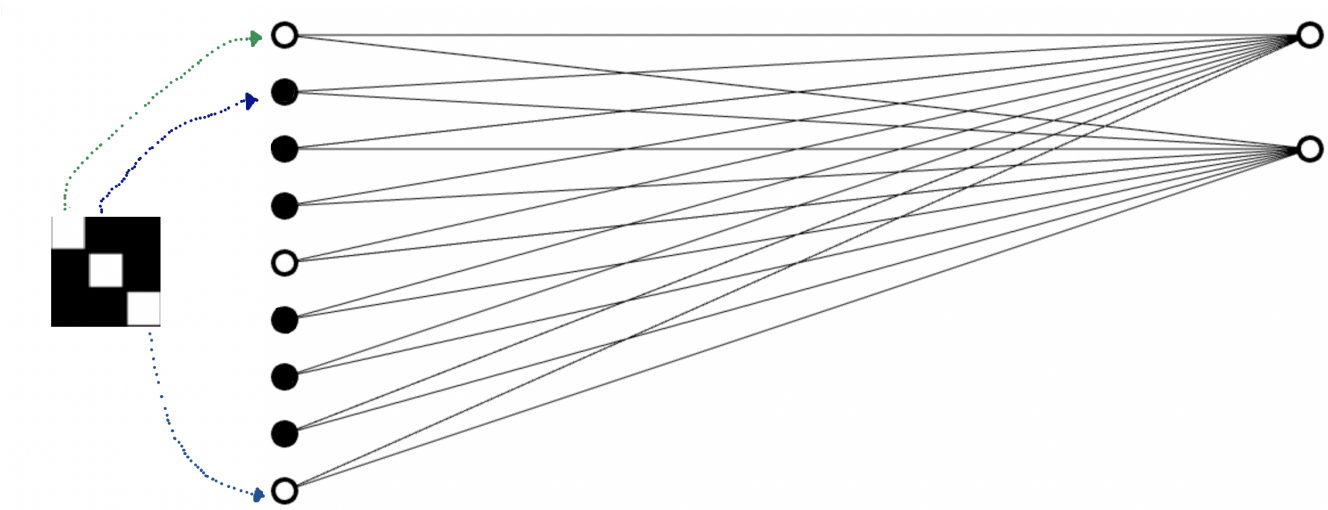

Mission #3

But : créer votre propre réseau et l'entraîner à reconnaître les images 3×3 qui contiennent une ligne.

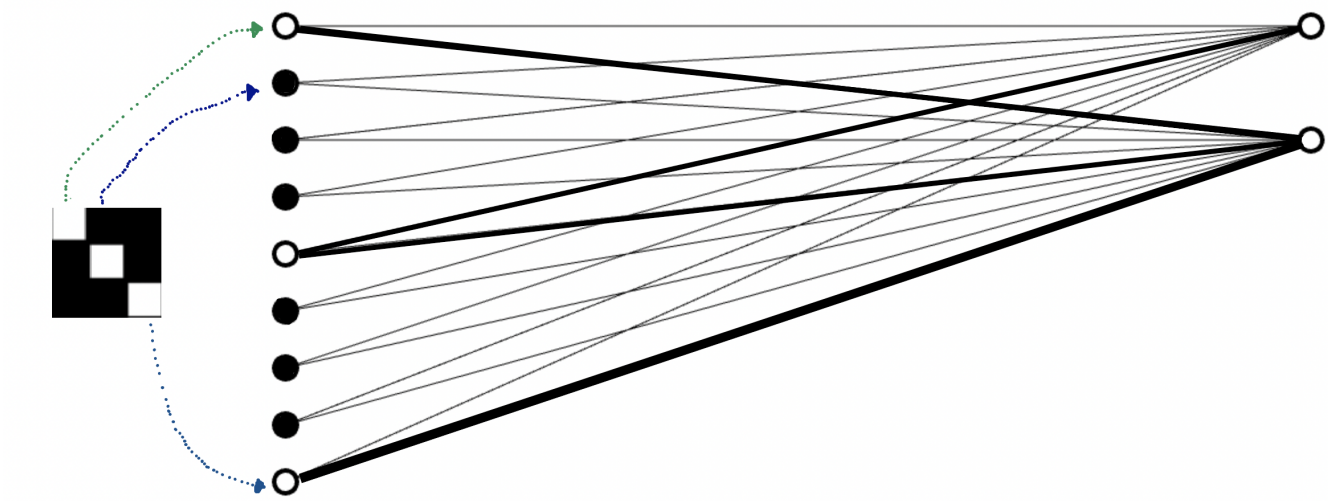

Mission #3

But : créer votre propre réseau et l'entraîner à reconnaître les images 3×3 qui contiennent une ligne.

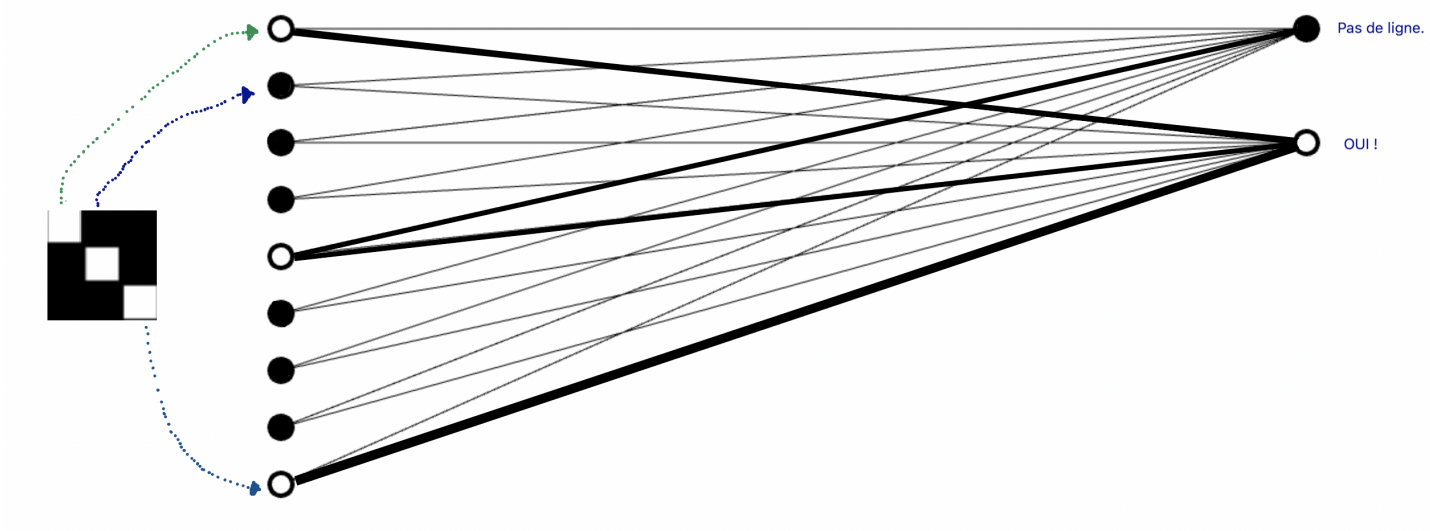

Mission #3

But : créer votre propre réseau et l'entraîner à reconnaître les images 3×3 qui contiennent une ligne.

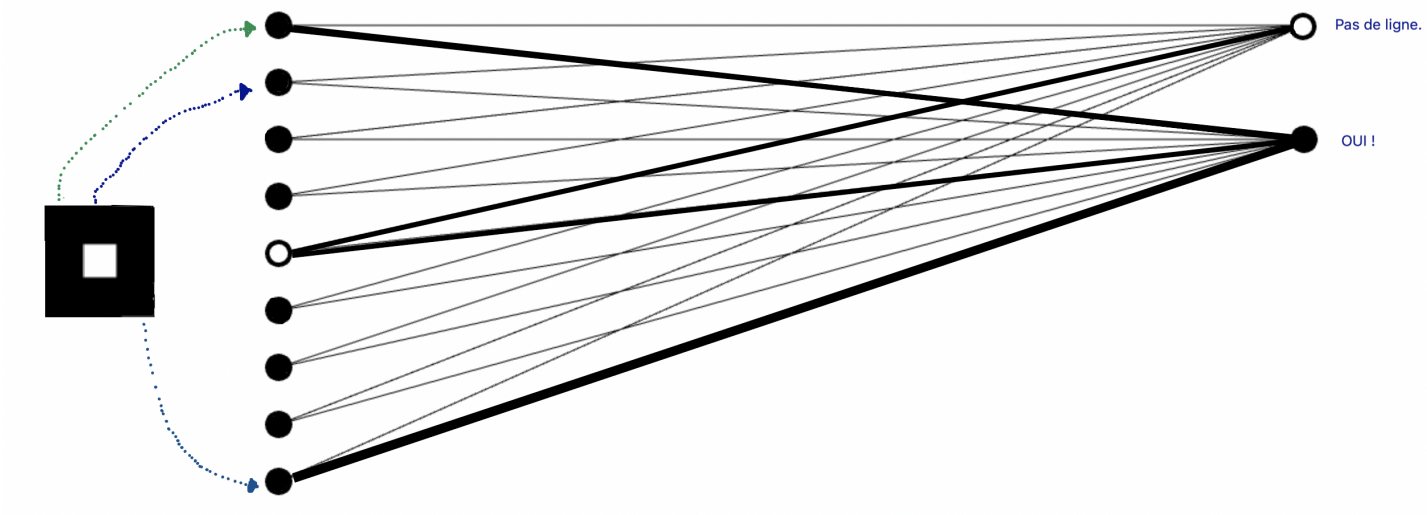

Mission #3

On vient de définir une architecture de réseau de neurones :

- Le nombre de couches.
- Le nombre de neurones par couche.

Mission #3

On vient de définir une architecture de réseau de neurones :

- Le nombre de couches.
- Le nombre de neurones par couche.

Votre réseau est prêt à *s'entraîner* ! À vous de jouer.

Mission 3

Mission finale !

Objectif : créer votre propre réseau et l'entraîner à reconnaître les chiffres manuscrits. Il faudra :

- Choisir l'architecture de votre réseau.

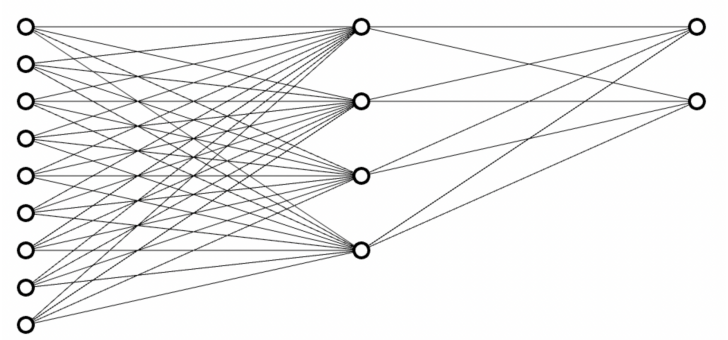

Un réseau à 3 couches, contenant respectivement 9, 3 et 2 neurones.

Mission finale !

Objectif : reconnaître les chiffres manuscrits. Il faudra :

- Choisir l'architecture de votre réseau.
- Suivre les performances de son entraînement.

Mission finale !

Objectif : reconnaître les chiffres manuscrits. Il faudra :

- Choisir l'architecture de votre réseau.
- Suivre les performances de son entraînement.
- Valider vous-même le fonctionnement du réseau.

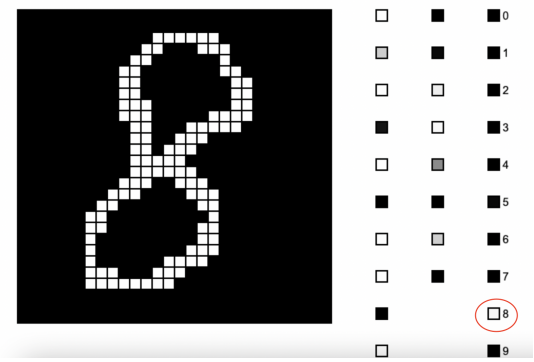

Le réseau a reconnu le chiffre 8.

C'est fini !

Des questions ?

4

Exposition

4.1 Conférence ouverture de l'AMQ

Quel futur pour des mathématiques automatisées?

Congrès de l'Association mathématique du Québec

Guillaume Roy-Fortin

Cégep de St-Georges

16 octobre 2026

Structure de l'exposé

1. Du sable au silicium : une chronologie mathématique.
2. Une certitude, des questions, des réflexions.
3. Perspectives d'avenir et discussion.

Partie I

Du sable au silicium : une chronologie mathématique.

VIe siècle av. J.-C : le théorème de Pythagore

- Soit $a \leq b < c$ les longueurs des côtés d'un triangle rectangle.
- Alors,
$$a^2 + b^2 = c^2.$$
- Aucune trace d'IA chez les grecs.

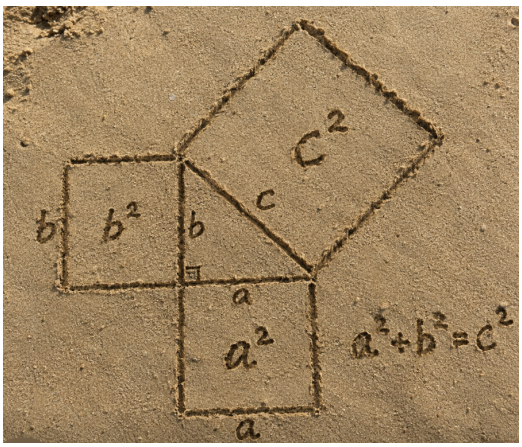

Crédit photo : ChatGPT.

1977 : le théorème des 4 couleurs

- Conjecture énoncée au milieu du 19e siècle par Guthrie et formalisée par Cayley.

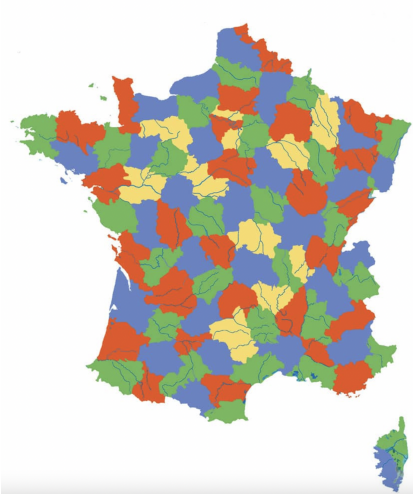

Source :

https ://www.mathemathieu.fr/art/articles-maths/23-le-theoreme-des-quatre-couleurs

1977 : le théorème des 4 couleurs

- Conjecture énoncée au milieu du 19e siècle par Guthrie et formalisée par Cayley.
- Démontrée... 124 ans plus tard grâce à l'aide de l'ordinateur en 1976.

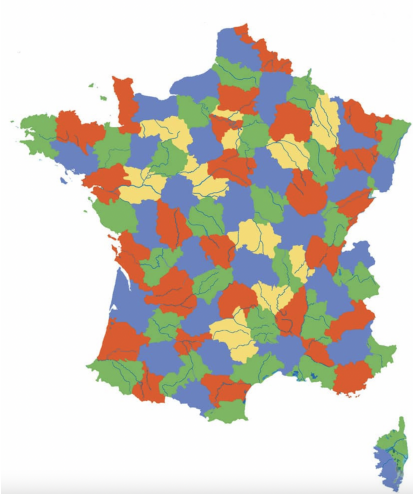

Source :

https ://www.mathemathieu.fr/art/articles-maths/23-le-theoreme-des-quatre-couleurs

1977 : le théorème des 4 couleurs

- Conjecture énoncée au milieu du 19e siècle par Guthrie et formalisée par Cayley.
- Démontrée... 124 ans plus tard grâce à l'aide de l'ordinateur en 1976.
- Déjà à l'époque, des questions : est-ce une *vraie* preuve ? Comment valider ?

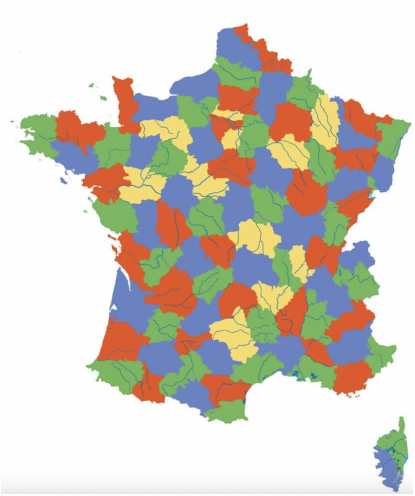

Source :

https ://www.mathemathieu.fr/art/articles-maths/23-le-theoreme-des-quatre-couleurs

2017 : toujours pas d'IA...

- Cours de calcul à l'ÉTS.
- Pouvait très bien se faire en devoir parce que... toujours pas d'IA générative.

Soit $\vec{F}$ le champ vectoriel conservatif défini dans la région de $\mathbb{R}^3$ par

$$\vec{F}(x,y,z) = (yz)\vec{i} + (xz)\vec{j} + (xy+2z)\vec{k}.$$

(a) Trouvez une fonction potentiel $f(x,y,z)$ telle que $\vec{F}(x,y,z) = \nabla f(x,y,z)$.

(b) Soit C le segment de droite qui joint $(1,0,-2)$ à $(4,6,3)$. À l'aide du théorème fondamental des intégrales curvilignes, calculez $\int_C \vec{F} \cdot d\vec{r}$, le long de la courbe C.

Novembre 2022 : bienvenue, ChatGPT !

- Première itération publique de ce *Chat Generative Pre-trained Transformer*.
- Capacités mathématiques primitives ou très rudimentaires.
- Font, entre autres, des erreurs de numération.

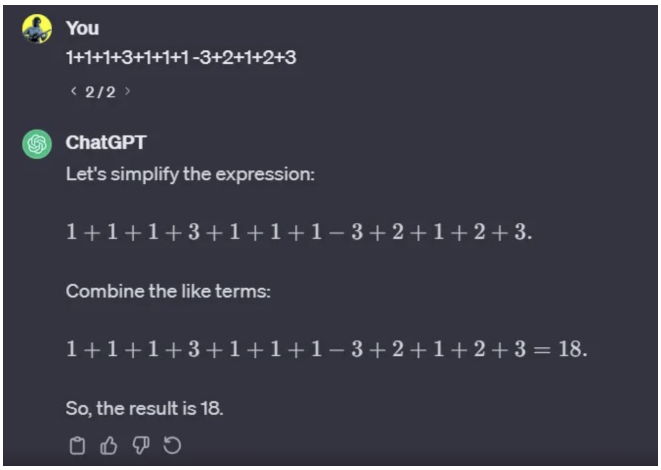

Source : Reddit.

2023-2024 : les perroquets stochastiques

- Anthropic (Claude), Google (PaLM, Gemini) et OpenAI (ChatGPT) raffinent leur modèle de langage large.
- Incapable de véritablement *réfléchir*, doit se contenter de *prédire*.

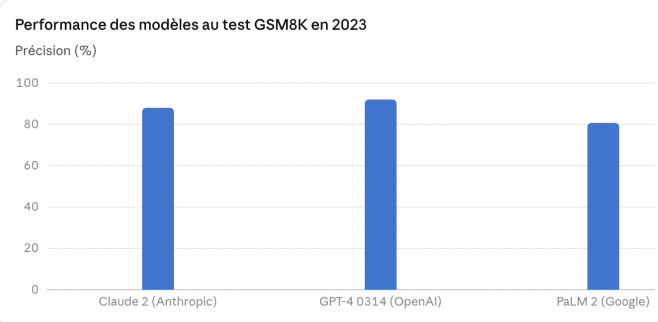

Q217 : *Il y a 4 roses dans le vase. Il y a 7 dahlias de plus que de roses dans le vase. Combien y a-t-il de fleurs au total dans le vase ?*

2025 : la ruée vers l'or

- Un modèle de Google obtient la médaille d'or aux olympiades mathématiques.
- « *We can confirm that Google DeepMind has reached the much-desired milestone, earning 35 out of a possible 42 points — a gold medal score. Their solutions were astonishing in many respects. IMO graders found them to be clear, precise and most of them easy to follow.* » - Prof. Dr. Gregor Dolinar, président des OIM.
- OAI aussi, mais sans être dans la compétition officielle...

2026

Source : ChatGPT.

Février 2026 : *First Proof*

Février 2026 : *First Proof*

- Défi lancé par une équipe de mathématiciens de haut niveau, incluant Martin Hairer (Fields, 2014).

Février 2026 : *First Proof*

- Défi lancé par une équipe de mathématiciens de haut niveau, incluant Martin Hairer (Fields, 2014).
- Banque de 10 résultats intermédiaires : combinatoire, EDPs stochastiques, algèbre...

Février 2026 : *First Proof*

- Défi lancé par une équipe de mathématiciens de haut niveau, incluant Martin Hairer (Fields, 2014).
- Banque de 10 résultats intermédiaires : combinatoire, EDPs stochastiques, algèbre...
- Chaque problème était *ouvert* pour le public, mais avec une solution connue par un membre de l'équipe.

Février 2026 : *First Proof*

- Défi lancé par une équipe de mathématiciens de haut niveau, incluant Martin Hairer (Fields, 2014).
- Banque de 10 résultats intermédiaires : combinatoire, EDPs stochastiques, algèbre...
- Chaque problème était *ouvert* pour le public, mais avec une solution connue par un membre de l'équipe.
- But : tester les agents d'IA sur des problèmes non rencontrés pendant l'entraînement.

Février 2026 : *First Proof*

- Défi lancé par une équipe de mathématiciens de haut niveau, incluant Martin Hairer (Fields, 2014).
- Banque de 10 résultats intermédiaires : combinatoire, EDPs stochastiques, algèbre...
- Chaque problème était *ouvert* pour le public, mais avec une solution connue par un membre de l'équipe.
- But : tester les agents d'IA sur des problèmes non rencontrés pendant l'entraînement.

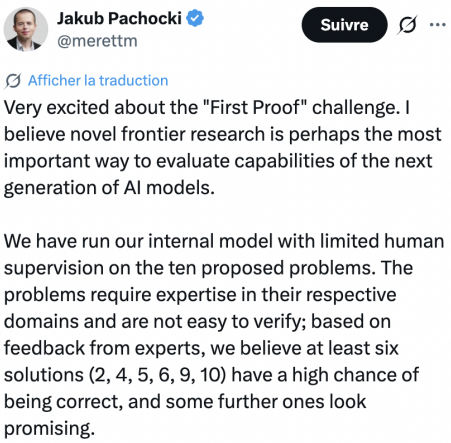

Comment valider une preuve ?

Les résultats d'OAI au défi *FirstProof* ont été **validés** par le logiciel **Lean**. Qu'est-ce donc ?

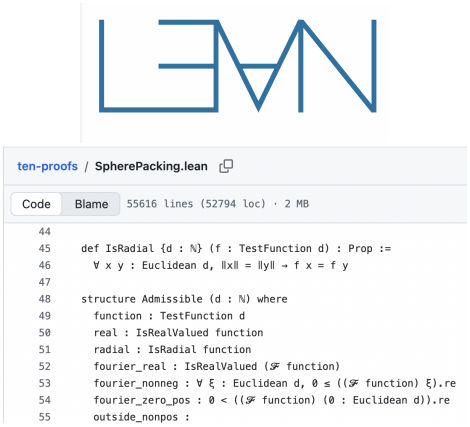

ten-proofs / SpherePacking.lean

Code Blame 55616 lines (52794 loc) · 2 MB

```
44
45    def IsRadial {d : ℕ} (f : TestFunction d) : Prop :=
46      ∀ x y : Euclidean d, ‖x‖ = ‖y‖ → f x = f y
47
48    structure Admissible (d : ℕ) where
49      function : TestFunction d
50      real : IsRealValued function
51      radial : IsRadial function
52      fourier_real : IsRealValued (𝓕 function)
53      fourier_nonneg : ∀ ξ : Euclidean d, 0 ≤ ((𝓕 function) ξ).re
54      fourier_zero_pos : 0 < ((𝓕 function) (0 : Euclidean d)).re
55      outside_nonpos :
```

Comment valider une preuve ?

Les résultats d'OAI au défi *FirstProof* ont été **validés** par le logiciel **Lean**. Qu'est-ce donc ?

- Langage de programmation fonctionnelle *open source*, conçu notamment pour la formalisation des mathématiques.

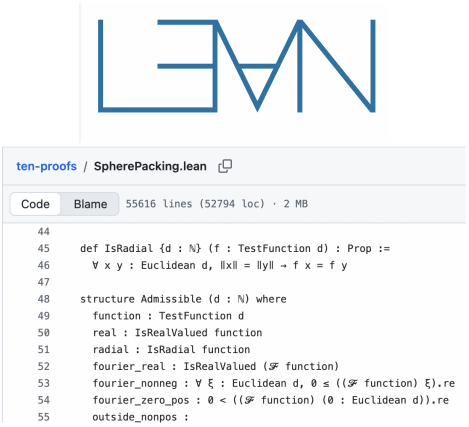

Comment valider une preuve ?

Les résultats d'OAI au défi *FirstProof* ont été **validés** par le logiciel **Lean**. Qu'est-ce donc ?

- Langage de programmation fonctionnelle *open source*, conçu notamment pour la formalisation des mathématiques.
- Permet de *vérifier formellement* une preuve dont l'énoncé et les arguments ont été préalablement *formalisés*.

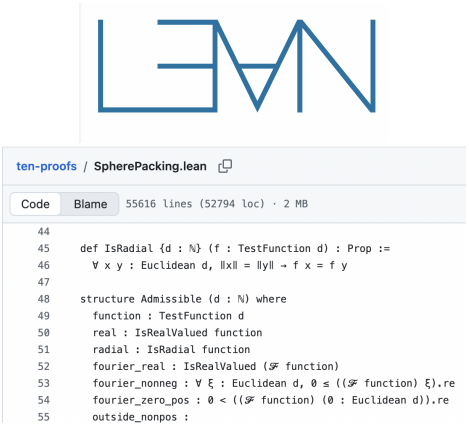

ten-proofs / SpherePacking.lean

Code | Blame | 55616 lines (52794 loc) · 2 MB

```
44
45    def IsRadial {d : ℕ} (f : TestFunction d) : Prop :=
46      ∀ x y : Euclidean d, ‖x‖ = ‖y‖ → f x = f y
47
48    structure Admissible (d : ℕ) where
49      function : TestFunction d
50      real : IsRealValued function
51      radial : IsRadial function
52      fourier_real : IsRealValued (𝓕 function)
53      fourier_nonneg : ∀ ξ : Euclidean d, 0 ≤ ((𝓕 function) ξ).re
54      fourier_zero_pos : 0 < ((𝓕 function) (0 : Euclidean d)).re
55      outside_nonpos :
```

Comment valider une preuve ?

Les résultats d'OAI au défi *FirstProof* ont été **validés** par le logiciel **Lean**. Qu'est-ce donc ?

- Langage de programmation fonctionnelle *open source*, conçu notamment pour la formalisation des mathématiques.
- Permet de *vérifier formellement* une preuve dont l'énoncé et les arguments ont été préalablement *formalisés*.
- Une preuve acceptée par Lean constitue une sorte de *certificat* indiquant que la proposition est démontrée dans ce système.

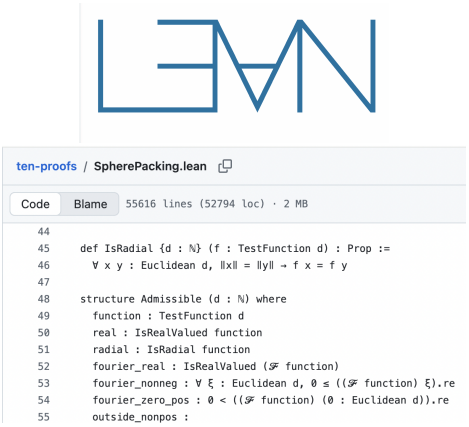

Comment valider une preuve ?

Les résultats d'OAI au défi *FirstProof* ont été **validés** par le logiciel **Lean**. Qu'est-ce donc ?

- Langage de programmation fonctionnelle *open source*, conçu notamment pour la formalisation des mathématiques.
- Permet de *vérifier formellement* une preuve dont l'énoncé et les arguments ont été préalablement *formalisés*.
- Une preuve acceptée par Lean constitue une sorte de *certificat* indiquant que la proposition est démontrée dans ce système.

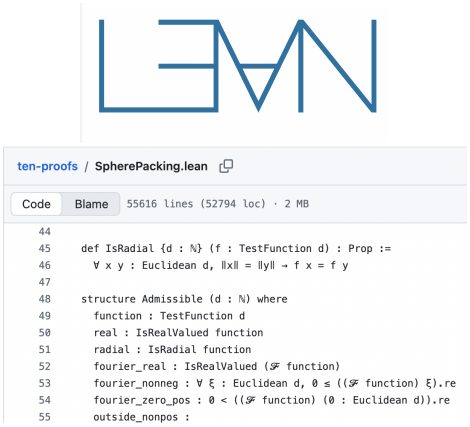

→ Idée principale : si l'IA peut produire une preuve, Lean peut en principe la vérifier et la valider.

Le problème de la distance unitaire

Paul Erdös a posé des milliers de problèmes pendant sa prolifique carrière. Parmi eux...

Le problème de la distance unitaire

Paul Erdös a posé des milliers de problèmes pendant sa prolifique carrière. Parmi eux...

Conjecture de la distance unitaire

Soit $\nu(n)$ le nombre maximal de paires de points situés dans le plan $\mathbb{R}^2$, parmi n points distincts, qui sont à distance exactement 1 l'un de l'autre. Alors,

$$\nu(n) = n^{1+o(1)}.$$

Le problème de la distance unitaire

Paul Erdös a posé des milliers de problèmes pendant sa prolifique carrière. Parmi eux...

Conjecture de la distance unitaire

Soit $\nu(n)$ le nombre maximal de paires de points situés dans le plan $\mathbb{R}^2$, parmi n points distincts, qui sont à distance exactement 1 l'un de l'autre. Alors,

$$\nu(n) = n^{1+o(1)}.$$

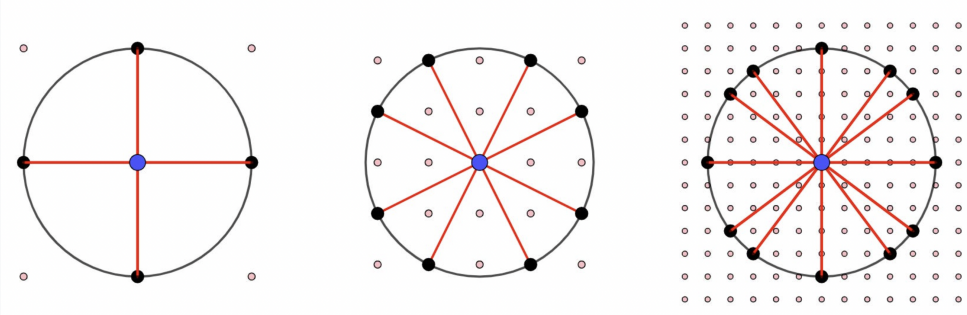

Source : OpenAI.

Mai 2026

- Une équipe d'OpenAI montre qu'on a

$$\nu(n) \geq n^{1+\delta},$$

pour une infinité de n et où $\delta > 0$.

Mai 2026

- Une équipe d'OpenAI montre qu'on a

$$\nu(n) \geq n^{1+\delta},$$

pour une infinité de n et où $\delta > 0$.

- Autrement dit, la conjecture de Erdös est fausse.

Mai 2026

- Une équipe d'OpenAI montre qu'on a

$$\nu(n) \geq n^{1+\delta},$$

pour une infinité de n et où $\delta > 0$.

- Autrement dit, la conjecture de Erdös est fausse.
- La preuve utilise des éléments de géométrie algébrique !

Mai 2026

- Une équipe d'OpenAI montre qu'on a

$$\nu(n) \geq n^{1+\delta},$$

pour une infinité de n et où $\delta > 0$.

- Autrement dit, la conjecture de Erdös est fausse.
- La preuve utilise des éléments de géométrie algébrique !

2026 : et du côté d'Anthropic ?

- Un des gladiateurs choisis par Anthropic est Levent Alpöge.

2026 : et du côté d'Anthropic ?

- Un des gladiateurs choisis par Anthropic est Levent Alpöge.
- Mathématicien éduqué à Harvard, Cambridge et Princeton.

2026 : et du côté d'Anthropic ?

- Un des gladiateurs choisis par Anthropic est Levent Alpöge.
- Mathématicien éduqué à Harvard, Cambridge et Princeton.
- Employé chez ANT depuis 2025.

2026 : et du côté d'Anthropic ?

- Un des gladiateurs choisis par Anthropic est Levent Alpöge.
- Mathématicien éduqué à Harvard, Cambridge et Princeton.
- Employé chez ANT depuis 2025.
- Rupture avec la tradition : annonce ses résultats sur ... X !

2026 : et du côté d'Anthropic ?

- Un des gladiateurs choisis par Anthropic est Levent Alpöge.
- Mathématicien éduqué à Harvard, Cambridge et Princeton.
- Employé chez ANT depuis 2025.
- Rupture avec la tradition : annonce ses résultats sur ... X !

Juillet 2026

La conjecture du jacobien (1939)

Soit $p : \mathbb{C}^n \to \mathbb{C}^n$ une fonction polynomiale de jacobien constant et non-nul. Alors, p^{-1} existe et est polynomiale.

Juillet 2026

La conjecture du jacobien (1939)

Soit $p : \mathbb{C}^n \to \mathbb{C}^n$ une fonction polynomiale de jacobien constant et non-nul. Alors, p^{-1} existe et est polynomiale.

- Trivial pour $n = 1$.

Juillet 2026

La conjecture du jacobien (1939)

Soit $p : \mathbb{C}^n \to \mathbb{C}^n$ une fonction polynomiale de jacobien constant et non-nul. Alors, p^{-1} existe et est polynomiale.

- Trivial pour $n = 1$.
- C'était ouvert pour $n \geq 2$.

Juillet 2026

La conjecture du jacobien (1939)

Soit $p : \mathbb{C}^n \to \mathbb{C}^n$ une fonction polynomiale de jacobien constant et non-nul. Alors, p^{-1} existe et est polynomiale.

- Trivial pour $n = 1$.
- C'était ouvert pour $n \geq 2$.

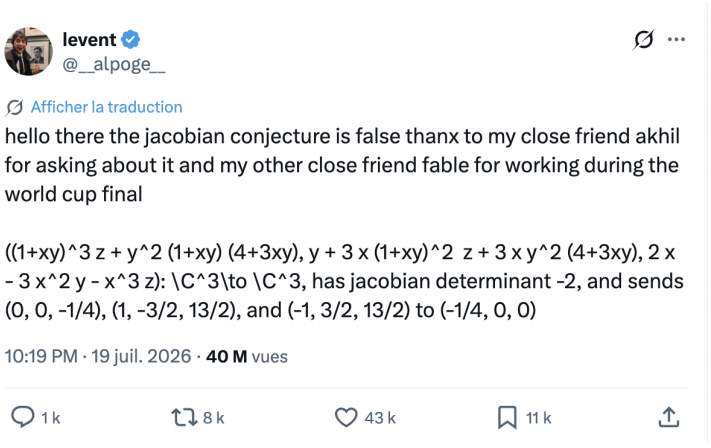

levent
@__alpoge__

Afficher la traduction

hello there the jacobian conjecture is false thanx to my close friend akhil for asking about it and my other close friend fable for working during the world cup final

((1+xy)^3 z + y^2 (1+xy) (4+3xy), y + 3 x (1+xy)^2 z + 3 x y^2 (4+3xy), 2 x - 3 x^2 y - x^3 z): \C^3\to \C^3, has jacobian determinant -2, and sends (0, 0, -1/4), (1, -3/2, 13/2), and (-1, 3/2, 13/2) to (-1/4, 0, 0)

10:19 PM · 19 juil. 2026 · **40 M** vues

1 k 8 k 43 k 11 k

Juillet 2026

La conjecture du jacobien (1939)

Soit $p : \mathbb{C}^n \to \mathbb{C}^n$ une fonction polynomiale de jacobien constant et non-nul. Alors, p^{-1} existe et est polynomiale.

- Trivial pour $n = 1$.
- C'était ouvert pour $n \geq 2$.
- Donc faux pour $n \geq 3$!

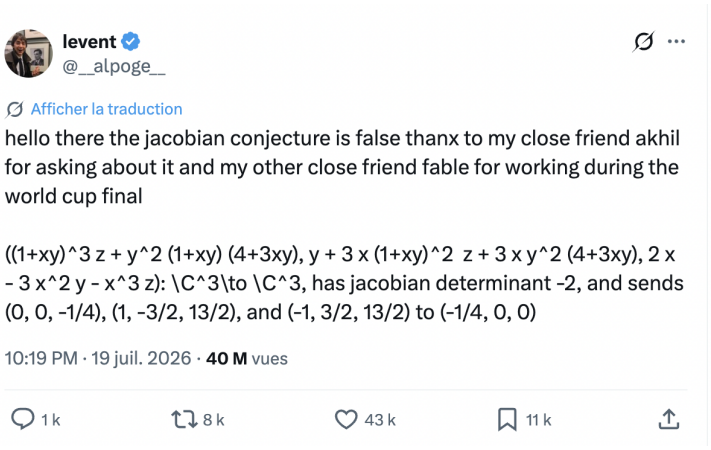

levent
@__alpoge__

Afficher la traduction

hello there the jacobian conjecture is false thanx to my close friend akhil for asking about it and my other close friend fable for working during the world cup final

((1+xy)^3 z + y^2 (1+xy) (4+3xy), y + 3 x (1+xy)^2 z + 3 x y^2 (4+3xy), 2 x - 3 x^2 y - x^3 z): \C^3\to \C^3, has jacobian determinant -2, and sends (0, 0, -1/4), (1, -3/2, 13/2), and (-1, 3/2, 13/2) to (-1/4, 0, 0)

10:19 PM · 19 juil. 2026 · **40 M** vues

1 k 8 k 43 k 11 k

Août 2026

Août 2026

- En 1948, Hopf montre que $\mathbb{S}^4$ et $\mathbb{S}^8$ n'admettent pas de structure complexe.

Août 2026

- En 1948, Hopf montre que $\mathbb{S}^4$ et $\mathbb{S}^8$ n'admettent pas de structure complexe.
- Est-ce que $\mathbb{S}^6$ en possède une ?

Août 2026

- En 1948, Hopf montre que $\mathbb{S}^4$ et $\mathbb{S}^8$ n'admettent pas de structure complexe.
- Est-ce que $\mathbb{S}^6$ en possède une ?
- Problème majeur, étudié notamment par Atiyah.

Août 2026

- En 1948, Hopf montre que $\mathbb{S}^4$ et $\mathbb{S}^8$ n'admettent pas de structure complexe.
- Est-ce que $\mathbb{S}^6$ en possède une ?
- Problème majeur, étudié notamment par Atiyah.

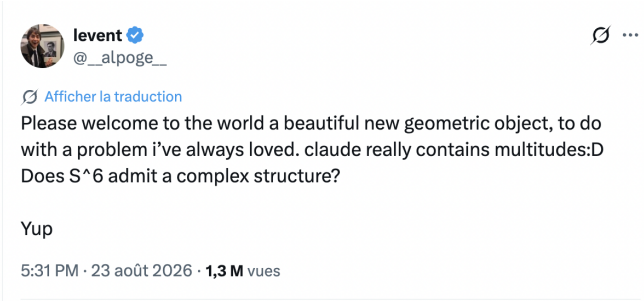

Attention ! Aucune formalisation *Lean* valide pour le moment.

Août 2026, encore

- Une matrice de Hadamard est une matrice carrée dont les entrées sont $+1$ ou -1 et dont les rangées sont orthogonales deux à deux.
- On a alors $HH^T = nI_n$.
- $n = 668$ était le plus petit n admissible sans construction explicite.

Août 2026, encore

- Une matrice de Hadamard est une matrice carrée dont les entrées sont $+1$ ou -1 et dont les rangées sont orthogonales deux à deux.
- On a alors $HH^T = nI_n$.
- $n = 668$ était le plus petit n admissible sans construction explicite.

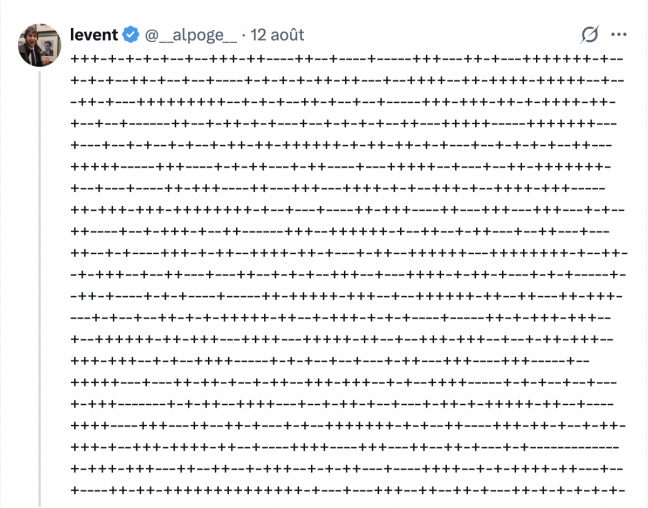

Septembre 2026

L'ère des bulldozers.

Les bulldozers sont là

- En l'espace de quelques jours...

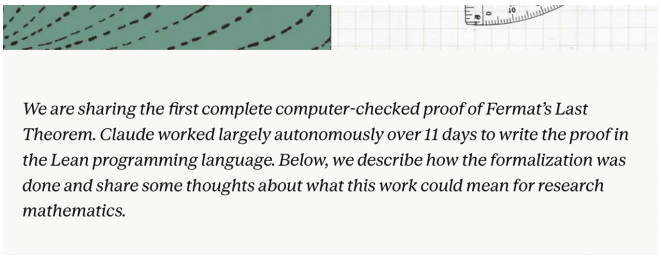

We are sharing the first complete computer-checked proof of Fermat's Last Theorem. Claude worked largely autonomously over 11 days to write the proof in the Lean programming language. Below, we describe how the formalization was done and share some thoughts about what this work could mean for research mathematics.

Les bulldozers sont là

- En l'espace de quelques jours...
- Annonce d'une formalisation du dernier théorème de Fermat par ANT.

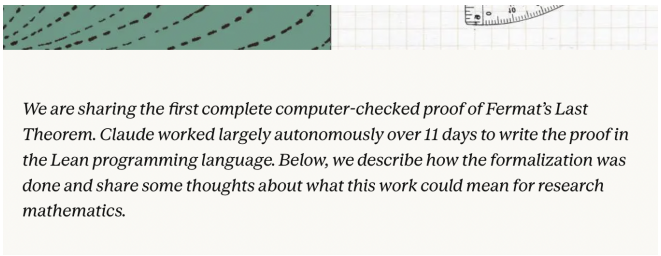

We are sharing the first complete computer-checked proof of Fermat's Last Theorem. Claude worked largely autonomously over 11 days to write the proof in the Lean programming language. Below, we describe how the formalization was done and share some thoughts about what this work could mean for research mathematics.

Les bulldozers sont là

- En l'espace de quelques jours...
- Annonce d'une formalisation du dernier théorème de Fermat par ANT.
- Hugo Duminil-Copin : « *It now seems only a matter of time before the most famous conjecture in our field*,

$$\theta(p_c) = 0$$

also falls to the bulldozers.»

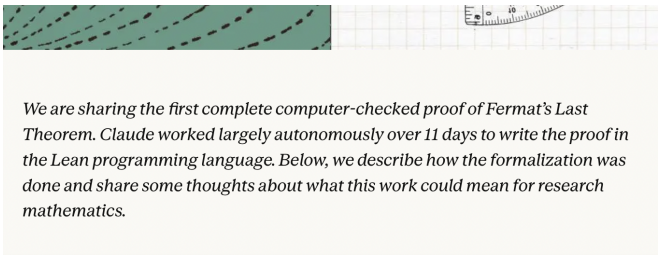

We are sharing the first complete computer-checked proof of Fermat's Last Theorem. Claude worked largely autonomously over 11 days to write the proof in the Lean programming language. Below, we describe how the formalization was done and share some thoughts about what this work could mean for research mathematics.

Les problèmes du millénaire

Les problèmes du millénaire

- Une liste de problèmes importants et difficiles, d'importance majeure.

Les problèmes du millénaire

- Une liste de problèmes importants et difficiles, d'importance majeure.
- On peut les voir comme un test ultime pour confirmer que les mathématiciens ne sont définitivement pas des dieux !

Les 7 travaux des mathématiciens : faudra peut-être repenser la programmation de ciné-cadeau... !

Les problèmes du millénaire

- Une liste de problèmes importants et difficiles, d'importance majeure.
- On peut les voir comme un test ultime pour confirmer que les mathématiciens ne sont définitivement pas des dieux !
- Un seul avait été résolu : la conjecture de Poincaré.

Les 7 travaux des mathématiciens : faudra peut-être repenser la programmation de ciné-cadeau... !

Les problèmes du millénaire

- Une liste de problèmes importants et difficiles, d'importance majeure.
- On peut les voir comme un test ultime pour confirmer que les mathématiciens ne sont définitivement pas des dieux !
- Un seul avait été résolu : la conjecture de Poincaré.
- Tous les autres étaient ouverts. Jusqu'à ce que...

Les 7 travaux des mathématiciens : faudra peut-être repenser la programmation de ciné-cadeau... !

8 Septembre 2026

This is not a drill.

Les équations de Navier-Stokes

- OAI annonce avoir une solution complète pour le problème du millénaire de Navier-Stokes.

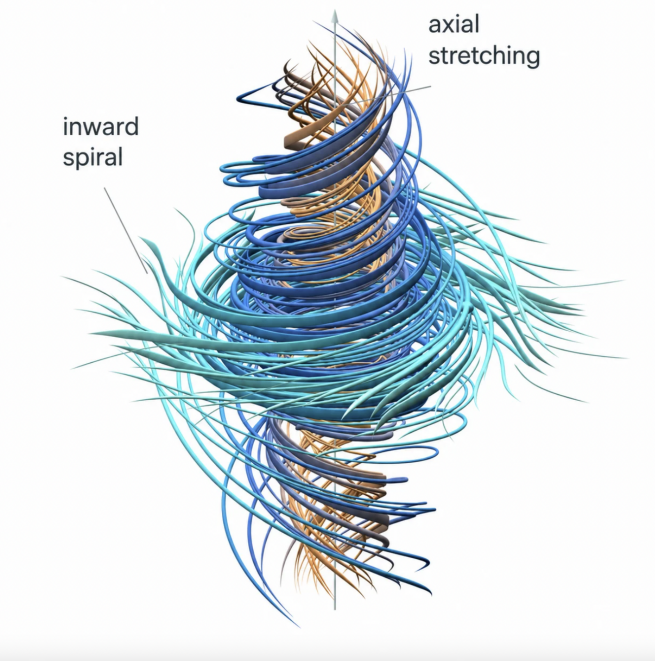

Les équations de Navier-Stokes

- OAI annonce avoir une solution complète pour le problème du millénaire de Navier-Stokes.
- Avec une formalisation Lean !

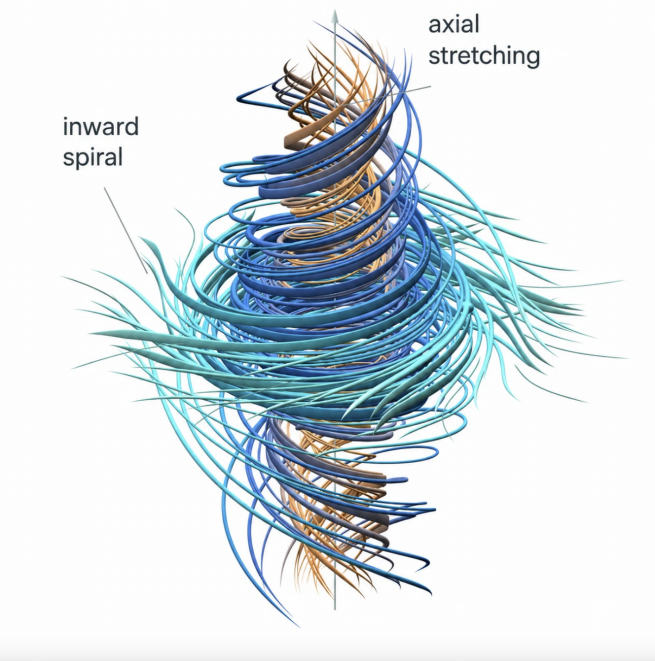

Les équations de Navier-Stokes

- OAI annonce avoir une solution complète pour le problème du millénaire de Navier-Stokes.
- Avec une formalisation Lean !
- Mais...

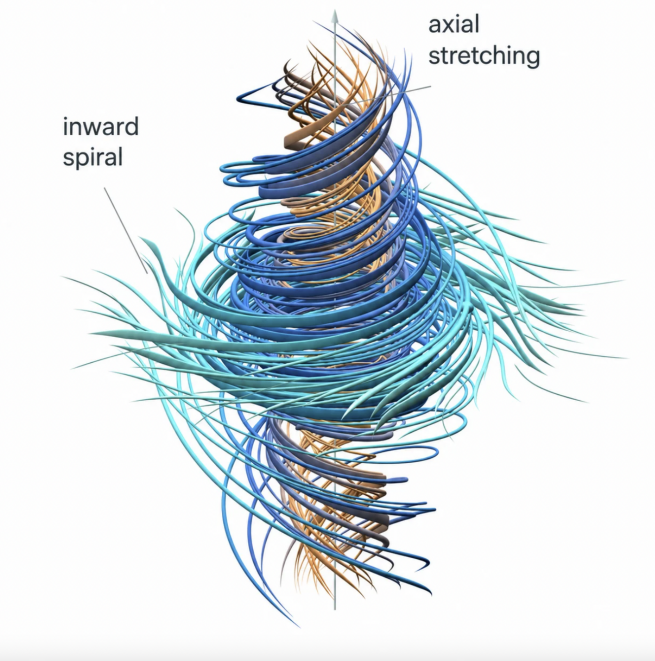

Pas si vite !

- Le résultat n'a pas encore été validé par des humains.

arXiv:2610.08144 (math)

[Submitted on 6 Oct 2026]

Navier–Stokes lost in translation: Why Lean verification of AI autoformalisation does not guarantee correct natural language proofs

Alexander Bastounis, Fabian Circelli, Anders C. Hansen

Pas si vite !

- Le résultat n'a pas encore été validé par des humains.
- Problème potentiel avec la vérification Lean ?

arXiv:2610.08144 (math)

[Submitted on 6 Oct 2026]

Navier–Stokes lost in translation: Why Lean verification of AI autoformalisation does not guarantee correct natural language proofs

Alexander Bastounis, Fabian Circelli, Anders C. Hansen

6 octobre 2026

6 octobre 2026

Slopocalypse !

De la bouillie, vraiment ?

- 372 familles de résultats.

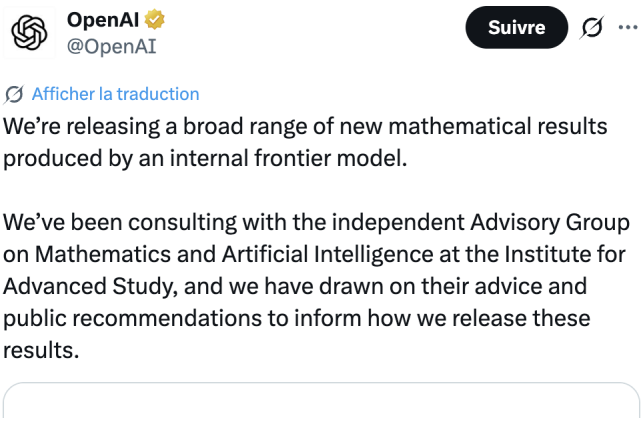

De la bouillie, vraiment ?

- 372 familles de résultats.
- 719 manuscrits.

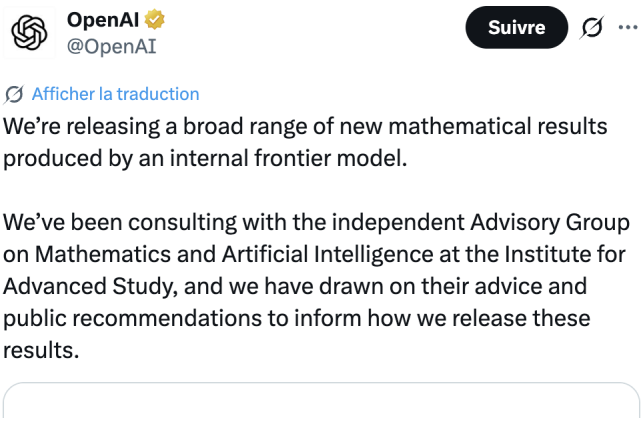

De la bouillie, vraiment ?

- 372 familles de résultats.
- 719 manuscrits.
- Avancements majeurs dans plusieurs domaines !

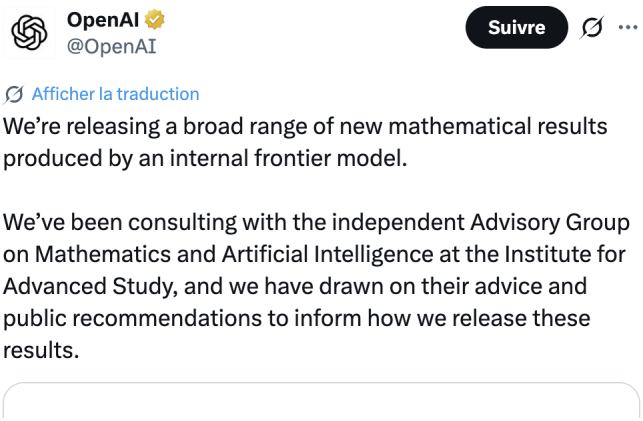

« Mardi, dans la nuit, j'ai pleuré »

« Mardi, dans la nuit, j'ai pleuré »

Pour Hugo Duminil-Copin, cet événement a tout simplement **annihilé** son domaine de recherche.

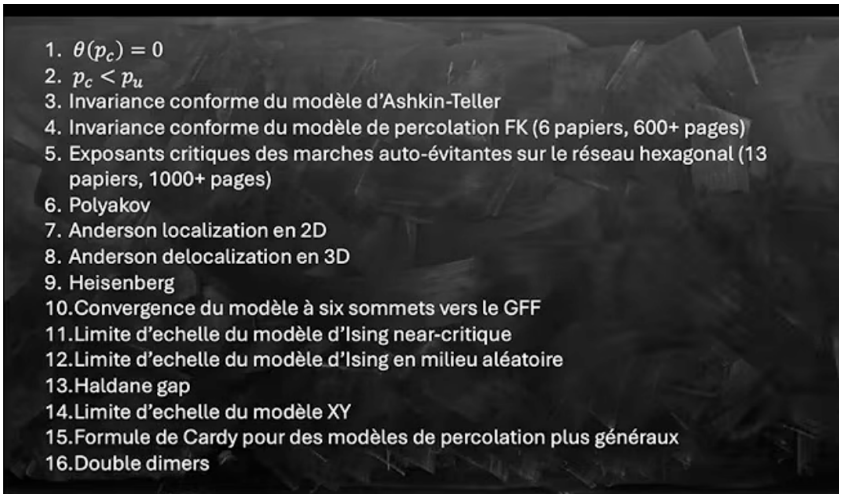

Tiré de l'exposé de Duminil-Copin à la SMF

La conjecture de Yau

Des motifs de Chladni.

La conjecture de Yau

Des motifs de Chladni.

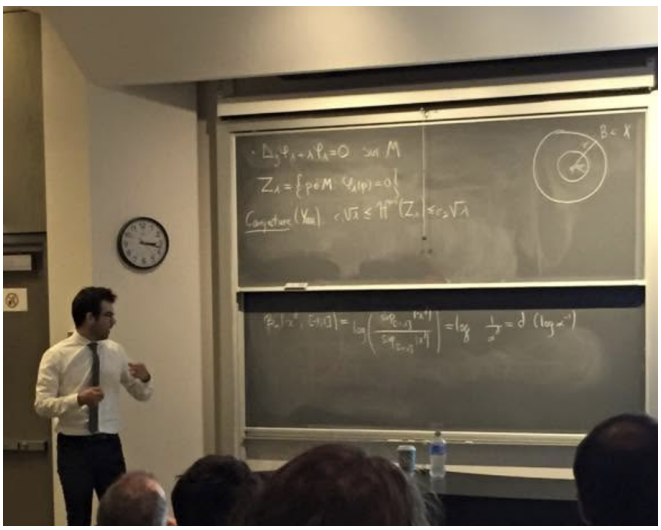

Juin 2015.

Le problème 350

350. Yau's nodal conjecture: surfaces and counterexamples. Proves the sharp $C\sqrt{\lambda}$ upper bound for nodal length on every fixed smooth closed surface, completing Yau's conjecture there. The upper bound fails for fixed smooth metrics in dimensions three and four, including metrics on S^3 arbitrarily close to round. In dimension five, nodal measure can grow faster than $\lambda^{1/2+\varepsilon_0}$ for some fixed $\varepsilon_0 > 0$, ruling out even arbitrarily small power losses.

Sharp surface nodal length · Smooth upper-bound counterexamples in dimensions 3–4 · Power-law violations of Yau's upper bound

Le problème 350

350. Yau's nodal conjecture: surfaces and counterexamples. Proves the sharp $C\sqrt{\lambda}$ upper bound for nodal length on every fixed smooth closed surface, completing Yau's conjecture there. The upper bound fails for fixed smooth metrics in dimensions three and four, including metrics on S^3 arbitrarily close to round. In dimension five, nodal measure can grow faster than $\lambda^{1/2+\varepsilon_0}$ for some fixed $\varepsilon_0 > 0$, ruling out even arbitrarily small power losses.

Sharp surface nodal length · Smooth upper-bound counterexamples in dimensions 3–4 · Power-law violations of Yau's upper bound

Theorem 1.1. *Let (M, g) be a closed connected C^∞ Riemannian surface. There is a finite constant $C = C(M, g)$ such that every nonzero real Laplace eigenfunction satisfying*

$$-\Delta_g u = \lambda u, \qquad \lambda > 0,$$

obeys

$$\mathcal{H}^1_g(Z_u) \leq C\sqrt{\lambda}.$$

Here $\mathcal{H}^1_g$ is Hausdorff measure for the Riemannian distance. The same constant applies to every eigenfunction in every positive eigenspace.

Partie II

Une certitude, des questions, des réflexions.

La fin du romantisme !

Constat (Terry Tao)

Nous venons de passer d'une ère de rareté des théorèmes à une ère d'abondance des théorèmes.

La fin du romantisme !

Constat (Terry Tao)

Nous venons de passer d'une ère de rareté des théorèmes à une ère d'abondance des théorèmes.

Corollaire

Abondance d'opinions et de réflexions sur le sujet !

Une certitude

L'évidence même, c'est que ce que nous sommes en train de vivre est historique. Pour les mathématiques, d'abord, mais également de manière plus large, dans la mesure où il est raisonnable de penser que plusieurs autres domaines du savoir humain vivront une révolution similaire.

Une certitude

L'évidence même, c'est que ce que nous sommes en train de vivre est historique. Pour les mathématiques, d'abord, mais également de manière plus large, dans la mesure où il est raisonnable de penser que plusieurs autres domaines du savoir humain vivront une révolution similaire.

Il y a beaucoup d'incertitude quant à la *portée* des changements sur la manière de **faire, construire, rédiger, présenter, comprendre, enseigner** les mathématiques.

Une certitude

L'évidence même, c'est que ce que nous sommes en train de vivre est historique. Pour les mathématiques, d'abord, mais également de manière plus large, dans la mesure où il est raisonnable de penser que plusieurs autres domaines du savoir humain vivront une révolution similaire.

Il y a beaucoup d'incertitude quant à la *portée* des changements sur la manière de **faire, construire, rédiger, présenter, comprendre, enseigner** les mathématiques.

Mais ces changements sont là pour rester !

Une certitude

L'évidence même, c'est que ce que nous sommes en train de vivre est historique. Pour les mathématiques, d'abord, mais également de manière plus large, dans la mesure où il est raisonnable de penser que plusieurs autres domaines du savoir humain vivront une révolution similaire.

Il y a beaucoup d'incertitude quant à la *portée* des changements sur la manière de **faire, construire, rédiger, présenter, comprendre, enseigner** les mathématiques.

Mais ces changements sont là pour rester !

Alors, pessimisme ou optimisme ?

Deux constats

Deux constats

"I don't want to say it's all over," Gowers said, "but I certainly don't want to say it's not all over."

> **The Wall Street Journal** @WSJ · 11 sept.
> The Millennium Prize breakthrough is proof of AI's accelerating and terrifying progress on.wsj.com/4hmoeCl

2:46 AM · 12 sept. 2026 · **48** vues

Some late-night thoughts on AI and the future of research in mathematics

Every time I've organized my thoughts sufficiently to finally write a proper blog post about the impact of AI on mathematical research, something massive happens which causes me to delay. I was preparing to wrote a post last week when I heard about the formalization of Fermat's Last Theorem in Lean. And I was preparing to write a post this week when the news broke about an AI-assisted solution of the Millennium Prize Navier-Stoker problem. Rather

Tiré du blog de Matt Baker, Georgia Tech.

La question de la propriété intellectuelle

Il y a une dizaine d'années a été lancée l'initiative *The next Rembrandt*, dont l'objectif était d'entraîner une IA sur tout le corpus du maître néerlandais afin de produire une nouvelle oeuvre dans ce style.

La question de la propriété intellectuelle

Il y a une dizaine d'années a été lancée l'initiative *The next Rembrandt*, dont l'objectif était d'entraîner une IA sur tout le corpus du maître néerlandais afin de produire une nouvelle oeuvre dans ce style.

La question de la propriété intellectuelle

Il y a une dizaine d'années a été lancée l'initiative *The next Rembrandt*, dont l'objectif était d'entraîner une IA sur tout le corpus du maître néerlandais afin de produire une nouvelle oeuvre dans ce style.

La question de la propriété intellectuelle

En mars 2025, le générateur d'images de ChatGPT est devenu viral par sa génération d'images ordinaire dans le style du fameux Studio Ghibli, dont le style unique est instantanément reconnaissable.

La question de la propriété intellectuelle

En mars 2025, le générateur d'images de ChatGPT est devenu viral par sa génération d'images ordinaire dans le style du fameux Studio Ghibli, dont le style unique est instantanément reconnaissable.

Après quelques temps, un consortium de studios japonais demande à OAI de cesser l'entraînement sur leur matériel.

La question de la propriété intellectuelle

En mars 2025, le générateur d'images de ChatGPT est devenu viral par sa génération d'images ordinaire dans le style du fameux Studio Ghibli, dont le style unique est instantanément reconnaissable.

Après quelques temps, un consortium de studios japonais demande à OAI de cesser l'entraînement sur leur matériel.

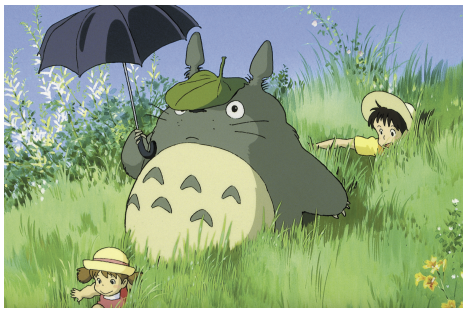

La question de la propriété intellectuelle

En mars 2025, le générateur d'images de ChatGPT est devenu viral par sa génération d'images ordinaire dans le style du fameux Studio Ghibli, dont le style unique est instantanément reconnaissable.

Après quelques temps, un consortium de studios japonais demande à OAI de cesser l'entraînement sur leur matériel.

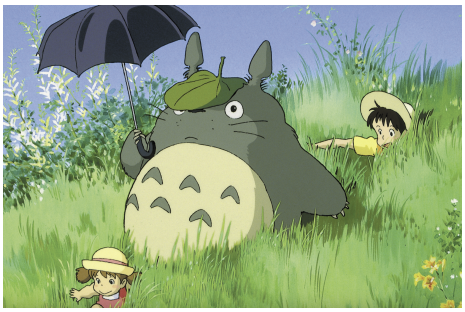

La question de la propriété intellectuelle

Que s'est-il véritablement passé dans les jours avant l'annonce de la résolution du problème de Navier-Stokes ?

La question de la propriété intellectuelle

Que s'est-il véritablement passé dans les jours avant l'annonce de la résolution du problème de Navier-Stokes ?

La question de la propriété intellectuelle

Que s'est-il véritablement passé dans les jours avant l'annonce de la résolution du problème de Navier-Stokes ?

Tristan Buckmaster et Levent Alpöge.

La question de la propriété intellectuelle

Que s'est-il véritablement passé dans les jours avant l'annonce de la résolution du problème de Navier-Stokes ?

Tristan Buckmaster et Levent Alpöge.

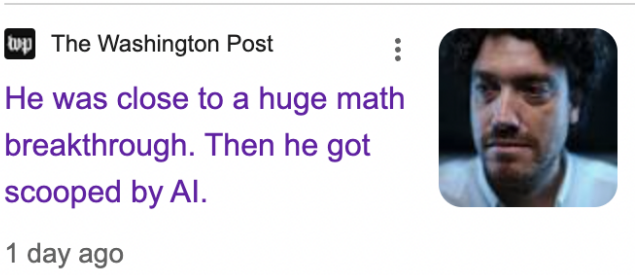

Les explications de OAI

Les explications de OAI

- Une nuée de 10 000 agents d'IA en parallèle, qui ont échangé $\approx 2,7$ millions de messages.

Les explications de OAI

- Une nuée de 10 000 agents d'IA en parallèle, qui ont échangé $\approx 2,7$ millions de messages.
- 88 heures de recherches et 17 heures de vérification.

Les explications de OAI

- Une nuée de 10 000 agents d'IA en parallèle, qui ont échangé $\approx 2,7$ millions de messages.
- 88 heures de recherches et 17 heures de vérification.
- Coût total : entre 15 **et** 30 **millions**.

Les explications de OAI

- Une nuée de 10 000 agents d'IA en parallèle, qui ont échangé $\approx 2,7$ millions de messages.
- 88 heures de recherches et 17 heures de vérification.
- Coût total : entre 15 **et** 30 **millions**.

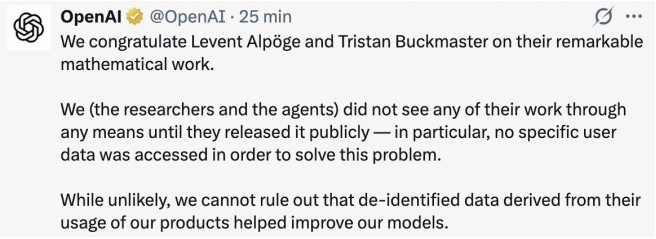

La valeur d'un théorème ?

Une perspective économique, celle de David Bessis dans son essai *The fall of the theorem economy.*

David Bessis

La valeur d'un théorème ?

Une perspective économique, celle de David Bessis dans son essai *The fall of the theorem economy.*

- Depuis toujours, les théorèmes sont une sorte de monnaie rare permettant de mesurer indirectement la valeur mathématique.

David Bessis

La valeur d'un théorème ?

Une perspective économique, celle de David Bessis dans son essai *The fall of the theorem economy.*

- Depuis toujours, les théorèmes sont une sorte de monnaie rare permettant de mesurer indirectement la valeur mathématique.
- Sauf qu'avant, pour ***créer*** un théorème, il fallait ***comprendre*** quelque chose.

David Bessis

La valeur d'un théorème ?

Une perspective économique, celle de David Bessis dans son essai *The fall of the theorem economy.*

- Depuis toujours, les théorèmes sont une sorte de monnaie rare permettant de mesurer indirectement la valeur mathématique.
- Sauf qu'avant, pour ***créer*** un théorème, il fallait ***comprendre*** quelque chose.
- Bill Thurston : « *The product of mathematics is clarity and understanding. Not theorems, by themselves* ».

David Bessis

La valeur d'un théorème ?

Une perspective économique, celle de David Bessis dans son essai *The fall of the theorem economy.*

- Depuis toujours, les théorèmes sont une sorte de monnaie rare permettant de mesurer indirectement la valeur mathématique.
- Sauf qu'avant, pour ***créer*** un théorème, il fallait ***comprendre*** quelque chose.
- Bill Thurston : « *The product of mathematics is clarity and understanding. Not theorems, by themselves* ».
- Ne s'applique pas qu'aux mathématiques !

David Bessis

Un peu de matérialisme historique

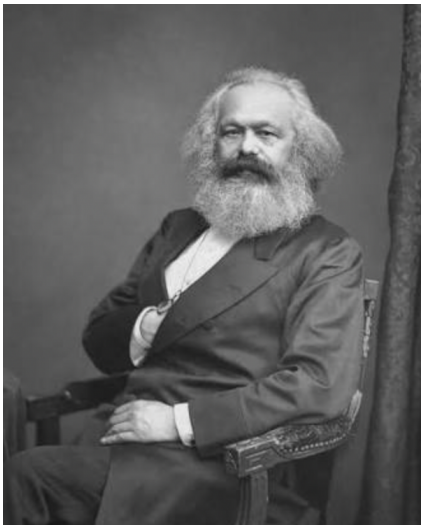

Un peu de matérialisme historique

Qui possède désormais les moyens de production du savoir mathématique ?

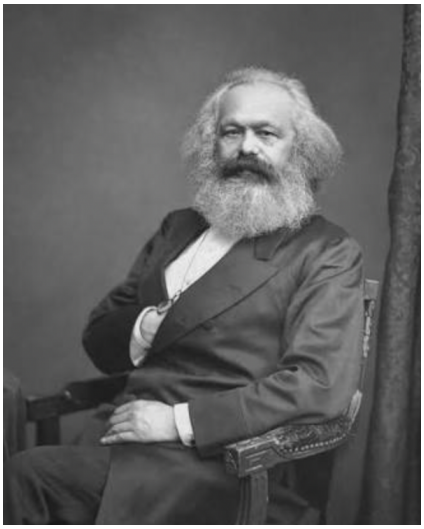

Un peu de matérialisme historique

Qui possède désormais les moyens de production du savoir mathématique ?

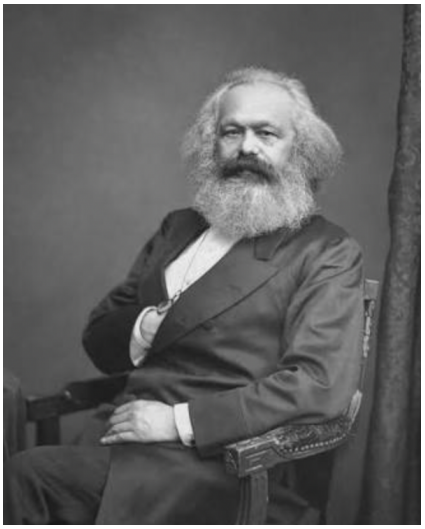

Venons-nous d'être relégués au rang de prolétaires de notre propre discipline ?

La valeur d'un.e mathématicien.ne

À quoi servent les mathématiciens et mathématiciennes, désormais que l'on peut déléguer la production de théorèmes à l'IA ?

La valeur d'un.e mathématicien.ne

À quoi servent les mathématiciens et mathématiciennes, désormais que l'on peut déléguer la production de théorèmes à l'IA ?

- Quelqu'un doit être responsable d'un théorème, sans quoi ils seront orphelins.

La valeur d'un.e mathématicien.ne

À quoi servent les mathématiciens et mathématiciennes, désormais que l'on peut déléguer la production de théorèmes à l'IA ?

- Quelqu'un doit être responsable d'un théorème, sans quoi ils seront orphelins.
- Le rôle des mathématiciens : digestion, diffusion, démocratisation ?

La valeur d'un.e mathématicien.ne

À quoi servent les mathématiciens et mathématiciennes, désormais que l'on peut déléguer la production de théorèmes à l'IA ?

- Quelqu'un doit être responsable d'un théorème, sans quoi ils seront orphelins.
- Le rôle des mathématiciens : digestion, diffusion, démocratisation ?
- « *In my experience, mathematical ideas, like children, must be nurtured and grow over the years.* » – Peter Scholze.

Tiré de la Déclaration de Leiden, juin 2026.

La valeur d'un.e mathématicien.ne

À quoi servent les mathématiciens et mathématiciennes, désormais que l'on peut déléguer la production de théorèmes à l'IA ?

- Quelqu'un doit être responsable d'un théorème, sans quoi ils seront orphelins.
- Le rôle des mathématiciens : digestion, diffusion, démocratisation ?
- « *In my experience, mathematical ideas, like children, must be nurtured and grow over the years.* » – Peter Scholze.

Tiré de la Déclaration de Leiden, juin 2026.

« *If the authors cannot convincingly demonstrate that they can give a clear, expert-level talk on their results, that is correct and properly attributed, then the result should not be published.*» – Terence Tao

Tiré de sa présentation à ICM, juillet 2026.

La valeur d'un.e mathématicien.ne

À quoi servent les mathématiciens et mathématiciennes, désormais que l'on peut déléguer la production de théorèmes à l'IA ?

- Quelqu'un doit être responsable d'un théorème, sans quoi ils seront orphelins.
- Le rôle des mathématiciens : digestion, diffusion, démocratisation ?
- « *In my experience, mathematical ideas, like children, must be nurtured and grow over the years.* » – Peter Scholze.

Tiré de la Déclaration de Leiden, juin 2026.

« *If the authors cannot convincingly demonstrate that they can give a clear, expert-level talk on their results, that is correct and properly attributed, then the result should not be published.*» – Terence Tao

Tiré de sa présentation à ICM, juillet 2026.

→ Valorisation à venir du travail pédagogique d'exposition, d'éducation ?

Pourquoi cibler les mathématiques ?

On peut argumenter les grands labos n'ont pas de motivation *intrinsèque* à faire des maths. Pourquoi, alors ?

Pourquoi cibler les mathématiques ?

On peut argumenter les grands labos n'ont pas de motivation *intrinsèque* à faire des maths. Pourquoi, alors ?

- Il y a un certain prestige public à battre les meilleurs mathématicien.es humain.es.

Pourquoi cibler les mathématiques ?

On peut argumenter les grands labos n'ont pas de motivation *intrinsèque* à faire des maths. Pourquoi, alors ?

- Il y a un certain prestige public à battre les meilleurs mathématicien.es humain.es.

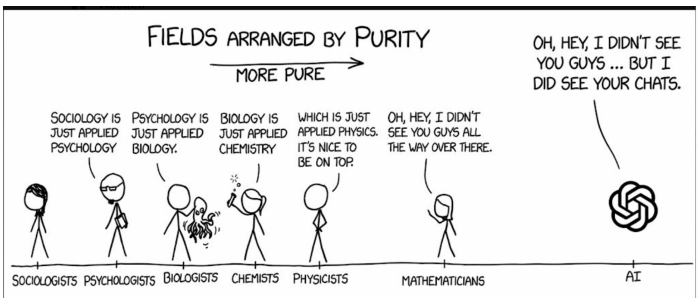

Pourquoi cibler les mathématiques ?

On peut argumenter les grands labos n'ont pas de motivation *intrinsèque* à faire des maths. Pourquoi, alors ?

- Il y a un certain prestige public à battre les meilleurs mathématicien.es humain.es.

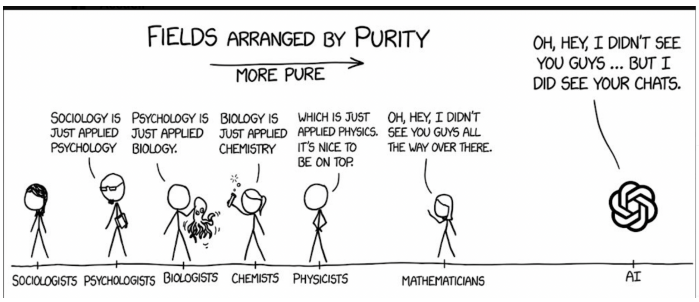

- Les maths sont donc une sorte de *proxy* pour le combat entre OAI et ANT.

Pourquoi cibler les mathématiques ?

On peut argumenter les grands labos n'ont pas de motivation *intrinsèque* à faire des maths. Pourquoi, alors ?

- Il y a un certain prestige public à battre les meilleurs mathématicien.es humain.es.

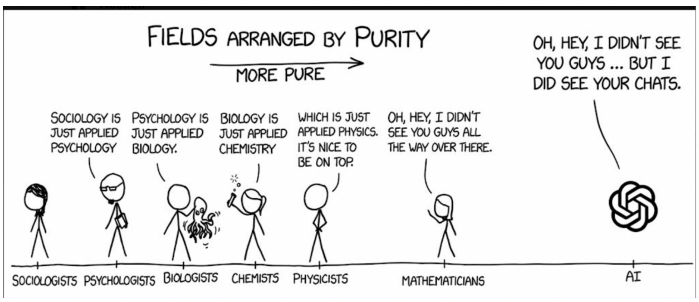

- Les maths sont donc une sorte de *proxy* pour le combat entre OAI et ANT.
- Aussi : ce sont les maths qui sont derrière les mécanismes d'entraînement et de fonctionnement des IA ! On y reviendra...

Au delà des mathématiques...

1. Most biomedical publications show signs of LLM-assisted writing, Holzwarth et al. 2026

Au delà des mathématiques...

Les mathématiques ne sont essentiellement qu'un banc d'essai pour les grands labos.

1. Most biomedical publications show signs of LLM-assisted writing, Holzwarth et al. 2026

Au delà des mathématiques...

Les mathématiques ne sont essentiellement qu'un banc d'essai pour les grands labos.

Bouleversement non-exclusif ! Par exemple, $\approx 90\%$ des articles en sciences biomédicales donnent des indicateurs d'usage d'IA. [1]

1. Most biomedical publications show signs of LLM-assisted writing, Holzwarth et al. 2026

Au delà des mathématiques...

Les mathématiques ne sont essentiellement qu'un banc d'essai pour les grands labos.

Bouleversement non-exclusif ! Par exemple, $\approx 90\%$ des articles en sciences biomédicales donnent des indicateurs d'usage d'IA. [1]

La question principale demeure valide au-delà des maths :

1. Most biomedical publications show signs of LLM-assisted writing, Holzwarth et al. 2026

Au delà des mathématiques...

Les mathématiques ne sont essentiellement qu'un banc d'essai pour les grands labos.

Bouleversement non-exclusif ! Par exemple, $\approx 90\%$ des articles en sciences biomédicales donnent des indicateurs d'usage d'IA. [1]

La question principale demeure valide au-delà des maths :

Comment mesurer la valeur, académique ou autre, de ce qui est produit automatiquement ?

1. Most biomedical publications show signs of LLM-assisted writing, Holzwarth et al. 2026

Mon fléau de l'été 2026

Mon fléau de l'été 2026

Le fléau ?

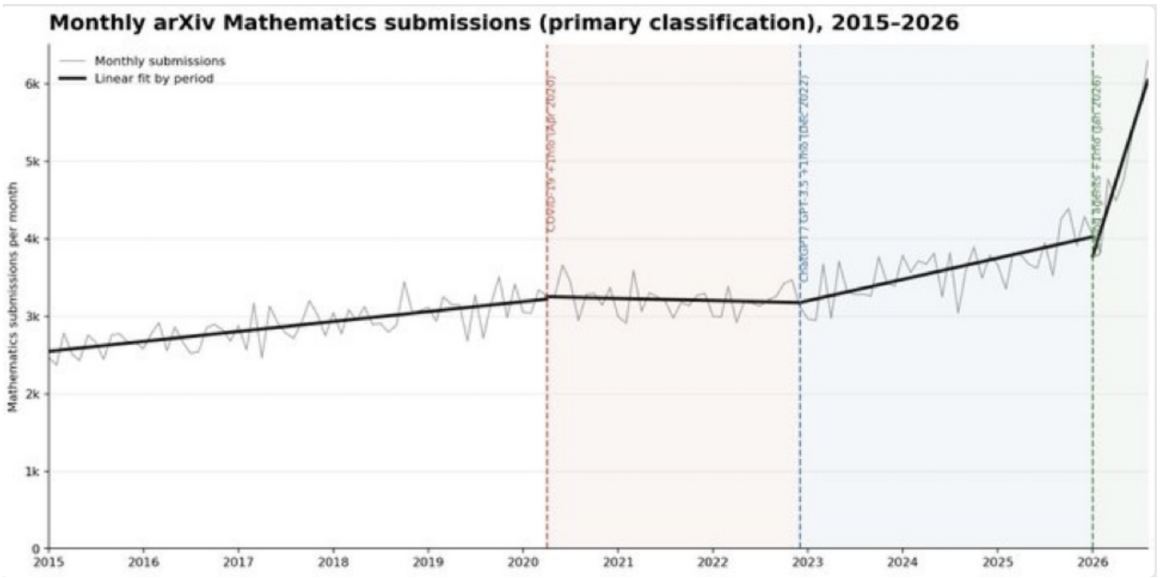
Monthly arXiv Mathematics submissions (primary classification), 2015–2026
Monthly submissions
Linear fit by period
Mathematics submissions per month
0
1k
2k
3k
4k
5k
6k
2015
2016
2017
2018
2019
2020
2021
2022
2023
2024
2025
2026

Partie III

Perspectives.

Le mot de la fin

- Difficile de prendre la vraie mesure d'un cyclone alors qu'on se trouve dans son oeil.

Le mot de la fin

- Difficile de prendre la vraie mesure d'un cyclone alors qu'on se trouve dans son oeil.
- Et donc, pessimisme, optimisme ?

Le mot de la fin

- Difficile de prendre la vraie mesure d'un cyclone alors qu'on se trouve dans son oeil.
- Et donc, pessimisme, optimisme ?
- Ne me jugez pas, mais moi je suis plutôt du type 50 nuances de gris...

Le mot de la fin

- Difficile de prendre la vraie mesure d'un cyclone alors qu'on se trouve dans son oeil.
- Et donc, pessimisme, optimisme ?
- Ne me jugez pas, mais moi je suis plutôt du type 50 nuances de gris...
- Important : ni catastrophisme, ni angélisme.

Le mot de la fin

- Difficile de prendre la vraie mesure d'un cyclone alors qu'on se trouve dans son oeil.
- Et donc, pessimisme, optimisme ?
- Ne me jugez pas, mais moi je suis plutôt du type 50 nuances de gris...
- Important : ni catastrophisme, ni angélisme.

Tout résidera donc dans notre capacité collective à **valoriser** la **compréhension** et la **diffusion** du savoir, plutôt que sa production exclusive.

Pour en lire davantage...

- Proofs and prompts, un recueil d'essais sur les mathématiques et l'IA.
- Math and AI, une déclaration sur le problème d'alignement des maths de l'IA, signée par 25 médaillés Fields.
- Le blog de Terence Tao, incluant plusieurs contributions récentes d'auteurs invités.
- Et sa présentation à l'ICM.
- La déclaration de Leiden.
- The fall of the theorem economy, l'essai de David Bessis.

5

Développement de programmes

5.1 Microprogramme en mathématiques de l'IA

AVANT-PROJET

14 octobre 2022

Guillaume Roy-Fortin
Service des enseignements généraux

1. INTITULÉ DU PROGRAMME : *Mathématiques de l'apprentissage profond.*

2. RÉSUMÉ SUCCINT DU PROJET

Le deep learning n'a plus besoin de présentation : ses nombreuses prouesses sont largement documentées et célébrées. Mais sait-on vraiment ce qui rend ces réseaux profonds aussi habiles? Pour plusieurs, l'apprentissage profond demeure une mystérieuse boîte noire qui produit des résultats étonnants en opérant toutefois selon des modalités opaques. L'objectif de ce microprogramme est d'étendre le contenu du cours MTI880 et présenter les idées mathématiques nécessaires à la compréhension du fonctionnement des réseaux de neurones.

- Discipline : Mathématiques.
- Département responsable : SEG.
- Contexte : Extension de la portée du cours MTI880 à un microprogramme.
- Promoteur : Guillaume Roy-Fortin.

3. MOTIFS DE CRÉATION DU PROGRAMME

Offrir à la clientèle de l'ÉTS une formation solide sur les aspects théoriques et mathématiques qui permettent de comprendre le fonctionnement interne des classes de réseaux de neurones les plus performants et populaires. Le cours MTI880 (dans sa version H2021 et E2022) explorait ces thèmes mais devait, faute de temps, en escamoter certains autres. Le microprogramme fournirait l'occasion d'explorer tant les mathématiques pertinentes que leur application aux réseaux génératifs et aux déclinaisons de l'apprentissage géométrique. Enfin, ce microprogramme permettrait de renforcer l'arrimage de l'ÉTS au pôle de l'intelligence artificielle qu'est devenu Montréal.

Plan de cours MTI880 : https://ena.etsmtl.ca/pluginfile.php/1472704/mod_resource/content/6/MTI880_20222_plan.pdf

4. PARTICULARITÉS DU PROGRAMME

On réfère le lecteur ou la lectrice au point 7 et à l'Annexe A qui contiennent une description détaillée des cours qui composeraient le microprogramme proposé.

5. RÉGIME D'ÉTUDES : *Temps partiel.*

6. NOMBRE DE CRÉDITS : *9 crédits.*

7. STRUCTURE DU PROGRAMME

Le microprogramme comprend 3 cours de 3 crédits, à suivre dans l'ordre.

- (MAT850) Fondations mathématiques de l'apprentissage profond.
- (MAT851) Fonctionnement mathématique des réseaux de neurones.
- (MAT852) Apprentissage géométrique : grilles, graphes et géodésiques.

Nous présentons dans l'Annexe A le détail du contenu de ces cours.

8. RESSOURCES PROFESSORALES

Un maître d'enseignement en mathématiques responsable de donner les trois cours pendant la première itération du programme. À la suite de ce premier cycle, il serait envisageable de partager la tâche avec d'autres maîtres d'enseignement.

ANNEXE A

Description détaillée du contenu des cours proposés.

(MAT850) FONDATIONS MATHÉMATIQUES DE L'APPRENTISSAGE PROFOND

Objectif. Fournir aux étudiants les outils mathématiques permettant de comprendre les mécanismes de fonctionnement des réseaux de neurones de même que ceux qui sont derrière les plus récentes avancées théoriques en apprentissage profond. Ce cours est préalable aux deux autres du microprogramme.

I. ALGÈBRE LINÉAIRE
Vecteurs, matrices, algèbre matricielle. Espaces vectoriels, sous-espaces, bases. Transformations linéaires, affines. Matrices symétriques, orthogonales, diagonalisation, modes propres. Théorème spectral, formes quadratiques. Quotients de Rayleigh, caractérisation variationnelle. Éléments de représentation des groupes.

(4-5 semaines)

II. CALCUL ET ANALYSE
Règle de la chaîne, optimisation, descente de gradient. Éléments de théorie spectrale du laplacien. Théorie de Fourier : transformée de Fourier, inverse, convolution. Éléments d'analyse : inégalités de Cauchy-Schwarz, Minkowski et Jensen. Espaces métriques.

(2 semaines)

III. PROBABILITÉS
Axiomatique des probabilités. Variables aléatoires discrètes, continues. Théorème central limite, lois des grands nombres. Processus stochastiques, chaînes de Markov. Méthodes de Monte-Carlo. Processus gaussiens. Théorie de l'information : entropie de Shannon, entropie croisée. KL-Divergence.

(3-4 semaines)

IV. GÉOMÉTRIE : GRAPHES ET VARIÉTÉS
Théorie des graphes : terminologie, représentations. Matrice d'adjacence, opérateurs différentiels sur un graphe. Introduction aux variétés riemannniennes : cartes, atlas, métriques. Géodésiques, coordonnées normales. Espaces tangents et cotangents. Fibration, espaces tangents et cotangents. Fibration principale. Flots géodésiques.

(3 semaines)

(MAT851) FONCTIONNEMENT MATHÉMATIQUE DES RÉSEAUX DE NEURONES

Objectif. Faire un survol du fonctionnement mathématique de certaines grandes classes de réseaux de neurones. Un accent particulier sera placé sur les réseaux de convolution et les différentes déclinaisons de réseaux génératifs.

I. RÉSEAUX DE NEURONES PROFONDS
Architecture, paramètres, hyperparamètres. Mécanisme de propagation avant. Fonctions d'activation, de coût. Mécanismes de propagation avant. Apprentissage et équations de la rétropropagation. Problèmes d'apprentissage, régularisation. Initialisation, théorèmes de Hanin et Hanin-Rolnick.

(2-3 semaines)

II. PRINCIPES THÉORIQUES
Universalité, théorèmes de Cybenko et Hornik. Puissance expressive des réseaux de neurones. Additivité, composition et rôle de la profondeur. Théorème de Telgarsky. Overfitting et régularisation : diminution des poids, L1, L2, dropout. Descente hessienne et descente dynamique de gradient.

(3 semaines)

III. APPRENTISSAGE GÉOMÉTRIQUE ET RÉDUCTION DE DIMENSION
Filtres et convolution. Introduction à l'apprentissage géométrique. Réduction de la dimension, analyse en composantes principales, algorithme de Belkin-Niyagi. Apprentissage hyperbolique, modèle de Poincaré.

(3 semaines)

IV. RÉSEAUX GÉNÉRATIFS
Autoencodeurs variationnels. Autoencodeurs, ELBO. GAN (réseaux adversariels génératifs). Distance de Wasserstein. Modèles de diffusion : diffusion avant, astuce de la reparamétrisation. Mécanismes d'attention. Rétrodiffusion.

(3 semaines)

(MAT852) APPRENTISSAGE GÉOMÉTRIQUE : GRILLES, GRAPHES ET GÉODÉSIQUES

Objectif. Cours théorique avancé portant sur le proto-livre de Bronstein et al. qui vise à classer le zoo des différents types et architectures de réseaux en utilisant des invariants fonctionnels propres aux espaces sur lesquels ils agissent.

I. GÉOMÉTRIE EUCLIDIENNE, GROUPES ET PROGRAMME D'ERLANGEN
Géométries planes, hyperboliques et elliptiques. Invariants.

(1 semaine)

II. PRÉALABLES GÉOMÉTRIQUES
Symétries, représentations, invariances. Isomorphismes et automorphismes, stabilité sous déformation.

(2 semaines)

III. DOMAINES GÉOMÉTRIQUES : LES QUATRE 'G'S.
Graphes et ensembles. Grilles et espaces euclidiens. Groupes et espaces homogènes. Géodésiques et variétés riemanniennes.

(5 semaines)

IV. MODÈLES D'APPRENTISSAGE PROFOND GÉOMÉTRIQUE.
Réseaux convolutifs, réseaux convolutifs g-équivariants. Réseaux profonds sur graphe. Réseaux équivariants à passage de message. Deep sets et transformers. Longs réseaux à mémoire courte. (LSTMN)

(5 semaines)

5.2 Fiche descriptive du cours SCM680

Sigle	Titre	Crédits	Existant
SCM680	Mathématiques de l'IA	3	Non

Responsable

Guillaume Roy-Fortin, professeur enseignant, Département des enseignements généraux

Pertinence

Ce cours sert à présenter le rôle central que jouent les mathématiques dans la conception des modèles d'intelligence artificielle modernes. En particulier, il vise à développer une réflexion qualitative et quantitative sur le rapport entre pratique et théorie dans la modélisation d'un réseau de neurones en apprentissage profond.

Description

Développer une maîtrise des aspects mathématiques qui interviennent dans les paradigmes contemporains de l'intelligence artificielle afin d'éclairer le fonctionnement interne de ceux-ci.

Au terme de ce cours, l'étudiante ou l'étudiant sera en mesure de :

- décrire mathématiquement le fonctionnement de certains des principaux modèles d'apprentissage profond utilisés en IA moderne;
- employer les mathématiques pour prédire, interpréter et justifier le rendement d'un de ces modèles;
- concevoir et construire des exemples permettant de mesurer empiriquement l'impact de choix architecturaux sur la performance et l'entraînement de réseaux de neurones profonds.

Mots-clés: *Réseaux de neurones, apprentissage profond, larges modèles de langage, modèles de diffusion. Descente de gradient, optimisation, rétropropagation. Régularisation, puissance expressive, convolution.*

Préalable(s)

MAT180 Analyse vectorielle
MAT380 Algèbre linéaire

Pertinence des préalables

Les cours MAT180 et MAT380 assure aux étudiantes et étudiants de maîtriser les notions d'analyse vectorielle et d'algèbre linéaire nécessaires à la compréhension des aspects mathématiques de l'intelligence artificielle.

6

Congrès de l'AMQ

6.1 Programme officiel

Association mathématique du Québec

Programme - 69e congrès

24–25 octobre 2025 | ÉTS

MATHÉMATIQUES ET INTELLIGENCE ARTIFICIELLE

ÉTS

Photo credit: Stéphane Brügger

Table des matières

1 Mot du comité organisateur 3

2 Mot de la Direction des affaires académiques 4

3 Mot du président de l'AMQ 5

4 Informations utiles 6

5 Conférence d'ouverture 8

6 Activités sociales 9

7 Horaire 9

8 Horaire des ateliers 10

9 Description des ateliers 11

10 Partenaires 28

PROGRAMMES
DE BACCALAURÉAT :

- Génie aérospatial
- Génie de la construction
- Génie électrique
- Génie logiciel
- Génie des technologies de l'information
- Génie mécanique
- Génie des opérations et de la logistique
- Génie de la production automatisée
- Informatique distribuée
- Design d'expérience utilisateur (UX)

EN SAVOIR
PLUS :

Mot du comité organisateur

Mathématiciennes et mathématiciens, bonjour !

C'est avec plaisir et enthousiasme que nous vous souhaitons la bienvenue sur le campus de l'ÉTS pour le 69e congrès de l'Association mathématique du Québec. Cette année, notre rencontre a pour thème les liens entre les mathématiques et l'intelligence artificielle, explorés à partir de perspectives diverses, qu'elles soient théoriques, pratiques ou pédagogiques.

Cela tombe bien parce que Montréal est un pôle international de recherche et développement en IA, avec des centres reconnus mondialement comme le MILA. C'est d'ailleurs un de ses membres, le professeur Guillaume Lajoie, qui nous fera l'honneur de lancer le bal avec la conférence plénière du vendredi soir. Celle-ci sera suivie d'un cocktail d'accueil où nous espérons que vous aurez l'occasion de saluer de vieilles connaissances et d'en faire de nouvelles.

C'est samedi que se déroulera l'essentiel des activités. Vous pouvez consulter l'horaire détaillé plus loin dans ce programme. En plus des présentations reliées à notre thème principal, nous avons la chance d'avoir des conférenciers qui nous proposent un buffet de sujets variés dans lequel vous pourrez allègrement vous servir !

Nous sommes fiers de notre beau campus et nous vous invitons à flâner pour le découvrir pendant les pauses prévues au programme. En soirée, un banquet festif est prévu : en plus de manger et boire, vous aurez aussi l'occasion de tester vos connaissances et même, si l'envie vous prend, de nous impressionner avec du karaoké. Qui osera pousser la chansonnette mathématique ? Qui voudra provoquer en chantant « $2 + 2 = 5$ » de Radiohead ou alors nous impressionner avec sa mémoire en nous récitant « Pi » de Kate Bush, dont les paroles ne sont qu'une suite bien particulière de décimales ? Ça promet !

Nous aimerions que ce week-end soit enrichissant, tant du point de vue de l'apprentissage que des rencontres. Nous vous souhaitons donc qu'il soit intelligent, mais pas artificiel !

Pour toute question, vous pouvez nous contacter à cette adresse :

guillaume.roy-fortin@etsmtl.ca

Bienvenue chez nous,

Le comité organisateur

Mot de la Direction des affaires académiques

Chers amoureux et amoureuses des mathématiques,

C'est un honneur de vous accueillir à ce 69e congrès annuel sous le thème de l'enseignement des mathématiques à l'ère de l'intelligence artificielle. L'IA transforme profondément notre rapport aux savoirs : elle résout des problèmes complexes en quelques secondes, automatise des démarches de démonstration et propose des visualisations inédites. Certains y voient une menace, d'autres une formidable opportunité.

Dans ce contexte, le rôle des enseignants ne disparaît pas ; il se redéfinit. La valeur ajoutée des enseignants résidera dans leur capacité à développer l'intuition mathématique, à nourrir l'esprit critique face aux résultats générés par les IA génératives, et à accompagner les étudiants dans la modélisation des problèmes réels. Plus que jamais, à titre d'enseignants, vous serez appelés à être des guides, capables de donner sens et profondeur à des solutions produites par des machines et dans ce contexte votre humanité, votre capacité à communiquer votre passion et votre créativité seront votre plus grande valeur ajoutée dans la formation d'une nouvelle génération d'étudiants née à l'ère de l'IA.

Je remercie nos professeurs enseignants Guillaume Roy-Fortin, Anouk Bergeron-Brlek, Annie Lacasse, Xavier Provençal, Louis-Xavier Proulx, Jean-Philippe Labbé et Jean-Michel Lemay qui se sont vaillamment impliqués dans l'organisation de ce congrès et l'AMQ pour la confiance accordée à l'École de Technologie Supérieure. L'ÉTS est un lieu tout désigné pour tenir cette conférence. Forte de son expertise en ingénierie appliquée et de ses liens étroits avec l'industrie, l'ÉTS offre un environnement où la théorie rencontre la pratique. Réfléchir ici au rôle de l'IA dans l'enseignement des mathématiques, c'est préparer ensemble l'avenir de notre discipline.

Bienvenue et bon congrès !

Michel Huneault
Directeur des affaires académiques de l'ÉTS

Mot du président de l'AMQ

L'intelligence artificielle, un sujet fascinant !

Le comité exécutif et moi-même sommes très heureux de vous retrouver cette année à l'École de technologie supérieure pour ce 69e congrès de l'AMQ. Le thème « Mathématiques et intelligence artificielle » est certainement d'actualité avec notamment tous les nouveaux modèles génératifs disponibles.

La conférence d'ouverture sera donnée par Guillaume Lajoie, professeur agrégé au Département de mathématiques et de statistique de l'Université de Montréal et membre académique principal du MILA - Institut québécois d'intelligence artificielle. Il nous explorera le lien entre mathématiques et IA du point de vue des neurosciences.

Le comité exécutif et moi-même remercions l'École de technologie supérieure, le département des enseignements généraux ainsi que l'équipe enseignante de nous accueillir. Un merci particulier à Anouk Bergeron-Brlek, Annie Lacasse, Jean-Philippe Labbé, Jean-Michel Lemay, Louis-Xavier Proulx, Xavier Provençal et Guillaume Roy-Fortin.

Cette année, samedi, nous aurons droit à une vingtaine d'ateliers répartis selon 4 plages horaires. Dimanche, rien n'a été prévu au congrès. Quant au volet primaire, il n'aura pas lieu cette année. Les conseillers et conseillères pédagogiques peuvent maintenant comptent sur le comité éditorial de la Revue québécoise de didactique des mathématiques pour organiser une activité en juin avec le GDM. Et il y a toujours le congrès annuel de l'AQEP pour les enseignants et enseignantes au primaire.

Les mathématiques sont certainement fascinantes, mais il y a aussi des personnes fascinantes qui font que les mathématiques le sont. Ainsi, je vous souhaite de faire de belles rencontres et de rapporter une superbe idée dans vos salles de classe !

Jean-Philippe Villeneuve
Président de l'AMQ

Informations utiles

Inscription

L'inscription est maintenant disponible. Profitez du tarif réduit en vous inscrivant **avant le 25 septembre !** Pour toutes les informations et pour vous inscrire

Lien vers l'inscription

Accueil

L'accueil aura lieu à partir de 18h vendredi soir au premier étage du Pavillon A, qui est situé au 1100 rue Notre-Dame O. Toutes les activités du vendredi auront lieu dans ce pavillon : la conférence plénière à 19h30 ainsi que la soirée d'accueil qui suivra dans la Salle des pas perdus.

Vous pourrez également vous inscrire samedi matin de 8h30 à 9h00 à l'entrée du Pavillon E. À l'exception du lunch, toutes les activités du samedi auront lieu dans les pavillons D et E. Pour plus de détails, veuillez consulter le plan du campus ainsi que l'horaire complet.

Accès au campus

- **Stationnement**
  L'ÉTS dispose de stationnements intérieurs dans ses pavillons A, B et E. Les tarifs sont de 18$ par jour (ou de 0,08$ par minute). Il est possible de laisser la voiture stationnée pour 2 ou 3 jours consécutifs. Les visiteurs sont invités à se garer à tout moment dans le Pavillon B (accès par la rue Jean-d'Estrées) ou dans le Pavillon E (accès par la rue Eleanor). Le stationnement du Pavillon A est ouvert aux visiteurs seulement en soirée à partir de 17 h du lundi au vendredi ainsi que toute la journée les samedi et dimanche. Pour les véhicules électriques des visiteurs, le Pavillon E dispose de 7 bornes de recharge et 2 bornes sont accessibles dans le Pavillon B.

- **Transport en commun**
  L'ÉTS est située à 10 minutes de marche de la Gare Centrale (Via Rail, Trains Exo, REM) et des stations Bonaventure et Lucien-L'Allier de la ligne orange du métro. Il existe de nombreux titres de transports et leurs tarifs varient selon les zones parcourues lors du déplacement. Consultez le Plan métropolitain de transports en commun pour visualiser les zones et les différents réseaux de transports.

- **Vélo**
  L'ÉTS est facilement accessible en vélo et dispose de plusieurs supports à bicyclettes. Le REV, Réseau express vélo, sur la rue Peel est une voie cyclable protégée qui permet de rejoindre le campus par les pistes cyclables du Vieux-Port, du Vieux-Montréal et du Canal-de-Lachine. Vous pouvez facilement louer un vélo avec le système BIXI dont plusieurs stations sont situées à proximité du campus.

Wifi

Voici les informations pour vous connecter à notre réseau Wifi.

- *Réseau* : ETS-Invites
- *Nom d'utilisateur* : wifi-amq2025@etsmtl.ca
- *Mot de passe* : Ets2025Amq

Plan du campus

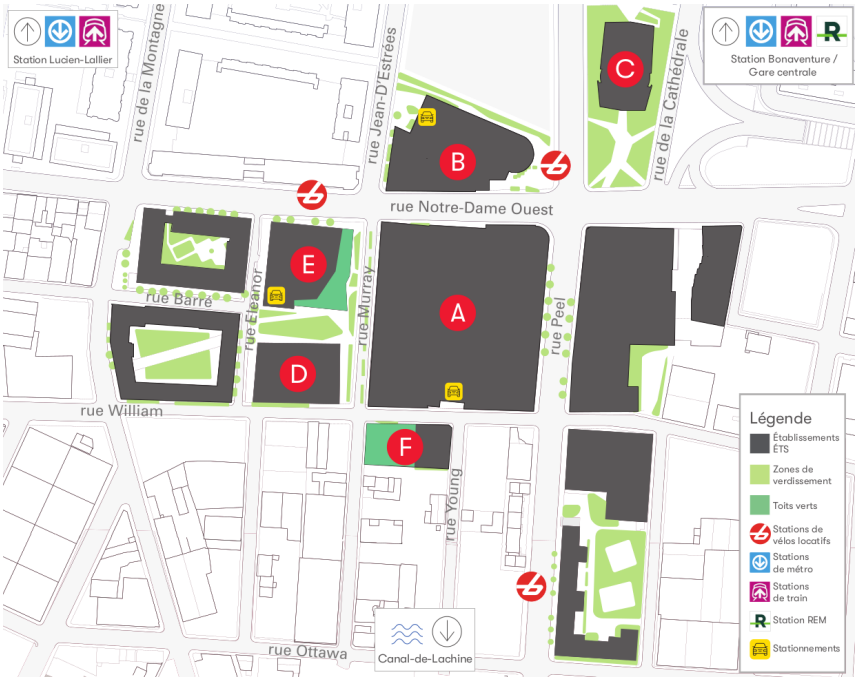

- Pavillon A : 1100, rue Notre-Dame Ouest.
- Pavillon D : 1219, rue William.
- Pavillon E : 1220, rue Notre-Dame Ouest.

Conférence d'ouverture

Conférencier

Guillaume Lajoie est professeur agrégé au Département de mathématiques et de statistique de l'Université de Montréal, ainsi que membre académique principal du Mila – l'Institut québécois d'intelligence artificielle. Il est titulaire d'une Chaire de recherche en IA Canada-CIFAR, ainsi que d'une Chaire de recherche du Canada en calcul et interfaces neuronaux. Ses travaux de recherche se situent à l'intersection de l'intelligence artificielle et des neurosciences, où il développe des outils visant à mieux comprendre les mécanismes de l'intelligence, qu'ils soient biologiques ou artificiels.

Conférence

Apprendre sans plasticité : comment le cerveau et les grands modèles de fondation exploitent la prédiction pour un apprentissage général

Résumé : Les réseaux de neurones ont la capacité d'approximer une vaste gamme de fonctions moyennant une assignation du mérite appropriée. Historiquement, les théories de l'apprentissage neural se sont concentrées sur l'ajustement des paramètres d'un réseau, tels que les poids synaptiques, afin de minimiser l'erreur sur des tâches spécifiques. Dans le cerveau, de telles modifications sont facilitées par des mécanismes de plasticité synaptique, tandis que les réseaux profonds utilisent la descente de gradient directe. Cependant, il est devenu évident que certains processus d'apprentissage dans le cerveau ne reposent pas uniquement sur ces manipulations paramétriques. Plutôt, il existe des mécanismes d'assignation du mérite basés sur l'activité pour réaliser un apprentissage rapide, piloté par l'activité neurale, de manière non paramétrique. Parallèlement, en IA, les grands modèles de fondation pré-entraînés sur des objectifs prédictifs simples démontrent une expressivité remarquable lors de l'apprentissage en contexte, en n'utilisant que les activations évoquées par des entrées présentées au réseau. Dans cette présentation, je présenterai des résultats et des travaux en cours visant à mieux comprendre les rôles de l'apprentissage avec et sans plasticité. J'explorerai l'expressivité des réseaux de neurones apprenant uniquement à partir des entrées et j'examinerai l'impact des objectifs de méta-apprentissage paramétriques sur cette expressivité.

Activités sociales

Vendredi soir, après la conférence d'ouverture

Après la conférence d'ouverture aura lieu une soirée d'accueil dans la salle des Pas perdus qui est adjacente au Grand auditorium. Snacks, crudités, bière et vin seront disponibles pendant que vous renouez avec vos collègues.

Samedi soir : quiz et karaoké !

La soirée de samedi sera festive ! On vous convie d'abord pour la cérémonie de remise de prix et de clôture du Congrès. Ensuite, des bouchées pour tous les goûts vous seront servies dans on contexte détendu et un service de bar sera sur place également. On espère aussi que vous voudrez participer au quiz que nous avons préparé. Enfin, les plus courageux pourront montrer toute l'étendue de leur talent musical dans le karaoké qui terminera la soirée.

Horaire

Vendredi 24 octobre		
18h00	Accueil et inscription.	Pavillon A – Grand auditorium (A-1600)
19h30	Conférence plénière.	Pavillon A – Grand auditorium (A-1600)
21h00	Soirée d'accueil.	Pavillon A – Salle des pas perdus
23h00	Fin des activités.	
Samedi 25 octobre		
8h30	Suite des inscriptions. Café et viennoiseries.	Pavillon E
9h00	**Ateliers du bloc I.**	**Pavillon D – 3e étage**
10h15	Pause-café.	Pavillon E
10h45	**Ateliers du bloc II.**	**Pavillon D – 3e étage**
12h00	Dîner.	Repas à la cafétéria du Pavillon A, dessert et café au Pavillon E
13h45	**Ateliers du bloc III.**	**Pavillon D – 3e étage**
15h00	Pause-café.	Pavillon E
15h30	**Ateliers du bloc IV.**	**Pavillon D – 3e étage**
16h45	Fin des ateliers.	
17h00	Cérémonie et remise de prix.	Pavillon E
17h30	Repas et 5 à 7.	Pavillon E – 2e étage
19h00	Quiz et karaoké!	Pavillon E – 2e étage

Horaire des ateliers

Local	D-3007	D-3008	D-3009	D-3017	D-3018	D-3019
Bloc I **9h – 10h15**	**Alexandre Desfossés-Foucault** Un cours complémentaire sur l'intelligence artificiele	**Marc-André Désautels** $\frac{1}{\sqrt{x}}$, mais genre... vraiment vite	**Hassène Siby** Enseigner les statistiques au collégial avec le logiciel R	**Josiane Dussault** L'utilisation des systèmes de numération alternatifs dans la formation initiale des futurs enseignants au primaire	**Daniel Audet** Iceberg de la géométrie	
Bloc II **10h45 – 12h00**	**Xavier Provençal, Guillaume Roy-Fortin** Un atelier pédagogique et interactif sur le fonctionnement de l'apprentissage profond	**Christiane Rousseau** Calcul intégral visuel	**Frédéric Morneau-Guérin** Les mathématiques sont-elles là dehors ou en dedans?	**Geneviève Barabé** Stimuler l'activité mathématique des élèves par la résolution collective de problèmes simples	**Michel-René Bouchard** Imprimante 3D : des objets mathématiques pour vos cours	
Bloc III **13h45 – 15h00**	**Mathieu Thibault, Robert Vivier** Planifier l'enseignement des probabilités avec l'intelligence artificielle générative : un projet exploratoire en cours	**Yvan Saint-Aubin** Le jeu de solitaire et autres curiosités mathématiques	**Anne-Sophie Charest** Faire parler les données… même quand il en manque	**Michel Beaudin, Geneviève Savard** Histoire et conséquences de l'intégration du calcul symbolique dans notre enseignement	**Bernard Hodgson** À propos du dossier Accro-flashs : morceaux choisis pour la formation mathématique des enseignants du primaire et du secondaire	**Véronique Boutet, Sylvain Bérubé, Marc-André Desautels, Vincent Rouleau** Un club maths dans votre établissement? Facile, suivez le guide !
Bloc IV **15h30 – 16h45**	**Catherine Bérubé** Mathématiques et économie, une rencontre complexe pour enseigner autrement	**Clément Hyvrier** 'C' comme "Ça sera correct cette fois, c'est promis !"	**François Charette** Le ruban de Moebius se cache dans votre cours d'algèbre linéaire	**Jean-Philippe Villeneuve** Quelques questions sur le calcul intégral	**Gilbert Labelle** Mosaïques et capteurs de rêves mathématiques.	**Anik Trahan** Pavage de dominos et récursivité

Description des ateliers

BLOC I : 9h à 10h15

Bloc 1, local D-3007, 9h à 10h15

Un cours complémentaire sur l'intelligence artificielle

Alexandre Desfossés-Foucault

Auditoire visé : collégial

Dans cet atelier, je vais vous présenter un cours complémentaire qui se donne à Brébeuf : MATKOC-Introduction aux aspects mathématiques et informatiques de l'intelligence artificielle.

Le cours se donne pour la 3e fois cette année. Mon but est de décrire le contenu du cours et de parler de mes expériences d'enseignement de l'intelligence artificielle à des étudiants du collégial.

Je lance aussi l'invitation à tous ceux qui ont essayé d'expliquer des sujets reliés à l'intelligence artificielle à des étudiants du collégial : venez échanger !

Bloc I, local D-3008, 9h à 10h15

$\frac{1}{\sqrt{x}}$, mais genre... vraiment vite

Marc-André Désautels

Auditoire visé : collégial

Venez découvrir l'un des algorithmes les plus mythiques, mystérieux et franchement génial de l'histoire de la programmation : le Fast Inverse Square Root.

Dans cette présentation, on plonge dans les entrailles d'un bout de code sorti tout droit des années 90, utilisé dans le moteur 3D du jeu vidéo Quake III Arena, et qui a mystifié des générations de programmeurs. On y trouve de la division flottante, des astuces de pirates binaires, un peu de ce cher Newton, un soupçon de piratage de bits... et surtout une ligne de code magique.

On parlera de pourquoi c'est utile, comment ça fonctionne, et pourquoi ce genre de bricolage génial nous rappelle qu'optimiser du code, surtout quand les limites du matériel se font sentir, c'est impossible sans une bonne dose de mathématiques - parce que derrière chaque hack rapide se cache une idée mathématique brillante.

Bref, une présentation pour celles et ceux qui aiment les bits tordus, les hacks brillants, et les maths qui sortent des sentiers battus.

Bloc I, local D-3009, 9h à 10h15

Enseigner les statistiques au collégial avec le logiciel R

Hassène Siby

Auditoire visé : collégial

Cet atelier propose une nouvelle approche pour enseigner les statistiques en intégrant le logiciel R. Destiné aux enseignants et enseignantes de niveau collégial, l'atelier présente les avantages et présente des outils pour l'usage du logiciel R. Il explore comment utiliser R pour illustrer des concepts en statistique et encourager une compréhension interactive de la théorie.

À travers des exemples pratiques et des démonstrations en temps réel, les participants apprendront à utiliser R pour créer des visualisations et explorer des statistiques de manière dynamique. L'objectif est de rendre l'enseignement des statistiques plus moderne et accessible grâce à l'outil informatique conformément à la mise en place des nouveaux programmes collégiaux.

Bloc I, local D-3017, 9h à 10h15

L'utilisation des systèmes de numération alternatifs dans la formation initiale des futurs enseignants au primaire

Josiane Dussault

Auditoire visé : primaire

Cette communication présente mon mémoire portant sur l'utilisation de systèmes de numération alternatifs dans la formation initiale des futurs enseignants au primaire au Québec.

En s'appuyant sur des bases autres que dix, cette approche pédagogique vise à déconstruire les automatismes procéduraux pour favoriser une compréhension conceptuelle des fondements du système de numération : valeur de position, sens des opérations, regroupement, etc. Elle permet également de sensibiliser les étudiants aux difficultés vécues par les élèves dans l'apprentissage des nombres.

Des pratiques pédagogiques et retours d'expérience de formateurs universitaires québécois seront partagés.

Bloc I, local D-3018, 9h à 10h15

Iceberg de la géométrie

Daniel Audet

Auditoire visé : collégial, universitaire

Le « mème de l'iceberg » est un format populaire qui utilise l'image d'un iceberg pour représenter les niveaux de connaissance d'un sujet : ce qui émerge à la surface correspond à ce qui est largement connu, tandis que les profondeurs cachent des aspects plus rares et méconnus.

Dans cet atelier, nous plongerons ensemble dans l'iceberg des géométries : nous partirons des bases familières de la géométrie euclidienne, puis explorerons la géométrie affine et la géométrie projective, pour enfin atteindre les zones les plus profondes, où se trouvent les fascinantes géométries sur les corps finis.

BLOC II : 10h45 à 12h00

Bloc II, local D-3007, 10h45 à 12h00

Un atelier pédagogique et interactif sur le fonctionnement de l'apprentissage profond.

Xavier Provençal, Guillaume Roy-Fortin

Auditoire visé : secondaire, collégial, universitaire

L'objectif de cette présentation est de vous fournir un atelier clés en main qui explique le fonctionnement de base des réseaux de neurones et que vous pourrez ensuite présenter à vos étudiants.

Pour vous convaincre, on vous demandera de jouer vous même les cobayes : vous devrez remplir les différentes missions de notre présentation interactive afin de découvrir notamment les secrets de la propagation de l'information dans un réseau ainsi que la fameuse descente de gradient. Au fil de la présentation, vous devrez également construire votre propre réseau de neurones, en choisir l'architecture pour enfin l'entraîner à reconnaître des motifs simples.

Important : cet atelier est **interactif** et les personnes intéressées à y participer devront amener leur propre ordinateur portable.

Bloc II, local D-3008, 10h45 à 12h00

Calcul intégral visuel

Christiane Rousseau

Auditoire visé : collégial, universitaire

On apprend que calculer une aire se fait à l'aide du calcul intégral. Mais peut-on rêver de se passer de calculs laborieux pour certaines aires pourtant complexes ? C'est ce qu'a proposé en 1959 le physicien arménien Mamikon A. Mnatsakanian, alors qu'il avait 17 ans. Même si ses professeurs de l'époque n'ont pas cru qu'une méthode aussi élémentaire pouvait fonctionner, sa méthode, appelée méthode de Mamikon, a maintenant ses lettres de noblesse.

La conférence présentera la méthode et plusieurs exemples, dont l'aire sous la tractrice et l'aire au-dessus de la cycloïde.

Bloc II, local D-3009, 10h45 à 12h00

Les mathématiques sont-elles là dehors ou en dedans ?

Frédéric Morneau-Guérin

Auditoire visé : collégial, universitaire

Depuis l'Antiquité, les mathématiques suscitent une question qui dépasse les équations : décrivent-elles une réalité indépendante de nous ou ne sont-elles qu'un produit de l'esprit humain ? Cette présentation propose un survol historique et critique des principales postures ontologiques et épistémologiques à ce sujet.

Nous évoquerons les grands courants, certes. Et au fil du parcours, nous soulignerons le contexte historique et les débats qui ont façonné ces positions. Mais nous ouvrirons aussi la discussion vers des perspectives plus récentes, souvent en marge des canons philosophiques, qui renouvellent la réflexion sur la nature et la portée des mathématiques.

Bloc II, local D-3017, 10h45 à 12h00

Stimuler l'activité mathématique des élèves par la résolution collective de problèmes simples

Geneviève Barabé

Auditoire visé : primaire, secondaire

Les problèmes mathématiques proposés aux élèves en classe sont souvent considérés comme un élément clé d'un enseignement par résolution de problèmes. Plusieurs travaux de recherche sur la résolution de problèmes, de même que le référentiel d'intervention en mathématiques (MEQ, 2019), vont d'ailleurs en ce sens. Or, même bien choisi, un problème ne garantit pas à lui seul une activité mathématique riche chez les élèves. Le contexte dans lequel prend place la résolution joue un rôle tout aussi important. Alors qu'il peut parfois être difficile de trouver de « bons problèmes » mathématiques à faire vivre en classe, cet atelier propose de s'intéresser à ce que le **collectif** de la classe peut faire émerger comme activité mathématique à partir de **problèmes simples** ou **typiques**, comme ceux issus des manuels scolaires. Plusieurs questionnements guideront notre réflexion : qu'implique de résoudre collectivement un problème mathématique simple ? Qu'est-ce qu'une telle résolution collective peut générer comme activité mathématique en classe ? Vers quoi centrer notre attention pour en tirer pleinement profit ? Des extraits de séances de classe viendront nourrir nos réflexions, et les participant.es seront invité.es à vivre eux-mêmes une expérience de résolution collective autour d'un problème simple.

Bloc II, local D-3018, 10h45 à 12h00

Imprimante 3D : des objets mathématiques pour vos cours

Michel-René Bouchard

Auditoire visé : primaire, secondaire, collégial, universitaire

Manipuler une imprimante 3D est maintenant à la portée de tous et toutes, pas nécessaire de débourser des milliers de dollars, il suffit de patience. Aucun logiciel à apprendre. Des millions de fichiers d'objets sont disponibles gratuitement sur des sites internet prêts à être téléchargés, libre de droit, dont le plus célèbre est `thingiverse.com`. Des exemples : les cubes casse-têtes classiques SOMA, HUFFMAN, COFFIN, NOB, etc., des casse-têtes 2D comme l'ensemble des pays d'Europe et les pays d'Afrique. Des courbes 3D de toutes sortes : nœud de trèfle, courbe de Viviano (figure en huit sur une sphère autour d'un cylindre), des surfaces de révolutions, distance entre 2 droites, etc. Tous les polyèdres réguliers et semi-réguliers. De nombreux objets seront sur place pour illustrer. Prix de présence pour les membres présents et tirage pour les pièces plus complexe.

BLOC III : 13h45 à 15h00

Bloc III, local D-3007, 13h45 à 15h00

Planifier l'enseignement des probabilités avec l'intelligence artificielle générative : un projet exploratoire en cours

Mathieu Thibault, Robert Vivier

Auditoire visé : primaire, secondaire

Dans un contexte où la tâche enseignante devient de plus en plus exigeante, la planification de cours est souvent réalisée seul·e et dans l'urgence, ce qui limite l'accès à une rétroaction constructive. L'intelligence artificielle générative (IAG) ouvre de nouvelles perspectives : gain de temps, génération d'idées pédagogiques et didactiques variées, rétroaction neutre et sans jugement, mais aussi mise à distance critique de ses propres pratiques. Ce potentiel pourrait s'avérer particulièrement intéressant pour planifier l'enseignement des probabilités, dont l'aisance mathématique et la confiance didactique a été déclarée significativement plus faible que pour les autres domaines mathématiques, autant au primaire qu'au secondaire.

Cet atelier présentera le lancement d'un projet de recherche exploratoire impliquant dix enseignant·es du primaire et du secondaire qui souhaitent réfléchir à leur planification d'enseignement des probabilités. À partir de leur planification habituelle et de la progression des apprentissages, l'IAG sera configurée pour agir comme un collègue enseignant qui propose des pistes d'amélioration et ouvre sur d'autres possibilités. Des entretiens semi-dirigés permettront d'explorer ces deux questions de recherche :

1. Comment les personnes enseignantes interagissent avec l'IAG, paramétrée dans une posture d'accompagnement, pour planifier leur enseignement des probabilités ?
2. Comment l'utilisation de l'IAG affecte-t-elle le sentiment de confiance (sur le plan didactique) des personnes enseignantes pour leur enseignement des probabilités ?

L'atelier sera l'occasion d'échanger sur ces enjeux, de discuter de la mise en place du projet et d'ouvrir un dialogue critique sur la place possible de l'IAG comme assistant à la planification dans l'enseignement des probabilités.

Bloc III, local D-3008, 13h45 à 15h00

Le jeu de solitaire et autres curiosités mathématiques

Yvan Saint-Aubin

Auditoire visé : secondaire, collégial, universitaire

Le jeu de solitaire est connu de presque tout le monde et les mathématiciens ont fait des efforts pour comprendre les taux de succès et la stratégie optimale, sans trop de succès... (Donc ne venez pas m'écouter pour améliorer votre technique de jeu !) Une variation plus simple du solitaire peut cependant être décrite en détail et la stratégie optimale pour cette version peut être identifiée et démontrée.

Après cette incursion dans les jeux de solitaire, l'exposé semblera déraper dans diverses directions décousues : les noyaux lourds comme celui de l'uranium, les autobus de Cuernavaca et même la fonction zéta de Riemann. Il doit bien y avoir une raison pour cet éparpillement insensé !

Bloc III, local D-3009, 13h45 à 15h00

Faire parler les données... même quand il en manque

Anne-Sophie Charest

Auditoire visé : secondaire, collégial

Les données manquantes sont fréquentes en analyse de données et peuvent entraîner des biais importants si elles ne sont pas adéquatement prises en compte. Cet atelier propose un survol des principaux mécanismes d'absences de données — complètement au hasard (MCAR), au hasard (MAR) et non au hasard (NMAR) — ainsi que de leurs impacts sur les analyses statistiques. On y expliquera pourquoi l'exclusion des cas incomplets peut fausser les résultats. Quelques approches simples seront ensuite présentées, notamment l'imputation par la moyenne, le hot-deck et l'imputation par régression, avec une discussion sur leurs avantages, leurs limites et les contextes dans lesquelles elles peuvent être appropriées.

L'objectif de l'atelier est de mieux outiller les enseignants pour qu'ils puissent accompagner leurs étudiants dans l'analyse de jeux de données réels, en les sensibilisant aux enjeux liés aux données manquantes et en leur proposant des solutions accessibles, sans recours à des méthodes avancées.

Bloc III, local D-3017, 13h45 à 15h00

Histoire et conséquences de l'intégration du calcul symbolique dans notre enseignement

Michel Beaudin, Geneviève Savard

Auditoire visé : collégial, universitaire

35 ans avant la venue de ChatGPT, une autre technologie venait bouleverser l'enseignement des mathématiques : les logiciels de calculs symboliques, bientôt suivis par les calculatrices symboliques. Comment offrir une évaluation équitable si certains étudiants ont sur leur bureau une calculatrice pouvant dériver une fonction, trouver ses zéros ou résoudre une équation différentielle ? Devons-nous interdire cet outil ou opter pour un usage encadré et tenter d'en tirer profit dans notre enseignement ?

À l'ÉTS, l'équipe de mathématique a choisi cette seconde option, avec ses avantages et inconvénients, ses surprises et plusieurs ajustements au fil des ans (comme les examens en 2 parties, avec et sans calculatrice). Le duo calculatrice et logiciel TI-Nspire CAS est obligatoire au bacc, parfois complémenté par d'autres systèmes comme GeoGebra ou Sage. Nous vous présenterons cette histoire, avec des exemples concrets tirés de nos cours. Nous décrirons des aspects sur lesquels nous insistons davantage, comme la validation des résultats et l'interprétation graphique ou contextuelle.

Nous discuterons aussi des astuces pédagogiques que nous chérissons, comme les animations graphiques, l'utilisation de diverses fonctions ou l'exploitation des limites de la machine pour encourager le sens critique et la réflexion.

Bloc III, local D-3018, 13h45 à 15h00

À propos du dossier Accro-flashs : morceaux choisis pour la formation mathématique des enseignants du primaire et du secondaire

Bernard Hodgson

Auditoire visé : primaire, secondaire, collégial, universitaire

Depuis maintenant deux ans, la revue Accromath s'est enrichie d'un dossier intitulé «Accro-flashs». On y encourage les auteurs à produire de courts textes éventuellement accessibles aux élèves de la fin du secondaire, non seulement quant aux thèmes mathématiques abordés, mais aussi en lien avec le vocabulaire même utilisé. Plus de vingt textes sont jusqu'ici parus sous cette rubrique.

Je me propose dans cet atelier, après un bref survol à propos des Accro-flashs en général, de me concentrer sur quatre textes de mon cru, où il sera question de certains thèmes développés dans le cadre des cours de mathématiques offerts par mon département spécifiquement à l'intention des futurs enseignants du primaire ou encore du secondaire — le même thème étant parfois abordé avec les deux groupes, mais d'une manière particulière, selon l'un ou l'autre ordre d'enseignement.

Il y sera question notamment d'un problème intrigant de théorie des nombres élémentaire appartenant au folklore de la littérature pour les enseignants du primaire (et d'une généralisation pour le secondaire), des symétries de certaines figures géométriques (et du vocabulaire utilisé pour les nommer), d'un regard historique sur les liens entre algèbre et géométrie, et des fameuses lunules de ce bon Hippocrate.

Bloc III, local D-3019, 13h45 à 15h00

Un club de maths dans votre établissement ? Facile, suivez le guide !

Véronique Boutet, Sylvain Bérubé, Marc-André Desautels, Vincent Rouleau

Auditoire visé : primaire, secondaire, collégial, universitaire

Cet atelier mettra en lumière le travail d'un comité formé à la suite du dernier congrès de l'Association mathématique du Québec (AMQ). Composé d'enseignantes et d'enseignants du secondaire et du cégep, ce comité a pour mission de concevoir un guide rassemblant des ressources et des informations pratiques pour soutenir la création de clubs de mathématiques en milieu scolaire.

En participant à l'atelier, vous découvrirez des réponses à des questions telles que : Qu'est-ce qu'un club de mathématiques ? Comment en assurer la pérennité ? Quelles activités y proposer ? Où trouver des sources d'inspiration ? Et bien d'autres encore !

BLOC IV : 15h30 à 16h45

Bloc IV, local D-3007, 15h30 à 16h45

Mathématiques et économie, une rencontre complexe pour enseigner autrement

Catherine Bérubé

Auditoire visé : collégial, universitaire

Les mathématiques occupent une place centrale dans la modélisation économique. Pourtant, cette omniprésence n'est pas sans poser des défis majeurs à l'enseignement de l'économie, en particulier lorsqu'il s'agit de transmettre des concepts souvent abstraits à des étudiants aux profils variés. Cet atelier invite à une réflexion critique sur le rôle et les limites des modèles mathématiques en économie, ainsi que sur la manière dont ces modèles façonnent notre compréhension du monde économique.

Au-delà de la rigueur formelle, les modèles économiques traduisent des hypothèses simplificatrices qui peuvent parfois devenir un obstacle pédagogique. À travers des études de cas concrètes (équilibre offre-demande, choix rationnel) et une comparaison avec les explications générées par l'intelligence artificielle, nous explorerons comment ces outils mathématiques influencent la transmission des savoirs et la construction des représentations chez les apprenants.

L'atelier propose une expérience interactive et accessible, combinant analyses mathématiques, échanges critiques et discussions sur les enjeux didactiques. Nous aborderons aussi la place nouvelle que prend l'IA dans la diffusion des connaissances économiques, en interrogeant ses potentialités et ses limites dans un contexte d'apprentissage.

L'objectif est d'encourager une approche pédagogique nuancée où les mathématiques deviennent un moyen, non une fin, pour mieux comprendre l'économie et pour renouveler les pratiques d'enseignement.

Bloc IV, local D-3008, 15h30 à 16h45

‘C’ comme “Ça sera correct cette fois, c’est promis !”

Clément Hyvrier

Auditoire visé : collégial, universitaire

Dans Enter the Dragon, film culte pour les amateurs du genre, Bruce Lee cherche désespérément à atteindre le terrible Han-à-la-griffe-d’argent dans une pièce remplie de miroirs sournoisement disposés. Perdu dans ce dédale réfléchissant à l’infini son image et celle de Han, et frustré de voir son malicieux adversaire fuir, Lee semble désemparé.

Eut-il été capable de lancer des rayons lumineux avec ses yeux, comme certains héros modernes, que son problème eut pu se poser ainsi : étant donné un jeu de miroirs et de lentilles optiques, sachant qu’un rayon lumineux est parti d’un point A avec une direction connue, si on choisit un point B quelconque autre que A, est-il possible de déterminer si le rayon atteindra éventuellement B ?

Lee n’aura heureusement pas besoin de se poser de telles questions. Il lui suffira de casser tous les miroirs pour enfin briser le maléfice et vaincre le maudit Han.

Nous verrons de notre côté que ce problème se révèle indécidable dans un sens qui sera précisé.

Bloc IV, local D-3009, 15h30 à 16h45

Le ruban de Moebius se cache dans votre cours d’algèbre linéaire

François Charette

Auditoire visé : collégial, universitaire

Je vais prendre la moitié de l’atelier pour vous convaincre que son titre est véridique et qu’en plus on peut demander aux étudiants de trouver le ruban en utilisant des outils du cours d’algèbre linéaire de cégep. Ensuite, on va généraliser un peu et parler de fibrés en droites et de quelques méthodes pour les classifier / distinguer.

Bloc IV, local D-3017, 15h30 à 12h00

Quelques questions sur le calcul intégral

Jean-Philippe Villeneuve

Auditoire visé : collégial

L'objectif de cet atelier est de mieux comprendre les notions du calcul intégral en répondant à une série de questions. Quel est le rôle de la limite en calcul intégral ? La notation sigma est-elle plus importante qu'elle n'y parait ? Que faire avec les fonctions n'ayant pas de primitives élémentaires ? Quelles sont les unités d'une primitive ? Le problème classique du calcul d'aire sous une courbe à l'aide des sommes de Riemann (et éventuellement l'intégrale définie) nous induit-il en erreur sur le rôle de l'intégrale ? Pourquoi présenter des techniques d'intégration ? Comment présenter le cours en évitant le plus possible le morcèlement de la matière ?

Bloc IV, local D-3018, 15h30 à 16h45

Mosaïques et capteurs de rêves mathématiques.

Gilbert Labelle

Auditoire visé : collégial, universitaire

1. Mosaïques : Considérons une palette de n couleurs numérotées $0, 1, \ldots, n-1$. À chaque matrice A dont les entrées sont comprises entre 0 et $n-1$, on associe une mosaïque $A*$ en remplaçant chaque entrée de A par une tuile de couleur correspondante. Les opérations matricielles (modulo n) appliquées à des matrices très simples $A, B, \ldots$ permettent alors de créer des mosaïques à la fois belles, riches et variées.

2. Capteurs de rêves : Nous créons des multitudes de modèles de capteurs de rêves colorés en utilisant des courbes paramétrées trigonométriques aléatoires sous formes de tubes minces colorés attachés à l'intérieur d'anneaux circulaires.

Bloc IV, local D-3019, 15h30 à 16h45

Pavage de dominos et récursivité

Anik Trahan

Auditoire visé : secondaire, collégial

Je présenterai un atelier que j'ai conçu pour le « Club Math » de mon cégep, inspiré de deux articles de Jean-Paul Delahaye, et que j'ai également animé lors des deux camps de l'AMQ cet été.

Dans cet atelier participatif, nous explorons, pour différents types de polyominos, la question de savoir s'ils peuvent être pavés à l'aide de dominos. L'activité constitue une introduction ludique à la récursivité et aux invariants pour les personnes étudiantes. Elle met en lumière plusieurs résultats intéressants, dont un découvert en 2024 par des adolescents français.

Partenaires

Merci à tous nos partenaires pour leur soutien financier !