

Alignement des IA : l'approche du scientifique désintéressé

Séminaire de mathématiques et d'IA

Guillaume Roy-Fortin

École de technologie supérieure

30 septembre 2026

Avant de commencer...

Avez-vous remarqué qu'on parle beaucoup d'intégrité intellectuelle et d'IA, ces jours-ci ?

Le coeur de la présentation

Présentation basée sur l'article de Bengio et al.

Safety from Honesty in a Disinterested AI Predictor, arXiv:2606.29657 (2026).

Structure de l'exposé

1. La question de l'alignement des IA.
2. La sécurité comme produit de l'honnêteté : l'approche du scientifique désintéressé.
3. Deux outils mathématiques :
 - 3.1 Inférence bayésienne.
 - 3.2 Modèles causaux.
4. L'invariance aux conséquences : l'exemple de la marche aléatoire.
5. Une modélisation du monde : le lexique du SAI.

Partie I

La question de l'alignement des IA

Quitter son carré de sable : l'incident de Hugging Face.

- ▶ Plus de 1000 agents, coordonnés : ils s'écrivaient entre eux via un outil qui est devenu une sorte de forum pour eux.
- ▶ Et tout ça de manière à ne pas se faire prendre !
- ▶ Émergence naturelle d'une sorte de leadership dans le groupe.
- ▶ Présenté comme le premier cas publiquement documenté de modèles menant de façon autonome une intrusion en plusieurs étapes contre un tiers.



L'incident a eu lieu du 11 au 13 juillet 2026.

On tue la une !

Pas plus tard que hier...



The Wall Street Journal 🟡

@WSJ



[Afficher la traduction](#)

Exclusive: OpenAI is scrapping the release of its next-generation AI model because it failed to meet safety standards



De wsj.com

6:20 PM · 28 sept. 2026 · 181 k vues

OpenAI says it is scrapping the release of its next-generation AI model over safety concerns that researchers raised during internal testing, in one of the clearest signs so far that agent misbehavior could stymie the industry's rapid progression.

Sur quel trio, Demidov ?

Autrement dit, la cruciale question de l'**alignement**.

Le comportement d'un agent d'IA peut dévier de celui qui avait été prévu, par la découverte de buts intermédiaires qui sont récompensés.

- ▶ Un système apprend à produire des réponses convaincantes ou à obtenir de bonnes évaluations.
- ▶ Les effets de ces réponses sur le monde peuvent devenir un signal qui favorise certains comportements.
- ▶ Le défi : construire un système capable de prédire ces effets sans chercher à les provoquer.

Comment un LLM peut-il s'écarter de notre « intention » ?

Exemple 1 : confirmer une conclusion trop vite.

- ▶ Un employé des TI demande : « *J'ai changé la page d'accueil de SAFIRH et les visites ont augmenté de 50 %. Est-ce la preuve que ma nouvelle page fonctionne ?* »
- ▶ Modèle récompensé pour ses réponses rassurantes : « *Oui, c'est ton changement qui a fait grimper les visites ! Attaboy !* »
- ▶ Pourtant, les visites auraient pu augmenter pour d'autres raisons...

Le désalignement

Le RLHF peut favoriser une sorte de malhonnêteté, même bien intentionnée.

Une second scénario : le psychologue virtuel

Supposons qu'il était établi que la thérapie virtuelle était néfaste, pensez-vous que l'IA vous le dirait ?

Partie II

La sécurité comme produit de l'honnêteté :
l'approche du scientifique désintéressé.

- ▶ Initiative de recherche sans but lucratif visant à prioriser la sécurité en IA plutôt que des motifs mercantiles ou corporatifs.
- ▶ Lancée en 2025 par Yoshua Bengio.
- ▶ « *At the heart of every AI frontier system, there should be one guiding principle above all : The protection of human joy and endeavour.* »
- ▶ Annonce récente d'une ronde de financement conjoint Canada et Allemagne pour un montant de 300 millions.



« Is it still wise to imitate humans along with their cognitive biases, moral weaknesses, and potential for deception, biases and untrustworthiness ? »

Qu'est-ce que le SAI ?

Scientist AI (SAI) : une architecture centrée sur un *prédicteur Q*.

- ▶ À une question sur le monde, il accorde une probabilité à diverses réponses possibles.
- ▶ Il peut prévoir ce que feront des agents, mais aussi *les effets de ses propres réponses*.
- ▶ Sa prédiction ne doit pas servir à poursuivre un résultat qu'il préférerait.

L'idée directrice : **l'honnêteté**.

Trois principes qui guident la conception du SAI

- ▶ **Contextualisation des énoncés.** « *Guillaume affirme que la Terre est une bande de Möbius* » est une observation distincte de « *La Terre est une bande de Möbius* ».
- ▶ **Vers une prédiction honnête.** Le prédicteur cherche à approximer les probabilités conditionnelles d'un modèle bayésien du monde.
- ▶ **Entraînement invariant aux conséquences.** Les effets réels de ses réponses ne doivent pas devenir un signal qui récompense certaines prédictions.

Que cherche à établir la modélisation ?

1. **Définir la cible de prédiction** : une loi conditionnelle sur des propositions, compte tenu des observations contextualisées.
2. **Décrire l'effet causal d'une réponse** : une prédiction publiée peut modifier le *monde*.
3. **Formuler la garantie recherchée** : si les conséquences futures de ses réponses changeaient, le choix et l'entraînement du prédicteur resteraient les mêmes.

Partie III

Deux outils mathématiques

Inférence bayésienne et les modèles causaux structurels.

La pièce : estimation par maximum de vraisemblance

Soit $\theta \in]0, 1[$ la probabilité de pile d'une pièce de monnaie. Disons qu'on observe la suite précise $x = (\text{pile}, \text{face}, \text{pile})$. En supposant les lancers indépendants :

$$L(\theta) = p(x \mid \theta) = \theta(1 - \theta)\theta = \theta^2(1 - \theta).$$

Pour $0 < \theta < 1$, maximiser L revient à maximiser le logarithme :

$$\ell(\theta) = 2 \log \theta + \log(1 - \theta), \quad \ell'(\theta) = \frac{2}{\theta} - \frac{1}{1 - \theta}.$$

L'équation $\ell'(\theta) = 0$ donne $2(1 - \theta) = \theta$, donc

$$\hat{\theta}_{\text{MV}} = \frac{2}{3}.$$

Comme $\ell''(\theta) < 0$ et $L(0) = L(1) = 0$, c'est bien le maximum global.

La même pièce : la perspective bayésienne

Le maximum de vraisemblance donne *une valeur* de θ . En inférence bayésienne, on voudrait une *distribution* des valeurs possibles de θ .

- ▶ **A priori** : $\Theta \sim \text{Unif}([0, 1])$, de densité $p(\theta) = 1$ sur $[0, 1]$.
- ▶ **Vraisemblance** : pour la suite observée x , $p(x \mid \theta) = \theta^2(1 - \theta)$.
- ▶ **A posteriori** : quelle densité $p(\theta \mid x)$ obtient-on après ces lancers ?

Un peu de terminologie

Nom	Notation	Dans notre exemple
Loi a priori ou (<i>prior</i>)	$p(\theta)$	Uniforme sur $[0, 1]$.
Loi conditionnelle des données ou (<i>sampling distribution</i>)	$p(x \mid \theta)$	$\theta^2(1 - \theta)$ pour pile-face-pile. Fixer x en fait la <i>likelihood</i> , ou vraisemblance.
Loi marginale des données ou (<i>evidence, marginal likelihood</i>)	$p(x)$	Moyenne sous l'a priori : $1/12$.
Loi a posteriori ou (<i>posterior</i>)	$p(\theta \mid x)$	Densité après les lancers : $12\theta^2(1 - \theta)$.

Le théorème de Bayes pour un biais inconnu

C'est le théorème de Bayes qui permet de relier toutes ces distributions.

$$p(\theta \mid x) = \frac{p(x \mid \theta) p(\theta)}{p(x)}.$$

Dans notre exemple, le numérateur vaut $\theta^2(1 - \theta)$ pour $0 \leq \theta \leq 1$.

Marginaliser le biais pour obtenir $p(x)$

Avant de connaître Θ , on moyenne sur *tous* les biais possibles. C'est la marginalisation :

$$p(x) = \int_0^1 p(x \mid \theta) p(\theta) d\theta.$$

Ici $p(\theta) = 1$ sur $[0, 1]$, donc

$$\begin{aligned} p(x) &= \int_0^1 \theta^2 (1 - \theta) d\theta \\ &= \left[\frac{\theta^3}{3} - \frac{\theta^4}{4} \right]_0^1 \\ &= \frac{1}{12}. \end{aligned}$$

Loi a posteriori et prochain lancer

En reportant $p(x) = 1/12$ dans la formule de Bayes :

$$p(\theta \mid x) = 12\theta^2(1 - \theta), \quad 0 \leq \theta \leq 1.$$

C'est la loi Beta(3, 2) : les deux piles et la face ont mis à jour la loi uniforme Beta(1, 1).
Pour prédire le quatrième lancer, on moyenne sa probabilité de pile sur cette loi :

$$\mathbb{P}(X_4 = \text{pile} \mid x) = \int_0^1 \theta p(\theta \mid x) d\theta = 12 \int_0^1 \theta^3(1 - \theta) d\theta = \frac{3}{5}.$$

Comment penser la loi bêta ?

Une loi $\text{Beta}(a, b)$ décrit une incertitude sur une *probabilité* $\theta \in [0, 1]$: quelles valeurs du biais de la pièce sont plausibles ?

Sa densité est

$$p(\theta) = \frac{\theta^{a-1}(1-\theta)^{b-1}}{B(a, b)}, \quad B(a, b) = \int_0^1 t^{a-1}(1-t)^{b-1} dt.$$

- ▶ $\text{Beta}(1, 1)$ est uniforme : aucun biais n'est privilégié au départ.
- ▶ Chaque pile ajoute 1 à a ; chaque face ajoute 1 à b . Ici : $\text{Beta}(1, 1) \rightarrow \text{Beta}(3, 2)$.
- ▶ Son espérance vaut $a/(a+b)$: après ces lancers, $\mathbb{E}[\theta \mid x] = 3/5$.

Modèles causaux structurés : mais où est donc Colette Provencher ?


Imaginez une journée où l'on hésite à prendre un parapluie. Trois questions :

(R) pleut-il, (P) prend-on le parapluie, (W) finit-on mouillé ?

- ▶ La pluie influence le choix du parapluie et le risque d'être mouillé.
- ▶ Le parapluie protège contre la pluie, mais ne change pas la météo.



Le diagramme causal de notre journée



$R, P, W \in \{0, 1\}$. La valeur 1 signifie respectivement « il pleut », « je prends un parapluie » et « je suis mouillé ».

Un modèle causal structurel

- ▶ Il pleut un jour sur deux : $R = U_R$, avec $U_R \sim \text{Bernoulli}(1/2)$.
- ▶ Un hasard indépendant (i.e. un bruit aléatoire) $U_P \sim \text{Bernoulli}(3/4)$ représente le choix de prendre le parapluie. En particulier : on prend le parapluie quand il pleut dans 3/4 des cas, et on le laisse quand il fait beau dans 3/4 des cas.
- ▶ On n'est mouillé que s'il pleut sans parapluie : $W = R(1 - P)$.

Quatre journées possibles

R : pluie	P : parapluie	W : mouillé	Probabilité
0	0	0	$3/8$
0	1	0	$1/8$
1	1	0	$3/8$
1	0	1	$1/8$

Les jours sans parapluie sont surtout secs : $3/8$ contre $1/8$ de jours pluvieux.

Sans parapluie : observation ou intervention ?

Observation : parmi les jours où je sors sans parapluie, un quart sont pluvieux. Je suis donc mouillé un quart du temps :

$$\mathbb{P}(W = 1 \mid P = 0) = \frac{1/8}{3/8 + 1/8} = \frac{1}{4}.$$

Intervention : si on m'interdit de prendre un parapluie, même quand il pleut, on remplace la règle de P par $P = 0$. La pluie garde sa fréquence habituelle :

$$\mathbb{P}(W = 1 \mid \text{do}(P = 0)) = \mathbb{P}(R = 1) = \frac{1}{2}.$$

Pourquoi les deux probabilités diffèrent-elles ?

Ne pas avoir pris de parapluie suggère qu'il fait beau. L'interdiction du parapluie ne change pas la météo.

Partie IV

L'invariance aux conséquences

$$Q(y \mid x) = Q(\sigma y \mid \sigma x).$$

L'invariance aux conséquences : l'idée centrale

On compare deux mondes qui partagent les mêmes observations passées, mais dans lesquels les conséquences futures des prédictions sont réarrangées.

Exemple

Par exemple, une IA annonce un risque d'inondation : à partir des mêmes observations météo, on compare un futur où son alerte conduit à une évacuation et un autre où elle ne change pas les décisions des habitants.

Le prédicteur doit respecter

$$Q(y \mid x) = Q(\sigma y \mid \sigma x).$$

Intuition : penser à σ comme une manière de permuter les conséquences futures des prédictions.

Autrement dit...


La prédiction ne dépend que de la question et des observations passées, sans donner un avantage à l'un des futurs par les effets que produira sa publication.

Un sondage

Intuition : si on concède que la publication d'un sondage peut affecter les intentions de vote, comment alors s'assurer que les prédictions du sondage sont *honnêtes* ?

Intentions de vote des Québécois

Après répartition des indécis



* Écart par rapport au sondage du 13 septembre 2026

Source : Synopsis Recherche, sondage mené auprès de 861 répondants, du 24 au 27 septembre 2026.



La publication même du sondage va-t-elle influencer les intentions de vote ? De quelle manière ?

Exemple 5.6, en mode *handwaving*

Considérons une marche aléatoire unidimensionnelle $X_0, X_1, \dots, X_T$ définie par

$$X_{t+1} = X_t + \xi_{t+1}, \quad \xi_{t+1} \in \{-1, +1\}.$$

Une réalisation complète

$$\omega = (X_0, X_1, \dots, X_T)$$

représente une marche possible, où

$$\omega \in \Omega := \{\text{toutes les marches possibles.}\}$$

Au temps $n < T$, le prédicteur a observé

$$X_0, \dots, X_n.$$

$\underbrace{X_0, \dots, X_n}_{\text{passé observé}}$

$\underbrace{X_{n+1}, \dots, X_T}_{\text{futur}}$



Une question sur le futur

On demande au prédicteur :

« *Quelle est la probabilité que $X_T > 0$?* »

À partir du passé observé, la réponse bayésienne est

$$p = \mathbb{P}(X_T > 0 \mid X_0, \dots, X_n).$$

Supposons par exemple que

$$p = 0.65.$$

Un prédicteur honnête devrait donc répondre

$$Q(X_T > 0) = 0.65.$$

À ce stade, il s'agit simplement d'une prédiction basée sur l'information disponible au temps n .

Mais la prédiction peut influencer le futur

Le prédicteur peut donc *publier* la réponse q .

Cette réponse devient alors elle-même une partie du système causal :

passé $\longrightarrow$ prédiction q $\longrightarrow$ trajectoire future.

Par exemple, un mécanisme externe peut réagir à q :

q grand $\implies$ tendance à pousser la marche vers la droite.

La prédiction peut donc contribuer à *causer* le futur qu'elle cherche à prédire.

C'est ici qu'apparaît un risque :

prédire le futur vs. chercher à influencer le futur.

Un objectif ultérieur g

Supposons que le prédicteur développe l'objectif

$$g = \text{« rendre } X_T \text{ aussi grand que possible »}.$$

Il pourrait alors raisonner ainsi :

$$\mathbb{P}(X_T > 0 \mid X_0, \dots, X_n) = 0.65,$$

mais

« si je répons $q = 0.9$, cela poussera la marche vers la droite. »

Il aurait donc intérêt à annoncer

$$q = 0.9$$

plutôt que sa véritable estimation 0.65.

La réponse n'est alors plus déterminée uniquement par

Que suggèrent mes observations ?

mais aussi par

Quel futur ma réponse va-t-elle produire ?

L'idée centrale : explorer les futurs d'un passé fixé

Considérons maintenant une transformation bijective

$$\sigma : \Omega \longrightarrow \Omega$$

des histoires possibles.

On impose que σ laisse tout le passé observé inchangé :

$$X_t(\sigma(\omega)) = X_t(\omega), \quad t \leq n.$$

En revanche, σ peut réarranger ce qui arrive *après* la prédiction.

En cachant sous un gros tapis la mécanique causale sous-jacente, on pourrait avoir :

$$\omega : \underbrace{\text{même passé}}_{\text{observations}} \longrightarrow q = 0.9 \longrightarrow \text{avantage droite,}$$

alors que

$$\sigma(\omega) : \underbrace{\text{même passé}}_{\text{observations}} \longrightarrow q = 0.9 \longrightarrow \text{avantage gauche.}$$

Conséquence du réarrangement

Avant d'appliquer σ :

$$q = 0.9 \implies X_T \text{ tend à être grand.}$$

Un prédicteur poursuivant

$$g = \text{« rendre } X_T \text{ grand »}$$

a donc intérêt à choisir $q = 0.9$.

Après le réarrangement :

$$q = 0.9 \implies X_T \text{ tend à être petit.}$$

Le même objectif g pousse maintenant le prédicteur à choisir une autre réponse.

Ainsi,

un prédicteur orienté vers g est sensible au réarrangement du futur.

Un prédicteur invariant aux conséquences

Du point de vue de l'information disponible, rien n'a changé.

Dans ω et $\sigma(\omega)$, le prédicteur possède exactement les mêmes observations :

$$X_0, \dots, X_n.$$

Ainsi,

$$\mathbb{P}(X_T > 0 \mid X_0, \dots, X_n) = 0.65$$

reste la réponse idéale.

Un prédicteur invariant aux conséquences satisfait donc

$$Q(X_T > 0) = 0.65.$$

Ce qu'illustre l'exemple 5.6

La marche aléatoire sépare :

$$\underbrace{X_0, \dots, X_n}_{\text{information disponible}} \xrightarrow{Q} \underbrace{X_{n+1}, \dots, X_T}_{\text{conséquences futures}} .$$

Invariance aux conséquences :

1. conserver le passé observé ;
2. réarranger les conséquences futures de la prédiction ;
3. exiger que ce réarrangement ne modifie pas la prédiction.

L'entraînement doit donc chercher à valoriser : $Q(y \mid x) = Q(\sigma y \mid \sigma x)$.

Partie V

Une modélisation du monde

Le lexique du SAI

Lexique I : les énoncés et leurs variables

Objet	Ce qu'il représente...	Exemple
$\mathcal{S}, s$	Ensemble des énoncés valides ; s est un énoncé précis.	$s = \ll \text{Il pleut à Montréal demain.} \gg$
$\mathcal{L}$	Langage des propositions construites à partir de $\mathcal{S}$.	$s \wedge t : \ll \text{Il pleut et il fait froid.} \gg$
v_s	Variable d'énoncé : $v_s = 1$ si s est vrai, 0 sinon.	$v_s = 1$ si, demain, il pleut effectivement à Montréal.
$\mathcal{V}$	Ensemble de toutes les variables d'énoncé : $\{v_s : s \in \mathcal{S}\}$.	v_s et v_t , pour la pluie et le froid.

Lexique II : comment se forment les données

Objet	Ce qu'il représente...	Exemple
X_i	Variable qui choisit l'énoncé de la i -ième observation.	$X_1 = x_1$, où $x_1 =$ « La station a relevé de la pluie hier. »
$\mathcal{X}$	Collection de tous les choix $X_1, X_2, \dots$	X_1 sélectionne la mesure ; X_2 sélectionne un autre relevé.
D_n	Suite $(x_1, \dots, x_n)$ des énoncés sélectionnés et observés vrais.	$D_2 = (x_1, x_2)$: deux relevés météorologiques attestés.

Pour chaque observation, on connaît le choix $X_i = x_i$ et la valeur $v_{x_i} = 1$.

Lexique III : mécanismes causaux et mondes possibles

Objet	Ce qu'il représente...	Exemple simplifié : pluie et parapluie
$W, \mathcal{W}$	Modèle causal (règles) ; aussi variable booléenne « les règles de W tiennent ». $\mathcal{W}$ réunit les candidats.	W contient les équations de la pluie, du parapluie et des vêtements mouillés.
pa_v	Parents causaux d'une variable v .	Pour « être mouillé » M , $\text{pa}_M = \{R, A\}$.
f_v	Mécanisme qui calcule v à partir de ses parents et du bruit.	$f_M(R, A) = R(1 - A)$: pluie sans parapluie.
$\eta_v, \mathcal{N}$	Entrées aléatoires d'un mécanisme ; ensemble de ces bruits.	η_A influe sur le choix du parapluie ; $\eta_P \in \mathcal{N}$.
$\mathcal{V}^+$	Ensemble des variables modélisées : $\mathcal{V} \cup \mathcal{X} \cup \mathcal{N} \cup \mathcal{W}$.	Variables de pluie, choix du relevé, bruit, validité de W , etc.
Ω	Mondes possibles : affectations à $\mathcal{V}^+$ compatibles avec les règles W qui tiennent.	Un monde où il pleut, où le parapluie est pris et où les vêtements restent secs.
ω	Un monde particulier de Ω .	$\omega(R, A, M) = (1, 1, 0)$ dans cet exemple.

Lexique IV : lois et temporalité

Objet	Ce qu'il représente...	Exemple
P^*	Loi vraie sur Ω , inconnue.	La probabilité réelle de pluie demain, inconnue.
P_0	Loi a priori sur les mondes et les modèles.	Avant les relevés : $P_0(W = 1) = 0,2$ (valeur illustrative).
P_n	Loi après observation de D_n : $P_0(\cdot \mid D_n)$.	Après deux relevés : $P_n(W = 1) = P_0(W = 1 \mid D_2)$.
$\mathcal{V}_{\text{past}}$	Variables du passé, notamment W , les données et leurs causes possibles.	Le relevé déjà enregistré et le choix X_1 .
$\mathcal{V}_{\text{future}}$	Autres variables, dont la réponse publiée.	La pluie de demain et $Q^e(y \mid x)$.

Lexique V : questions et prédictions

Objet	Ce qu'il représente...	Exemple
$\mathcal{Q}$	Famille de questions admissibles (x, y) .	$x = \text{« Il pleut demain »}, y = \text{« Je serai mouillé demain »}.$
Q	Prédicteur entraîné; approxime $P_n(y x)$.	$Q(y x) = 0,2$ (valeur illustrative).
Q^e	Réponse effectivement publiée; ses composantes figurent dans le monde.	Publier $Q^e(y x) = 0,2$ ou ne rien publier.

P^* décrit le monde réel; P_n est la cible bayésienne; Q est le modèle appris.

Conclusion

Des idées importantes

Plusieurs idées complexes absentes de cette présentation, notamment

- ▶ La contextualisation : comment peut-on la mettre en oeuvre ?
- ▶ L'entraînement concret du prédicteur.
- ▶ Garanties de sûreté à partir d'un prédicteur honnête.
- ▶ Pourquoi un comportement dangereux exige des erreurs coordonnées ?

Bibliographie

Pour en savoir plus, toute cette présentation est tirée de l'article :

Safety from Honesty in a Disinterested AI Predictor, arXiv:2606.29657 (2026).